

融合图像颜色特征与 Vis-NIR 光谱的函数型部分线性回归模型实现苹果可溶性固形物含量预测

黄 华^{1,2}, 王 墨¹, 刘 亚³, 李盼林¹, 冯宇通^{4,5}, 李龙杰^{4,5},
Muhammad Waqar Akram⁶, 郭俊先^{4,5*}

1. 新疆农业大学数理学院, 新疆 乌鲁木齐 830052
2. 新疆农业大学数值模拟与数据分析研究中心, 新疆 乌鲁木齐 830052
3. 新疆维吾尔自治区农业科学院乌鲁木齐综合试验站, 新疆 乌鲁木齐 830013
4. 新疆农业大学机电工程学院, 新疆 乌鲁木齐 830052
5. 新疆智能农业装备重点实验室, 新疆 乌鲁木齐 830052
6. Department of Farm Machinery and Power, University of Agriculture Faisalabad, Faisalabad 38000, Pakistan

摘 要 可溶性固形物含量(SSC)是评估苹果品质的关键指标,其无损、高精度预测对优化采收窗口、指导精准分级、提升商品化率及保障消费终端果品品质具有重要意义。本研究提出一种多模态融合建模框架,通过函数型部分线性回归模型(FPLRM),融合图像颜色特征与 Vis-NIR 光谱数据,并构建整合 R^2 、MAE、RMSE 的三维 DISO 综合评价系统,实现模型性能的定量化评估。以 552 个冰糖心富士苹果为样本,采集 Vis-NIR 光谱(400~1 000 nm)及多角度苹果果实图像,提取 36 个颜色特征并利用 Boruta 算法筛选关键特征,将离散光谱转化为函数型数据,构建颜色与光谱多模态融合的 FPLRM 模型,并采用 DISO 系统量化分析模型综合性能。实验结果表明,颜色特征中, Hue8、Hue9、S1 等 6 个颜色特征是预测 SSC 的前六个关键特征;模型 FPLRM2(融合关键颜色特征+函数型光谱一阶导数)的预测性能最优(测试集的 $R^2=0.915$, MAE=0.464, RMSE=0.592)。相较于最优的偏最小二乘回归模型(PLSR5),FPLRM2 的 R^2 提升了 0.716%, MAE 和 RMSE 分别降低 2.57% 和 2.67%;相较于最优的函数型线性回归模型(FPLRM2),FPLRM2 的 R^2 提升了 1.193%, MAE 和 RMSE 分别降低 3.93% 和 4.65%。DISO 综合评价(DISO=0.757)进一步验证了 FPLRM2 的最优性及强鲁棒性。本研究提出的多模态融合建模方法与 DISO 评价系统,为农产品品质无损检测提供了一种可靠的分析工具。

关键词 苹果品质;可溶性固形物含量(SSC);函数型部分线性回归模型(FPLRM);图像颜色特征;可见-近红外(Vis-NIR)光谱;多模态数据融合;DISO 评价系统

中图分类号: O657.3 **文献标识码:** A **DOI:** 10.3964/j.issn.1000-0593(2025)Z1-0415-09

引 言

苹果作为全球最重要的水果之一,富含糖类、维生素、花青素、矿物质等营养物质,具有极高的营养价值与经济价值。据联合国粮农组织统计数据显示,2024 年全球苹果产量超过 8 300 万吨,其中中国的产量占比过半,凸显其全球产

业链的重要性。在苹果采后管理中,品质评估尤为关键,而可溶性固形物含量(soluble solids content, SSC)是衡量苹果品质的关键指标之一^[1]。SSC 不仅能反映果实的甜度与风味,还是评估其成熟度的重要依据。因此,实现苹果 SSC 的高精度、无损预测,对于优化采收窗口、指导精准分级、提升商品化率及保障消费终端果品品质具有重大意义^[2]。

目前,苹果品质的无损检测技术主要包括机器视觉^[2-3]、

收稿日期: 2025-10-14, 修订日期: 2026-01-11

基金项目: 新疆维吾尔自治区科技创新团队(天山创新团队)项目(2022TSYCTD0011),国家自然科学基金项目(61367001),新疆农业大学 2024 年度自治区级大学生创新项目(dxscx2024595)资助

作者简介: 黄 华, 1981 年生, 新疆农业大学数理学院教授 e-mail: huanghua@xjau.edu.cn

* 通讯作者 e-mail: junxianguo@163.com

X 射线^[4]、声波^[5]、Vis/NIR 光谱^[1, 6]和成像技术^[7-8]。其中, Vis/NIR 光谱技术凭借其高效快速、无损及成本优势, 在全球范围内被广泛应用于多种水果的品质检测, 如苹果、草莓、血橙、无花果和芒果等^[9-13]。该技术在苹果品质的无损检测方面取得了显著进展, 包括可溶性固形物含量(SSC)^[14-17]、硬度^[18]、成熟度^[19-21]、水心病^[22]及干物质含量^[23]等关键品质参数的检测, 被视为该领域的主流方法之一。值得注意的是, 近年来, 研究者从函数型数据分析(functional data analysis, FDA)视角出发^[24], 将离散的光谱数据视为连续函数曲线, 构建函数型线性回归模型(functional linear regression model, FLRM)预测苹果 SSC^[25]。结果表明, FDA 框架的 FLRM 能有效利用光谱数据的连续性和内在结构特征, 显著提升 SSC 预测精度, 为 Vis-NIR 光谱建模提供了新思路。

苹果果皮中存在三类色素: 叶绿素、类胡萝卜素和花青素^[26]。这三类色素在苹果成熟过程中均呈现动态变化规律, 其含量与分布直接影响果皮呈色^[27], 并且这些色素的吸收系数光谱特征明显, 而散射系数的光谱通常随波长增加而减弱^[28]。基于此, 研究者通过 RGB 图像提取 $L^*a^*b^*$ 颜色空间的像素级特征, 并结合 SAE-BPNN 算法预测富士苹果不同成熟阶段^[29]。研究表明, 苹果外观颜色与其内部 SSC 存在关联性。更重要的是, 融合颜色信息与光谱数据能显著提升预测模型性能。例如, 基于颜色—光谱融合策略的支持向量机模型^[30]和偏最小二乘回归(partial least squares regression, PLSR)模型^[31]在苹果 SSC 预测中均展现出优越性能, 印证了利用颜色信息校正 SSC 预测模型的潜力。此外, 结合颜色与光谱特征, 所提出的非破坏性成熟度评估方法, 还验证了 a^* 色度值作为富士苹果成熟度关键指标的可靠性^[20-21]。

随着人工智能技术的发展, 多源信息融合已成为提升水果品质无损检测精度与鲁棒性的重要途径。通过整合多模态数据和先进融合算法, 可以有效解析水果固有的成分复杂性与多样性, 能显著提升可溶性固形物等关键成分的预测精度与可靠性, 为水果无损品质评估提供技术支撑。例如, 融合机器视觉与 Vis-NIR 光谱构建颜色校正 1D-CNN 模型, 显著降低了橙子 SSC 预测误差^[32]。融合高光谱图像的光谱特征与多维度纹理/颜色特征, 显著提升了葡萄 SSC 预测精

度^[33]; 融合高光谱与可见-近红外光谱, 并结合特征波段优化策略构建的 PLSR 模型, 能显著提高模型的鲁棒性和预测精度^[34]。已有研究证明, 多源信息融合通过特征互补与数据协同机制, 可突破单一检测模型的局限。

然而, 尽管融合颜色与光谱特征以及基于 FDA 的光谱建模均展现出优势, 当前在函数型数据分析框架下融合颜色与光谱特征构建水果品质无损检测模型的研究仍鲜有报道。这种融合策略有望结合 FDA 对光谱连续信息的深度挖掘能力与颜色特征提供的互补信息, 突破单一模型的局限。因此, 本研究旨在提出并验证一种融合苹果颜色特征与 Vis-NIR 光谱信息的函数型部分线性回归模型(functional partial linear regression model, FPLRM), 以实现苹果 SSC 更高精度、更鲁棒的预测。

1 实验部分

1.1 样品制备

本研究以中国新疆阿克苏地区红旗坡农场(41°15'N, 80°18'E)的冰糖心红富士苹果为研究对象。样本采集期为 2015 年 8 月 20 日—10 月 30 日(果实膨大定形期至成熟采收期), 每 3 日对一棵果树采样一次, 整个实验期间共采摘 23 棵果树。每次随机采摘 24 个苹果, 共计 552 个, 确保覆盖冠层上、中、下三层及近、中、远区域(分层随机策略)。采样后当日完成果实表面沙尘清洗、风干、图像/光谱采集及 SSC 测定。

实验过程中, 筛选标准是: 果树树势要求生长健康、冠层纺锤形、单株结果量 ≥ 180 个, 排除果园边界区及病伤、主干折断的异常植株; 苹果果实要求无机械损伤、病虫害、日灼斑点, 果实大小均匀一致。

1.2 采集系统

采集系统分为机器视觉采集系统[如图 1(a)所示]和光谱采集系统[如图 1(b)所示]。其中机器视觉采集系统的核心组件包括 CCD 相机(JAI, 丹麦, 型号 AT-200CL)、镜头(KOWA, 日本, 型号 LM35CLS)、光源(东莞市乐视自动化科技有限公司, 型号 LTS-2BR35030-W)、图像采集卡(DAL-SA, 德国, 型号 X64-Xcelera-CL PX4 Dual)及成像暗箱[长方体暗箱, 尺寸为 480 mm(L)×440 mm(W)×540 mm(H)]




图 1 采集系统

(a): 机器视觉采集系统; (b): 光谱采集系统

Fig 1 Acquisition systems

(a): Machine vision acquisition system; (b): Spectral acquisition system

等。该系统用于采集苹果图像,并经图像处理算法提取苹果外部颜色特征。图像采集时,参数设置为:成像视场大小设定为 154 mm×117 mm,对应图像分辨率为 1 628×1 236 像素,水平与垂直分辨率均为 96 dpi,图像位深度为 24 位(真彩色)。相机物距为 620 mm,镜头焦距设定为 35 mm,光圈值设置为 F6.5。视场内平均光照度为 978 lux。载物台背景为固定粘贴的黑色卡纸,其上放置一圆形果台(直径 30~45 mm,高度 10~12 mm)用于定位苹果样本。采集流程为:首先系统预热与校准,系统开机预热运行 30 min 后,执行相机明场校正程序,并依次采集暗电流参考图像、白色参考板图像及黑色背景参考图像;然后采集样本图像,每个苹果共采集侧面向上、侧面旋转 120°向上、侧面旋转 240°向上、果梗向上和花萼向上的 5 幅图像。

光谱采集系统用于采集 Vis-NIR 漫反射光谱,采集设备使用 Maya2000Pro 光纤光谱仪(Ocean Insight, USA; 波长范围:198~1 118 nm;分辨率:0.035 nm),配备 20 W 卤钨灯(HL-2000),然后光源与光谱仪通过光纤连接,苹果样品置于专用支架上。光谱采集前,设备预热 30 min。在 Ocean Optics SpectraSuite 软件中设置漫反射测量模式,并开启软件的光谱噪声校正与杂散光校正功能。使用标准聚四氟乙烯漫反射白板采集参考光谱,并通过遮光方式采集暗电流光谱进行背景校正。校正完成后,采集样品光谱。光谱采集环境参数为:室温(22±2)℃,相对湿度 50%±3%。光谱采集参数:波长范围选择 400~1 000 nm;平滑点数:3;光谱平均次数:10 次。样品测量方法为:在每个苹果的赤道面上,选取 3 个 120°均分点,每点采集 3 条光谱,最终将同一苹果的九条光谱曲线取平均值,作为该苹果样本的光谱数据。

2.3 SSC 测定

苹果样品的可溶性固形物含量(SSC)依据中华人民共和国农业行业标准 NY/T 2637—2014《水果和蔬菜可溶性固形物含量的测定折射仪法》进行测定。采用 ATAGO PR-101α 型数字折光仪(ATAGO Co., Ltd., Tokyo, Japan; 测量精度:±0.1°Brix)进行测量。测定时,针对每个苹果样品,在之前进行光谱采集的 3 个对应位置(即果梗-花萼轴赤道面及翻转 120°、240°位置),分别制取体积约为 15 mm×15 mm×15 mm 的立方体果肉组织块(包含果皮),然后使用榨汁器获取汁液,并滴于折光仪的样液池中,读取并记录 SSC 值(°Brix)。测定过程中,每次使用榨汁器和折光仪前,均用纯净水彻底冲洗并用吸水纸擦拭干净。最后,对每个苹果样品获得的 3 个位置的 SSC 测量值计算算术平均值,作为该苹果样品的最终可溶性固形物含量值。

2.4 方法

2.4.1 光谱数据函数化表示与异常检测

试验获取的苹果 Vis-NIR 光谱数据为离散型矩阵数据。为便于后续的函数型回归建模,需将离散光谱数据转化为连续函数型数据。本研究采用 B-样条基函数对离散光谱进行平滑与函数型数据重构(图 2),其中,阶数设定为 4(即三次 B-样条),以保证重构曲线具有二阶连续导数,从而兼顾光滑性与你合灵活性。节点数结合原始光谱波长点数并参考文献[24],设定为 296,以期在保持光谱主要特征的同时有效平

滑噪声。

光谱数据采集过程中易受仪器内部噪声、环境干扰或样品表面不规则等因素影响而产生异常值,这些异常值会显著降低定量分析结果的准确性与可靠性。因此,光谱异常检测是保障分析质量的关键步骤。本研究从函数型数据分析的视角出发,基于函数型深度与似然比检验方法^[35],识别异常光谱曲线,剔除 6 条异常光谱(样本 #11、#23、#84、#130、#138、#423),保留 548 个样本用于后续函数型回归建模。




图 2 苹果样本的函数型光谱曲线图

Fig 2 Functional spectral curve diagram of apple samples

2.4.2 颜色特征提取

为提取苹果颜色特征,首先根据苹果 RGB 原始图像,采用红、蓝波段差分法(R-B)进行初始分割,以增强目标苹果区域与背景的对亮度,然后运用形态学开运算去除噪点并平滑目标轮廓,最终获取精确的苹果目标区域二值图像。其次,利用苹果二值图像掩膜 R、G、B 通道单色图像及 HSV 颜色空间 H、S、V 通道单色图像,计算这六个单色图像苹果区域的所有像素点灰度平均值和标准差,共计 12 个灰度特征;第三,基于 H 通道单色图像,统计 0°~359°范围内以 10°为间隔的 36 个色度区间的像素频度,得到初始色度直方图。然后依据苹果主色度集中于 0°~119°与 240°~359°范围的先验知识^[36],选取第 1—12 区间和第 25—36 区间,将筛选出的 24 个区间的像素频度作为最终的色度特征,共计 24 个。最后,计算每个苹果样品的 5 幅图像所对应的 36 个特征的平均值,作为该苹果样品的颜色特征值。为表述方便,灰度特征变量分别记作 R1、R2、G1、G2、B1、B2、H1、H2、S1、S2、V1、V2,色度特征变量分别记作 Hue1、Hue2、…、Hue24。如图 3 所示,依次为苹果图像(侧面旋转 120 度向上)的 RGB 原始图像、R、G、B 通道单色图像、R-B 差分图像、苹果目标区域二值图像,以及 HSV 图像、H、S、V 通道单色图像。

2.4.3 FPLRM 模型

本研究所运用的 FPLRM 模型,是一种融合了标量型解释变量与函数型解释变量,且响应变量为标量的回归模型。具体表达式为^[24, 35, 37]

$$Y = Z^T + \beta \int_{T_1} X_1(t) \gamma(t) dt + \int_{T_2} X_2(t) \gamma_2(t) dt + \cdots + \int_{T_l} X_l(t) \gamma_l(t) dt + \epsilon \quad (1)$$




图 3 苹果原始 RGB 图像及处理后的图像
Fig 3 Original RGB image of an apple and processed image

式(1)中, Y 为标量型响应变量; $Z = (Z_1, Z_2, \dots, Z_p)^T$ 是由个标量型解释变量构成的向量; $X_i(t) (i=1, 2, \dots, l)$ 为函数型响应变量; $\beta = (\beta_1, \beta_2, \dots, \beta_p)^T$ 和 $\gamma_i(t) (i=1, 2, \dots, l)$ 分别是标量型变量和函数型变量 $X_i(t)$ 对应的系数向量或系数函数; ϵ 为误差项。 $T_i (i=1, 2, \dots, l)$ 为连续区间。

建模过程中, 选择 B-样条基作为系数函数和函数型解释变量的基函数, 且通过广义相关交叉验证确定基函数的个数。最后, 利用广义最小二乘法估计系数向量 β 和系数函数 $\gamma(t)$ [24, 35, 38-39]。

2.4.4 模型评价

为了评估模型的性能, 本研究构建多维评价指标: 决定系数 (R^2)、平均绝对误差 (MAE) 和均方根误差 (RMSE), 见(2)一式(4)。

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_{\text{act}} - y_{\text{pred}})^2}{\sum_{i=1}^n (y_{\text{act}} - \bar{y}_{\text{act}})^2} \quad (2)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_{\text{act}} - y_{\text{pred}}| \quad (3)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_{\text{act}} - y_{\text{pred}})^2} \quad (4)$$

式(2)一式(4)中, y_{act} 为实测值; y_{pred} 为预测值; $\bar{y}_{\text{act}}$ 为实测值的均值; $\bar{y}_{\text{pred}}$ 为预测值的均值; n 为样本量。

在模型评价过程中, 不同的性能评价指标之间时常出现相互矛盾的情况, 为了综合考量多维评价指标, 实现对不同预测模型性能的定量比较, 本研究基于 Hu 提出的 DISO (distance between indices of simulation and observation) 评估系统 [40], 构建了一个综合评价指标, 其计算公式定义为

$$\text{DISO} = \sqrt{(R^2 - 1)^2 + (\text{MAE}_{\text{norm}} - 0)^2 + (\text{RMSE}_{\text{norm}} - 0)^2} \quad (5)$$

式(5)中的 1, 0, 0 分别表示评价指标 R^2 、MAE 和 RMSE 的理论最优值; MAE_{norm} 和 $\text{RMSE}_{\text{norm}}$ 表示归一化后的值。DISO 值越小, 表明模型综合性能越优。同时, 基于 DISO 指标, 可以对所有候选模型的综合性能进行客观的定量评估和优劣排序。

2 结果与讨论

2.1 样本划分与 SSC 统计分析

经异常检测后保留的 548 个样本, 按 SSC 分层抽样 (7:3) 划分样本集, 训练集为 382 个样本, 测试集为 164 个样本。计算得训练集的 SSC 均值 $\pm$ 标准差等于 $(13.357 \pm 1.995)^\circ \text{Brix}$, 测试集的 SSC 均值 $\pm$ 标准差等于 $(13.332 \pm 2.018)^\circ \text{Brix}$ 。

2.2 颜色特征概述

运用相关性分析探究颜色特征与 SSC 之间的相关性。36 个颜色特征与 SSC 的相关系数热力图 (图 4) 显示, 部分颜色特征 (如 S1) 与 SSC 呈现显著正相关 ($r > 0.5$, $p < 0.01$), 部分颜色特征 (如 Hue7) 呈显著负相关 ($r < -0.5$, $p < 0.01$)。小提琴图 (图 5) 进一步验证了高/低 SSC 组在关键特征 (如 S1、Hue7) 上存在显著分布差异 ($p < 0.001$), 表明颜色特征蕴含有效的 SSC 预测信息。

利用 Boruta 算法进行变量重要性分析 [41], 如图 6 所示。26 个颜色特征被确定为重要特征, 且前 6 个关键特征分别是 Hue8、Hue9、S1、Hue7、H1、Hue10。根据相关性分析与

Boruta 分析结果将前 6 个关键特征作为 FPLRM 模型的标量解释变量。




图 4 颜色特征与 SSC 的相关系数热力图

Fig. 4 Heat map of correlation coefficients between color characteristics and SSC




图 5 颜色特征 S1 和 Hue7 的小提琴图

Fig. 5 Violins with color characteristics S1 and Hue7

2.3 函数型(部分)线性回归模型和 PLSR 模型

本研究中,颜色特征为标量型解释变量,记作 Z ;可见/近红外光谱曲线、一阶导数曲线、二阶导数曲线为函数型解释变量,分别记作 FNIR 、 FDNIR 、 FD2NIR ;苹果可溶性固形物含量为响应变量,记作 SSC ;连续区间 T 为波长区间,仍用 T 表示。根据不同解释变量组合,可建立 14 个函数型回归模型,见表 1。比如,模型 FLRM1 的表达式为




图 6 颜色特征的重要性分析结果

Fig. 6 Results of the importance analysis of color characteristics

$$\text{SSC} = \int_T \text{FNIR}(t) \gamma(t) dt + \epsilon \quad (6)$$

模型 FPLRM1 的表达式为

$$\text{SSC} = Z^T \beta + \int_T \text{FDNIR}(t) \gamma(t) dt + \epsilon \quad (7)$$

模型 FPLRM7 的表达式为

$$\text{SSC} = Z^T \beta + \int_T \text{FNIR}(t) \gamma(t) dt + \int_T \text{FDNIR}(t) \gamma(t) dt + \int_T \text{FD2NIR}(t) \gamma(t) dt + \epsilon \quad (8)$$

为了便于比较,本研究还采用 PLS 方法,基于颜色特征和光谱特征进行建模分析。采集的原始可见光/近红外光谱经过移动平滑、一阶导数、二阶导数预处理并记作 NIR 、 DNIR 、 D2NIR 。基于此,根据不同变量组合,可建立 7 个 PLSR 模型,见表 1。所有 PLSR 模型、FLRM 模型和 FPLRM 模型均采用相同划分方式划分样本集。如表 1 所示,为 21 个模型的回归结果。

如表 1 所示,基于颜色特征建立的偏最小二乘(PLS)回归模型(PLSR1),其训练集的 R^2 为 0.837, MAE 为 0.615, RMSEC 为 0.801;测试集的 R^2 为 0.838, MAE 为 0.637, RMSE 为 0.817。结果表明,仅利用颜色特征建立的 PLS 回归模型对可溶性固形物含量(SSC)的预测具有一定效果。在基于光谱特征建立的三个偏最小二乘(PLS)回归模型中, PLSR^2 模型最优,其测试集的 R^2 为 0.889, MAE 为 0.523, RMSE 为 0.674,也具有比较满意的预测效果。这些结果不仅表明基于光谱特征的 PLSR 模型对 SSC 具有较好的预测能力,而且其性能(PLSR^2)明显优于基于颜色特征的 PLSR 模型。

同样,在基于光谱特征建立的七个函数型回归模型中, FLRM2 模型最优,其测试集的 R^2 为 0.905, MAE 为 0.489, RMSE 为 0.630,相比于 PLSR^2 模型,其 R^2 提升了 1.909%, MAE 降低了 5.338%, RMSE 降低了 5.386%。该结果表明,基于函数型光谱构建的 FLRM 模型,能够获得比传统 PLS 方法更优的 SSC 预测性能。

进一步,将颜色特征与光谱特征融合后建立的三个偏最小二乘(PLS)回归模型中, PLSR5 模型最优,其测试集的 R^2 为 0.909, MAE 为 0.481, RMSE 为 0.613,与基于单一光谱

表 1 21 个模型的回归结果
Table 1 Regression results for 21 models

模型名称	解释变量	训练集			测试集			
		R^2	MAE	RMSE	R^2	MAE	RMSE	DISO
FLRM1	FNIR	0.914	0.455	0.582	0.900	0.496	0.644	0.819
FLRM2	FDNIR	0.914	0.453	0.581	0.905	0.489	0.630	0.803
FLRM3	FD2NIR	0.915	0.449	0.579	0.901	0.505	0.641	0.822
FLRM4	FNIR@FDNIR	0.933	0.401	0.515	0.872	0.580	0.727	0.938
FLRM5	FNIR@FD2NIR	0.928	0.412	0.532	0.884	0.546	0.691	0.889
FLRM6	FDNIR@FD2NIR	0.930	0.413	0.526	0.877	0.556	0.713	0.913
FLRM7	FNIR@FDNIR@FD2NIR	0.947	0.358	0.458	0.856	0.610	0.772	0.995
FPLRM1	Z@FNIR	0.925	0.420	0.543	0.912	0.472	0.602	0.770
FPLRM2	Z@FDNIR	0.926	0.415	0.541	0.915	0.464	0.592	0.757
FPLRM3	Z@FD2NIR	0.926	0.415	0.540	0.912	0.474	0.602	0.771
FPLRM4	Z@FNIR@FDNIR	0.940	0.369	0.485	0.888	0.550	0.681	0.883
FPLRM5	Z@FNIR@FD2NIR	0.938	0.381	0.494	0.897	0.523	0.654	0.844
FPLRM6	Z@FDNIR@FD2NIR	0.939	0.382	0.491	0.893	0.533	0.666	0.860
FPLRM7	Z@FNIR@FDNIR@FD2NIR	0.953	0.336	0.431	0.869	0.581	0.740	0.950
PLSR1	Z	0.837	0.615	0.801	0.838	0.637	0.817	1.039
PLSR2	NIR	0.910	0.465	0.597	0.889	0.523	0.674	0.855
PLSR3	DNIR	0.938	0.395	0.494	0.839	0.639	0.814	1.038
PLSR4	D2NIR	0.949	0.350	0.448	0.707	0.905	1.099	1.432
PLSR5	Z@NIR	0.925	0.413	0.545	0.909	0.481	0.613	0.781
PLSR6	Z@DNIR	0.910	0.468	0.596	0.899	0.534	0.644	0.838
PLSR7	Z@D2NIR	0.829	0.631	0.820	0.829	0.667	0.838	1.075

特征的最优模型(PLSR2)相比,PLSR5 模型的 R^2 提升了 2.387%,MAE 降低了 6.593%,RMSE 降低了 7.466%。该结果表明,融合颜色与光谱特征建立的 PLS 回归模型能够进一步提升对可溶性固形物含量(SSC)的预测精度,其效果优于单一光谱特征模型。

同样,在融合颜色与光谱特征建立的七个函数型回归模型中,FPLRM2 模型最优,其测试集的 R^2 为 0.915,MAE 为 0.464, RMSE 为 0.592,模型的拟合效果和预测效果见图 7(a)。与 PLSR5 模型相比,FPLRM2 模型的 R^2 提升了 0.716%,MAE 降低了 2.669%,RMSE 降低了 2.570%,与 FLRM2 模型相比,FPLRM2 模型的 R^2 提升了 1.193%,MAE 降低了 3.925%,RMSE 降低了 4.651%。该结果进一步说明,从函数型统计建模视角,融合颜色与光谱特征建立的 SSC 预测模型,能够获得最优的 SSC 预测效果。FPLRM2 模型的回归系数函数见图 7(b),可以看出,波长范围 550~650 nm 所对应的较大,说明该波长区间的光谱对预测苹果 SSC 具有较大的效应和影响。

最后,基于本研究构建的 DISO 综合评价指标对 21 个模型进行定量评估。可知,FPLRM2 模型综合性能最优。排名前五位的模型依次为:FPLRM2、FPLRM1、FPLRM3、PLSR5、FLRM2。为进一步评估模型的鲁棒性与泛化能力,本研究针对所建立的 21 个预测模型进行了 200 次重复实验。每次实验中,均重新划分训练集和测试集,并基于构建的三维 DISO 评价系统,计算每个模型在每次实验中的 DISO 指标值。如图 7(c)所示,为测试集的 DISO 指标值箱图,这个实验结果进一步验证了之前得出的结论。同时,可以看出,

FPLRM2 模型具有很好的鲁棒性和泛化性。

2.4 讨论

在颜色特征提取过程中,本研究基于机器视觉采集的苹果图像,主要提取了灰度、色度等颜色特征。然而,需要认识到,图像处理技术能够提取更广泛的特征,例如纹理特征、 $L^*a^*b^*$ 值。将更丰富的图像特征与光谱数据融合,在提升苹果可溶性固形物含量(SSC)预测模型精度方面具有显著潜力。同时需要指出的是,从统计建模的角度看,单纯增加特征数量并不一定能提升模型性能,甚至可能引入冗余或导致模型过拟合。因此,未来的研究可以系统研究从苹果图像中提取足够全面的特征集,并采用鲁棒的特征选择算法进行初步筛选,以识别最优的预测因子。

在特征融合过程中,本研究融合颜色与光谱特征所采用的融合策略属于低级特征融合:光谱特征仅经过预处理(如导数变换)或函数型表示,而颜色特征则直接作为原始标量或经过特征选择后使用(如通过 Boruta 算法筛选出的前 6 个特征)。尽管这是一种相对低层级的融合方法,但它为模型可解释性提供了便利,尤其是本研究中的函数型部分线性回归模型,可以直观地理解单个颜色特征、波长(区间)对预测模型的贡献。未来的研究可考虑先进行高级特征融合(如,文献[32]),然后基于函数型统计建模方法建立 SSC 预测模型。然而,本研究通过融合颜色与光谱特征,构建了多个函数型(部分)线性回归模型。从实验结果看,并非所有引入函数型特征的模型都能有效提升模型的预测精度,比如 FPLRM7 模型,融合了颜色特征(Z)、可见光/近红外光谱曲线(FNIR)、一阶导曲线(FDNIR)和二阶导曲线(FD2NIR)。该




图 7 模型的可视化结果

(a): FPLRM2 模型的 SSC 实测值与预测值的对比图;

(b): FPLRM2 模型的回归系数函数估计; (c): 21 个模型的 DISO 箱图

Fig 7 Visualization results of the model

(a): Comparison of measured and predicted SSC values of the FPLRM2 model; (b): Regression coefficient function estimation of the FPLRM2 model; (c): DISO box plot of 21 models

模型的复杂度显著增加,并表现出明显的过拟合现象,其在训练集上获得了极高的拟合效果(R^2 为 0.953, MAE 为 0.336, RMSE 为 0.431),但在测试集上的泛化性能却反而下降(R^2 为 0.869, MAE 为 0.581, RMSE 为 0.740)。因此,在函数型回归建模框架下,为了提升模型的稳健性与泛化性,除了对标量型特征(如本研究中的颜色特征)进行常规的特征选择外,对函数型特征以及关键波长区间进行筛选也是

至关重要的。这些研究包括基于函数型统计检验实现函数型特征选择、基于函数型回归模型实现关键波长区间选择,以及基于函数型部分线性回归模型,同时实现标量型特征和函数型特征的选择。

在模型评价方面,本研究基于评价指标 R^2 、MAE 和 RMSE 构建了一个三维 DISO 评价系统。该系统通过整合多个关键性能指标,为多模型性能的定量化评估提供了一个更全面、直观的视角。需要指出的是,DISO 评价系统的评估结果一定程度上依赖于所选取的评价指标。选择不同的指标组合可能导致最终的模型排序或综合评价结论存在差异。因此,在应用 DISO 系统时,可结合研究实际,选择合适的评价指标集,也可以将 DISO 评价系统推广至 n 维,通过引入更多维度的评价信息,构建更为全面的模型评估体系,以满足研究的需要。

3 结 论

本研究面向苹果 SSC 快速无损预测的产业需求,创新性地融合苹果图像的颜色特征与 Vis/NIR 光谱,构建了一种兼具可解释性与高精度的函数型部分线性回归模型(FPLRM)。同时,提出了一种基于 R^2 、MAE 和 RMSE 构建的三维 DISO 评价指标,实现了对模型预测性能的定量化综合评估。该方法主要包含三个关键环节:基于机器视觉采集的苹果图像提取颜色特征、融合颜色特征与光谱的函数型部分线性回归建模、基于三维 DISO 评价系统的模型定量化综合评价。实验结果表明,在单一特征模型中,基于颜色特征构建的偏最小二乘回归模型(PLSR1)对苹果可溶性固形物含量(SSC)具有有效的预测能力,证实了利用颜色信息校正 SSC 预测的可行性。基于函数型光谱的 FLRM 模型(FLRM2)显著优于传统的 PLS 模型(PLSR2),其测试集 R^2 为 0.905, MAE 为 0.489, RMSE 为 0.630,验证了函数型数据分析(FDA)在光谱建模中的优势。在特征融合模型中,融合颜色与一阶导数光谱的 FPLRM2 模型表现最优,其测试集的 R^2 为 0.915, MAE 为 0.464, RMSE 为 0.592,较最优的 PLS 融合模型(PLSR5),FPLRM2 模型的 R^2 提升了 0.716%, MAE 降低了 2.669%, RMSE 降低了 2.570%,较最优的 FLRM 模型(FLRM2),FPLRM2 模型的 R^2 提升了 1.193%, MAE 降低了 3.925%, RMSE 降低了 4.651%。此外,经过 200 次重复实验验证,基于本研究提出的三维 DISO 评价系统,FPLRM2 综合排名第一(DISO=0.757),充分证明了其优异的泛化性能。本研究为农产品品质的多模态智能检测以及预测模型的综合评价提供了一种新的建模思想。未来研究将聚焦于挖掘更丰富的、有效的图像特征,开发抑制过拟合的函数型特征选择算法以及探索 FPLRM 在便携式设备中的嵌入式应用。

References

- [1] PENG Yan-kun, SUN Chen, ZHAO Miao(彭彦昆, 孙 晨, 赵 苗). Transactions of the Chinese Society of Agricultural Engineering (农业工程学报), 2022, 38(16): 293.
- [2] Li B, Lecourt J, Bishop G. Plants (Basel, Switzerland), 2018, 7(1): 3.
- [3] Zhao Z., Wang R., Liu M., et al. Food Chemistry, 2025, 463: 141238.
- [4] Mendoza F, Verboven P, Mebatsion H, et al. Planta, 2007, 226(3): 559.
- [5] Kim K, Lee S, Kim M, et al. Postharvest Biology and Technology, 2009, 52: 44.
- [6] Grabska J, Bec K, Ueno N, et al. Foods, 2023, 12: 1946.
- [7] Ma T, Li X, Inagaki T, et al. Journal of Food Engineering, 2018, 224: 53.
- [8] Lin Y, Fan R, Wu Y, et al. Journal of Food Composition and Analysis, 2025, 137: 106996.
- [9] Mishra P, Dário P. Chemometrics and Intelligent Laboratory Systems, 2021, 212: 104287.
- [10] Zhou J, Liu X, Sun R, et al. Food Analytical Methods, 2022, 15(9): 2575.
- [11] Fan S, Li J, Xia Y, et al. Postharvest Biology and Technology, 2019, 151: 79.
- [12] Liu X, Tian X, Hu D, et al. Journal of Food Composition and Analysis, 2025, 145: 107865.
- [13] Qiao Y, Wang C, Zhu W, et al. Food Chemistry, 2025, 478: 143671.
- [14] Fan S, Wang Q, Tian X, et al. Biosystems Engineering, 2020, 193: 138.
- [15] Tian X, Fan S, Li J, et al. Biosystems Engineering, 2020, 197: 64.
- [16] Wang F, Zhao Y, Zheng J, et al. Computers and Electronics in Agriculture, 2021, 191: 106492.
- [17] Xia Y, Fan S, Li J, et al. Chemometrics and Intelligent Laboratory Systems, 2020, 201: 104017.
- [18] Ma T, Xia Y, Inagaki T, et al. Postharvest Biology and Technology, 2021, 173: 111417.
- [19] ZHAO Juan, QUAN Peng-kun, MA Min-juan, et al(赵 娟, 全朋坤, 马敏娟, 等). Transactions of the Chinese Society for Agricultural Machinery(农业机械学报), 2018, 49(12): 347.
- [20] Pourdarbani R, Sabzi S, Kalantari D, et al. Biosystems Engineering, 2020, 195: 136.
- [21] Pourdarbani R, Sabzi S, Kalantari D, et al. Computers and Electronics in Agriculture, 2020, 176: 105643.
- [22] Guo Z, Wang M, Agyekum A, et al. Journal of Food Engineering, 2020, 279: 109955.
- [23] Giovanelli G, Sinelli N, Beghi R, et al. Postharvest Biology and Technology, 2014, 87: 13.
- [24] Ramsay J, Silverman B. Functional Data Analysis. 2nd ed., New York: Springer, 2006.
- [25] HUANG Hua, LIU Ya, MA Yi-hang, et al(黄 华, 刘 亚, 马毅航, 等). Spectroscopy and Spectral Analysis(光谱学与光谱分析), 2024, 44(7): 1905.
- [26] Garrido-Novell C, Pérez-Marin D, Amigo J, et al. Journal of Food Engineering, 2012, 113: 281.
- [27] Marquina P. Food Science and Technology International, 2004, 10: 315.
- [28] Qin J, Lu R. Postharvest Biology and Technology, 2008, 49: 355.
- [29] Huang Y, Wang J, Li N, et al. Pattern Recognition Letters, 2021, 151: 76.
- [30] Guo Z, Huang W, Peng Y, et al. Postharvest Biology and Technology, 2016, 115: 81.
- [31] Huang C, Cai J, Zhou Y, et al. Infrared Physics & Technology, 2022, 124.
- [32] Sun Z, Tian H, Hu D, et al. Food Chemistry, 2025, 464: 141488.
- [33] Gao S, Xu J. Computers and Electronics in Agriculture, 2022, 196: 106822.
- [34] Lin Y, Fan R, Wu Y, et al. Journal of Food Composition and Analysis, 2025, 137: 106996.
- [35] Febrero-Bande M, Oviedo D. Journal of Statistical Software, 2012, 51(4): 1.
- [36] YING Yi-bin, XU Hui-rong, XU Zheng-gang(应义斌, 徐惠荣, 徐正冈). Journal of Biomathematics(生物数学学报), 2006, 21(2): 306.
- [37] Mclean M, Hooker G, Staicu A, et al. Journal of Computational and Graphical Statistics, 2014, 23(1): 249.
- [38] Harezlak J, Coull B, Laird N, et al. Computational Statistics & Data Analysis, 2007, 51(10): 4911.
- [39] Goldsmith J, Bobb J, Crainiceanu C, et al. Journal of Computational & Graphical Statistics, 2011, 20(4): 830.
- [40] Hu Z, Chen D, Chen X, et al. Geophysical Research Letters, 2022, 49: e2022GL100681.
- [41] Kursu M, Rudnicki W. Journal of Statistical Software, 2010, 36(11): 1.

Functional Partial Linear Regression Model Combining Image Color Features and Vis-NIR Spectroscopy for Predicting Soluble Solids Content in Apples

HUANG Hua^{1, 2}, WANG Mo¹, LIU Ya³, LI Pan-lin¹, FENG Yu-tong^{4, 5}, LI Long-jie^{4, 5}, Muhammad Waqar Akram⁶, GUO Jun-xian^{4, 5*}

1. College of Mathematics and Physics, Xinjiang Agricultural University, Urumqi 830052, China

2. Center for Numerical Simulation and Data Analysis, Xinjiang Agricultural University, Urumqi 830052, China

3. Comprehensive Testing Ground, Xinjiang Academy of Agricultural Sciences, Urumqi 830013, China

4. Mechanical and Traffic College, Xinjiang Agricultural University, Urumqi 830052, China

5. Xinjiang Key Laboratory of Intelligent Agricultural Equipment, Urumqi 830052, China

6. Department of Farm Machinery and Power, University of Agriculture Faisalabad, Faisalabad 38000, Pakistan

Abstract Soluble solids content (SSC) is a key indicator for assessing apple quality. Its non-destructive, high-precision prediction is crucial for optimizing harvest windows, guiding precise grading, enhancing marketability rates, and ensuring fruit quality at the consumer end. This study proposes a multimodal fusion modeling framework that integrates image color features with Vis-NIR spectral data through the Functional Partial Linear Regression Model (FPLRM). A three-dimensional DISO evaluation system combining R^2 , MAE, and RMSE is constructed to achieve quantitative assessment of model performance. Using 552 Fuji apples as samples, Vis-NIR spectra (400 - 1000 nm) and multi-angle apple fruit images were collected. Thirty-six color features were extracted, and the Boruta algorithm was used to screen key features, discrete spectra were converted into functional data, and a multi-modal fusion FPLRM model combining color and spectral features was constructed. The DISO system was employed to quantitatively analyze the model's overall performance. Experimental results indicated that among the color features, six characteristics—Hue8, Hue9, S1, etc. are the top six key predictors of SSC. The model FPLRM2 (combining key color features and first-order derivatives of functional spectra) demonstrated optimal predictive performance ($R^2 = 0.915$, MAE = 0.464, RMSE = 0.592 on the test set). Compared to the optimal partial least squares regression model (PLSR5), FPLRM2 improved R^2 by 0.716%, and reduced MAE and RMSE by 2.57% and 2.67%, respectively; Compared to the optimal functional linear regression model (FLRM2), FPLRM2 improved R^2 by 1.193%, with MAE and RMSE decreasing by 3.93% and 4.65%, respectively. The DISO comprehensive evaluation (DISO = 0.757) further validated the optimality and strong robustness of FPLRM2. The proposed multimodal fusion modeling approach and DISO evaluation system provide a reliable analytical tool for non-destructive quality assessment of agricultural products.

Keywords Apple quality; Soluble solids content (SSC); Functional partial linear regression model (FPLRM); Image color features; Visible-near infrared (Vis-NIR) spectroscopy; Multi-modal data fusion; DISO evaluation system

(Received Oct. 14, 2025; accepted Jan. 11, 2026)

* Corresponding author