

跨年苹果近红外产地溯源的无泄漏评估协议

李盼林¹, 张庆莉¹, 焦齐太³, 李宇畅¹, 孙佳美¹, 黄华^{1,2*}

(1. 新疆农业大学数理学院, 乌鲁木齐 830052; 2. 新疆农业大学数值模拟与数据分析研究中心, 乌鲁木齐 830052; 3. 新疆农业大学机电工程学院, 乌鲁木齐 830052)

摘要: 苹果产地溯源的近红外模型跨采收年份部署时性能显著下降, 而少样本评估的可靠性还受一种隐性偏差侵蚀: 编码器预训练时已见过留出的评估年份, 使跨年泛化被系统性高估。构建覆盖 3 个采收年份、4 个产地、9 个采集域的苹果近红外基准 (1 950 个果实、4 529 条光谱、229 个波段), 提出留一采收年份无泄漏评估协议——令编码器训练集与留出年份严格不相交 (折限定编码器), 并与共享编码器同口径对照。结果表明, 共享编码器使宏 F1 虚高 0.242~0.363; 因两臂仅编码器训练集不同, 该虚高可归因于编码器而非分类器, 并在 5 个真实域划分的公开数据集上复现, 总体泄漏 0.124。无泄漏协议下各方法优劣随参考样本量而变, 且评估口径本身即足以颠覆方法选型。该协议不增加样本或标注, 为苹果等农产品近红外产地溯源的可靠评估与现场方法选型提供了实用规范。

关键词: 可见-近红外光谱; 高光谱成像; 无损检测; 产地溯源; 苹果; 少样本学习; 评估泄漏; 域偏移

中图分类号: TP391.4; O657.33; S661.1 **文献标志码:** A

0 引言

苹果是全球消费量最大的温带水果之一, 中国产量占全球供应的一半以上 (2024 年为 52.4%)^[1]。不同产地的苹果在市场价格与品牌价值上差异显著, 地理标志保护、食品安全溯源与打击虚假标注均依赖对果实产地的可靠判别。传统的稳定同位素比值与多元素指纹技术虽准确——金晓彤等^[2]用电感耦合等离子体质谱测定 23 种微量元素, 对东北三省大米的判别正确率达 96.3%——但依赖专业实验室与湿法前处理、检测周期长, 难以满足批量快速筛查^[3]。近红外 (near-infrared, NIR) 漫反射光谱无需消耗品、单次扫描不足 1 min 即可获得可解读的光谱, 其信号综合反映可溶性固形物、有机酸、多酚与水分等成分, 在高维光谱空间中形成与产地相关的“指纹”, 为快速无损溯源提供了可行途径^[4,5]。国内学者已研制出手持式可见-近红外苹果品质检测终端并实现多产地通用建模^[6], 表明该技术的现场工程化部署已具备可行性。

近红外结合化学计量学用于农产品产地判别已有二十余年积累。在国内, 白雪冰等^[7-8]以理化指标与色味光谱特性结合机器学习判别西北干红葡萄酒产地与酒龄 (准确率 95% 以上), 并进一步细分贺兰山东麓 5 个子产区 (灵敏度 87.5%~100%); 耿莹蕊等^[9]以近红外结合灰狼算法优化的支持向量机鉴别 8 个产地烟叶, 整体正确率达 96.62%; 杨文政等^[10]以电子鼻特征优化实现黄连产地鉴别。国际上, 便携式近红外已用于蜂蜜产地与掺假的同步鉴别^[11], 光谱指纹结合机器学习亦成功用于红茶^[12]、大豆^[14]与西洋参^[15]的产地溯源, 以及食用油的真伪鉴别^[13]。在苹果上, Gao 等^[16]将改进的注意力模块

嵌入一维卷积网络, 在四类苹果上取得高精度分类; 毕淑慧等^[17]用 D-S 证据理论融合偏最小二乘与极限学习机双模型, 将烟台红富士的分类准确率由单模型的 92.25% 提升至 95.35%; 张宇等^[18]横向对比 5 种机器学习模型完成苹果损伤分级, 并发现 Savitzky-Golay 平滑为最优预处理。当数据充足时, 支持向量机 (support vector machine, SVM) 与卷积神经网络进一步外推了性能边界^[19]; 但 Mishra 等^[20]联合 11 位化学计量学学者撰文指出, 深度学习在光谱建模中的部分宣称收益被夸大, 其潜在陷阱亟需清算。

针对跨仪器、跨季节的域偏移, Roger 等^[21]在最新综述中明确指出: 目前关于无损光谱传感器的绝大多数文献只停留在“建模+独立数据集应用”的概念验证层面, 而未证明验证阶段获得的性能在测量条件改变后依然成立。校准迁移与模型更新是主流应对手段: 吴琪等^[22]用斜率/偏差校正仅需 20 个新样本即把跨品种苹果的预测均方根误差从 1.076 降至 0.233 °Brix; Li 等^[23]与 Pan 等^[24]分别研究了苹果的跨设备与跨季节校准迁移; 夏宇等^[25]用高光谱实现玉米种子贮藏年份的跨品种识别, 是本刊近年正面处理“跨条件泛化”的代表性工作。对抗域适应亦已进入农业光谱工程^[26]。少样本学习为新季节、新产区仅有寥寥参考样本的现实处境提供了出路: 原型网络以支持集均值嵌入表示类别、以最近原型完成分类, 结构简洁、归纳偏置充分^[27], 并已在高光谱小样本分类^[28,29]与作物胁迫识别^[30]中取得成功。国内农业领域亦已广泛采用该范式: 全吾梦等^[31]用度量型元学习实现酿酒葡萄品种的 5-way 5-shot 鉴定, 梁炜健等^[32]以迁移学习初始化配合元学习优化完成小样本害虫分类。

收稿日期: 修订日期:

基金项目: 新疆维吾尔自治区科技创新团队 (天山创新团队) 项目 (2022TSYCTD0011); 国家自然科学基金项目 (61367001); 2025 年国家级大学生创新创业训练计划项目 (202510758022)

作者简介: 李盼林 (2004—), 男, 山东青岛人, 新疆农业大学本科生, 主要从事高维数据统计分析及应用、深度学习研究。Email:

panlinryang@gmail.com

*通信作者: 黄华 (1981—), 男 (土家族), 重庆秀山人, 新疆农业大学教授, 硕士, 硕士生导师, 主要从事高维数据统计分析及应用研究。Email: huanghua@xjau.edu.cn

然而，将上述范式移植到跨年苹果近红外溯源时，仍有两个关键问题悬而未决。其一，缺乏覆盖多采收年份、且配有标准化“留一年份”评估协议的苹果近红外基准，导致不同研究报告的跨年性能彼此无从比较。蒋雪松等^[33]在本刊综述中已明确指出，林果品质无损检测领域仍存在“模型泛化能力差、缺乏公共数据集”等问题，并呼吁未来应围绕建立公共数据集与元学习方向展开研究。其二，也是更隐蔽的一点：当表示编码器先在包含留出测试年份的全量数据上预训练、再用于少样本评估时，相当于让模型“预先见过”考题。数据泄漏导致预测性能虚高已在机器学习驱动的科学中被系统揭示^[34]，Király 等^[35]更进一步将其正式引入化学计量学模型验证，指出重复测量的不当使用会在训练/测试划分中造成泄漏；Rosenblatt 等^[36]则量化证明特征选择泄漏与重复个体泄漏会剧烈虚高预测性能，且小数据集会放大该效应。但发生在表示学习层的这一类泄漏——编码器预训练阶段接触留出域——其量级在现有近红外溯源研究中从未被正式估计。

如何量化表示层评估泄漏对跨年少样本性能的影响，并在无目标域标签的现实约束下给出可靠且不需额外样本的评估方式，构成本研究拟解决的关键科学问题。

为此，本研究开展三方面工作：1）整合并构建覆盖 2018、2019、2025 三个采收年份、4 个产地、9 个采集域的苹果近红外光谱基准，提出标准化、无泄漏的留一采收年份（leave-one-harvest-year-out, LOEO）评估协议；2）通过折限定编码器与共享编码器的同口径配对比较，量化评估泄漏对跨年宏 F1 的系统性影响，并以

标签置换负控与独立公开数据集加以验证；3）在无泄漏协议与统一评估口径下系统对比 SVM、偏最小二乘判别分析（partial least squares discriminant analysis, PLS-DA）、最近质心与原型网络在不同支持样本量下的表现，给出面向实际部署的方法选择与评估协议建议。

1 材料与方法

1.1 数据集构建

苹果近红外漫反射光谱于 2018、2019、2025 三个采收年份，在中国 4 个主要产区——新疆（XJ）、山东（SD）、陕西（SX）、甘肃（GS）采集。样品以红富士品种为主，购自当地批发市场，尽量覆盖多个果园批次以提高代表性，于室温（20~25 ℃）存放不超过 3 d 后测量。2018、2019 年光谱由光纤式可见-近红外点光谱仪采集（原生 590~1 250 nm），每果仅在赤道面采集 1 条；2025 年由便携式可见-近红外推扫式高光谱成像系统采集（原生 391~1 001 nm），每果在 3~5 个面位各采 1 条（新疆 204 果：194 果 5 面、9 果 4 面、1 果 3 面；山东 215 果：212 果 5 面、3 果 3 面；甘肃 230 果全部 5 面）。跨年谐调时将两台仪器统一裁剪至 590~1 001 nm 公共窗口，以三次样条插值重采样，得到 229 个波段（591~1 001 nm）。各采集域按年份-产地编号为 E1~E9，三年合计 1 950 个果实、4 529 条光谱（表 1）。本文所有实验中“样本”均指单条光谱。2025 年的多面设计为面均值消融（2.4 节）提供了果内空间异质性信息；甘肃仅在 2025 年采集，在 LOEO-2025 折中构成源域不存在的新产地类别。

表 1 跨年苹果近红外光谱基准的数据集统计

Table 1 Statistics of the cross-year apple NIR spectral benchmark

采集域 Domain	采收年份 Harvest year	产地 Region	果实数 Fruits	光谱数 Spectra	每果面位数 Facets per fruit
E1	2018	新疆 XJ	229	229	1
E2	2018	山东 SD	201	201	1
E3	2018	陕西 SX	200	200	1
E4	2019	新疆 XJ	241	241	1
E5	2019	山东 SD	215	215	1
E6	2019	陕西 SX	215	215	1
E7	2025	新疆 XJ	204	1 009	3~5
E8	2025	山东 SD	215	1 069	3~5
E9	2025	甘肃 GS	230	1 150	5
合计 Total	—	—	1 950	4 529	—

注：2018、2019 年每果仅采赤道面 1 条光谱；2025 年每果在 3~5 个面位各采 1 条（甘肃 230 果全部 5 面，新疆 10 果、山东 3 果不足 5 面）。甘肃（GS）仅在 2025 年采集，在 LOEO-2025 折中构成源域不存在的新产地类别。

Note: One equatorial spectrum per fruit was acquired in 2018 and 2019, whereas 3 to 5 facet spectra per fruit were acquired in 2025. Gansu was sampled only in 2025 and therefore constituted an unseen origin class in the LOEO-2025 fold.

预处理对每条光谱独立进行、不使用任何跨样本统计量，以保留跨年分布差异：先以 15 点窗口、二阶多项式的 Savitzky-Golay 平滑^[37]（滤波系数仅由窗口决定、与数据无关），再施加标准正态变量（standard normal variate, SNV）变换^[38]逐条消除果面几何与漫反射光程差异引起的散射效应。该“SG 平滑+SNV”流程与张宇等^[18]在苹果可见-近红外上独立得到的最优预处理结论一致。王鑫磊等^[39]在异源近红外（实验室级与工程在线两类仪器）上系统比较 5 种预处理及其组合共 156 个模

型，发现最优预处理方案随仪器分化；这从侧面支持本文的保守设计——预处理逐条独立进行、不引入任何跨样本统计量，以免把仪器或年份特有的分布信息带入模型。本文刻意回避联合跨年标准化，因其会人为对齐年间分布、导致过于乐观的结果。最终特征为每样本 229 个光谱变量，覆盖 591~1 001 nm 可见光-近红外过渡区约 600 nm 处为色素（叶绿素/花青素）吸收，长波端含 O—H、C—H 键泛音与合频（约 970 nm 处水分吸收），其光子穿透深度足以承载果肉成分信息^[40]。图 1a 显示，

即便经逐条 SNV 归一化，三个采收年份之间仍存在系统性偏移，以 2025 年偏离最远。图 1b 则限定在 2025 年这一个采集年份内比较三个产地（陕西仅采于历史年、甘肃仅采于 2025，跨年混合会把仪器效应误读为产地效应

应），可见同年份内产地间存在稳定但幅度较小的判别性差异，构成本任务可行的基础。这一差异的量级明显小于图 1a 的跨年偏移，说明跨年域偏移才是本任务的主要障碍。




图 1 预处理后苹果近红外光谱的跨年域偏移 (a) 与 2025 年内的产地可分性 (b)

Fig.1 Cross-year domain shift (a) and within-2025 origin separability (b) of the preprocessed apple NIR spectra

注：曲线为均值，阴影为 ± 1 标准差；波段范围 591~1 001 nm。（b）限定在 2025 年这一个采集年份内比较三个产地——因陕西仅采于 2018 / 2019、甘肃仅采于 2025（表 1），若跨年混合作产地均值，年份与仪器效应会被误读为产地效应（实测混合口径下产地间距离为同年份内真实距离的 4~6 倍）。同年份内三产地曲线的差异虽小于（a）中的跨年偏移，但稳定存在，构成本任务可行的基础；这一对比也直观说明跨年域偏移的量级远大于产地间差异，正是本文所要解决的难点。

Note: Curves denote means and shaded bands denote ± 1 standard deviation over the 591 to 1 001 nm range. Panel (b) is restricted to the 2025 harvest year, because Shaanxi was sampled only in 2018/2019 and Gansu only in 2025 (Table 1); pooling across years would confound the instrument and year effect with the origin effect. The within-year between-origin differences, although smaller than the cross-year shift in (a), are stable and make the task feasible — and the contrast itself shows that the cross-year domain shift far exceeds the between-origin difference.

1.2 留一采收年份（LOEO）无泄漏评估协议

主评估框架为留一采收年份（LOEO）：每个采收年份依次作目标域、其余两年作源域，得三折——LOEO-2018、LOEO-2019、LOEO-2025。其中 2025 折最难，因甘肃为源域中不存在的新产地，且新疆、山东以不同测量协议（单面对比多面）出现在源域中。各结果为每折支持集多次独立重采样的均值，重采样次数随实验协议而异（10~50 次，逐项见补充材料 S2），主指标为对各产地等权的宏 F1。

关键在于区分两种编码器协议：**共享编码器**在 E1~E8 共 8 个采集域（含全部三个采收年份，即含目标年）上联合元训练后冻结，用于 LOEO 评估——这是近红外少样本建模中若不特别把评估年份从表示学习中隔离更容易发生的做法（E9 即 2025 年甘肃为源域不存在的新产地类别，留作下游少样本评估，不参与任何编码器训练）；这里要点明，该臂是**有标签**地接触了目标年份的产地标签，故 2.2 节量化的是“目标年份有标签样本参与表示训练”所造成的评估泄漏上界，而非无标签域暴露的效应；**折限定编码器**为每折仅用源域情节从头重训，目标年信息在编码器训练期完全不可访问，是本文倡导的无泄漏标准。二者性能之差即评估泄漏的度量。两臂还有一处非对称需要交代：折限定编码器在 LOEO-2018 与 LOEO-2019 折的源域含 E9（2025 年甘肃），故其元训练见到 4 个产地类别，而共享编码器的训练集固定为 E1~E8、只见 3 个产地类别。该差异使折限定臂在这两

折上获得更丰富的元训练任务，方向上会缩小而非放大两臂差距；因此本文报告的泄漏量是偏保守的一侧。LOEO-2025 折的两臂类别空间一致（均为 3 个产地），不受此影响。除明确注明外，本文所有性能比较均使用折限定编码器。每个评估情节从目标折随机采样 3-way K-shot 支持集，该折中支持集之外的全部果实构成查询集（而非固定数目的查询样本），以充分利用目标域数据、降低查询采样噪声；为防果内信息泄漏，支持集与查询集在**果实个体（fruit ID）**层面严格不相交——同一果的所有面位光谱被整体分入支持集或查询集之一，绝不跨集出现。这一划分规则与 Király 等^[35]关于“重复测量不当使用会造成训练/测试划分泄漏”的警示一致。每折的支持集重采样若干次后取宏 F1 均值，重采样次数随实验而异（见补充材料 S2）。

1.3 评估泄漏的机制分析

折限定与共享协议的经验差距并非实现层面的偶然，而是分布漂移下评估设计的原理性缺陷。为理解共享编码器为何会系统性高估跨年性能，本节在一个可解析的简化模型（线性-高斯最近原型）下分析其内在机制：目标域类样本服从同协方差高斯分布、各类等概率，编码器为线性映射（取自两协议共用的紧可行集），判决规则为欧氏最近原型，分析在**总体原型**（ $K \rightarrow \infty$ 的理想极限）下进行。定义类对的**嵌入可分性**为查询沿判决法向投影后的信噪比，其加权平方和即可分性目标 J ；折限定编码器为源域目标的最大化者，共享编码器为源域与

目标域混合目标的最大化者。记两协议在目标域的期望少样本精度为 A_H 与 A_R ，评估泄漏偏差 $\Delta = A_H - A_R$ 。完整假设、引理与证明见补充材料 S1。

机制分析（评估泄漏方向为正） 在上述简化设定与总体原型下，二类情形可解析地得到 $\Delta = \Phi(s(W_H)/2) - \Phi(s(W_R)/2) \geq 0$ （ Φ 为标准正态分布函数），当且仅当两协议在目标域的嵌入可分性相等时取等；多类情形在“各成对可分性坐标支配且同类噪声相关结构不变”的充分条件下亦不小于零。

其直接推论为：1) **无漂移即无泄漏**——两域同分布时两协议的最优编码器重合、泄漏归零，故评估泄漏是分布漂移的产物；2) **原理性修复**——要避免这一系统性高估，表示学习的训练集应与评估留出域不相交，这正是折限定协议。注意，上述分析给出的是“共享协议不低估”（ $\Delta \geq 0$ ），而非“折限定协议无偏”。

必须诚实标注**适用边界**：该分析成立于线性编码器、同协方差高斯、总体原型与二类情形，多类情形需额外的坐标支配充分条件；它并不自动覆盖本文实际使用的神经编码器、有限 K 与多类设置。故本文不以其替代实证证据，而是把 $\Delta \geq 0$ 作为方向性预测加以检验：该预测在多个具有真实域划分的公开数据集上均成立（2.5 节），且在真实嵌入上对充分条件作了直接诊断——多类折上“坐标支配”（条件 ii）的成立比例均值为 0.862（诊断脚本口径）/ 0.813（正式检验脚本口径，2 000 次自助重采样 95% 置信区间 [0.682, 0.931]，下界远高于随机基线 0.5）。另需指出，上述分析的另一充分条件“同类噪声相关结构不变”（条件 i）在 Indian Pines 高光谱与芒果部分折上明显失效（见补充材料 S1.8），故多类情形的非负性主要由经验证据支撑、而非由该简化分析保证。两诊断脚本以同一标称种子重训编码器，因跨域套件运行于非逐位可复现的后端，逐折支配比例在两次重训间存在波动（个别折差异较大），故并列报告其均值、单折数值不宜视作稳定量；比例最低的折同时也是泄漏最弱的折之一，方向上与上述分析一致。该结论与域适应的经典泛化界^[41]在精神上一致：两域分布距离越大，用源域信息评估目标域性能的偏差越不可忽略。

1.4 原型网络与对比方法

原型网络（prototypical network）^[27]以 K 个支持样本的均值嵌入为类原型，将查询样本判给最相近的原型。**编码器**为一维卷积-全连接混合网络，以适配光谱的局部带形结构：输入 229 个波段先经两层一维卷积（通道数 32 与 64，卷积核宽 7 与 5，各接批归一化与 ReLU），再以固定步长平均池化压缩波段维；池化输出展平后经两层全连接（隐藏层 256 维，接批归一化、ReLU 与 dropout 0.3）投影到 128 维嵌入，并作 ℓ_2 归一化。**判决规则**为归一化嵌入空间上的余弦原型分类：类原型取该类支持样本嵌入的均值并重新作 ℓ_2 归一化，查询样本与各原型的余弦相似度经温度系数（取 10）缩放后送入 softmax。由于嵌入与原型均已归一化，余弦相似度与平方欧氏距离在判决上等价（ $\|a-b\|^2 = 2 - 2a \cdot b$ ），温

度系数只影响损失的尖锐程度、不改变分类边界。**元训练**以 Adam 优化器^[42]（学习率 10^{-3} ，余弦退火）在源域 3-way K-shot 情节上最小化查询交叉熵损失，共训练 2 000 个情节，取源域验证宏 F1 最高的检查点用于评估。元训练情节内，支持样本取该果全部面位嵌入的均值、查询样本取该果的随机单个面位——这一设定使编码器在训练期即面对“以稳定原型判别单次扫描”的任务形态，与实际部署一致。

为在支持样本极少时利用源域类统计信息，构造源质心融合变体 ProtoNet-C：以融合权重对当前情节支持集均值与源域类均值嵌入做凸组合，权重为 0 时退化为原始原型网络，为 1 时退化为完全锚定源质心的最近质心分类器。ProtoNet-C 在此作为探索性变体，而非本文的核心算法贡献。

并行对比四种方法：**SVM**^[43]（径向基核，正则化参数固定为 10、核宽取 scale 启发式，测试时在 K 个目标支持样本上重拟合）、**PLS-DA**^[44]（以 K 个支持样本构建偏最小二乘投影，潜变量数取支持样本数减一、波段数与类别数三者的最小值，即该情节下的最大可行维数）、**原始原型网络**（不做源质心融合）与**最近质心**。三种传统方法的超参数在全部情节中固定，未做逐情节网格搜索——在 $K=1$ 的极小样本情节中无法划分出用于调参的内部验证集，逐情节调参会引入目标域信息；固定超参数虽可能使其性能略低于充分调参的上限，但保证了跨 K 的可比性，且不违反无泄漏约束。三种传统方法在折内对输入再次施加 SNV。因光谱已在预处理阶段完成 SNV，该操作对绝大多数样本是幂等的：4 529 条中 4 523 条的偏差小于 10^{-4} （全体平均偏差 1.2×10^{-4} ）。余 6 条 2025 年山东样本存在可见偏差（最大 0.121），其逐条谱线标准差为 0.994 而非 1——这些样本的原始光谱含传感器失效波段（数据卡已记录），经平滑与插值后大段取常数值，故 SNV 未能完全归一化。该 6 条占全部样本的 0.13%，对结果的影响可忽略；且 SNV 逐条独立、不引入任何折外统计量，故不违反无泄漏约束。

为保证 like-for-like 可比，五种方法在 2 结果与分析中共用同一折限定情节划分与同一**单面查询协议**（2018、2019 年本就每果单面，2025 年随机抽 1 个面位），即面对完全相同的支持集与查询集；两种原型网络方法使用折限定编码器嵌入，三种传统方法按标准用法直接在 SNV 光谱空间上工作。单面口径的统一性至关重要：2025 年每果有 3~5 个面位，若某方法使用面位均值而其他方法仅用单面，前者将凭空获得一份平均降噪红利（多面位均值相对单面的总增益约 0.11，其中查询侧主效应 +0.077、支持侧 +0.025、交互 +0.012，见 2.4 节），使方法排序失真——这恰是本文所批评的口径不一致问题，故在主对比中被严格排除；多面增益单独在 2.4 节作为消融报告。

传统无监督域适应方法在执行分布对齐时需访问目标域全量无标签数据，与本文仅在推理阶段访问 K 个目标有标签支持样本的情节协议存在根本性协议不对称，直接比较将引入对其有利的信息优势，故未纳入对照。

1.5 消融与统计分析

源质心融合消融比较三种配置：配置 A（三折统一融合权重 0.4）、配置 B（2018/2019 折用 0.4、2025 折不融合）、配置 C（三折均不融合），以检验源质心注入在跨年分布偏移下有益还是有害；并对融合权重在 0~1 区间做连续扫描。**面均值消融**在 2025 折以 2×2 设计交叉支持侧（单面/多面均值）与查询侧（单面/多面均值），分解面均值增益中支持侧与查询侧的独立贡献。

统计分析以**折**为主分析单位（主分析单位数 n_{primary} = 外层折数 = 3）。5 个固定随机种子用于降低编码器初始化与情节采样带来的噪声，**不构成独立样本**：3 折 × 5 种子的 15 个数值在折内高度相关，若当作 15 个独立样本会低估方差、夸大显著性。因此置信区间一律采用**以折为聚类单位的 cluster bootstrap**（2 000 次重采样），P 值采用 Nadeau-Bengio 方差修正的重采样配对 t 检验，效应量以 Cohen's d 量化，跨多个 K 值的比较以 Holm 程序控制族错误率。必须指出，LOEO 设计仅提供 3 个主分析单位，检验功效受到根本限制：即便某一比较在上述口径下达到显著，若退化为最保守的“折级均值三点配对检验”（ $n=3$ ），亦可能不显著；本文将同时报告这一保守结果，并以“折级一致性 + 效应量 + 置信区间”为主要依据，不以单一 P 值立论。正文报告的全部核心结果在单块 NVIDIA RTX 4090（CUDA，5 个固定随机种子，开启确定性算法）上获得。

评估口径的完整披露。 本文的核心论点是评估口径足以颠覆结论，故有义务把自身各项实验的口径（编码器、面位口径、重采样次数）逐一列明——完整清单见补充材料 S2。两点需强调：其一，**泄漏对照（表 2）的两臂在面位口径、编码器架构、K 值与查询集构造上完全一致**（均为多面位均值），**方法对比（表 3）的五种方法在面位口径上亦完全一致**（均为单面），故泄漏量与方法排序均不可归因于面位协议。其二，**表 2 与表 3 的绝对数值不可跨表比较**——二者面位口径不同（多面位均值相对单面的总增益约 0.11，见 2.4 节），跨表比较将重蹈本文所批评的覆辙。**关于配对口径。** 泄漏对照两臂的支持集重采样相互独立、次数亦不同（表 2），故泄漏量是两个独立期望估计之差，而非严格配对差。由求和的线性性，逐情节配对差的均值与两臂均值之差**在数学上恒等**（ $E[a_i - b_i] \equiv E[a] - E[b]$ ），因此独立重采样**不影响泄漏点估计的无偏性**，只影响其方差估计；且独立口径把两臂的采样噪声相加，所给置信区间通常比严格配对口径**更宽、更保守**（实测 2019 折宽 2.4 倍）。换言之，本文报告的不确定性是偏保守的一侧。为进一步确认，另做了严格配对验证（同一支持集同时送入两个编码器、逐情节求泄漏；CUDA、4 个固定种子、每折 50 次重复）：三折的配对泄漏分别为 **0.247±0.031、**

0.340±0.021、0.499±0.039，三折合并 **0.362±0.011**——与表 2 独立重采样口径下的 0.250 / 0.339 / 0.501（合并 0.363）**逐折吻合至 0.003 以内**。这从实证上确认：泄漏量的点估计不受配对与否影响，表 2 的结论稳健成立。

2 结果与分析

2.1 折限定编码器验证

报告 LOEO 性能前，先确认每个折限定编码器在源域上的判别能力，以排除训练不足的编码器对下游比较的干扰。2018、2019、2025 三折的源域验证准确率分别为 0.945±0.002、0.938±0.007、0.949±0.006（5 个固定种子，三折均值 0.944；取自各折限定编码器检查点的源域验证记录），表明编码器在各自训练分布内能干净区分产地；2019 折的轻微下降与该年山东、陕西两产地间更大的光谱重叠一致。然而域内判别力强并不等于跨年迁移力强——真正的问题是：当该编码器用于对留出目标年份的少样本分类时，性能会下降多少。

2.2 评估泄漏量化：共享编码器对比折限定编码器

为把编码器泄漏与源质心融合权重彻底解耦，在两种同权重口径下各做一次 like-for-like 对照（表 2、图 2）。**口径一（两臂融合权重均为 0.4）**：共享编码器（在含目标折的全部三年数据上训练）三折均值宏 F1 为 0.926，折限定编码器（仅用非目标年重训）为 0.563，评估泄漏达 0.363。**口径二（两臂均不融合，为主实验最优配置）**：共享 0.922、折限定 0.679，评估泄漏 0.242（5 个种子的均值，泄漏量的跨种子标准差 0.020）。两口径下评估泄漏均稳健为正——方向在全部 3 折、全部 5 个种子上一致，效应量比 2.3 节的方法间差异大一个数量级——**支持泄漏源自编码器“看过”目标域，而非融合权重造成的假象，与 1.3 节机制分析的方向预测一致。**

关于“漂移越大泄漏越大”的逐折单调性须诚实区分口径：融合权重 0.4 口径下泄漏随漂移单调递增（以年份偏移为主的 2018、2019 折分别为 0.250、0.339，同时混淆年份、协议与类别空间的 2025 折达 0.501）；但不融合口径下逐折泄漏大致持平（0.260、0.227、0.240）。其机制明确：0.4 的源质心融合在协议失配的 2025 折严重有害，把该折折限定臂由 0.668 压至 0.414，从而人为放大了泄漏；移除融合后 2025 折折限定性能回升、该折泄漏回落至与其余折相当。故单调性仅作 0.4 口径下的观察，不作跨口径的普适断言。

这些数字说明：使用共享编码器时（在近红外元学习文献中相当普遍），0.9 以上的 LOEO 宏 F1 报告值需大幅打折扣——它在相当程度上反映的是协议漏洞而非真实的跨年泛化能力。折限定协议是跨年基准更合适的评估标准，本文后续所有结果均使用折限定编码器。

表 2 评估泄漏：共享编码器对比折限定编码器（K=5，5 个固定种子均值）

Table 2 Evaluation leakage: shared versus fold-restricted encoder (K=5, mean over five fixed seeds)				
编码器协议 Encoder protocol	LOEO-2018	LOEO-2019	LOEO-2025	三折均值 Mean
口径一：两臂融合权重均为 0.4 Regime I: fusion weight 0.4 in both arms				

共享编码器 (全数据) Shared (all years)	0.929	0.935	0.915	0.926
折限定编码器 (折内重训) Fold-restricted	0.678	0.596	0.414	0.563
评估泄漏 Evaluation leakage	0.250	0.339	0.501	0.363
口径二：两臂均不融合 (like-for-like) Regime II: no fusion in both arms				
共享编码器 (全数据) Shared (all years)	0.928	0.929	0.908	0.922
折限定编码器 (折内重训) Fold-restricted	0.668	0.702	0.668	0.679
评估泄漏 Evaluation leakage	0.260	0.227	0.240	0.242

注：数值为宏 F1。评估泄漏 = 共享编码器 - 折限定编码器。两种口径的两臂均使用相同的源质心融合权重，故泄漏不可归因于融合权重。标签置换负控 $P < 0.001$ 。

Note: Values are macro-F1. Evaluation leakage is defined as the shared-encoder score minus the fold-restricted score. Both arms within each regime used an identical source-centroid fusion weight, so the leakage cannot be attributed to the fusion weight. Label-permutation control gave $P < 0.001$.




图2 评估泄漏：两种编码器协议的逐折性能落差 (a) 与泄漏量的 95%置信区间 (b)

Fig.2 Evaluation leakage: per-fold performance gap between the two encoder regimes (a) and the leakage with its 95% confidence interval (b)

注：K=5，源质心融合权重 0.4 口径，5 个固定种子。(a) 中每条哑铃的长度即该折的评估泄漏 Δ ；点线为 3 类随机基线 (0.333)。(b) 为泄漏量的点估计与 95% 置信区间 (以折为聚类单位的 cluster bootstrap, 2 000 次重采样)；菱形为三折合并估计；三折的置信区间下界均远离零，泄漏方向稳健为正。Note: K=5, source-centroid fusion weight of 0.4 in both arms, five fixed seeds. In (a) the length of each dumbbell is the evaluation leakage Δ of that fold; the dotted line marks the three-class random baseline (0.333). Panel (b) gives the point estimate of the leakage and its 95% confidence interval (cluster bootstrap with the fold as the clustering unit, 2 000 resamples); the diamond is the pooled three-fold estimate. All lower bounds lie well above zero, so the leakage is robustly positive.

2.3 不同支持样本量下的跨方法比较

五种方法在统一评估口径 (折限定编码器、单面查询、5 个固定种子) 下的宏 F1 随支持样本量 K 的变化见表 3、图 3，呈清晰的交叉模式。在小样本区 ($K \leq 10$) 折限定原始原型网络稳定领先：K=1 时按降序为原始原型网络 (0.579)、最近质心 (0.545)、ProtoNet-C (0.542)、SVM (0.518)、PLS-DA (0.472)；其对 SVM 的优势随 K 增大而单调收窄 (K=1 时 +0.061、K=3 时 +0.057、K=5 时 +0.039、K=10 时 +0.019)。K=20 时 SVM 反超 (0.697 对 0.678)，并在 K=50 时把差距拉大到 0.759 对 0.685。其机制可解释：固定容量编码器的最近原型机制在类原型均值稳定后从额外支持样本获益有限，而 SVM 的最大间隔优化能持续利用更丰富的目标域几何结构。因此交叉点位于 K=10 与 K=20 之间。

须如实指出：本文构造的源质心融合变体 ProtoNet-C 在无泄漏的折限定协议下在所有 K 上均劣于不融合的原始原型网络 (如 K=5 时 0.562 对 0.648)，且其随 K 的增长近乎停滞 (K=1 至 K=50 仅由 0.542 升至 0.573)——源质心一旦以固定权重注入，就会持续把类原型拉

向源域位置，K 增大所带来的目标域信息因而被稀释。这与 2.4 节的融合消融结论一致：源质心注入在跨年分布偏移下总体有害。该变体不构成本文的方法学主张；本文的核心贡献是评估协议而非该变体，此处将其作为阴性结果如实报告。

折级配对统计 (主分析单位数 $n_{\text{primary}} = 3$ 折；5 个固定种子仅用于降低情节采样噪声，不构成独立样本；折内先对种子取均值，再于 3 个折级值上作 Nadeau-Bengio 方差修正的配对检验，并对 6 个 K 作 Holm 校正；置信区间取以折为聚类单位的 cluster bootstrap, 2 000 次重采样) 显示：K=1 时折限定原始原型网络相对 SVM 的差值为 +0.061 (95% 置信区间 [+0.046, +0.085], Cohen's $d = 2.91$)；K=3 时 +0.057 ([+0.007, +0.097], 下界仍为正)；K=5、K=10 时差值分别为 +0.039、+0.019，置信区间已跨过零；K=20 起符号翻转为负 (-0.019)，K=50 时为 -0.073 ([-0.123, -0.005])。

特别地，在上述主分析口径下，K=1 处的差异并未达到统计显著 (原始 $P=0.086$ ，Holm 校正后 $P=0.515$)；其余各 K 亦均不显著。若改把 3 折 $\times$ 5 种子

的 15 个配对差当作独立样本，则 $K=1$ 处 Holm 校正后 $P=0.015$ ——但这正是 1.5 节所批评的做法（折内数值高度相关，当作独立样本会低估方差、夸大显著性），故本文不予采信，亦不据此宣称显著性。

因此本文不主张原型网络在小样本区“显著”优于 SVM，而将该优势作为方向性证据报告，其依据是对同一组折级差值的三项互补刻画（因导出自同一 3 折，彼此并不统计独立）：①效应量大（Cohen's $d = 2.91$ ）；②以折为聚类单位的置信区间下界为正（+0.046，该区间仅 3 个聚类、覆盖性有限，仅供参考）；③优势方向在全部 3 个折上一致（种子层面 15/15 亦无例外，但独立单位仅为 3 折，其符号检验 $P=0.125$ ，故方向一致性本身也不构成显著性证据，仅作为稳定性的辅助观察）。LOEO 设计仅提供 3 个主分析单位，统计功效受到根本限制——这是该设计为换取“无泄漏”所付出的代价，本文如实交代这一边界，而不以放宽统计口径的方式换取显著性。这一边界不影响本文主结论：2.2 节评估泄漏的效应量（0.24~0.50）比此处的方法间差异大一个数量级，在任何统计口径下都稳健为正。

表 3 五种方法在各支持样本量下的 LOEO 宏 F1

Table 3 LOEO macro-F1 of five methods across support-set sizes

支持样本量 K	原始原型网络 ProtoNet	支持向量机 SVM	源质心融合变体 ProtoNet-C	偏最小二乘判别 PLS-DA	最近质心 Nearest centroid
1	0.579±0.007	0.518±0.007	0.542±0.014	0.472±0.008	0.545±0.005
3	0.629±0.010	0.572±0.007	0.559±0.014	0.587±0.005	0.594±0.003
5	0.648±0.007	0.609±0.002	0.562±0.015	0.631±0.004	0.615±0.003
10	0.669±0.007	0.650±0.002	0.567±0.017	0.660±0.002	0.634±0.004
20	0.678±0.007	0.697±0.002	0.570±0.016	0.678±0.003	0.647±0.002
50	0.685±0.008	0.759±0.002	0.573±0.021	0.691±0.002	0.655±0.002

注：数值为三折均值 ± 跨种子标准差（5 个固定种子，每折 50 次重复）；粗体为各支持样本量下的最优方法。五种方法共用同一折限定情节划分与同一单面查询协议（每果仅取 1 个面位），其中两种原型网络方法使用折限定编码器嵌入，三种传统方法直接在 SNV 预处理后的光谱空间上工作，以保证 like-for-like 可比。2.4 节报告的多面位均值增益不计入本表。

Note: Values are three-fold means ± the across-seed standard deviation (five fixed seeds, 50 repetitions per fold). Bold indicates the best method at each support-set size. All five methods shared one fold-restricted episode split and one single-facet query protocol (one facet per fruit); the two prototypical-network methods operated on fold-restricted encoder embeddings, whereas the three conventional methods operated directly on SNV-preprocessed spectra, ensuring like-for-like comparability. The multi-facet averaging gain reported in Section 2.4 is not included here.




图 3 五种分类方法的 LOEO 宏 F1 随支持样本量的变化 (a) 及其排名翻转 (b)

Fig.3 LOEO macro-F1 of five classifiers as a function of the support-set size (a) and the resulting rank flip (b)

注：折限定编码器，统一单面查询口径，三折均值，5个固定种子。(a) 误差棒为 ± 1 跨种子标准差；灰带标出原始原型网络与支持向量机的交叉区间 ($K=10\sim 20$)。(b) 为各方法在每个支持样本量下的排名 (1 为最优)：原始原型网络在 $K\leq 10$ 时稳居第一， $K=20$ 起被支持向量机取代——方法排序随支持样本量发生翻转，这是“评估口径决定方法选型”的直接体现。

Note: Fold-restricted encoders under a unified single-facet query regime, three-fold means, five fixed seeds. In (a) error bars denote ± 1 across-seed standard deviation, and the grey span marks the crossover interval between the prototypical network and the support vector machine ($K = 10$ to 20). Panel (b) gives the rank of each method at every support-set size (1 = best): the plain prototypical network ranks first for $K \leq 10$ and is overtaken by the support vector machine from $K = 20$ onwards, so the method ordering flips with the support-set size.

2.4 源质心融合与面均值消融

源质心融合消融 ($K=5$, 补充材料图 S1) 中三配置的三折均值宏 F1 为：配置 A (三折统一权重 0.4) 0.563、配置 B (仅 2025 折不融合) 0.648、配置 C (三折不融合) 0.679，以配置 C 最优。源融合在 2025 折损失最大 (0.414 对 0.668)，因源质心由单面的 2018/2019 光谱计算，与多面采集的 2025 目标域存在测量协议失配。完整的融合权重连续扫描 (5 个种子，补充材料图 S1) 显示：LOEO-2025 与 LOEO-2019 折随权重增大严格单调递减 (分别自不融合时的 0.671、0.698 降至完全锚定源质心时的 0.199、0.520)，LOEO-2018 折则较为平坦 (0.678 降至 0.650)。漂移越强，源质心注入的危害越大，这与 1.3 节机制分析的推论互为镜像。故在跨年苹果近红外场景下，折限定情节原型应优先取不融合配置。

面均值消融 (2025 折 2×2 设计, $K=5$) 把面均值增益拆为两项独立贡献：仅查询侧面均值 +0.077、仅支持侧面均值 +0.025，交互效应 +0.012。主要增益来自查询侧——跨多个面位平均查询光谱可降低单次测量的随机方差。该结论对现场扫描协议的资源分配具实践指导意义：在相同扫描预算下，应优先在查询侧 (待测样品) 多采集面位，而非在支持侧 (参考集) 多采。

2.5 外部验证与跨数据集复现

为检验评估泄漏并非苹果数据特有，在玉米 (跨仪器)、药片 (跨仪器)、芒果^[45] (跨采收季) 近红外与 Indian Pines 高光谱遥感场景 (跨空间象限) 等公开数据集上重复量化 (各数据集的模式、波段、规模、任务、来源与 SHA-256 校验见补充材料数据卡表 S1.7)。这些数据连同本文苹果基准均具有**真实的域划分**，与本文的 LOEO 设定同构 (橄榄油数据集因采用 IID 序号划分、不含域漂移，属记忆化上限 (详见本节后文)，故不计入此证据链)。以数据集为随机效应的混合效应模型对上述**5 个真实域划分数据集 (16 折)** 给出总体泄漏 0.124 (95% 置信区间 [0.055, 0.194])，逐折 15/16 为正、逐数据集 5/5 全为正 (数据集级符号检验 $P=0.031$)；即便把橄榄油作为记忆化上限一并纳入 (6 数据集、17 折)，总体泄漏仍为 0.132 (95% 置信区间 [0.071, 0.192])，结论不变。这表明表示层评估泄漏并非苹果近红外的特例或超参数假象，而是在跨作物、跨仪器、跨模态的多个真实域划分公开数据集上一致出现的现象；但数据集数量尚不足以支撑“普遍规律”的断言，其在更广泛模态与任务上的量级仍需进一步检验。

这里需专门说明公开橄榄油光谱数据 (傅里叶变换红外，四国产地，60 样本) 的性质：本文沿用了该数据集在 UCR 归档中的官方训练/测试序号划分 (前 30 条为

源、后 30 条为目标)，该划分并非按域构造，两半的类别分布相同、不存在可辨识的域漂移；且其“共享”臂的编码器在包含全部查询样本的全量数据上训练。因此该对照给出的 0.178 (折限定 0.822、共享 1.000, $K=3$) 实为**训练集包含测试集时的记忆化上限**，而非本文所定义的跨域表示层泄漏；共享臂宏 F1 恒为 1.000 即是记忆化的直接体现。本文将其作为“泄漏的极端情形”列出，**不将其计入跨域泄漏的证据链**，也提醒读者：即便在无域漂移的划分下，让表示学习看到评估样本同样会使报告值失真——只是其机制是记忆化而非表示偏移。

2.6 负控、不确定性校准与波段可解释性

对折限定原型网络施加三类负控 (各 $\geq 1\ 000$ 次置换) 以确认性能来自真实的光谱-产地关联：标签置换后真实宏 F1 显著高于置换零分布 (逐折 $P<0.001$)；以同形状随机噪声替换光谱输入后性能退化至随机水平 (三折宏 F1 约 0.33，与 3 类随机基线相当)；仅用中性样本序号的标识符探针不高于随机 (三折宏 F1 0.21~0.24)。三项负控排除了标签结构、数据管线与采样顺序等捷径。

不确定性校准方面，折限定原型网络的逐折期望校准误差为 0.028、0.075、0.089，其中大于 0.05 的 2019、2025 折经温度缩放后降至 0.057、0.051，表明少样本产地分类存在中等程度的过自信、可由单参数缩放有效缓解，为高风险溯源决策提供更可信的概率输出。

可解释性上，以 SHAP 与置换重要性 (按果实编号分组划分以防同果泄漏) 定位的判别波段集中于 591~605 nm (中位 603.5 nm) 的可见光-色素区，并延伸至长波段 C—H (糖类/有机物) 与 O—H (水分) 的合频与倍频吸收带，与苹果成分的产地相关差异在化学上自洽，支持模型捕获的是有意义的成分指纹而非伪相关。

3 讨论

3.1 评估泄漏的成因与应对

共享编码器协议导致的评估泄漏并非偶发，而是“编码器在含测试域的全量数据上预训练后冻结”这一工作流的系统性后果——其参数在接触第一个支持样本之前，就被目标域的分布特征所塑造。近红外场景下泄漏还有额外放大机制：接触过 2025 年多面光谱的编码器已学到该测量协议特有的空间结构，人为降低了 2025 折的分类难度。1.3 节的机制分析只要求编码器是可优化的表示映射，未限定其形式，故该机制在原理上不依赖特定架构；但本文仅在一维卷积编码器上实证，其他架构下的泄漏量级有待验证。

补救方案直接而无可回避：为每个 LOEO 折仅在源域上独立重训编码器。此操作的计算代价不可忽略，但

目前尚无在保证评估纯洁性的同时绕过该代价的可靠替代。值得强调的是，这一隐患并非苹果近红外独有。Király 等^[35]已在化学计量学中指出重复测量与参数选择造成的泄漏，Rosenblatt 等^[36]在神经影像中量化了特征选择泄漏与重复个体泄漏的虚高效应，Apicella 等^[46]系统综述了机器学习与迁移学习中的泄漏风险，Joeres 等^[47]则提出了以组合优化实现低泄漏数据划分的通用工具。本文所刻画的表现层泄漏位于这一谱系的末端：即使样本划分完全正确，只要表示学习阶段接触了留出域，跨域泛化数字仍会被系统性高估。据此建议：未来的跨年近红外基准研究应明确所用的编码器协议，将折限定性能作为必要基线，并把共享编码器结果标注为“上限参考”而非真实性声明。这与 Camacho^[48]近期倡导的模型验证规范化方向一致。

3.2 方法选择的实践边界

位于 $K=10$ 与 $K=20$ 之间的交叉点划定了两种部署情境。其一为采收季初期或新产区初次接入供应链——每产地仅能获取少量有标注参考样本：此区间内元学习原型方法稳定占优（ $K=1$ 时领先 SVM 0.061，以折为聚类单位的 95% 置信区间 [0.046, 0.085]，Cohen's $d = 2.91$ ； $K=3、5、10$ 时仍分别领先 0.057、0.039、0.019。受 LOEO 仅 3 个主分析单位所限，上述优势未达统计显著，一律作为方向性依据）。原型网络的优势来源清晰：它把源域元训练学到的判别性表示直接迁移到目标域，在支持样本稀缺、无法可靠估计目标域类边界时，这一先验最有价值。其二为具备条件维护适度参考集的常规检验场景（如口岸入境检验）：SVM 自 $K=20$ 起反超，且随支持样本增加持续增长、推理更简、可解释性更好，是更稳妥的选择。吴琪等^[22]报告“仅需 20 个新样本即可显著改善跨品种预测”，与本文交叉点恰落在 $K=20$ 的观察相互印证——这一样本量似乎正是判别式模型能够可靠估计目标域类边界的经验门槛。

更值得对照的是：耿莹蕊等^[9]在同一批次、同一采集条件下以近红外结合优化 SVM 鉴别 8 个产地烟叶，报告 96.62% 的整体正确率；而本文表明，同样以 SVM 为分类器，一旦评估换成跨采收年份的无泄漏留一协议，其宏 F1 在 $K=5$ 时仅为 0.609、即便支持样本增至 50 个也只有 0.759。这一数量级的落差正是本文的核心警示——域内随机划分下的高精度不能外推到跨年部署。

此外，本文的源质心融合变体在无泄漏协议下全程劣于不融合配置，是一个诚实报告的负结果——它提示：在跨年分布偏移下，把源域类质心注入目标域原型不但无益，反而会把源域的偏移一并带入。这与毕淑慧等^[17]在单一年份内报告的“多模型融合有益”形成有趣对照，说明“融合总是有益”的直觉在域偏移下并不成立。

须明确适用边界：本文评估的是商品流通批次条件下手持近红外的产地区分能力，而非纯地理化学信号；交叉点位置仅在本文采集条件（591~1 001 nm、四产区）下成立，实际值将随仪器、类别数与漂移强度而变。

3.3 局限性与未来方向

样品来源与混淆因素。样品购自批发市场、以红富士为主但未严格控制单一品系，采收成熟度、储藏与流通处理均未记录，故光谱差异可能同时编码地理产地、品种、成熟度与供应链效应；本文因此将溯源声明限定为“市售批次条件下的产地相关判别”而非纯地理化学检测。**跨年偏移的复合性质。**应当强调，本文的“跨年”域偏移并非纯粹的采收年份效应：2018/2019 采用单面赤道点谱、2025 改用多面推扫成像（表 1），且甘肃仅见于 2025、陕西不见于 2025，故 LOEO-2025 折实为年份、采集仪器、面位协议与类别空间四者叠加的复合偏移。这恰是实际部署中“换年往往伴随换仪器/换流程”的真实情形，本文的无泄漏协议评估的即是此复合偏移下的泛化；分离纯年份分量需同仪器多年份数据，留待后续正交设计。**地域与仪器推广性。**数据集限于中国三至四个产区、可见-近红外波段（591~1 001 nm），能否推广到欧洲原产地保护苹果或短波红外（1 000~2 500 nm）仪器需新数据回答。**方法层面与基线设定。**未纳入现代深度基线（折限定源域训练的一维残差网络/注意力网络）与传统域适应方法（因协议不对称需公平化改造后方可纳入）；本文倡导的折限定源域训练在机制上更接近域泛化而非域适应。此外，五方法比较中传统基线采用全情节固定超参（SVM 核宽 scale、 $C=10$ ；PLS-DA 潜变量取自动上界），以保证跨 K 可比并避免逐情节调参引入目标域信息，代价是方法选型的交叉点（ $K=10\sim 20$ ）依赖于这一固定基线设定；若允许基线在源域上系统调参，交叉点位置可能移动，故本文的选型建议应理解为固定基线口径下的方向性结论，而非跨调参方案的普适定论。**统计功效。**LOEO 仅提供 3 个主分析单位，方法间比较的统计功效有限，这是留一年份设计的固有代价；本文以效应量与折级一致性为主要依据，并已如实标注未达显著的结论。**未来方向。**域差距感知的自适应融合（由源-目标分布距离动态推断融合权重）有望在低差距场景找回部分源原型收益；以年份×协议×产地三因素正交设计可分离 LOEO-2025 折的复合混淆。九域数据集与评估代码计划在论文接受后公开。

4 结论

1) 构建了覆盖 3 个采收年份（2018、2019、2025）、4 个产地、9 个采集域的苹果近红外光谱基准（1 950 个果实、4 529 条光谱、229 个波段），并提出标准化、无泄漏的留一采收年份（LOEO）少样本评估协议。

2) 系统量化了表示层评估泄漏：共享编码器相对无泄漏的折限定编码器使 LOEO 宏 F1 系统性虚高，在同一源质心融合权重口径下，融合权重为 0.4 时虚高 0.363、不融合时虚高 0.242，两口径下泄漏均稳健为正（三折一致、五种子一致），标签置换负控 $P<0.001$ ，并在玉米、药片、芒果、Indian Pines 高光谱场景等 5 个具有真实域划分的公开数据集上复现（总体泄漏 0.124，95% 置信区间 [0.055, 0.194]，逐数据集全为正）。因此，

折限定编码器训练与归纳性协议说明应成为跨年近红外基准报告的基本规范,而非可选项。

3) 在无泄漏协议与统一的单面查询口径下,不融合的折限定情节原型是稳健默认配置,源质心融合在所有支持样本量上均劣于不融合,构成一个诚实报告的负结果;方法选择以可获得的参考样本量为轴——每类参考样本不超过 10 个时折限定原型网络持续领先 SVM ($K=1$ 时领先 0.061,以折为聚类单位的 95%置信区间 [0.046, 0.085], Cohen's $d = 2.91$; $K=3, 5, 10$ 时分别领先 0.057、0.039、0.019。受 3 个主分析单位所限,上述优势均未达统计显著 ($K=1$ 处 Holm 校正后 $P=0.515$),一律作为方向性证据报告——依据是效应量大、置信区间下界为正、且方向在 3 个折上一致(符号检验 $P=0.125$,不构成显著性证据), $K=20$ 起 SVM 反超并持续拉大 ($K=50$ 时 0.759 对 0.685),交叉点位于 $K=10$ 与 $K=20$ 之间;面均值增益主要来自查询侧

(+0.077, 远大于支持侧 +0.025)。须强调该选型结论依赖于评估口径的统一,而两处不一致会沿相反方向改变方法排序:其一,若令部分方法使用面位均值光谱而其余方法仅用单面(并配线性核 SVM),依赖面位均值的传统方法被系统性抬高,交叉点被前移至 $K=3$ 附近,从而给出“小样本区也应放弃元学习”的相反建议;其二,若沿用共享编码器,则被抬高的是依赖编码器的原型网络(其宏 F1 虚高至 0.9 以上,见表 2),交叉点反而后移乃至消失。两者方向虽反,却共同说明:评估口径的任一处不一致都足以颠覆方法选型,这是本文最直接的实践警示。

上述结果为苹果等农产品近红外产地溯源模型的可靠评估、以及现场快速筛查中的方法选型与部署提供了直接依据,有助于地理标志产品保护与农产品质量安全监管。

【参考文献】

- [1] FAO. FAOSTAT: Crops and livestock products (QCL)[DB/OL]. Rome: Food and Agriculture Organization of the United Nations, 2025[2026-04-15]. <https://www.fao.org/faostat/en/#data/QCL>.
- [2] 金晓彤, 王冬艳, 王兴佳, 等. 用微量元素对东北大米产地识别的技术[J]. 农业工程学报, 2022, 38(22): 246-252. JIN Xiaotong, WANG Dongyan, WANG Xingjia, et al. Identification technology for rice origins via tracking trace elements in Northeast China[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(22): 246-252. (in Chinese with English abstract)
- [3] DANEZIS G P, TSAGKARIS A S, CAMIN F, et al. Food authentication: Techniques, trends and emerging approaches[J]. TrAC Trends in Analytical Chemistry, 2016, 85: 123-132.
- [4] NICOLAÏ B M, BEULLENS K, BOBELYN E, et al. Nondestructive measurement of fruit and vegetable quality by means of NIR spectroscopy: A review[J]. Postharvest Biology and Technology, 2007, 46(2): 99-118.
- [5] WALSH K B, BLASCO J, ZUDE-SASSE M, et al. Visible-NIR 'point' spectroscopy in postharvest fruit and vegetable assessment: The science behind three decades of commercial use[J]. Postharvest Biology and Technology, 2020, 168: 111246.
- [6] 郭志明, 王郡艺, 宋焯, 等. 手持式可见近红外苹果品质无损检测系统设计与试验[J]. 农业工程学报, 2021, 37(22): 271-277. GUO Zhiming, WANG Junyi, SONG Ye, et al. Design and experiment of the handheld visible-near infrared nondestructive detecting system for apple quality[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(22): 271-277. (in Chinese with English abstract)
- [7] 白雪冰, 杨佳宁, 姜醒睿, 等. 西北地区干红葡萄酒产地与酒龄的理化判别方法[J]. 农业工程学报, 2022, 38(13): 319-326. BAI Xuebing, YANG Jianing, JIANG Xingrui, et al. Discrimination method for the origin and age of dry red wine by physico-chemical indices in northwest China[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(13): 319-326. (in Chinese with English abstract)
- [8] 白雪冰, 陈鑫龙, 刘乾鑫, 等. 基于色味指标光谱特性的贺兰山东麓干红葡萄酒产地细分[J]. 农业工程学报, 2024, 40(15): 253-261. BAI Xuebing, CHEN Xinlong, LIU Qianxin, et al. Origin subdivision of dry red wine from Helan Mountain's East Foothill based on the spectral characteristics of the color and taste indicators[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(15): 253-261. (in Chinese with English abstract)
- [9] 耿莹蕊, 沈欢超, 倪鸿飞, 等. 近红外光谱结合灰狼算法优化支持向量机实现烟叶产地快速鉴别[J]. 光谱学与光谱分析, 2022, 42(9): 2830-2835. GENG Yingrui, SHEN Huanchao, NI Hongfei, et al. Support vector machine optimized by near-infrared spectroscopic technique combined with grey wolf optimizer algorithm to realize rapid identification of tobacco origin[J]. Spectroscopy and Spectral Analysis, 2022, 42(9): 2830-2835. (in Chinese with English abstract)
- [10] 杨文政, 邹凤杰, 闫嘉. 基于 MI-HSIC 混合加权指数电子鼻特征优化的黄连产地鉴别[J]. 农业工程学报, 2025, 41(23): 303-312. YANG Wenzheng, ZOU Fengjie, YAN Jia. Origin identification of Coptis Chinensis via electronic nose feature optimization based on MI-HSIC hybrid weighted index[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(23): 303-312. (in Chinese with English abstract)
- [11] CAREDDA M, CIULU M, TILOCCA F, et al. Portable NIR spectroscopy to simultaneously trace honey botanical and geographical origins and detect syrup adulteration[J]. Foods, 2024, 13(19): 3062.
- [12] LI Y C, LOGAN N, QUINN B, et al. Fingerprinting black tea: When spectroscopy meets machine learning a novel workflow for geographical origin identification[J]. Food Chemistry, 2024, 438: 138029.

- [13] YE Q, MENG X. Highly efficient authentication of edible oils by FTIR spectroscopy coupled with chemometrics[J]. Food Chemistry, 2022, 385: 132661.
- [14] HAN T, WANG Z, XU S, et al. Synergetic application of near-infrared spectroscopy and electronic eye combined with an improved CNN-VMamba mixed network for soybean origin traceability[J]. European Food Research and Technology, 2026, 252(6): 252.
- [15] YANG Y, WANG S Q, ZHU Q B, et al. Non-destructive geographical traceability of American ginseng using near-infrared spectroscopy combined with a novel deep learning model[J]. Journal of Food Composition and Analysis, 2024, 136: 106736.
- [16] GAO S P, JIANG M L, FAN Y L, et al. High-precision apple classification and traceability based on enhanced CBAM for near-infrared spectroscopy[J]. Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy, 2026, 357: 127766.
- [17] 毕淑慧, 李雪, 申涛, 等. 基于多模型证据融合的苹果分类方法[J]. 农业工程学报, 2022, 38(13): 141-149. BI Shuhui, LI Xue, SHEN Tao, et al. Apple classification based on evidence theory and multiple models[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(13): 141-149. (in Chinese with English abstract)
- [18] 张宇, 张重阳, 段鑫鑫, 等. 基于线性判别分析和机器学习的可见-近红外光谱苹果损伤分级[J]. 食品科学, 2024, 45(22): 255-261. ZHANG Yu, ZHANG Chongyang, DUAN Xinxin, et al. Visual/near-infrared spectroscopy combined with linear discriminant analysis and machine learning for classification of apple damage[J]. Food Science, 2024, 45(22): 255-261. (in Chinese with English abstract)
- [19] WALSH J, NEUPANE A, KOIRALA A, et al. Review: The evolution of chemometrics coupled with near infrared spectroscopy for fruit quality evaluation. II. The rise of convolutional neural networks[J]. Journal of Near Infrared Spectroscopy, 2023, 31(3): 109-125.
- [20] MISHRA P, PASSOS D, MARINI F, et al. Deep learning for near-infrared spectral data modelling: Hypes and benefits[J]. TrAC Trends in Analytical Chemistry, 2022, 157: 116804.
- [21] ROGER J M, DIAZ V F, NIKZAD-LANGERODI R. Cloning instruments, model maintenance and calibration transfer[J]. TrAC Trends in Analytical Chemistry, 2025, 191: 118319.
- [22] 吴琪, 陈孝敬, 石文, 等. 结合近红外光谱和模型更新的苹果品质无损检测[J]. 分析测试学报, 2025, 44(6): 1154-1160. WU Qi, CHEN Xiaojing, SHI Wen, et al. Combining near-infrared spectroscopy and model updating for nondestructive testing of apple quality[J]. Journal of Instrumental Analysis, 2025, 44(6): 1154-1160. (in Chinese with English abstract)
- [23] LI L, HUANG W, WANG Z, et al. Calibration transfer between developed portable Vis/NIR devices for detection of soluble solids contents in apple[J]. Postharvest Biology and Technology, 2022, 183: 111720.
- [24] PAN L, LI H, HU Z, et al. Standard-free sample model transfer of visible/near-infrared spectral model of apple ripeness under seasonal variation[J]. Journal of Food Composition and Analysis, 2024, 128: 106028.
- [25] 夏宇, 孟静武, 罗斌, 等. 高光谱结合理化参数跨品种识别玉米种子贮藏年份[J]. 农业工程学报, 2024, 40(16): 261-268. XIA Yu, MENG Jingwu, LUO Bin, et al. Cross-species identification of maize seed storage year by hyperspectral combination of physicochemical parameters[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(16): 261-268. (in Chinese with English abstract)
- [26] REHMAN T U, JIN J. Deep adversarial domain adaptation for hyperspectral calibration model transfer among plant phenotyping systems[J]. Biosystems Engineering, 2022, 224: 246-258.
- [27] SNELL J, SWERSKY K, ZEMEL R S. Prototypical networks for few-shot learning[C]//Advances in Neural Information Processing Systems 30. Long Beach, USA: Curran Associates, 2017: 4077-4087.
- [28] YU C, GONG B, SONG M, et al. Multiview calibrated prototype learning for few-shot hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-13.
- [29] HU L, HE W, ZHANG L P, et al. Cross-domain meta-learning under dual-adjustment mode for few-shot hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-16.
- [30] RUAN S W, CANG H, CHEN H X, et al. Hyperspectral classification of frost damage stress in tomato plants based on few-shot learning[J]. Agronomy, 2023, 13(9): 2348.
- [31] 全吾梦, 施钦晔, 范一言, 等. 基于少样本学习的酿酒葡萄品种鉴定方法[J]. 农业工程学报, 2025, 41(4): 211-219. QUAN Wumeng, SHI Qinchao, FAN Yiyan, et al. Few-shot learning for identifying wine grape varieties with limited data[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(4): 211-219. (in Chinese with English abstract)
- [32] 梁伟健, 郭庆文, 王春桃, 等. 基于空间注意力增强 ResNeSt-101 网络和迁移元学习的小样本害虫分类[J]. 农业工程学报, 2024, 40(6): 285-297. LIANG Weijian, GUO Qingwen, WANG Chuntao, et al. Few-shot pest classification using spatial-attention-enhanced ResNeSt-101 network and transfer-based meta-learning[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(6): 285-297. (in Chinese with English abstract)
- [33] 蒋雪松, 计恺豪, 姜洪喆, 等. 深度学习在林果品质无损检测中的研究进展[J]. 农业工程学报, 2024, 40(17): 1-16. JIANG Xuesong, JI Kaihao, JIANG Hongzhe, et al. Research progress of non-destructive detection of forest fruit quality using deep

- learning[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(17): 1-16. (in Chinese with English abstract)
- [34] KAPOOR S, NARAYANAN A. Leakage and the reproducibility crisis in machine-learning-based science[J]. Patterns, 2023, 4(9): 100804.
- [35] KIRÁLY P, TÓTH G. Being aware of data leakage and cross-validation scaling in chemometric model validation[J]. Journal of Chemometrics, 2025, 39(4): e70026.
- [36] ROSENBLATT M, TEJAVIBULYA L, JIANG R T, et al. Data leakage inflates prediction performance in connectome-based machine learning models[J]. Nature Communications, 2024, 15(1): 1829.
- [37] SAVITZKY A, GOLAY M J E. Smoothing and differentiation of data by simplified least squares procedures[J]. Analytical Chemistry, 1964, 36(8): 1627-1639.
- [38] BARNES R J, DHANOA M S, LISTER S J. Standard normal variate transformation and de-trending of near-infrared diffuse reflectance spectra[J]. Applied Spectroscopy, 1989, 43(5): 772-777.
- [39] 王鑫磊, 韩鲁佳, 杨增玲, 等. 预处理方法对异源近红外秸秆营养成分速测模型的影响[J]. 农业工程学报, 2025, 41(9): 216-226. WANG Xinlei, HAN Lujia, YANG Zengling, et al. Influence of preprocessing methods on the rapid quantitative models for crop straw nutrients using different near-infrared spectroscopy devices data[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(9): 216-226. (in Chinese with English abstract)
- [40] LAMMERTYN J, PEIRS A, DE BAERDEMAEKER J, et al. Light penetration properties of NIR radiation in fruit with respect to non-destructive quality assessment[J]. Postharvest Biology and Technology, 2000, 18(2): 121-132.
- [41] BEN-DAVID S, BLITZER J, CRAMMER K, et al. A theory of learning from different domains[J]. Machine Learning, 2010, 79(1/2): 151-175.
- [42] KINGMA D P, BA J. Adam: A method for stochastic optimization[C/OL]//Proceedings of the 3rd International Conference on Learning Representations. San Diego, USA, 2015[2026-07-14]. <https://arxiv.org/abs/1412.6980>.
- [43] CORTES C, VAPNIK V. Support-vector networks[J]. Machine Learning, 1995, 20(3): 273-297.
- [44] GELADI P, KOWALSKI B R. Partial least-squares regression: A tutorial[J]. Analytica Chimica Acta, 1986, 185: 1-17.
- [45] ANDERSON N T, WALSH K B, SUBEDI P P, et al. Achieving robustness across season, location and cultivar for a NIRS model for intact mango fruit dry matter content[J]. Postharvest Biology and Technology, 2020, 168: 111202.
- [46] APICELLA A, ISGRÒ F, PREVETE R. Don't push the button! Exploring data leakage risks in machine learning and transfer learning[J]. Artificial Intelligence Review, 2025, 58(11): 339.
- [47] JOERES R, BLUMENTHAL D B, KALININA O V. Data splitting to avoid information leakage with DataSAIL[J]. Nature Communications, 2025, 16(1): 3337.
- [48] CAMACHO J. A set of rules for model validation[J]. Journal of Chemometrics, 2026, 40(2): e70110.

A leakage-free few-shot evaluation protocol for cross-year apple origin traceability

LI Panlin¹, ZHANG Qingli¹, JIAO Qitai³, LI Yuchang¹, SUN Jiamei¹, HUANG Hua^{1,2*}

(1. College of Mathematics and Physics, Xinjiang Agricultural University, Urumqi 830052, China; 2. Research Center for Numerical Simulation and Data Analysis, Xinjiang Agricultural University, Urumqi 830052, China; 3. College of Mechanical and Electrical Engineering, Xinjiang Agricultural University, Urumqi 830052, China)

Abstract: The geographical origin traceability of apples by near-infrared spectroscopy is compromised in cross-year deployment by a subtle, rarely quantified evaluation bias: when the representation encoder has been pre-trained on data that already contain the held-out evaluation year, the reported few-shot accuracy is systematically inflated. This study aimed to quantify this representation-layer evaluation leakage on a controlled cross-year apple benchmark, to determine whether the inflation originated from the encoder rather than from the downstream classifier, and to provide a correction requiring no extra samples or labels. A near-infrared benchmark spanning three harvest years (2018, 2019 and 2025), four production regions and nine acquisition domains was constructed, comprising 1 950 fruits and 4 529 diffuse-reflectance spectra with 229 wavelength bands over the 591 to 1 001 nm window. A leave-one-harvest-year-out protocol was defined, with each harvest year serving in turn as the target domain. Two encoder-training regimes were compared under otherwise identical settings: a shared encoder pre-trained on all years including the held-out year, and a fold-restricted encoder whose training set was kept strictly disjoint from it. Within a prototypical-network framework, the two regimes and five classifiers were compared under one unified single-facet regime, with support and query sets separated at the fruit level. The shared encoder inflated the macro-F1 score relative to the fold-restricted encoder by 0.363 under a source-centroid fusion weight and by 0.242 without fusion, so the inflation persisted under two independent like-for-like regimes and could not be attributed to the fusion weight. Because the two arms differed only in whether the encoder training set contained the held-out year, the inflation was attributable mainly to the encoder rather than to the classifier; a label-permutation control gave a probability below 0.001, ruling out random-label and pipeline shortcuts. The same inflation was reproduced across five datasets carrying a genuine domain split

(apple, maize, tablet, mango and the Indian Pines hyperspectral scene), with an overall leakage of 0.124 (95% confidence interval 0.055 to 0.194) that stayed positive on every dataset. Under the leakage-free protocol, the prototypical network led the support vector machine whenever at most ten reference samples per class were available, by 0.061 at one sample and narrowing to 0.019 at ten; because the design afforded only three primary analysis units, this margin did not reach statistical significance (a probability of 0.515 after Holm correction) and was reported as a directional trend only. The support vector machine overtook it beyond twenty samples, placing the crossover between ten and twenty reference samples, so the optimal classifier depended on the number of reference samples realistically obtainable. The evaluation regime alone could reverse this apparent conclusion, and the two inconsistencies acted in opposite directions. Letting some methods use facet-averaged spectra while others use a single facet (with a linear-kernel support vector machine) inflated the facet-averaged conventional methods and moved the apparent crossover forward to about three samples; retaining the shared encoder, by contrast, inflated the encoder-based prototypical network and pushed the crossover later or removed it altogether. The source-centroid fusion variant proved inferior to plain prototype averaging at every support-set size and was reported as a negative result. Representation-layer evaluation leakage caused a systematic, non-negative overestimation of cross-year few-shot performance in apple near-infrared origin traceability and could reverse method-selection decisions. Keeping the representation-learning set strictly disjoint from the held-out evaluation year removed this bias without requiring any samples or labels beyond the support set already used, and applied to any encoder-plus-nearest-prototype evaluation. Reporting the difference between the fold-restricted and the shared protocols is recommended as a standard reliability check for near-infrared origin traceability and, more broadly, for cross-domain few-shot detection in agricultural products.

Key words: visible-near infrared spectroscopy; hyperspectral imaging; nondestructive detection; geographical origin traceability; apples; few-shot learning; evaluation leakage; domain shift

补充材料 S1 评估泄漏偏差非负性的理论证明

(对应正文 1.3 节「评估泄漏的理论刻画」)

本补充材料给出正文 1.3 节所述命题的完整假设、引理、证明，以及理论条件在真实数据上的经验诊断。全部推导在一个可解析的**线性-高斯最近原型模型**下进行。为便于审阅，本材料自包含地重述所有记号与假设，不依赖正文的省略表述。

S1.1 记号与假设

S1.1.1 设定

考察目标域 T 上的情节式 (episodic) 少样本分类，共 C 个类别，类先验等概率。

类条件分布。 在类条件高斯模型下，类 c 的样本满足

$$x | (y=c) \sim N(\mu_c^D, \Sigma^D), \Sigma^D > 0, D \in \{src, T\},$$

即同一域内各类共享协方差矩阵，类均值 $\{\mu_c^D\}$ 仿射独立。 src 表示源域 (编码器可访问的域)， T 表示留出的目标域。

编码器。 编码器为线性映射

$$\phi_w(x) = Wx, W \in \mathcal{W} \subset \mathbb{R}^{d \times p},$$

其中可行集 $\mathcal{W}$ 对两种协议**相同** (即两协议的唯一差别在于训练数据，而非模型容量)。

分类器。 给定类原型 $\{p_c\} \subset \mathbb{R}^d$ ，查询样本 q 按欧氏最近原型规则判决：

$$\hat{y} = \arg \max_c \left\{ -\|Wq - p_c\|_2 \right\}.$$

平局在假设 1 的非退化条件下为零测度事件，任意打破即可。

总体原型。 全部分析在**总体原型** (population prototype) 下进行：

$$p_c(W) = W \mu_c^T.$$

这是 $K \rightarrow \infty$ 的理想极限—— K -shot 样本原型 $\hat{p}_c = \frac{1}{K} \sum_{i=1}^K W x_i^{(c)}$ 依大数律收敛到 $W \mu_c^T$ 。有限 K 的情形见

S1.2 的**注记 1**，其经验行为见 S1.8。

精度与泄漏偏差。 记编码器 W 在总体原型下的目标域期望精度为

$$A(W) = E_{y,q} [1\{\hat{y} = y\}].$$

对协议 $\bullet \in \{R, H\}$ (R = 折限定 fold-restricted, H = 共享 shared/pooled) 记 $A_\bullet = A(W_\bullet)$ ，并定义**评估泄漏偏差**

$$\Delta := A_H - A_R.$$

S1.1.2 嵌入可分性

定义 (嵌入可分性)。 对域 D 与类对 (c, c') ，记嵌入后的类均值差及其单位方向为

$$a_{cc'}(W; D) := W(\mu_c^D - \mu_{c'}^D), \dot{a}_{cc'}(W; D) := \frac{a_{cc'}(W; D)}{\|a_{cc'}(W; D)\|_2},$$

嵌入协方差为 $S_W^D := W \Sigma^D W^T$ 。定义**嵌入可分性**

$$s_{cc'}(W; D) := \frac{\|W(\mu_c^D - \mu_{c'}^D)\|_2}{\sqrt{\dot{a}_{cc'}^T (W \Sigma^D W^T) \dot{a}_{cc'}}} \geq 0.$$

这不是马氏距离，而是查询样本沿判决法向投影后的**信噪比** (projected decision SNR)：分子是投影后的类间间隔，分母是投影后的噪声标准差。它——而非马氏距离——才是欧氏最近原型精度的直接决定量 (见引理 1)。

由对称性， $\dot{a}_{c'c} = -\dot{a}_{cc'}$ 而 $\dot{a}_{c'c}^T S_W^D \dot{a}_{c'c} = \dot{a}_{cc'}^T S_W^D \dot{a}_{cc'}$ ，且 $\|a_{c'c}\| = \|a_{cc'}\|$ ，故

$$s_{cc'}(W; D) = s_{c'c}(W; D),$$

即 s 关于类对是对称的 (此性质在 S1.4 与 S1.8 中都要用到)。

S1.1.3 假设

假设 1 (非退化紧可行集)。 存在常数 $\rho > 0$ ，使得对一切 $W \in \mathcal{W}$ 、一切域 $D \in \{src, T\}$ 、一切类对 $c \neq c'$ ：

$$\|W(\mu_c^D - \mu_{c'}^D)\|_2 \geq \rho, \dot{d}_{cc'}^\tau (W \Sigma^D W^\tau) \dot{d}_{cc'} \geq \rho.$$

且 W 为紧集。

假设1排除三类退化：①嵌入后类均值重合（此时 $\dot{d}_{cc'}$ 与 $s_{cc'}$ 无定义）；②投影方差为零（此时 $s_{cc'} = \infty$ ）；③判决平局取正测度。在假设1下， $s_{cc'}(\cdot; D)$ 在 W 上有限、连续、有界，从而下面的极大化问题有解。

假设2（可分性目标与两协议的最优编码器）。取固定权重 $w_{cc'} > 0$ ，定义可分性目标

$$J(W; D) = \sum_{c < c'} w_{cc'} s_{cc'}^2(W; D).$$

由假设1， $J(\cdot; D)$ 在紧集 W 上连续，故极大点存在。两协议的编码器分别取为总体目标的**全局极大点**：

$$W_R \in \arg \max_{W \in W} J(W; src),$$

$$W_H \in \arg \max_{W \in W} [(1-\lambda)J(W; src) + \lambda J(W; T)], \lambda \in (0, 1],$$

其中 λ 反映留出域 T 在混合（pooled）训练集中的有效权重。为简记，令

$$J_\lambda(W) := (1-\lambda)J(W; src) + \lambda J(W; T).$$

关于假设2的说明。 $J(\cdot; T)$ 是本高斯模型下 ProtoNet 度量损失所极大化的总体对应量：ProtoNet 以「查询到本类原型的距离小于到他类原型的距离」为训练信号，在总体原型下该信号的强度恰由沿判决法向的信噪比 $s_{cc'}$ 决定。这一对应是建模层面的设定，而非本材料所证明的结论（见 S1.9 第3条）。

两协议的差别至此完全形式化：折限定编码器 W_R 只看见源域目标 $J(\cdot; src)$ ；共享编码器 W_H 的目标里以权重 $\lambda > 0$ 混入了留出域的目标 $J(\cdot; T)$ 。泄漏偏差 Δ 度量的正是这一「提前看见考题」所带来的精度虚高。

S1.2 引理1（总体原型下的成对正确概率）

引理1。固定编码器 W 与类对 (c, c') ，取总体原型 $p_c = W \mu_c^T$ 、 $p_{c'} = W \mu_{c'}^T$ 。在 S1.1 的设定与假设1下，类 c 的查询样本被判为 c （相对于 c' ）的概率恰为

$$\Pr[\text{正确} | (c, c')] = \Phi(1/2 s_{cc'}(W; T)),$$

其中 Φ 为标准正态分布函数。该概率通过 $s_{cc'}(W; T)$ 且仅通过 $s_{cc'}(W; T)$ 依赖于 W 与 Σ^T ，并关于 $s_{cc'}$ 严格递增。

证明。

第1步（把二原型判决化为中垂超平面）。原型确定（非随机）时，二原型最近判决为

$$\|Wq - p_c\|_2^2 < \|Wq - p_{c'}\|_2^2.$$

两边展开并消去公共项 $\|Wq\|^2$ 、

整理得

$$-2(Wq)^\tau p_c + \|p_c\|^2 < -2(Wq)^\tau p_{c'} + \|p_{c'}\|^2,$$

即

$$2(Wq)^\tau (p_c - p_{c'}) > \|p_c\|^2 - \|p_{c'}\|^2 = (p_c - p_{c'})^\tau (p_c + p_{c'}),$$

亦即

$$(Wq - 1/2(p_c + p_{c'}))^\tau (p_c - p_{c'}) > 0.$$

这正是以 $p_c, p_{c'}$ 的中垂超平面为界的半空间。

第2步（沿法向投影）。记 $m := W(\mu_c^T - \mu_{c'}^T) = p_c - p_{c'}$ ， $\dot{d} := m / \|m\|_2$ 。由假设1， $\|m\|_2 \geq \rho > 0$ ，故 (S1.1) 两端同除以 $\|m\|_2 > 0$ 不改变不等号方向，(S1.1) 等价于

$$t := \dot{d}^\tau (Wq - 1/2(p_c + p_{c'})) > 0.$$

即：正确事件 $= \{t > 0\}$ ，且判决只依赖 Wq 沿 $\dot{d}$ 的分量。

第3步（ t 的精确分布）。对 $q \sim$ 类 c ，有 $Wq \sim N(W\mu_c^T, S)$ ， $S := W\Sigma^T W^\tau$ 。 t 是 Wq 的仿射函数，故 t 服从一维正态分布，其均值为

$$E[t] = \dot{d}^\tau (W\mu_c^T - 1/2(W\mu_c^T + W\mu_{c'}^T)) = \dot{d}^\tau \cdot 1/2(W\mu_c^T - W\mu_{c'}^T) = 1/2 \dot{d}^\tau m = 1/2 \|m\|_2,$$

方差为

$$\text{Var}[t] = \dot{d}^T S \dot{d}.$$

由假设 1, $\dot{d}^T S \dot{d} \geq \rho > 0$, 故方差严格为正。

第 4 步 (求概率)。于是

$$\Pr[\text{正确}] = \Pr[t > 0] = \Phi\left(\frac{E[t]}{\sqrt{\text{Var}[t]}}\right) = \Phi\left(\frac{\|m\|_2/2}{\sqrt{\dot{d}^T S \dot{d}}}\right) = \Phi(1/2 s_{cc'}(W; T)).$$

第 5 步 (唯一依赖性与单调性)。由第 2 步, 只有 Wq 沿 $\dot{d}$ 的投影进入判决, 故与 $\dot{d}$ 正交的协方差成分完全不影响精度——这解释了为何精度只通过标量 $s_{cc'}$ 依赖 (W, Σ^T) 。严格单调性即 Φ 的严格单调性。■

注记 1 (有限 K : 为何必须用总体原型)。有限 K 时样本原型 $\hat{p}_c = W \mu_c^T + 1/K \sum_{i=1}^K W \varepsilon_i^{(c)}$ 是随机的, 判决法向 $\hat{p}_c - \hat{p}_{c'}$ 本身也随机, (S1.1) 左端不再是 Wq 的仿射函数 (它含 Wq 与随机法向的乘积项)。此时精确的成对正确概率为

$$\Pr[B^T D > 0], B := Wq - 1/2(\hat{p}_c + \hat{p}_{c'}), D := \hat{p}_c - \hat{p}_{c'}.$$

直接计算: $B \sim N(1/2 m, (1 + 1/2 K) S)$ (因 $\text{Var}[1/2(\hat{p}_c + \hat{p}_{c'})] = 1/4 \cdot 2/K S = 1/2 K S$, 与 Wq 独立可加), $D \sim N(m, 2/K S)$, 且

$$\text{Cov}(B, D) = -\text{Cov}(1/2(\hat{p}_c + \hat{p}_{c'}), \hat{p}_c - \hat{p}_{c'}) = -1/2(1/K S - 1/K S) = 0,$$

二者联合高斯且协方差为零, 故独立。该概率一般不等于 $\Phi(s/2)$, 且不再是单一标量 s 的函数。因此本材料的命题是总体原型 ($K \rightarrow \infty$) 层面的断言。关键在于: 原型噪声由两协议共同承担, 它同时压低 A_R 与 A_H ; 有限 K 下 Δ 的符号与量级不作闭式断言, 改由经验检验 (S1.8)。

S1.3 引理 2 (混合编码器的目标域可分性支配)

引理 2。在假设 1-2 下,

$$J(W_H; T) - J(W_R; T) \geq \frac{1-\lambda}{\lambda} (J(W_R; src) - J(W_H; src)) \geq 0.$$

该不等式只界定标量目标 $J(\cdot; T)$, 它本身并不界定任何单个 $s_{cc'}$, 也不界定精度。

证明。

第 1 步 (右端非负)。 W_R 极大化 $J(\cdot; src)$, 故对一切 $W \in W$ (特别是 $W = W_H$) 有

$$J(W_R; src) \geq J(W_H; src),$$

即 (S1.2) 的右端 ≥ 0 。

第 2 步 (用 W_H 的最优性)。 W_H 极大化 J_λ , 故

$$(1-\lambda)J(W_H; src) + \lambda J(W_H; T) \geq (1-\lambda)J(W_R; src) + \lambda J(W_R; T).$$

第 3 步 (移项)。把含 $J(\cdot; T)$ 的项移到左边、含 $J(\cdot; src)$ 的项移到右边:

$$\lambda(J(W_H; T) - J(W_R; T)) \geq (1-\lambda)(J(W_R; src) - J(W_H; src)) \geq 0,$$

末一个 ≥ 0 由第 1 步及 $1-\lambda \geq 0$ (因 $\lambda \in (0, 1]$) 得到。两边同除以 $\lambda > 0$ 即得 (S1.2)。■

直观。引理 2 是一句「天下没有免费的午餐」: 共享编码器 W_H 若要在混合目标上胜过 W_R , 它在源域上至多只能损失 $J(W_R; src) - J(W_H; src)$, 而这份损失必须由目标域上至少 $\frac{1-\lambda}{\lambda}$ 倍的增益来偿付。目标域信息一旦进入表示学习, 目标域的可分性目标就不可能变差。

警示 (多类情形不可直接外推)。 (S1.2) 控制的是加权平方和 $\sum_{c < c'} w_{cc'} s_{cc'}^2$ 。该和上升时, 个别 (最难的) 类对的 $s_{cc'}$ 完全可能下降。反例: 可分性向量由 $(1, 10, 10)$ 变为 $(0.5, 100, 100)$, 平方和大幅上升, 但最小成对可分性由 1 降至 0.5。因此多类情形必须另加条件 (见 S1.6)。

S1.4 命题 (二类情形评估泄漏偏差非负)

命题 1 (评估泄漏偏差非负, $C=2$)。在 S1.1 的设定、假设 1-2、总体原型与 $C=2$ 下, 记 $s := s_{12}$, 则

$$\Delta = A_H - A_R = \Phi(1/2 s(W_H; T)) - \Phi(1/2 s(W_R; T)) \geq 0$$

且等号成立当且仅当 $s(W_H; T) = s(W_R; T)$ 。

证明。

第1步 ($C=2$ 时精度=成对正确概率) . $C=2$ 、类先验等概率时

$$A(W) = 1/2 \Pr[\hat{y}=1/y=1] + 1/2 \Pr[\hat{y}=2/y=2].$$

只有两个类, 故「判为本类」与「相对另一类判对」是同一事件. 由引理1 (分别取 $(c, c')=(1, 2)$ 与 $(2, 1)$) :

$$\Pr[\hat{y}=1/y=1] = \Phi(1/2 s_{12}(W; T)), \Pr[\hat{y}=2/y=2] = \Phi(1/2 s_{21}(W; T)).$$

由 S1.1.2 的对称性 $s_{21}=s_{12}=s$, 两式相等, 故

$$A(W) = \Phi(1/2 s(W; T)).$$

第2步 (目标域可分性支配) . $C=2$ 时只有一个类对, 故

$$J(W; T) = w_{12} s^2(W; T), w_{12} > 0.$$

由引理2, $J(W_H; T) \geq J(W_R; T)$, 即

$$w_{12} s^2(W_H; T) \geq w_{12} s^2(W_R; T) \Rightarrow s^2(W_H; T) \geq s^2(W_R; T).$$

因 $s \geq 0$ (定义即非负) 且 $u \mapsto u^2$ 在 $[0, \infty)$ 上严格递增, 两边开方得

$$s(W_H; T) \geq s(W_R; T).$$

第3步 (转为精度) . 把 (S1.3) 分别用于 W_H, W_R , 再用 Φ 的严格单调性与 (S1.4):

$$\Delta = \Phi(1/2 s(W_H; T)) - \Phi(1/2 s(W_R; T)) \geq 0.$$

第4步 (等号条件) . Φ 严格单调, 故 $\Delta=0 \Leftrightarrow 1/2 s(W_H; T) = 1/2 s(W_R; T) \Leftrightarrow s(W_H; T) = s(W_R; T)$.

■

这就是正文1.3节所引的命题. 它把「共享编码器被高估」由经验观察提升为可证伪的规律: 在上述模型下, Δ 不可能为负; 若实测 $\Delta < 0$, 则必有某条假设失效 (这一点在 S1.8 的诊断中得到正面利用)。

S1.5 推论 (无漂移即无泄漏 / 原理性修复)

推论1 (无漂移即无泄漏) . 在命题1的假设下, 并设 $J(\cdot; src)$ 的极大点唯一. 若源域与目标域同分布, 即

$$\mu_c^T = \mu_c^{src} (\forall c), \Sigma^T = \Sigma^{src},$$

则 $W_H = W_R$, 从而 $\Delta=0$.

证明. 同分布时, 对一切 $W \in W$ 与一切类对, $a_{cc}(W; T) = a_{cc}(W; src)$ 且 $S_W^T = S_W^{src}$, 故 $s_{cc}(\cdot; T) \equiv s_{cc}(\cdot; src)$, 进而

$$J(\cdot; src) \equiv J(\cdot; T) =: J_{pool}.$$

于是混合目标 $J_\lambda = (1-\lambda) J_{pool} + \lambda J_{pool} = J_{pool}$. 两协议因而在极大化同一个函数. 由极大点唯一性, $W_H = W_R$, 故 $A_H = A_R$, $\Delta=0$. ■

含义. 评估泄漏是分布漂移的产物. 域内随机划分 (无漂移) 下, 共享编码器与折限定编码器给出相同的评估结论; 一旦跨域 (跨年、跨仪器、跨产地), 二者才分道扬镳. 这解释了为何该问题在传统的域内交叉验证范式中长期不可见。

推论2 (零漂移处消失; 漂移下一般为正) . 在命题1的假设下: (i) Δ 是源/目标域参数 (均值与协方差) 的连续函数, 且在无漂移集合上取零; (ii) 若 $W_R \notin \arg \max_{W \in W} J_\lambda(W)$, 则 $s(W_H; T) > s(W_R; T)$, 从而 $\Delta > 0$ (严格正)。

证明.

(i) 由假设1, $s(\cdot; D)$ 关于 W 与域参数连续; Φ 连续; 故 Δ 连续. 零漂移处取零即推论1.

(ii) 设 $W_R \notin \arg \max J_\lambda$. 因 $W_H \in \arg \max J_\lambda$, 必有严格不等式

$$J_\lambda(W_H) > J_\lambda(W_R),$$

展开即

$$(1-\lambda) J(W_H; src) + \lambda J(W_H; T) > (1-\lambda) J(W_R; src) + \lambda J(W_R; T).$$

移项得

$$\lambda (J(W_H; T) - J(W_R; T)) > (1-\lambda) (J(W_R; src) - J(W_H; src)) \geq 0,$$

末一步用引理2第1步与 $1-\lambda \geq 0$. 因 $\lambda > 0$, 得 $J(W_H; T) > J(W_R; T)$ 严格成立. 仿命题1第2步 ($C=2$, $J = w_{12} s^2$, $s \geq 0$), 得 $s(W_H; T) > s(W_R; T)$; 再由 Φ 严格单调, 得 $\Delta > 0$. ■

说明. 条件「 $W_R \notin \arg \max J_\lambda$ 」的含义是：源域最优编码器不再是混合目标的最优编码器——这正是源域最优与目标域最优不重合（即存在实质漂移）时的一般情形。反过来，当 λ 很小时， W_R 仍可能碰巧最大化 J_λ ，此时下界退化为 $\Delta \geq 0$ （非严格）。我们不对「一般情形」作测度论意义上的 **generic 断言**，只作上述条件式断言（见 S1.9 第 5 条）。

推论 3（原理性修复）. 欲无偏估计跨域少样本泛化性能，表示学习的训练集必须与评估留出域不相交。

证明. 由假设 2， λ 恰是留出域 T 在表示学习目标中的有效权重。 $\lambda=0$ 当且仅当表示学习完全不接触 T ，此时 $J_\lambda = J(\cdot; src)$ ，其极大点即 W_R ，故 $W_H = W_R$ 、 $\Delta=0$ ：评估无偏。反之，任何 $\lambda>0$ （即表示学习阶段以任何权重接触了 T ）都落入推论 2 (ii) 的情形，一般给出 $\Delta>0$ ，即系统性高估。■

这正是本文倡导的折限定（fold-restricted）协议：为每个留一年份折，仅用源域情节从头重训编码器，使目标年信息在编码器训练期完全不可访问。推论 3 表明这不是一种「更保守的做法」，而是消除表示层目标域暴露这一泄漏来源的直接操作（在本命题的理想化假设下即可去除该来源的高估；本文不据此主张折限定估计对样品来源、仪器、年份等其余偏差亦无偏）。

S1.6 多类情形的充分条件

$C>2$ 时，命题 1 不能由引理 2 单独外推。原因有二：

引理 2 只控制加权和 $\sum_{c<c'} w_{cc'} s_{cc'}^2$ ，该和上升时最难类对的 $s_{cc'}$ 可能下降（S1.3 的反例 $(1, 10, 10) \rightarrow (0.5, 100, 100)$ ）；

即使全部成对可分性都不下降，多类精度仍不一定上升——因为改变 W 会同时改变若干条判决法向之间的相关结构（夹角），而多元高斯的正交象限概率并非在相关矩阵变动时关于均值单调。

因此，多类只能给出显式充分条件下的命题。

S1.6.1 标准化决策边际

对真实类 c 与每个竞争类 $c' \neq c$ ，定义类 c 查询相对 c' 的标准化决策边际

$$Y_{cc'}(W) := \frac{\dot{d}_{cc'}(W)^T (Wx - 1/2(p_c(W) + p_{c'}(W)))}{\sqrt{\dot{d}_{cc'}(W)^T S_W^T \dot{d}_{cc'}(W)}}, x/y=c,$$

并把它们堆叠为

$$Y_c(W) := (Y_{cc'}(W))_{c' \neq c} \in \mathbb{R}^{C-1}.$$

S1.6.2 命题与证明

命题 2（多类条件非负性， $C>2$ ）. 在 S1.1 的设定、假设 1-2、总体原型下，若对每个类 c 同时满足：(i) 同类噪声相关结构不变： $R_c(W_H) = R_c(W_R)$ ，其中 $R_c(W)$ 为 $Y_c(W)$ 的相关矩阵，其 (c', c'') 元为

$$[R_c(W)]_{c'c''} = \frac{\dot{d}_{cc'}(W)^T S_W^T \dot{d}_{cc''}(W)}{\sqrt{\dot{d}_{cc'}(W)^T S_W^T \dot{d}_{cc'}(W)} \sqrt{\dot{d}_{cc''}(W)^T S_W^T \dot{d}_{cc''}(W)}};$$

(ii) 成对可分性坐标支配：对一切 $c' \neq c$ ，

$$s_{cc'}(W_H; T) \geq s_{cc'}(W_R; T),$$

则 $A_H \geq A_R$ ，即 $\Delta \geq 0$ 。

证明.

第 1 步（把多类正确事件写成正交象限事件）. 对真实类 c 的查询 x ，最近原型规则判为 c 当且仅当

$$\|Wx - p_c(W)\|^2 \leq \|Wx - p_{c'}(W)\|^2 \quad \forall c' \neq c.$$

对每个 c' 重复引理 1 第 1 步的展开（消去公共项 $\|Wx\|^2$ ），得等价形式

$$(Wx - 1/2(p_c(W) + p_{c'}(W)))^T (p_c(W) - p_{c'}(W)) \geq 0 \quad \forall c' \neq c.$$

因 $p_c(W) - p_{c'}(W) = a_{cc'}(W)$ 且由假设 1 有 $\|a_{cc'}(W)\| \geq \rho > 0$ ，逐个类对同除以 $\|a_{cc'}(W)\| \cdot \sqrt{\dot{d}_{cc'}(W)^T S_W^T \dot{d}_{cc'}(W)} > 0$ （两个正数），不等号方向不变，故上式等价于

$$Y_{cc'}(W) \geq 0 \quad \forall c' \neq c,$$

即

$$P_c(W) := \Pr[\hat{y} = c / y = c] = \Pr[Y_c(W) \in \mathbb{R}_+^{C-1}].$$

（几何上：原空间中这是查询高斯落入类 c 的 Voronoi 多面体的概率；在标准化边际坐标下，它是多元高斯的正正交象限概率。）

第2步（求 $Y_c(W)$ 的均值与相关矩阵）。 因 $W_X / y = c \sim N(p_c(W), S_W^T)$ ，而每个 $Y_{cc'}(W)$ 是 W_X 的仿射函数，故 $Y_c(W)$ 为多元高斯。其第 c' 个坐标的均值为

$$E[Y_{cc'}(W) / y = c] = \frac{\hat{d}_{cc'}^T(p_c(W) - 1/2(p_c(W) + p_{c'}(W)))}{\sqrt{\hat{d}_{cc'}^T S_W^T \hat{d}_{cc'}}} = \frac{1/2 \hat{d}_{cc'}^T(p_c(W) - p_{c'}(W))}{\sqrt{\hat{d}_{cc'}^T S_W^T \hat{d}_{cc'}}}.$$

利用 $\hat{d}_{cc'}^T(p_c(W) - p_{c'}(W)) = \hat{d}_{cc'}^T a_{cc'}(W) = \|a_{cc'}(W)\|$ ，即得

$$E[Y_{cc'}(W) / y = c] = 1/2 s_{cc'}(W; T).$$

各坐标已按自身标准差标准化，故其协方差矩阵即相关矩阵 $R_c(W)$ （形式如命题所列）。记

$$m_c(W) := (1/2 s_{cc'}(W; T))_{c' \neq c}, Y_c(W) \sim N(m_c(W), R_c(W)).$$

第3步（在辅助概率空间上构造同分布副本）。 由 (S1.5)， $P_c(W)$ 只依赖 $Y_c(W)$ 的边际分布。由条件 (i)，记 $R_c := R_c(W_H) = R_c(W_R)$ 。 R_c 可能奇异，故取谱分解

$$R_c = U_c \text{diag}(\gamma_{c,1}, \dots, \gamma_{c,C-1}) U_c^T, \gamma_{c,j} \geq 0,$$

并令 $L_c := U_c \text{diag}(\sqrt{\gamma_{c,1}}, \dots, \sqrt{\gamma_{c,C-1}})$ ，则 $L_c L_c^T = R_c$ 。在一个辅助概率空间上取 $Z_c \sim N(0, I_{C-1})$ ，令 $\xi_c := L_c Z_c$ ，则 $\xi_c \sim N(0, R_c)$ （ R_c 奇异时亦成立）。定义辅助副本

$$\tilde{Y}_H := m_c(W_H) + \xi_c, \tilde{Y}_R := m_c(W_R) + \xi_c.$$

由第2步，

$$\tilde{Y}_H \stackrel{d}{=} Y_c(W_H), \tilde{Y}_R \stackrel{d}{=} Y_c(W_R),$$

故用 $\tilde{Y}_H, \tilde{Y}_R$ 比较 $P_c(W_H)$ 与 $P_c(W_R)$ 是合法的边际分布比较。

重要澄清。 该耦合只发生在辅助空间上，用于比较两个边际分布的正正交象限概率；它并不断言真实实验中 W_H 与 W_R 下的查询噪声共享同一实现。

第4步（坐标均值支配 $\Rightarrow$ 逐实现事件包含）。 由条件 (ii) 及第2步， $m_c(W_H) \geq m_c(W_R)$ 逐坐标成立。对任意固定实现 $\xi_c = \xi$ ：若 $m_c(W_R) + \xi \in \mathbb{R}_+^{C-1}$ ，则逐坐标有

$$m_c(W_H) + \xi \geq m_c(W_R) + \xi \geq 0,$$

故 $m_c(W_H) + \xi \in \mathbb{R}_+^{C-1}$ 。于是事件包含

$$\{\tilde{Y}_R \in \mathbb{R}_+^{C-1}\} \subseteq \{\tilde{Y}_H \in \mathbb{R}_+^{C-1}\}$$

逐实现成立。取辅助空间上的概率并用第3步的同分布性：

$$P_c(W_H) \geq P_c(W_R) \quad \forall c.$$

第5步（按等概率类先验平均）。

$$A_H = \frac{1}{C} \sum_{c=1}^C P_c(W_H) \geq \frac{1}{C} \sum_{c=1}^C P_c(W_R) = A_R,$$

即 $\Delta \geq 0$ 。■

几何含义。 该充分条件的意思是：共享编码器可以提高每个类相对所有竞争类的标准化边际均值（条件 ii），但不改变同一真实类下不同竞争超平面之间标准化噪声的耦合方式（条件 i）。它允许信噪比整体增大，但要求「决策法向之间的夹角结构」保持一致。

条件是充分而非必要的。它不能由引理2自动推出（引理2只给出加权和下降）。没有该条件时，本文不从理论主张 $C > 2$ 的 $\Delta \geq 0$ ，而改由经验 Δ 支撑（正文2.5节；本材料S1.8）。该条件的可诊断性正是S1.8的内容。

S1.7 泄漏关于漂移的下界，以及 MMD 不充分的反例

本节把「漂移越大、泄漏越大」写成可证明的解析下界，并指出一个关键陷阱：原始输入空间的 MMD 不是本下界中充分的漂移度量。

S1.7.1 泄漏相关漂移（汇合目标缺口）

定义（泄漏相关漂移）。

$$D_{pool,\lambda}(src, T) := J_{\lambda}(W_H) - J_{\lambda}(W_R) = \max_{W \in W} J_{\lambda}(W) - J_{\lambda}(W_R) \geq 0.$$

它刻画的是：一旦把目标域放进表示训练，可分性目标相对源域最优编码器还能额外获得多少。

诚实标注. 尽管记号含 D , $D_{pool,\lambda}$ 不是外生的 domain-shift 距离，也不是只由原始边缘分布定义的距离；它是在给定 W, J, λ 并解出 W_H, W_R 之后由 J_{λ} 定义的后验目标量。下面的证明并不反过来用 Δ 定义它，故不循环；但解释实验时必须称其为「目标缺口」而非「漂移距离」。

S1.7.2 显式下界

命题 3 ($C=2$ 下由泄漏相关漂移控制的显式下界). 在 S1.1 的设定、假设 1-2、总体原型、 $C=2$ 下，另设 $s(\cdot; T)$ 在 W 上连续。由 W 紧致与非退化，目标域信噪比上确界

$$S_T^* := \sup_{W \in W} s(W; T)$$

有限且可达，且 $S_T^* > 0$ 。取任一已知有限上界 $S_T \geq S_T^*$ ($S_T > 0$)，记唯一一类对权重 $w := w_{12} > 0$ 。则

$$\Delta \geq \frac{\exp(-S_T^2/8)}{4\sqrt{2\pi} w S_T \lambda} D_{pool,\lambda}(src, T).$$

证明. 记

$$\Delta J_T := J(W_H; T) - J(W_R; T), \Delta J_{src} := J(W_H; src) - J(W_R; src).$$

第 1 步 (由目标缺口下界目标域可分性目标增益). 因 W_R 极大化 $J(\cdot; src)$ ，有 $\Delta J_{src} \leq 0$ 。按定义

$$D_{pool,\lambda} = J_{\lambda}(W_H) - J_{\lambda}(W_R) = (1-\lambda)\Delta J_{src} + \lambda\Delta J_T.$$

因 $1-\lambda \geq 0$ ($\lambda \in (0, 1]$) 且 $\Delta J_{src} \leq 0$ ，故 $(1-\lambda)\Delta J_{src} \leq 0$ ，于是

$$D_{pool,\lambda} \leq \lambda\Delta J_T \Rightarrow \Delta J_T \geq \frac{1}{\lambda} D_{pool,\lambda} \geq 0.$$

第 2 步 (把目标增益转为信噪比增益). $C=2$ 时 $J(W; T) = w s^2(W; T)$ 。记 $s_H := s(W_H; T)$, $s_R := s(W_R; T)$ 。由非退化， $s_H > 0, s_R > 0$ ，故 $s_H + s_R > 0$ 。于是

$$\Delta J_T = w(s_H^2 - s_R^2) = w(s_H - s_R)(s_H + s_R).$$

由 (S1.6) 有 $\Delta J_T \geq 0$ ，而 $w(s_H + s_R) > 0$ ，故

$$s_H - s_R \geq 0.$$

又 $0 \leq s_R, s_H \leq S_T$ ，故 $s_H + s_R \leq 2S_T$ ，从而

$$\Delta J_T = w(s_H - s_R)(s_H + s_R) \leq 2w S_T (s_H - s_R),$$

(此处用了 $s_H - s_R \geq 0$ ，故放大 $s_H + s_R$ 至 $2S_T$ 保持不等号方向)，即

$$s_H - s_R \geq \frac{\Delta J_T}{2w S_T}.$$

第 3 步 (把信噪比增益转为精度增益). 由 (S1.3), $A(W) = \Phi(s(W; T)/2)$ 。令 $g(s) := \Phi(s/2)$ ，则在 $[0, S_T]$ 上

$$g'(s) = 1/2 \phi(s/2), \phi(u) = 1/\sqrt{2\pi} \exp(-u^2/2).$$

因 ϕ 在 $u \geq 0$ 上单调不减，对一切 $s \in [0, S_T]$ 有

$$g'(s) \geq 1/2 \phi(S_T/2) = \frac{1}{2\sqrt{2\pi}} \exp(-S_T^2/8) > 0.$$

由微分中值定理 ($s_R, s_H \in [0, S_T]$, $s_H \geq s_R$)，存在 $\zeta \in [s_R, s_H] \subseteq [0, S_T]$ 使

$$\Delta = g(s_H) - g(s_R) = g'(\zeta)(s_H - s_R) \geq \frac{1}{2\sqrt{2\pi}} \exp(-S_T^2/8) (s_H - s_R).$$

代入 (S1.7):

$$\Delta \geq \frac{\exp(-S_T^2/8)}{2\sqrt{2\pi}} \cdot \frac{\Delta J_T}{2w S_T} = \frac{\exp(-S_T^2/8)}{4\sqrt{2\pi} w S_T} \Delta J_T,$$

再代入 (S1.6) 得

$$\Delta \geq \frac{\exp(-S_T^2/8)}{4\sqrt{2\pi}wS_T\lambda} D_{pool,\lambda}. \blacksquare$$

关于紧致性的必要性。第 3 步用的是 g 在紧区间 $[0, S_T]$ 上的正下导数。标准正态分布函数的全局 Lipschitz 常数 $1/\sqrt{2\pi}$ (对 g 而言是 $1/(2\sqrt{2\pi})$) 只能给出上界；要得到正的下界，必须有 $S_T < \infty$ ——这正是假设 1 中 W 紧致的后果。

下界的性质。令 $h_{pool}(d) := \frac{\exp(-S_T^2/8)}{4\sqrt{2\pi}wS_T\lambda} d$ ，则

$h_{pool}(0) = 0$ ：泄漏相关漂移为零时，下界归零（与推论 1 一致）；

h_{pool} 关于 d 单调不减：漂移越大，泄漏的下界越大；

由 $W_H \in \arg \max J_\lambda$ ，有

$$D_{pool,\lambda} > 0 \Leftrightarrow W_R \notin \arg \max_{W \in W} J_\lambda(W),$$

即当且仅当源域最优编码器不是混合目标的全局极大点时，下界严格为正， $\Delta > 0$ （与推论 2 (ii) 一致）。

推论 4（源域牺牲量形式； $\lambda \in (0, 1)$ ）。记源域最优牺牲量 $G_{src} := J(W_R; src) - J(W_H; src) \geq 0$ ，则

$$\Delta \geq \frac{\exp(-S_T^2/8)}{4\sqrt{2\pi}wS_T} \cdot \frac{1-\lambda}{\lambda} G_{src}.$$

证明。引理 2 给出 $\Delta J_T \geq \frac{1-\lambda}{\lambda} G_{src}$ ；命题 3 的第 2-3 步已给出 $\Delta \geq \frac{\exp(-S_T^2/8)}{4\sqrt{2\pi}wS_T} \Delta J_T$ 。两式合并即得。

■

解读。共享编码器若为迎合混合目标而偏离源域最优点、并因此付出正的源域目标牺牲 G_{src} ，则目标域上的泄漏至少按该牺牲量线性增长。局限： $\lambda = 1$ 时源域项在混合目标中消失，系数 $(1-\lambda)/\lambda = 0$ ，此时应改用命题 3 的 $D_{pool,\lambda}$ 形式。

S1.7.3 原始 MMD 不是充分的漂移度量：一个反例

必须强调：命题 3 的下界中，原始输入空间的 MMD 不能替代 $D_{pool,\lambda}$ 。

反例。取 $C=2$ 、一维输入 ($p=d=1$)、 $W=\{1\}$ （单点集，显然紧致）、 $\Sigma^{src} = \Sigma^T = 1$ 。源域类均值为

$$\mu_1^{src} = -1, \mu_2^{src} = +1,$$

目标域为全体类别的共同平移 $a \neq 0$ ：

$$\mu_1^T = -1+a, \mu_2^T = +1+a.$$

（非退化条件成立： $\|a_{12}(W)\|=2$ ，投影方差 $=1$ ，取 $\rho \leq 1$ 即可。）

(1) 泄漏为零。共同平移不改变类间差与协方差：

$$\mu_1^{src} - \mu_2^{src} = \mu_1^T - \mu_2^T = -2, \Sigma^{src} = \Sigma^T = 1.$$

故对一切 $W \in W$ ， $s(W; src) = s(W; T)$ ，从而 $J(\cdot; src) \equiv J(\cdot; T)$ ，进而 $J_\lambda \equiv J(\cdot; T)$ 。又 W 为单点集，必有

$$W_H = W_R = 1, \Rightarrow \Delta = 0.$$

(2) 线性核 MMD 严格为正。边缘分布整体平移， $E_{src} X = 1/2(-1+1) = 0$ ， $E_T X = 1/2((-1+a)+(1+a)) = a$ ，故线性核 MMD 平方为

$$M_{lin}(src, T) = \|E_{src} X - E_T X\|^2 = a^2 > 0.$$

(3) 结论。任何形如「 $m > 0 \Rightarrow h(m) > 0$ 且 $\Delta \geq h(M_{lin})$ 」的无条件线性核 MMD 定理都会在该例上失败（左端为 0，右端为正）。对 RBF 等平移敏感的特征核，同一共同平移例中仍有 $P_{src}^X \neq P_T^X$ 、 $M_k > 0$ ，而 Δ 仍为 0——故原始 MMD 不能作为普遍充分的漂移度量。

机制。共同平移改变了边缘分布（因而 MMD 为正），却完全没有改变类间间隔、噪声结构与最近原型判决（因而泄漏为零）。要把「 Δ 随 MMD 增大」写成解析下界，必须额外假设原始 MMD 下控制分类相关的目标缺口：即存在同一组常数 $\eta > 0, \tau \geq 0$ （可依赖核 k 、 λ 、 W 、 J 与所考察的漂移族 F ，但不得依赖单个 (src, T) ），使得对该族中每个 (src, T) 均有

$$D_{pool,\lambda}(src, T) \geq \eta[M_k(src, T) - \tau]_+,$$

此时由命题 3 立得 $\Delta \geq \frac{\exp(-S_T^2/8)\eta}{4\sqrt{2\pi}wS_T\lambda} [M_k(src, T) - \tau]_+$ 。这是一个族级校准假设，经验可检验但不自动成立。

安全的表述。 若该校准假设不成立，则「 Δ 与 MMD 正相关」只应作为经验规律报告，而不能作为无条件的数学定理。这与本文的实测结果一致：跨数据集混合效应回归中，MMD 的标准化斜率为 -0.009 (95%置信区间 $[-0.048, 0.030]$, $P=0.647$)，不显著——原始 MMD 并不线性预测泄漏的量级（见 S1.8 表 S1.6）。理论与实证在此互为印证：泄漏由「泄漏相关漂移」下界，而非由原始 MMD 下界。

S1.8 理论条件在真实数据上的诊断（有限 K 、神经编码器、多类）

S1.8.0 产出与追溯

诊断在 4 个多类公开数据集的 13 个留一域折上进行：玉米 NIR（跨仪器 m5spec / mp5spec / mp6spec, 3 折）、药片 NIR（跨仪器 instr1 / instr2, 2 折）、芒果 NIR（跨采收季 S1 - S4, 4 折）、Indian Pines 高光谱成像（跨空间象限 Q0 - Q3, 4 折）。每折均按两协议各训练一个编码器（共享 W_H ：在含留出域的全部域上元训练；折限定 W_R ：仅在源域上元训练），随后在留出域的嵌入中估计各类对可分性 $\hat{s}_{cc}$ 。

S1.8.1 命题 2 条件 (ii)：坐标支配

坐标支配比例定义为满足 $\hat{s}_{cc}(W_H; T) \geq \hat{s}_{cc}(W_R; T)$ 的类对占全部类对之比（3 类 $\rightarrow$ 3 对；5 类 $\rightarrow$ 10 对；6 类 $\rightarrow$ 15 对）。

表 S1.1 命题 2 条件在 13 个多类折上的诊断

数据集	留出域	类数	坐标支配比例（条件 ii）	相关结构相对变化（条件 i）
玉米 corn	m5spec	3	1.000	0.001
玉米 corn	mp5spec	3	0.667	0.003
玉米 corn	mp6spec	3	1.000	0.003
药片 tablet	instr1	3	0.667	0.133
药片 tablet	instr2	3	1.000	0.003
芒果 mango	S1	3	0.667	0.001
芒果 mango	S2	3	1.000	0.001
芒果 mango	S3	3	1.000	0.029
芒果 mango	S4	3	1.000	0.938
Indian Pines	Q0	6	0.933	0.508
Indian Pines	Q1	6	0.867	0.384
Indian Pines	Q2	5	1.000	0.430
Indian Pines	Q3	5	0.400	0.324
均值			0.862	0.212

结论。 条件 (ii) 在 13 折上的平均成立比例为 **0.862**——远高于随机基线 0.5。坐标支配比例最低的折是 Indian Pines Q3 (**0.400**)，该折是漂移最强的空间象限之一（其原始 $MMD^2 = 5.06$ ，为 Indian Pines 四折中最大）。

S1.8.2 命题 2 条件 (i)：相关结构不变

相关结构相对变化定义为各类的标准化边际相关矩阵在两协议间的相对 Frobenius 差

$$\frac{\|\hat{R}_c(W_H) - \hat{R}_c(W_R)\|_F}{\|\hat{R}_c(W_R)\|_F}$$

再对类取均值；条件 (i) 要求该量接近 0。

诚实报告。 该量的分布不是「点光谱数据集一律很小、高光谱成像较大」这样干净的两分：

玉米（3 折）：0.001 / 0.003 / 0.003 —— 极小；

药片（2 折）：0.133 / 0.003；

芒果（4 折）：0.001 / 0.001 / 0.029 —— 极小，但 S4 折高达 0.938，是全部 13 折中最大的一个；

Indian Pines（4 折）：0.324 / 0.384 / 0.430 / 0.508 —— 一致地中等偏大。

因此可以断言的是：Indian Pines（高光谱成像）四折的相关结构变化一致地大于绝大多数点光谱折，与该模态更强的几何重排相符；但芒果 S4 折是一个显著的例外（0.938），说明条件 (i) 在个别点光谱折上也会明显失效。13 折总均值为 0.212。

S1.8.3 条件强度与实际泄漏的正式检验

把坐标支配比例作为命题 2 条件强度的连续代理，检验其与**实际泄漏** Δ 的逐折关系。此处的 Δ 由**真实目标域** 嵌入上重采样有限 K 原型 ($K=5$) 得到。

表 S1.2 逐折条件强度与真实嵌入泄漏

数据集	留出域	坐标支配比例	Δ ($K=5$, 真实嵌入)
玉米 corn	m5spec	0.667	+0.006
玉米 corn	mp5spec	1.000	+0.057
玉米 corn	mp6spec	0.333	+0.053
药片 tablet	instr1	0.667	+0.041
药片 tablet	instr2	0.667	+0.059
芒果 mango	S1	1.000	+0.046
芒果 mango	S2	1.000	+0.090
芒果 mango	S3	1.000	+0.056
芒果 mango	S4	1.000	+0.085
Indian Pines	Q0	0.933	+0.171
Indian Pines	Q1	1.000	+0.145
Indian Pines	Q2	0.900	+0.182
Indian Pines	Q3	0.400	+0.028

表 S1.3 正式统计检验

统计量	数值
支配比例 - Δ 的 Spearman ρ	+0.439
置换检验 P (1 000 次)	0.121 (未达显著)
支配比例均值	0.813
支配比例 bootstrap 95%置信区间 (2 000 次重采样)	[0.682, 0.931]
负 Δ 折 vs 正 Δ 折的 Mann - Whitney P	不适用 (无负折)

结论与诚实说明。

条件 (ii) 得到正式的区间证据：支配比例的 95%置信区间下界 0.682 远高于随机基线 0.5。

方向一致但未达显著：支配比例与实际泄漏正相关 ($\rho=+0.44$)，方向与理论预测一致，但置换检验 $P=0.121$ 未达显著。我们如实归因于两点：①折数太少 ($n=13$)，统计功效根本不足；②在真实嵌入下 **13 折的 Δ 全为正** (最小为玉米 m5spec 的 +0.006，其次为 Indian Pines Q3 的 +0.028)，「条件失效折」的对照几乎不存在，Mann - Whitney 检验因无负折而无法计算。

理论条件最弱的折确实是泄漏最弱的折之一：坐标支配比例最低的 Indian Pines Q3 (0.400)，其真实嵌入泄漏 +0.028 是 13 折中**第二小的**——理论条件失效之处，泄漏也随之趋近于零，二者机制吻合。

与正文 1.3 节的一致性。正文 1.3 节表述为「坐标支配比例最低的折同时也是**泄漏最弱的折之一**」，与上述第 3 条一致。须如实补充：全部 17 折中折级泄漏最小者为**玉米 mp5spec** ($\Delta=-0.002$ ，其坐标支配比例 0.667 并非最低)，而 Indian Pines Q3 的泄漏为正 (③ 5 种子折均值 +0.073、真实嵌入 ② +0.028)。故本文**不主张**「支配最低折即唯一负折」，仅主张「理论条件最弱之处泄漏亦最弱」，二者机制吻合。

S1.8.4 有限 K ：线性-高斯仿真

在线性-高斯最近原型模型中，用**有限 K 样本原型** (而非总体原型) 经验估计 $E[\Delta]$ (20 维输入、3 类、每 K 重复 200 次)。

表 S1.4 有限 K 线性-高斯仿真

K	$E[\Delta]$	$sd(\Delta)$	$Pr[\Delta \geq 0]$
1	+0.0198	0.045	0.810
3	+0.0097	0.022	0.870
5	+0.0065	0.015	0.930
10	+0.0070	0.012	0.925
20	+0.0062	0.012	0.910

结论。 $K \in \{1, 3, 5, 10, 20\}$ 全程 $E[\Delta]>0$ (自 +0.020 至 +0.006)，单个情节 $\Delta \geq 0$ 的概率为 0.81 - 0.93。非负泄漏在超出总体原型极限的有限 K 区间依然稳健成立 (注意 $E[\Delta]$ 关于 K 并非单调： $K=10$ 略高于 $K=5$ ；理论上也未断言 K 单调性，见注记 1 与 S1.9 第 4 条)。

S1.8.5 有限 K + 神经编码器：真实嵌入

进一步把有限 K 论证从解析仿真提升到**真实神经嵌入**：在共享编码器 W_H 与折限定编码器 W_R 的**真实输出嵌入**上重采样有限 K 原型，逐 K 计算 $\Delta(K)$ = 共享宏 F1 - 折限定宏 F1。

表 S1.5 真实神经嵌入上的有限 K 泄漏

K	$E[\Delta]$ (真实嵌入)	逐折为正比例
1	+0.079	0.923
3	+0.079	1.000
5	+0.078	1.000
10	+0.073	0.923
20	+0.062	0.692

结论. 真实神经嵌入上, $K \in \{1, 3, 5, 10, 20\}$ 全程 $E[\Delta] > 0$, 逐折为正比例 0.69 - 1.00。且**真实嵌入**的泄漏量级显著大于**线性-高斯仿真** (0.062 - 0.079 对 0.006 - 0.020) ——这表明**理想化模型**是一个保守的下界, **真实表示**的几何结构进一步放大了泄漏。

S1.8.6 可证伪核心的跨数据集检验

理论给出的可证伪核心是 $\Delta \geq 0$, 以及泄漏由「**泄漏相关漂移**」而非原始 **MMD** 下界。本文以 **5 个具有真实域划分的数据集** (苹果、玉米、药片、芒果、Indian Pines, 共 16 折) 为主口径检验之; 橄榄油因采用 UCR 官方 IID 序号划分、不含域漂移 (共享臂记忆化使宏 F1 恒为 1.000, 见正文 2.5 节), 属**记忆化上限**而非域漂移, 故不计入主口径证据链, 仅作稳健性对照 (并入后为 6 数据集、17 折):

表 S1.6 跨数据集泄漏与 MMD 回归

项目	主口径: 5 真实域数据集 (16 折)	稳健性: 并入橄榄油 (6 数据集、17 折)
总体泄漏 (以数据集为随机效应, $\Delta \sim 1 + (1/\text{数据集})$)	0.124 (95% CI [0.055, 0.194], $P = 4.4 \times 10^{-4}$)	0.132 (95% CI [0.071, 0.192], $P = 2.1 \times 10^{-5}$)
cluster-bootstrap 截距	0.124 (95% CI [0.068, 0.194])	0.134 (95% CI [0.084, 0.190])
折级符号检验	15/16 折为正 ($P = 2.6 \times 10^{-4}$)	16/17 折为正 ($P = 1.4 \times 10^{-4}$)
数据集级符号检验	5/5 数据集全为正 ($P = 0.031$)	6/6 数据集全为正 ($P = 0.016$)
MMD 标准化斜率 (MMD 仅在 4 个外部集逐折可得, 两口径同值)	-0.009 (95% CI [-0.048, 0.030], $P = 0.647$, 不显著)	同左
各数据集泄漏	苹果 0.242、Indian Pines 0.167、芒果 0.083、药片 0.078、玉米 0.050	另: 橄榄油 0.178 (IID 记忆化上限, 不入主口径)

结论. ①方向性预测 $\Delta \geq 0$ 在 5 个真实域数据集上**全部**得到验证 (并入橄榄油记忆化上限后 6/6 仍成立), 主口径总体泄漏 0.124; ②**原始 MMD 的斜率不显著** ($P = 0.647$), 与 S1.7.3 的反例**完全一致**——原始 MMD 本就不是理论中充分的漂移度量, 其不能线性预测泄漏量级这一实测结果, 恰恰印证 (而非削弱) 了理论的边界刻画。

表 S1.7 数据卡: 本文所用全部数据集的模式、波段、规模、任务与来源

数据集	模式/波段	规模/队列 (漂移轴, 折数)	任务 (类别)	来源
苹果 (本文九域)	可见-近红外点谱/229 波段 (591 - 1001 nm)	4 529 谱、1 950 果, 3 年×4 产地 (复合漂移, 3 折)	地理产地判别 (4 类)	本文自建
玉米 Corn	近红外点谱/700 波段	80 样×3 仪器 m5/mp5/mp6 (3 折)	蛋白含量 (源域三分位, 3 类)	Cargill
药片 Tablet	近红外点谱/650 波段	2 仪器, 各含标定/测试/验证子集 (2 折)	活性成分 (源域三分位, 3 类)	2002 IDRC 「Shootout」
芒果 Mango	近红外点谱/306 波段	4 采收季 (评估每季采样至 ≤500 谱, 原始 11 691 谱, 4 折)	干物质 (源域三分位, 3 类)	Anderson 2020[45]
Indian Pines	AVIRIS 高光谱成像/200 波段	145×145 像元, 2×2 空间象限 (4 折)	地物分类 (象限内 5~6 类)	EHU/Purdue
橄榄油 OliveOil (对照)	FT-IR 谱/570 波段	60 样、4 国别, UCR 官方 IID 序号划分、无域漂移 (1 折)	产地判别 (4 类)	UCR 档案

注: 前 5 个数据集 (苹果、玉米、药片、芒果、Indian Pines) 均为真实域划分、构成主口径证据链 (共 16 折); 橄榄油采用 UCR 官方 IID 序号划分、不含域漂移, 仅作记忆化上限对照、不计入主口径。各数据集折级泄漏 Δ 见表 S1.6。数据来源与许可: 苹果为新疆农业大学内部采集、暂未公开 (managed access), 可向通讯作者 (huanghua@xjau.edu.cn) 按个案申请; 玉米与药片见 Eigenvector Research 公开数据库 (<https://eigenvector.com/resources/datasets/>); 橄榄油见 UCR 时序分类档案 (<https://www.timeseriesclassification.com/description.php?Dataset=OliveOil>); 芒果见 Mendeley Data

(<https://data.mendeley.com/datasets/46htwnp833>)；Indian Pines 见 EHU/Purdue 高光谱场景库 (https://www.ehu.es/ccwintco/index.php/Hyperspectral_Remote_Sensing_Scenes)；各数据集按其原始许可使用。全部数据集原始/预处理文件的 SHA-256 (前 16 位)：苹果 f5c0aff9b18c3eb、橄榄油 472c5b73157b2e0f、玉米 e28fd4be274a54ca、药片 129a32ec9e194e56、芒果 86159e2df9244fa5、Indian Pines 立方体 ec2f8808710919d5、标注 65c4687a8ab04f6d；复现指南与完整数据卡见公开仓库 <https://github.com/2004lryan/016representation-layer-eval-leakage> (MIT 许可)。

S1.9 适用边界的诚实声明

本命题不是本文结论的替代品，而是其方向性预测的来源。必须明确以下边界：

模型是理想化的。命题 1 成立于线性编码器、同协方差高斯、总体原型 ($K \rightarrow \infty$)、二类、紧非退化可行集、全局极大点这一整套假设之下。本文实际使用的是神经编码器（非线性）、有限 K ($K=1 \sim 50$)、多类 (3-way)，并以 SGD 求得局部极小。该命题并不自动覆盖本文的实际设置。

多类需要额外的充分条件。 $C>2$ 时， $\Delta \geq 0$ 不能由引理 2 单独推出 (S1.3 与 S1.6 已给出反例与机制)。命题 2 需要「同类噪声相关结构不变 (条件 i) + 成对可分性坐标支配 (条件 ii)」这一显式充分条件，该条件充分而非必要。S1.8 的诊断表明：条件 (ii) 平均成立比例 0.862 (95% CI 下界 0.682，远高于 0.5)，但条件 (i) 在个别折 (芒果 S4、Indian Pines 各折) 上明显失效。因此本文不从理论主张多类无条件非负，多类的非负性由经验证据支撑。

可分性目标与 ProtoNet 损失的对应是建模设定。假设 2 中「 $J(\cdot; T)$ 是本高斯模型下 ProtoNet 度量损失所极大化的总体对应量」是一个建模层面的对应假设，本材料并未从 ProtoNet 的交叉熵型损失出发严格导出 J 。真实的元训练目标与 J 的差距，是理论与实验之间的一处已知裂缝。

不对 K 依赖作闭式断言。有限 K 时样本原型有噪、判决法向随机 (注记 1)，它同时压低 A_R 与 A_H ，其净效应依赖具体区间。本材料不断言 Δ 关于 K 的任何闭式单调性；S1.8.4 的仿真结果本身即非单调。 K 依赖完全由经验刻画。

「一般为正」不是 generic 意义上的定理。推论 2 (ii) 是条件式断言 (「若 $W_R \notin \arg \max J_\lambda$ ，则 $\Delta > 0$ 」)。本材料未证明该条件在参数空间中以概率 1 成立，故不作测度论意义上的 genericity 主张。

下界中的「漂移」不是外生分布距离。命题 3 的 $D_{pool,\lambda}$ 是由 W_H, W_R, J_λ 定义的后验目标缺口，不是外生的 domain-shift 距离。原始 MMD 不是充分的漂移度量 (S1.7.3 反例)；「 Δ 随 MMD 增大」只在族级校准假设下才是定理，否则只能作为经验规律报告。本文的实测 (MMD 斜率 $P=0.647$ 不显著) 正落在「不能作为定理」的一侧故本文不作此主张。

命题的作用是提供可证伪预测。综上，本文不以理论替代实证。理论的价值在于给出一个可证伪的方向性预测 $\Delta \geq 0$ ，以及一条机制性解释 (泄漏是分布漂移的产物，其充分的修复方向是让表示学习的训练集与评估留出域不相交)。该预测在本文 5 个真实域划分数据集、16 折上得到检验 (正文 2.2、2.5 节；本材料 S1.8.6)：15/16 折为正、5/5 数据集为正、总体泄漏 0.124 (95% CI [0.055, 0.194])；并入橄榄油记忆化上限后 6/6 数据集仍为正。若未来出现系统性的 $\Delta < 0$ 证据，本理论即被证伪——这正是我们把它写成命题而非比喻的原因。

补充材料 S2 各项实验的评估口径清单

(对应正文 1.5 节)

结果 Result	编码器 Encoder	面位口径 Facet regime	重采样次数 Resamples
表 2 泄漏对照 (两种融合口径)	共享对比折限定	多面位均值	10~50
表 3、图 3 五方法对比	折限定	单面位 (统一)	50
图 S1 融合权重 α 扫描	折限定	多面位均值	50
2.4 节 面均值消融	折限定	2x2 交叉设计	50

注：所有实验的查询集均为该折中支持集之外的全部果实，且与支持集在果实个体层面严格不相交。“多面位均值”指对同一果全部面位嵌入取均值后再 ℓ_2 归一化；“单面位”指每果随机取 1 个面位。同一行内的两臂或各方法口径完全一致；跨行的绝对数值不可直接比较。泄漏对照两臂的重采样次数不同 (共享臂 10 或 50 次、折限定臂 15 次)，故泄漏为两个独立期望估计之差；由求和的线性性，其点估计与严格配对差恒等 (见 1.5 节)。Note: The query set is always all fruits of the fold outside the support set, strictly disjoint from it at the fruit level. Within a row the two arms, or the several methods, share an identical regime; absolute values must not be compared across rows.

补充材料 S3 源质心融合权重 α 的敏感性分析

(对应正文 2.4 节；该变体为阴性结果，故置于补充材料)




图 S1 源质心融合权重 α 对三折 LOEO 宏 F1 的影响： $\alpha \times$ 折的热力图 (a) 与融合的代价 (b) (K=5) Fig. S1 Effect of the source-centroid fusion weight α on LOEO macro-F1: heat map over $\alpha \times$ fold (a) and the cost of fusion (b) (K=5)

注：K=5，5 个固定种子。 $\alpha=0$ 时退化为原始原型网络， $\alpha=1$ 时退化为完全锚定源质心的最近质心分类器。(a) 中★为各折的最优 α ，红色虚线为 ProtoNet-C 所用的 $\alpha=0.4$ ；三折的最优 α 均落在 0~0.2，且 LOEO-2025 折随 α 增大急剧劣化。(b) 量化 $\alpha=0.4$ 相对不融合 ($\alpha=0$) 的代价：2018 折几乎无差异，2019 折损失 0.101，协议与类别空间双重失配的 2025 折损失达 0.251。Note: K=5, five fixed seeds. $\alpha=0$ reduces to the plain prototypical network and $\alpha=1$ reduces to a nearest-centroid classifier fully anchored on the source centroids. In (a) the stars mark the optimal α of each fold and the red dashed line marks $\alpha=0.4$ as used by ProtoNet-C; the optimal α of all three folds falls between 0 and 0.2, and the LOEO-2025 fold degrades sharply as α grows. Panel (b) quantifies the cost of $\alpha=0.4$ relative to no fusion ($\alpha=0$): almost no change on the 2018 fold, a loss of 0.101 on the 2019 fold, and a loss of 0.251 on the 2025 fold, which suffers both a protocol and a label-space mismatch.