

苹果可溶性固形物含量的函数型回归建模与小样本超参数选择

李盼林¹, 杨双泽¹, 李宇畅¹, 黄 华^{1,2}

(1. 新疆农业大学 数理学院, 新疆 乌鲁木齐 830052; 2. 新疆农业大学 数值模拟与数据分析研究中心, 新疆 乌鲁木齐 830052)

摘 要: 可溶性固形物含量 (SSC) 是反映苹果品质的重要指标, 其光谱预测模型的标定依赖破坏性测定, 训练集样本量往往受限。以新疆阿克苏、山东烟台、陕西洛川三个产地两个年份共 1 300 个红富士苹果为试材, 采集其 590~1 250 nm 的近红外透射光谱并测定 SSC, 从函数型数据分析视角将光谱离散数据转化为函数型数据, 建立惩罚函数型线性回归 (PFLR) 模型与函数型主成分回归 (FPCR) 模型, 并以偏最小二乘回归 (PLSR)、支持向量回归 (SVR)、随机森林 (RF) 和一维卷积神经网络 (1D-CNN) 模型为对照, 在同一预处理、同一批嵌套交叉验证折 (外层 5 折、内层 5 折) 与相同候选数的统一协议下比较各模型的性能, 进而考察训练集样本量与超参数选择策略对各模型的影响。结果表明, PFLR 模型仅用 80 个基函数即优于使用全部 2 048 个波段的 PLSR 模型 (R^2 分别为 0.796 与 0.763, 5 个外层折中 4 折占优), 维度压缩未损失精度; 但 SVR 模型在全样本 ($R^2=0.811$) 及所考察的全部训练集样本量上均不低于两种函数型模型, 函数型方法的精度优势仅相对 PLSR 模型成立; 该排序在嵌套交叉验证与随机、SPXY、Kennard-Stone 三类共五种样本划分方式下、以及按 LLH-GBID 综合指数得分衡量时均未改变, 但贝叶斯相关 t 检验显示 SVR 与 PFLR 模型有 0.794 的概率落在实际等价区间内, 二者难分高下。随模型类别真正分化的是超参数选择: 训练集样本量为 80 时, 由固定超参数改为交叉验证选择使 FPCR 模型的 R^2 由 0.443 降至 0.094 (落差 0.349), 而 SVR 模型的同一落差仅为 0.018; 候选配置间的精度极差反而是 SVR 模型更大, 说明差别在于交叉验证能否在小样本下为函数型模型选中好的配置。回归系数函数的极值集中于 868~957 nm, 跨越 900 nm 这一常规划分界线。故, 函数型建模可在小样本下有效替代 PLSR 模型且在训练集样本量为 30~80 时宜固定保守的超参数而不依赖交叉验证选择。

关键词: 函数型数据分析; 近红外光谱; 可溶性固形物含量; 小样本; 超参数选择

中图分类号: S661.1; O212.7 **文献标志码:** A

Functional regression modelling of soluble solids content in apple and hyperparameter selection with small calibration sets

LI Pan-lin¹, YANG Shuang-ze¹, LI Yu-chang¹, HUANG Hua^{1,2}

(1. College of Mathematics and Physics, Xinjiang Agricultural University, Urumqi Xinjiang 830052, China; 2. Research Center of Numerical Simulation and Data Analysis, Xinjiang Agricultural University, Urumqi Xinjiang 830052, China)

¹收稿日期:

基金项目: 新疆维吾尔自治区自然科学基金面上项目 (项目编号待公示后补); 2026 年新疆农业大学大学生创新项目 (S202610758116、DXSCX2026349、DXSCX2026350)。

作者简介: 李盼林 (2004—), 男, 研究方向为函数型数据分析与光谱建模, E-mail: panlinryan@gmail.com。

通讯作者简介: 黄华 (1981—), 男, 教授, 研究方向为高维数据分析与机器学习, E-mail: huanghua@xjau.edu.cn。

Abstract: Soluble solids content (SSC) is an important indicator of apple quality. Calibration of its spectral prediction model relies on destructive reference measurement, so the training set size is often limited. Taking 1 300 Fuji apples from three producing areas (Aksu of Xinjiang, Yantai of Shandong and Luochuan of Shaanxi) over two years as samples, near-infrared transmittance spectra in 590-1 250 nm were collected and SSC was measured. From the perspective of functional data analysis, the discrete spectra were converted into functional data, and penalized functional linear regression (PFLR) and functional principal component regression (FPCR) models were established, with partial least squares regression (PLSR), support vector regression (SVR), random forest (RF) and one-dimensional convolutional neural network (1D-CNN) models as references. All models were compared under a unified protocol with identical preprocessing, the same nested cross-validation folds (5 outer, 5 inner) and the same number of candidate configurations, and the effects of training set size and hyperparameter selection strategy were then examined. The results show that the PFLR model with only 80 basis functions outperformed the PLSR model using all 2 048 wavelengths (R^2 of 0.796 versus 0.763, winning in 4 of 5 outer folds), so the dimension reduction cost no accuracy; however, the SVR model was no worse than either functional model on the full sample ($R^2=0.811$) and at every training set size examined, and the accuracy advantage of the functional models holds only against PLSR; this ranking was unchanged under five sample partitioning schemes (nested cross-validation, random, SPXY and Kennard-Stone) and under the LLH-GBID composite index score, although a Bayesian correlated t-test put the probability that SVR and PFLR fall within the region of practical equivalence at 0.794. What actually differed between model classes was hyperparameter selection: at a training set size of 80, replacing a fixed hyperparameter by cross-validated selection reduced the R^2 of the FPCR model from 0.443 to 0.094 (a drop of 0.349), whereas the corresponding drop for the SVR model was only 0.018; since the spread across candidate configurations was actually larger for SVR, the difference lies in whether cross-validation can identify a good configuration for the functional models under small samples. The extrema of the regression coefficient function concentrated in 868-957 nm, crossing the conventional 900 nm division. Therefore, functional modelling can replace PLSR effectively under small samples, and with 30-80 training samples a fixed conservative hyperparameter should be preferred to cross-validated selection.

Key words: functional data analysis; near-infrared spectroscopy; soluble solids content; small sample; hyperparameter selection

0 引言

可溶性固形物含量 (soluble solids content, SSC) 是反映苹果品质和成熟度的主要指标之一, 直接决定果实的商品等级与市场价值。传统测定方法依赖折光仪对果肉汁液进行破坏性测量, 样品一经检测即失去商品价值。可见/近红外光谱技术利用含氢官能团的倍频与合频吸收对被测物质进行定量分析, 具有快速、无损、可在线部署等优点, 已成为果蔬内部品质检测的主流手段[1-3], 在苹果、猕猴桃、青枣等果品的 SSC 检测中均有应用[4-7], 新疆本地亦已开展基于近红外透射光谱的红富士苹果品质研究[8]。研究一种在标定样本有限的条件下仍然稳健的 SSC 光谱预测方法, 对苹果的采后分级和商品化具有重要意义。

在光谱定量建模中, 偏最小二乘回归 (partial least squares regression, PLSR) 模型通过提取潜变量克服波段间的强共线性, 长期占据主导地位[9]; 近年来, 卷积神经网络等深度学习方法也被引入光谱回归任务[10,11]。然而, 上述方法都把光谱视为离散的高维向量, 忽略了相邻波段之间固有的连续性与光滑性, 而这恰是光谱数据区别于一般高维数据的本

质特征。

函数型数据分析 (functional data analysis, FDA) 为此提供了自然的数学语言[12]。该方法将每条光谱视为定义在波长区间上的连续函数, 通过基函数展开实现从离散采样到连续函数的转换, 从而在建模中显式利用光谱的连续性。FDA 已被用于高光谱图像分类[13,14]、血迹光谱判别[15]与作物产量反演[16]。文献[17]以新疆阿克苏冰糖心红富士苹果为研究对象, 分别以光谱曲线及其一阶、二阶导数为函数型解释变量建立函数型线性回归模型, 验证了该类模型用于苹果 SSC 预测的有效性。

从已有的研究可以发现, 方法之间的比较大多在样本充足的条件下进行, 对训练集样本量受限这一实际约束关注较少。该约束在苹果 SSC 检测中尤为突出: 每增加一个标定样本即意味着破坏一枚果实并完成一次折光仪测定, 更换产地或年份时标定往往需要重做。函数型方法通过基函数展开与粗糙惩罚引入光滑性先验, 理论上应在小样本下更为稳健, 但基函数个数、平滑参数等超参数本身也需估计, 小样本下这些超参数能否被可靠选出, 尚鲜有研究报道。

基于此, 以新疆阿克苏、山东烟台、陕西洛川三个产地两个年份的红富士苹果为研究对象, 采集其近红外透射光谱并测定 SSC, 构建惩罚函数型线性回归模型与函数型主成分回归模型, 以 PLSR、支持向量回归 (support vector regression, SVR)、随机森林 (random forest, RF) 与一维卷积神经网络 (1D-CNN) 模型为对照。方法之间的横向比较只有在预处理、数据划分、选参方式与候选配置数都相同的条件下才有意义, 因此全样本比较在统一协议下进行: 六个方法共用同一批随机划分, 各自在训练集内以同一方式从 12 组候选中选参。在此基础上考察基函数族与基函数个数的选择、训练集样本量与超参数选择策略对方法优劣的影响, 并通过回归系数函数分析有效波段, 以期为标定样本受限条件下的建模方法选择提供依据。

1 函数型数据分析建模方法

1.1 光谱的函数型表征

设第 i 个样品在波长 λ 处的光谱值为 $x_i(\lambda)$, $\lambda \in [\lambda_{\min}, \lambda_{\max}]$ 。函数型数据分析假定 $x_i(\lambda)$ 是关于波长的连续光滑函数, 将其在一组基函数 $\{\phi_k(\lambda)\}$ 上展开为

$$x_i(\lambda) = \sum_{k=1}^L c_{ik} \phi_k(\lambda) \quad (1)$$

式中: L 为基函数个数; c_{ik} 为展开系数。为兼顾拟合精度与曲线光滑性, 展开系数由带粗糙惩罚的最小二乘估计

$$\hat{c}_i = \operatorname{argmin}_c \left\{ \|x_i - \Phi c\|^2 + \lambda_s c' R c \right\} \quad (2)$$

式中: Φ 为基函数在各采样波长处取值构成的矩阵; R 为二阶导数的内积矩阵, $R_{jk} = \int \phi_j''(\lambda) \phi_k''(\lambda) d\lambda$; λ_s 为平滑参数。若不加该惩罚, L 较大时展开系数会转而拟合采样噪声, 使重建曲线出现虚假的高频振荡, 其二阶导数尤为敏感。本研究并列比较三次 B 样条基与傅里叶基两种基函数族: 前者为局部支撑基, 对吸收峰这类局部特征的刻画更灵活; 后者为全局周期基, 对整体平缓趋势的表达更紧凑。近红外光谱两类形态兼有, 事前难以断定何者更合适, 故一并考察 (见 3.2 节)。基函数个数 L 取 20、40、60、80, 上限取 80 是因为此时维度已由 2 048 个波长点压缩到约 1/25, 再增大将失去降维的意义。

1.2 惩罚函数型线性回归

函数型线性回归假定响应变量与函数型自变量之间满足

$$y_i = \alpha + \int \beta(\lambda) x_i(\lambda) d\lambda + \varepsilon_i \quad (3)$$

式中： $\beta(\lambda)$ 为待估的回归系数函数。将 $\beta(\lambda)$ 在同一组基函数上展开为 $\beta(\lambda) = \sum_k b_k \varphi_k(\lambda)$ ，则积分项可写作 $c_i' J b$ ，其中 J 为基函数的 Gram 矩阵， $J_{jk} = \int \varphi_j(\lambda) \varphi_k(\lambda) d\lambda$ 。记设计矩阵 $Z = C J$ ，系数向量由带粗糙惩罚的广义最小二乘估计

$$\hat{b} = (Z' Z + \lambda_\beta s R)^{-1} Z' (y - \bar{y}) \quad (4)$$

式中： λ_β 为平滑参数； $s = \text{tr}(Z Z') / \text{tr}(R)$ 为尺度因子。引入尺度因子的原因在于 J 与 R 的数值量级相差悬殊：波长归一化后，本研究所用傅里叶基的 $\text{tr}(R)$ 比 $\text{tr}(J)$ 高 7~8 个数量级（ $L=40$ 时为 4.9×10^7 倍， $L=80$ 时为 7.8×10^8 倍），若以绝对值设定惩罚强度，惩罚项将压制数据项而使系数函数退化为零。 λ_β 的候选网格因试验而异：3.2 节为 $10^{-10} \sim 10^2$ 的 13 点对数网格，3.3 节与 3.4 节的网格分别在 3.3 节正文与表 4 注中给出。

1.3 函数型主成分回归

对展开系数矩阵 C 在函数内积意义下作主成分分解，即以 Gram 矩阵 J 的 Cholesky 因子对 C 作变换后进行奇异值分解，取前 K 个函数型主成分得分作为自变量建立多元线性回归， K 为需要选择的超参数。函数型主成分得分作为低维表征的有效性已有理论支撑：在分类任务中，当各阶主成分的均值差异显著时，误分类率随样本量增加趋于零[18]；本研究将其得分用作回归的自变量。并列考察 PFLR 与 FPCR 两个函数型模型，是因为二者代表函数型回归的两条路线：前者直接估计整条回归系数函数、以粗糙惩罚控制复杂度，其超参数 λ_β 是连续的；后者先作无监督降维再回归，其超参数 K 是离散的成分个数。两类超参数的估计难度不同，小样本下是否同样难以选准，正是本研究要回答的问题之一。

2 试验部分

2.1 试验材料与光谱采集

试验样品为红富士苹果，采自新疆阿克苏、山东烟台与陕西洛川三个产地，分两个年份采集，两个年份采用相同的采集方案[8,19]。样品于室温 20°C 下静置 24 h 后采集光谱。

光谱采集设备选用美国海洋光学公司 USB2000+ 型光纤光谱仪，光源为 JCR12V 100 W 卤钨灯，采用近红外透射方式采集：将苹果置于果托上，苹果与果托之间不留光缝；光谱采集参数为积分时间 120 ms、平均次数 3、平滑度 5。所得光谱覆盖 590.7~1 249.6 nm，共 2 048 个波长点。样品的 SSC 选用日本 ATAGO 公司 PR-101 型数字折光仪（精度 $\pm 0.1^\circ\text{Brix}$ ）在光谱采集后立即作破坏性测定，单位为 $^\circ\text{Brix}$ 。

(5, 25) $^\circ\text{Brix}$ 覆盖成熟期红富士的常规糖度范围，超出者判为测定或记录异常。剔除该范围以外的个别记录后，两个年份分别保留 629 个与 671 个样品，合计 1 300 个，其中新疆 470 个、山东 416 个、陕西 414 个。

三个产地样品的 SSC 存在实质差异：第 1 年新疆、山东、陕西的 SSC 均值 $\pm$ 标准差分别为 (13.44 $\pm$ 1.29)、(11.84 $\pm$ 1.30)、(13.41 $\pm$ 1.23) $^\circ\text{Brix}$ ，第 2 年分别为 (15.46 $\pm$ 1.27)、(13.30 $\pm$ 1.11)、(12.73 $\pm$ 1.15) $^\circ\text{Brix}$ ，全部样品为 (13.42 $\pm$ 1.66) $^\circ\text{Brix}$ 。新疆样品的 SSC 在两个年份均处于较高水平：合并两个年份后，新疆、山东、陕西的 SSC 均值分别为 14.48、12.60、13.06 $^\circ\text{Brix}$ ，1%~99% 分位区间分别为 [11.2, 18.1]、[9.1, 16.0]、[10.2, 16.0] $^\circ\text{Brix}$ ，

三者并不重合。这一差异构成 3.6 节跨产地迁移的直接背景。

2.2 光谱预处理

为抑制果实个体间光程差异与组织散射引起的基线漂移，比较 5 种预处理方案：不做处理、标准正态变量变换（standard normal variate, SNV）、多元散射校正（multiplicative scatter correction, MSC）、Savitzky-Golay 一阶导数（窗宽 15、二次多项式，记为 SG-1D）以及 SNV 与 SG-1D 的串联。如图 1 所示，为三个产地样品的平均光谱及其一阶导数光谱。从图形可以看出，原始光谱在 590~800 nm 存在明显的产地间基线差异；经 SNV 与一阶导数处理后，基线漂移被有效抑制，850~1 000 nm 区间的形态差异得以凸显 [图 1(b) 内嵌图]。




图 1 三个产地苹果的平均近红外透射光谱：(a) 原始光谱（阴影为 ± 1 标准差）；(b) SNV+SG 一阶导数光谱（内嵌图为 850~1 000 nm 局部放大）

Fig.1 Mean near-infrared transmittance spectra of apples from the three producing areas: (a) raw spectra (shaded area denotes ± 1 standard deviation); (b) SNV+SG first-derivative spectra (inset: enlarged view of 850-1 000 nm)

2.3 对照模型与评价指标

离散建模对照按建模机理选取四类互不重叠的代表，以便把精度差异归因到机理而非个别实现：PLSR 代表线性潜变量方法，是光谱定量分析的行业基准；SVR（径向基核）代表核方法，用以判断差异是否来自非线性；RF 代表树集成，它不对波段间的平滑性或线性作任何假定，可作为「完全不利用连续性」的参照；1D-CNN 代表深度学习，其卷积核同样沿波长方向滑动，是与函数型方法机理上最接近的对照。四者与两个函数型模型合计六个方法，覆盖五类建模机理。各试验的超参数选择方式、候选网格与重复次数不尽相同均在相应表注或正文中写明：表 1 为各方法在固定配置下对 5 种预处理的筛选；表 2 为函数型模型内部对基函数族与个数的比较；表 3 为六个方法在统一协议下的等预算比较，协议与候选网格见 3.3 节；表 4 为小样本下固定超参数与交叉验证两种选参策略的对比；表 5~表 7 为综合评价的原始指标、综合结果与灵敏度分析；表 8 为五种样本划分方式下的综合指数得分。表 1~表 3 与表 5~表 8 均在上述 5 折外层划分上得出，故各表的 5 个观测即 5 个外层折。表 4 是刻意改变训练集样本量的试验，训练集须由人为指定的 N 个样本构成，无法套用等分折的做法，故该表在每个 N 上重复随机抽样 20 次取平均：抽样波动随 N 减小而急剧增大，20 次是使 N=20 处的均值稳定所需。该表内层的交叉验证取 4 折而非主协议的 5 折：训练集最小仅 20 个样本，5 折时每折的验证样本只剩 4 个，取 4 折可保有 5 个。

利用测试集的决定系数 R^2 、均方根误差 $RMSE$ 和相对分析误差 RPD 评价模型的性能其中 RPD 为测试集 SSC 参考值的标准差 s_y 与 $RMSE$ 之比。需要指出的是，在同一测试集上三者互为严格单调变换 ($R^2=1-(RMSE/s_y)^2$, $RPD=s_y/RMSE$)，按其一排序即等同于按其余两者排序，单靠这一组指标无法反映模型在误差分布其他方面的差别。为在同等条件下作多指标的统一比较，3.7 节采用综合评价框架 $LLH-GBID$ 。采用该框架而非直接对指标加权求和，有三点考虑：其一，它以效用向量到理想点的距离而非加权平均作为综合量，任一指标改善都不会使综合值变差，避免加权和中某一项的恶化被另一项的改善完全抵消；其二，它采用维度权重与维度内指标权重的两级结构，某一维度包含较多指标时不会被重复计权；其三，其综合距离可分解为平均效用缺口与两项不均衡量，除给出排序外还能指出各方法的短板所在。该框架先按评价含义划分 4 个维度，每维取 1 项彼此不构成确定性函数关系的指标：整体拟合取 R^2 ，平均误差取平均绝对误差 MAE ，大误差风险取绝对误差的 90% 分位数 $P90$ ，系统偏差取平均偏差 $bias$ ；再按方向把原始值统一转换为区间 $[0, 1]$ 的正向效用值，效益型（越大越好）与成本型（越小越好）分别取

$$\tilde{u}_j = \frac{x_j - L_j}{I_j - L_j} \quad \text{或} \quad \tilde{u}_j = \frac{L_j - x_j}{L_j - I_j} \quad (5)$$

目标型（越接近目标值 T_j 越好）取 $\tilde{u}_j = 1 - |x_j - T_j|/\tau_j$ ，三者一律截断为 $u_j = \text{clip}(\tilde{u}_j) \in [0, 1]$ 。理想值 I_j 取理论最优 (R^2 取 1, MAE 与 $P90$ 取 0)；基准值 L_j 对 R^2 取理论无技能值 0，对 MAE 与 $P90$ 取事先指定的基准模型（以训练集 SSC 均值预测测试集）在同一测试集上的相应误差，选用均值预测作基准是因为它对应「完全不使用光谱信息」的无技能水平，与 R^2 的理论基准 0 同源，可使四项指标的基准口径一致； $bias$ 按目标型处理， $T_j=0$, $\tau_j=0.25s_y$ （训练集）。记指标缺口 $d_j=1-u_j$ ，先在维度内聚合为缺口距离、再在维度间聚合为综合理想距离：

$$D_d = \left[\sum_{j \in J_d} v_{j|d} d_j^{q_w} \right]^{1/q_w}, \quad GBID = \left[\sum_d W_d D_d^{q_B} \right]^{1/q_B} \quad (6)$$

两级权重均取等权（维度权重 $W_d=1/4$ ，维度内 $v_{j|d}=1$ ），主分析取 $q_B=q_w=2$ ，此时 $GBID$ 即效用向量到理想点的加权欧氏距离，其平方可分解为 $GBID^2=(1-\bar{u})^2+C_B^2+C_w^2$ ，三项依次为平均效用缺口、维度间不均衡与维度内不均衡；进一步定义 0—100 综合指数得分 $GBIDS=100(1-GBID)$ ，越高越接近理想。另设非补偿性准入门槛：核心指标 R^2 的效用不低于 0.5 时记为通过，未通过者即使 $GBIDS$ 较高也不标注为综合最优。该框架为条件相对评价，结果依赖指标体系、权重、基准与参数设定，仅用于同一试验条件下的方法比较；上述参数在计算任何综合指数之前已一次锁定，此后未作调整。

除特别说明外，模型精度一律以嵌套交叉验证评价。外层把 1300 个样本随机等分为 5 折，每次以其中 4 折（1040 个）训练、余下 1 折（260 个）测试；在每个外层训练折内部再随机等分为 5 折作内层交叉验证，各候选配置分别算 5 折的均方根误差均值，取最小者为选中配置，再用整个外层训练折重新拟合该配置，最后在对应的外层测试折上评价。5 个外层折互不重叠、合起来恰覆盖全部样本，故每个样本都恰有一次以「模型未曾见过它」的身份被预测。

之所以采用嵌套交叉验证，而不是把样本按某个比例一次或若干次随机分成训练集与测试集：后者各次的测试集互相重叠、合起来也不覆盖全部样本，报告的精度取决于恰好抽到哪一批样本；更要紧的是，若在同一次划分上既选超参数又报告精度，选参这一步自身的乐观偏倚会计入最终精度。嵌套的两层把这两件事分开：内层只负责选参，外层只负责评价，两者不共用样本。内层取 5 折，是因为外层训练折有 1040 个样本，5 折时每折

的验证样本约 208 个，足以稳定区分各候选配置。

统计口径按外层折数计：本文报告的均值 $\pm$ 标准差、置信区间与配对检验，其样本量均为 5 个外层折。划分方式本身是否影响结论，在 3.7 节以另外四种划分方式检验。

3 结果与讨论

3.1 预处理与建模方法的组合

5 种预处理与 4 种建模方法的组合结果见表 1。由表 1 可知，预处理对精度的影响与建模方法存在交互：SVR 模型在 MSC 与 SNV 下表现最好 (R^2 分别为 0.775 与 0.758)，而 PLSR 模型在 SNV+SG-1D 下达到最优 (0.763)；单看最高的一格是 MSC 与 SVR 的组合 (0.775)。但后续统一协议要同时容纳六个方法，故按四个模型的平均值择优：SNV+SG-1D 的四法平均 R^2 为 0.691，高于 MSC 的 0.668、SNV 的 0.664、原始的 0.569 与 SG-1D 的 0.563，且是唯一使 RF 与 1D-CNN 两个较弱模型都达到 0.63 以上的预处理；若改按单格最优选 MSC，二者反而降至 0.539 与 0.596。综合来看，SNV+SG-1D 对模型选择最不敏感，后续函数型建模均在该预处理基础上进行。

表 1 不同预处理与建模方法组合的预测精度 (R^2)

Tab.1 Prediction accuracy (R^2) of combinations of preprocessing and modelling methods

预处理	PLSR	SVR	RF	1D-CNN
原始	0.581	0.659	0.501	0.535
SNV	0.762	0.758	0.549	0.587
MSC	0.761	0.775	0.539	0.596
SG-1D	0.639	0.596	0.580	0.435
SNV+SG-1D	0.763	0.713	0.655	0.632

注：5 折交叉验证，表中为 5 折的均值；PLSR 的潜变量数在每个训练折内以 5 折交叉验证选取，其余三法用各自的默认设置，以便把差异归因到预处理；方法之间的对等超参数搜索见 3.3 节。

3.2 基函数族与基函数个数

两种基函数族在 4 种基函数个数下的表现见表 2。由表 2 可知，两者总体接近，傅里叶基在 $L=80$ 时最优 (PFLR 模型的 $R^2=0.797$, $RMSE=0.739^\circ\text{Brix}$)，B 样条基在 $L=80$ 时次之 (0.795, 0.744)。基函数个数过少会造成欠拟合， $L=20$ 时两种基的 PFLR 精度分别降至 0.611 与 0.672。需要说明的是，本节的评价协议虽与 3.3 节相同，候选网格却是两法各扫各的 (PFLR 扫 13 个 λ_β ，FPCR 扫 5 个 K)，并非 3.3 节那种「每方法 12 组」的等预算网格，故本节数值只用于在函数型模型内部选基函数族与基个数，与离散方法的比较一律放在 3.3 节的统一协议下进行。本节的作用是为后续试验定下函数型模型的基设定：3.3 节的全样本比较取本节表现最好的傅里叶基、 $L=80$ ；3.4 节的小样本试验改取 B 样条基、 $L=40$ ，因为该节 N 最小为 20， $L=80$ 的基函数个数已远超训练样本量、展开系数无法稳定估计，而 $L=40$ 在本节中与 $L=80$ 的差距不大 (B 样条基下 PFLR 模型的 R^2 分别为 0.762 与 0.795)。

表 2 基函数族与基函数个数对函数型模型精度的影响

Tab.2 Effect of basis family and number of basis functions on the accuracy of functional models

基函数族	L	PFLR 的 R^2	RMSE/ $^\circ\text{Brix}$	FPCR 的 R^2
B 样条	20	0.611	1.024	0.613
B 样条	40	0.762	0.800	0.758

基函数族	L	PFLR 的 R^2	RMSE/°Brix	FPCR 的 R^2
B 样条	60	0.773	0.780	0.752
B 样条	80	0.795	0.744	0.770
傅里叶	20	0.672	0.937	0.671
傅里叶	40	0.759	0.803	0.764
傅里叶	60	0.783	0.766	0.755
傅里叶	80	0.797	0.739	0.791

注：嵌套交叉验证（外层 5 折、内层 5 折），表中为 5 个外层折的均值； λ_p 与主成分个数 K 均在每个外层训练折内以 5 折交叉验证选取。

3.3 统一协议下的方法比较

方法之间的横向比较只有在同等条件下才有意义。为此，六个方法在此使用同一套协议：同为 SNV+SG-1D 预处理；共用 2.3 节所述的同一批外层 5 折与内层 5 折划分，即在同一个外层训练折上各自完成内层选参，再在同一个外层测试折上评价，六个方法逐折一一对应；候选配置数对六个方法一律为 12 组，即各方法所获的调参预算相同；取 12 是因为它在各方法各自合理的参数范围内都能自然构成（如 SVR 为 4×3 、FPCR 与 PFLR 均为 2×6 ），既保证预算相等，又不必把某一方法的网格外扩到无意义的区域：PLSR 为潜变量 2~24（步长 2）；SVR 为 $C \in \{1, 10, 100, 1\,000\}$ 与 $\gamma \in \{\text{scale}, 10^{-3}, 10^{-4}\}$ 的组合；RF 为树数 $\in \{200, 400, 800\}$ 与每次分裂的特征比例 $\in \{\sqrt{p}, 0.1, 0.3, 1.0\}$ 的组合；1D-CNN 为 3 种宽度与层数组合、2 种学习率与 2 种丢弃率的组合；FPCR 为 $L \in \{40, 80\}$ 与 $K \in \{5, 10, 15, 20, 25, 30\}$ 的组合；PFLR 为 $L \in \{40, 80\}$ 与 $\lambda_p \in \{10^{-8}, 10^{-6}, 10^{-4}, 10^{-2}, 1, 10^2\}$ 的组合。结果见表 3；如图 2 所示，为 SVR、PFLR 与 PLSR 模型的折外预测值与实测值的关系，这三个模型分别为本数据上最优的离散方法、最优的函数型方法与行业基准。图中每个模型各有 1 300 个点：嵌套交叉验证中每个样本恰好在一个外层折里充当测试样本，把 5 折的预测拼起来即得到全部样本的折外预测，故散点图不再只反映某一次划分抽到的那一批样本。

表 3 统一协议下各建模方法的预测精度

Tab.3 Prediction accuracy of each modelling method under the unified protocol

建模方法	数据表征	R^2	RMSE/°Brix	RPD
SVR	离散	0.811±0.030	0.714±0.055	2.32±0.18
PFLR（傅里叶，L=80）	函数型	0.796±0.039	0.741±0.068	2.24±0.20
FPCR（傅里叶，L=80）	函数型	0.764±0.054	0.797±0.083	2.09±0.21
PLSR	离散	0.763±0.018	0.803±0.047	2.06±0.07
1D-CNN	离散	0.710±0.013	0.889±0.065	1.86±0.04
RF	离散	0.678±0.026	0.938±0.076	1.77±0.07

注：SNV+SG-1D 预处理；嵌套交叉验证（外层 5 折、内层 5 折），六个方法共用同一批折；各方法均在外层训练折内以 5 折交叉验证从 12 组候选中选参；表中为 5 个外层折的均值 ± 标准差；RPD 为该折测试样本参考值标准差与 RMSE 之比。

由表 3 可知，SVR 模型的精度最高（ $R^2=0.811$ ，RMSE=0.714 °Brix，RPD=2.32）。函数型方法中 PFLR 模型表现最好（0.796，0.741，2.24）；在同一批外层折上与各对照方法逐折配对比较，PFLR 模型相对 PLSR 模型平均高出 0.033，5 折中 4 折占优；相对 RF

与 1D-CNN 模型分别高出 0.119 与 0.086, 5 折全部占优; 但相对 SVR 模型平均低 0.015, 5 折中仅 1 折占优。该结果表明, 函数型建模用 80 个基函数即可胜过使用全部 2 048 个波段的 PLSR 模型, 维度压缩到约 1/25 而精度不降; 但它并不优于全部离散方法, SVR 模型在本数据上仍是精度最高的选择。

进一步, 与调参前的结果对照可以看出条件统一的必要性。在同为 SNV+SG-1D 预处理、但各方法沿用默认超参数的表 1 中, SVR 模型的 R^2 为 0.713、RF 为 0.655、1D-CNN 为 0.632, 均低于 PLSR 模型的 0.763; 在获得与其他方法相同的 12 组候选后, 三者分别升至 0.811、0.678 与 0.710。其中 SVR 模型的升幅最大 (0.098), 足以把它由 PLSR 模型之下抬到之上, 1D-CNN 模型也由此反超 RF 模型, 即调参预算是否对等直接改变了方法之间的排序, 未经等预算调参的横向比较不足以支撑优劣判断。1D-CNN 模型在调参后仍低于 PLSR 模型与两种函数型模型、仅高于 RF 模型, 这与其参数规模有关: 选中配置含 120 289 个可训练参数, 而每个外层训练折仅 1 040 个样本; 需要指出的是, 该结论限于本研究的网络结构、1 300 个样本的数据规模与 12 组候选的调参预算, 不构成对一维卷积网络的普遍评价。

还需说明这套等预算网格自身的边界。SVR 模型的 5 个外层折全部选中惩罚系数 C 的上界 1 000, FPCR 模型有 4 折选中主成分个数 K 的上界 30, 二者都落在预注册网格的边缘, 因此有必要在协议之外单独检验网格上限是否限制了它们的表现。把 SVR 的 C 向上延伸至 10^5 (18 组候选) 后 R^2 为 0.799, 反低于原网格的 0.811, 说明其上界并未构成限制; 而把 FPCR 的 K 向上延伸至 60 (15 组候选) 后 R^2 升至 0.792, 相对提高 3.7%, 超过 2% 的判定线。这意味着表 3 中 FPCR 模型落后于 PFLR 模型的那一段差距有一部分来自等预算网格对 K 设定的上限, 而非该模型本身的能力。由于延伸后的候选数已超出各方法一律 12 组的约定, 该结果不计入表 3, 只在此说明表 3 的适用边界。




图 2 统一协议下 SVR、PFLR 与 PLSR 模型全部 1 300 个样本的折外预测值与实测值的关系 (点色为样本点相对密度)

Fig.2 Out-of-fold predicted versus measured SSC of all 1 300 samples for the SVR, PFLR and PLSR models under the unified protocol (colour: relative point density)

3.4 小样本条件下的模型表现与超参数选择

将训练集样本量 N 由 20 逐步增至 400, 每个 N 重复抽样 20 次, 各模型的精度演变如图 3 与表 4 所示。离散对照同时列入 PLSR 与 SVR 模型: 3.3 节已表明 SVR 是本数据上最强的离散方法, 若小样本比较只以 PLSR 为对照, 所得优劣不足以说明问题。

表 4 不同训练集样本量与超参数选择策略下的预测精度 (R^2)Tab.4 Prediction accuracy (R^2) under different training set sizes and hyperparameter selection strategies

N	PLSR	SVR		FPCR		PFLR	
		固定	交叉验证	固定	交叉验证	固定	交叉验证
20	0.005	0.158	0.042	-0.115	-0.026	-0.556	-0.349
30	0.055	0.262	0.154	0.167	-0.020	0.051	-0.060
50	0.192	0.413	0.356	0.373	0.115	0.266	0.183
80	0.290	0.493	0.475	0.443	0.094	0.357	0.238
120	0.326	0.547	0.640	0.478	0.391	0.444	0.468
200	0.468	0.629	0.735	0.497	0.641	0.502	0.633
400	0.654	0.689	0.780	0.512	0.665	0.500	0.687

注：B 样条基， $L=40$ ；每个样本量重复抽样 20 次取平均，测试集为其余样本中的 400 个；四个模型均直接以 SNV+SG-1D 光谱为输入，未作额外的逐波段标准化；固定超参数分别取 FPCR 的 $K=10$ 、PFLR 的 $\lambda_p=10^{-3}$ 、SVR 的 $C=100$ 与 $\gamma=\text{'scale'}$ ；负值表示预测劣于用均值预测。

由表 4 可知，以固定超参数的策略比较，函数型方法确实明显优于 PLSR 模型： $N=80$ 时 FPCR 模型的 R^2 为 0.443，PLSR 为 0.290，高出 0.153； $N=50$ 与 120 时的差距分别为 0.181 与 0.152。但把 SVR 模型纳入对照后，这一优势不再成立：SVR 在所考察的每一个样本量、两种超参数策略下都不低于两种函数型模型，固定超参数时 $N=20$ 为 0.158，而 FPCR 与 PFLR 分别为 -0.115 与 -0.556； $N=80$ 为 0.493，高于 FPCR 的 0.443； $N=400$ 为 0.689，而两种函数型模型分别为 0.512 与 0.500。由此可知，函数型建模在小样本下的精度优势是相对 PLSR 模型而言的，而 PLSR 恰是这一区间中最弱的离散方法；SVR 模型在小样本下同样稳健，本研究未观察到函数型方法对它的精度优势。

随模型类别真正分化的不是精度，而是交叉验证能否在小样本下选对超参数。表 4 与图 3(c) 给出两种策略的对比：当主成分个数 K 与平滑参数 λ_p 改由训练集内的 4 折交叉验证选择时，FPCR 模型在 $N=80$ 时的 R^2 由 0.443 降至 0.094，落差 0.349；PFLR 模型由 0.357 降至 0.238，落差 0.119；而同一样本量下 SVR 模型的两种策略之差仅为 0.018 (0.493 与 0.475)。从图 3(c) 可以看出，FPCR 模型的落差在 $N=30\sim 80$ 区间始终最大，三个模型的差值均在 $N=200$ 以上转为正值，即样本量充足时交叉验证选参优于固定超参数。

该差别并非源于函数型模型的超参数更为敏感。在 $N=80$ 下把各方法的 12 组候选逐个跑出，候选之间的 R^2 极差 SVR 为 0.567，反而大于 FPCR 的 0.389 与 PFLR 的 0.376，差别在于交叉验证能否把好的那一档挑出来：以各自网格上能达到的最优精度为参照，交叉验证选出的配置与之相差，SVR 为 0.061 (最优 0.536，选出 0.475)，PFLR 为 0.170 (0.408 与 0.238)，FPCR 则达 0.380 (0.474 与 0.094)，FPCR 交叉验证选出的结果 (0.094) 几乎落到该网格最差的一档 (0.084)。这一失效可以直接观察到：在 $N=80$ 的 20 次重抽中，交叉验证有 10 次选中 $K=20$ ，而该取值恰是网格上表现最差的一档 ($R^2=0.084$ ，相邻的 $K=15$ 则为 0.474)；交叉验证所选的 K 与逐次事后最优的 K 仅 3 次一致，由此造成的平均精度损失达 0.495 (0.094 与 0.589)。其直接原因是误差估计本身不稳定： $N=80$ 时 4 折交叉验证的每折仅约 20 个样本，所选 K 处 4 折 MSE 的相对标准差中位为 26% (范围 12%~59%)，各候选 K 的交叉验证均值之差常被这一波动淹没。 $N=400$ 时该反转最为明显：FPCR 模型交叉验证为 0.665，固定超参数为 0.512。需要说明固定值的来历：表 4 的固定超参数 (FPCR 的 $K=10$ 、PFLR 的 $\lambda_p=10^{-3}$ 、SVR 的 $C=100$) 均在试验前设定、对所有 N 相同，并未参照本数据的结果选取； $N=80$ 的逐候选

结果显示, FPCR 模型在 $K=8\sim15$ 之间均可达 $0.385\sim0.474$, 而 $K\leq3$ 与 $K\geq20$ 时明显变差故「保守」应理解为取中等偏小的 K , 并非越小越好。综上说明, 在本研究数据的 $N=30\sim80$ 区间, 函数型模型宜固定一个保守的超参数而不依赖交叉验证选择; 两种策略的交叉点因模型而异: FPCR 模型位于 $N\approx120\sim200$ 之间, 而 PFLR 模型在 $N=120$ 时交叉验证 (0.468) 已略优于固定 λ_p (0.444), 故上述建议不宜跨模型外推。 $N=20$ 时两种函数型模型的 R^2 均为负, 此时任何一种策略都不成立。

如图 3(d)~(f) 所示, 为 $N=80$ 、固定超参数时一次代表性抽样下三个模型的训练集与测试集预测结果 (取 20 次重抽中六个模型 $\times$ 策略组合的测试集 R^2 与各自 20 次均值偏差最小的一次)。从图形可以看出, 三者的训练集点并未紧贴对角线: SVR、FPCR 与 PFLR 模型的训练集 R^2 分别为 0.694 、 0.544 与 0.584 , 相应的测试集 R^2 为 0.460 、 0.407 与 0.392 。说明在固定的保守超参数下, 三个模型均未把 80 个训练样本拟合至无残差, 限制精度的是训练样本所能提供的信息量而非过拟合; 两种函数型模型的点云较对角线平缓, 对高糖度样品预测偏低、对低糖度样品预测偏高, 呈向均值收缩的形态。




图 3 训练集样本量与超参数选择策略对各模型预测精度的影响: (a) 固定超参数; (b) 交叉验证选超参数; (c) 同一次抽样下两种策略的 R^2 差值 (阴影为 20 次重抽均值的标准误); (d)~(f) $N=80$ 、固定超参数时代表性一次抽样下 SVR、FPCR 与 PFLR 模型的训练集与测试集预测值与实测值的关系

Fig.3 Effect of training set size and hyperparameter selection strategy on the prediction accuracy of each model: (a) fixed hyperparameters; (b) cross-validated hyperparameters; (c) paired difference in R^2 between the two strategies (shaded: standard error of the mean over 20 resamples); (d)-(f) predicted versus measured SSC of the training and test sets at $N=80$ with fixed hyperparameters on a representative resample

3.5 回归系数函数与有效波段

以上比较回答了在本数据上应当选哪一类方法。函数型建模的另一处价值在于回归系数函数可直接读出各波长的贡献, 本节据此考察模型实际利用了哪些波段。如图 4(a) 所示

为 PFLR 模型估计得到的回归系数函数，其绝对值在 868~957 nm 区间最为集中，在 1 125~1 153 nm 存在次级极值。900~1 100 nm 一般被归属为 O—H 伸缩振动的二级倍频区在果肉组织中该区间由水的吸收主导，糖类的 O—H 与 C—H 吸收亦落在其中[20]，因此系数主峰所处的位置在化学上是可解释的；但本研究的数据不足以把该区间的响应在水与糖之间分开，上述归属只能作为对系数分布的一种解释，而非本研究的试验结论。该区间与卷积神经网络经有效波长选择所定位的响应区间亦可相互印证[21]。




图 4 回归系数函数与各波段区间的贡献：(a) PFLR 模型的回归系数函数（阴影为极值窗口）；(b) 各波段区间单独建模的精度；(c) 各波段区间原始光谱的信噪比

Fig.4 Regression coefficient function and contribution of each wavelength interval: (a) regression coefficient function of the PFLR model (shaded: windows of extrema); (b) accuracy of models built on each interval alone; (c) signal-to-noise ratio of the raw spectra in each interval

以约 100 nm 为步长将全波段划分为 6 个子区间分别建模（末段并入 1 100~1 250 nm，使各段的波长点数相当），各区间的精度与原始光谱的信噪比分别如图 4(b) 和图 4(c) 所示。由图 4(b) 可知，700~800 nm 单独建模的 R^2 最高（0.682），590~700 nm 与 800~900 nm 分别为 0.345 与 0.309，而 900 nm 以上各区间均不超过 0.194。若按整段建模，590~900 nm 可达 $R^2=0.761$ ，900~1 250 nm 仅为 0.171，1 000~1 250 nm 为 -0.016。这与回归系数函数的极值位置并不矛盾：系数主峰位于 868~957 nm，恰好跨越 900 nm 这一常规划分界线，按此切分会将该信息窗口一分为二，致使两侧单独使用时均不完整。

长波区整段建模失效的原因并不是信号质量。信噪比按各区间原始强度的均值与相邻波长差分的稳健标准差（1.4826 倍中位绝对偏差）之比计算；由图 4(c) 可知，原始强度下 900 nm 以上各区间的信噪比（513~814）高于可见光区（168~480），且不存在信号饱和。差别出现在预处理之后：在实际送入模型的 SNV+SG-1D 光谱上，590~900 nm 有 61.0% 的波段与 SSC 的相关系数绝对值超过 0.2，该区间协方差谱的有效维数仅为 2.5（有效维数取协方差谱的指数熵：设特征值归一化为 p_i ，则有效维数为 $\exp(-\sum p_i \ln p_i)$ ，方差全部集中于一个方向时为 1、均匀分散到 m 个方向时为 m ），即数百个波段承载的是少数几个高度冗余、方向一致的变异；而 1 000~1 250 nm 相应比例降至 14.2%，有效维数升至

11.4, 其中 1 000~1 100 nm 更是仅有 0.3% 的波段超过 0.2、有效维数达 37.0。这说明该区间的变异分散在许多近乎独立的方向上, 缺少可供潜变量方法提取的共同成分, 而不是「没有任何与 SSC 相关的波段」, 该区间单波段相关系数的最大值仍有 0.298。综上说明, 可被现有建模方法利用的糖度信息集中于跨越可见与近红外分界的 868~957 nm 窗口, 长波区是否另有可用信息, 需要与本研究不同的建模方式才能回答。

3.6 跨产地泛化

3.4 节关于小样本与选参策略的结论, 在实际中最直接的用武之地是更换产地后需要重新标定的场景: 实际检测中常需将某一产地建立的模型用于其他产地。本节按产地划分而不沿用 2.3 节的随机等分折, 是因为要回答的问题正是「换一个产地模型还成不成立」: 随机折会把三个产地的样本混进同一折, 训练折里已经含有目标产地的样本, 跨产地这件事就被抹掉了。以目标产地留出 40 个样本、其余样本作测试集这一设定为例(取 40 个是因为该值落在 3.4 节考察的 $N=30\sim80$ 区间内, 可与该节的选参结论直接对照), 以山东样本建立的模型直接用于新疆样本时 R^2 为 -0.677 (该值在目标域留出 20 个与 40 个样本时相同), 即预测效果劣于直接使用均值, 出现明显的负迁移; 反方向(新疆 $\rightarrow$ 山东)为 0.085, 呈现明显的不对称性。这一不对称与两地 SSC 分布的位置关系一致: 以山东样本建模时, 有 20.6% 的新疆样本的 SSC 高于训练集的 99% 分位, 模型须向上外推反方向则有 14.9% 的山东样本低于训练集的 1% 分位。同批样品的产地判别研究亦表明三个产地的光谱存在可分的系统性差异[19], 这类跨域问题在统计学上可纳入函数型迁移学习的框架[22]。若在目标产地采集 40 个标定样本重新建模(15 次重抽平均), 以 PLSR 模型重建可将山东 $\rightarrow$ 新疆的 R^2 由 -0.677 提升至 0.424; 以交叉验证选参的 PFLR 模型重建则仅为 0.265, 与 3.4 节小样本下交叉验证选参失效的结果一致。由此可知, 当检测对象更换产地时, 与其沿用源产地模型, 不如采集少量目标产地样本重新标定, 且此时宜采用固定超参数而非交叉验证选参。

3.7 样本划分方式与综合评价

以上比较均建立在 5 折嵌套交叉验证与单项指标之上, 其结论是否依赖于这两项设定, 需要单独检验。划分方面, 在 3.3 节的其余设定不变的前提下另换四种方式取训练集: 按 70% 与 75% 两种比例作重复随机划分(各重复 5 次); 以 SPXY 算法选取 75%; 以 Kennard-Stone 算法选取 75%。选前两种是为了检验「训练集与测试集互斥且覆盖全体」这一点是否影响结论: 重复随机划分正是各次测试集互相重叠、合起来不覆盖全体的那一类做法, 也是同类研究中最常见的做法, 把它与嵌套交叉验证并列即可看出改协议是否改结论。选后两种算法作对照, 是因为二者的差别恰好在于是否使用参考值: Kennard-Stone 仅按光谱距离取样, SPXY 在其上一并计入 SSC 参考值的距离, 并列比较即可分离「按光谱取样」与「按光谱与参考值共同取样」各自的影响。两种距离均在 SNV+SG-1D 光谱上计算; 二者均为确定性算法, 各只有一种划分结果, 故不作统计推断。为控制篇幅, 四种新划分只考察表 3 中精度居前的四个方法, 其候选网格与选参方式与表 3 完全相同。指标方面, 按 2.3 节的 LLH-GBID 框架, 另取 MAE、绝对误差的 90% 分位数 P90 与平均偏差 bias 三项指标, 与 R^2 一起构成 4 个维度, 主分析(嵌套交叉验证、六个方法)的原始指标与综合指数得分 GBIDS 见表 5, 综合结果与分解见表 6, 五种划分方式下的 GBIDS 见表 8。

由表 6 可知, 六个方法的 R^2 效用均不低于 0.5, 全部通过准入门槛。综合排序为 SVR (GBIDS=70.9)、PFLR (69.7)、FPCR (66.9)、PLSR (64.8)、1D-CNN (59.9)、RF (57.5), 与 3.3 节按 R^2 得到的排序一致。由分解项可以看出, 四个维度

中系统偏差的效用最高（0.911~0.936），即所考察的方法均无明显的系统性高估或低估；差别主要出现在平均误差与大误差风险两个维度（效用 0.444~0.618）。维度内不均衡量 C_w 恒为 0，因为每个维度只含 1 项指标；维度间不均衡量 C_B 介于 0.138~0.196，SVR 与 PFLR 模型最小（均为 0.138），RF 与 1D-CNN 模型最大（0.196 与 0.183），说明后两者的短板更为集中。

表 5 统一协议下各建模方法的综合评价原始指标与综合指数得分

Tab.5 Raw metrics entering the composite evaluation and composite index score of each modelling method under the unified protocol

建模方法	R ²	MAE/°Brix	P90/°Brix	平均偏差/°Brix	GBIDS
SVR	0.811±0.030	0.515±0.020	1.059±0.074	-0.025±0.019	70.9
PFLR	0.796±0.039	0.536±0.014	1.089±0.049	-0.008±0.038	69.7
FPCR	0.764±0.054	0.582±0.016	1.177±0.094	-0.006±0.033	66.9
PLSR	0.763±0.018	0.612±0.028	1.290±0.060	-0.005±0.036	64.8
1D-CNN	0.710±0.013	0.696±0.051	1.449±0.116	-0.011±0.040	59.9
RF	0.678±0.026	0.731±0.057	1.531±0.101	+0.009±0.041	57.5

注：与表 3 为同一批 5 个外层折（训练 1 040 个、测试 260 个），表中为 5 折的均值 ± 标准差；P90 为测试集绝对误差的 90% 分位数，平均偏差为预测值减实测值的均值；两个函数型模型均为傅里叶基、L=80；R² 与表 3 相同，RMSE 与 RPD 因与 R² 互为单调变换而未纳入综合评价。

表 6 统一协议下各建模方法的 LLH-GBID 综合评价结果

Tab.6 LLH-GBID composite evaluation of each modelling method under the unified protocol

建模方法	准入	平均 效用 $\bar{u}$	C_B	C_w	GBID	GBIDS (95% 置信区间)	平均 排名	第一名 频率/%
SVR	通过	0.743	0.138	0.000	0.291	70.9 (69.9~71.8)	1.2	80.0
PFLR	通过	0.730	0.138	0.000	0.303	69.7 (68.4~70.5)	1.8	20.0
FPCR	通过	0.707	0.152	0.000	0.331	66.9 (65.3~68.2)	3.2	0.0
PLSR	通过	0.689	0.165	0.000	0.352	64.8 (63.8~65.5)	3.8	0.0
1D-CNN	通过	0.643	0.183	0.000	0.401	59.9 (57.9~61.5)	5.0	0.0
RF	通过	0.622	0.196	0.000	0.425	57.5 (55.4~59.3)	6.0	0.0

注：嵌套交叉验证的 5 个外层折；主分析取 $q_B=q_w=2$ ；准入门槛为核心指标 R² 的效用不低于 0.5（软否决）； $GBID^2=(1-\bar{u})^2+C_B^2+C_w^2$ ；置信区间、平均排名与第一名频率由 2 000 次以折为单位的 bootstrap 给出；GBID 越小、GBIDS 越高表示越接近理想。

以综合最优的 SVR 模型为参照，其余五个方法的 GBID 差值按 Nadeau-Bengio 修正的配对 t 检验判定，自由度取外层折数减 1，95% 置信区间另由 2 000 次以外层折为重采样单位的 bootstrap 给出。作 Nadeau-Bengio 修正是因为 5 个外层折的训练折两两重叠达各自的 3/4，直接按独立样本计算方差会低估不确定性；五个配对差同时检验，故按 Holm 校正。结果分为两档：PLSR、RF 与 1D-CNN 模型的 GBID 差值分别为 0.060、0.134 与 0.110，校正后 p 分别为 0.002、0.008 与 0.015，均劣于 SVR 模型；而 FPCR 与 PFLR 模型的差值为 0.039 与 0.012，校正后 p 为 0.062 与 0.197，在 5 个外层折上未达显著。

仅凭「未达显著」还不足以区分「确实相近」与「样本量不足以判断」，故按预案进一步作贝叶斯相关 t 检验：它把 k 折交叉验证的折间相关直接建进后验，并以事先设定的 $\epsilon=0.02$ 为实际等价区间，直接给出「两法之差落在该区间内」的概率。结果为：SVR 模型实质优于 PLSR、RF 与 1D-CNN 模型的概率分别为 0.999、0.998 与 0.995，优于 FPCR

模型的概率为 0.908；而 SVR 与 PFLR 模型有 0.794 的概率落在实际等价区间之内，SVR 实质更优的概率仅为 0.198。由此可知，SVR 模型在综合评价中稳居第一，但它相对最好的函数型模型 PFLR 的领先并不构成实质差异，真正被数据支持的是它相对 PLSR、RF 与 1D-CNN 模型的优势，这与 3.3 节按单项指标得到的判断一致。

表 7 汇总四项灵敏度分析。短板参数 (q_B, q_W) 取 4 种配置时排序完全不变，两两 Kendall τ 均为 1.000；2 000 组两级 Dirichlet 随机权重与维度权重 $\pm 20\%$ 扰动下，SVR 模型第一名的概率为 100%，六个方法的名次无一发生变动，与主排序的平均 Kendall τ 为 1.000；基准值改取候选集最差值，以及改用相关性折扣权重与 Mahalanobis 去相关，三者的排序与主分析亦完全一致（Kendall τ 均为 1.000）。两项诊断一并说明：四项指标的上、下截断比例均为 0；MAE 与 P90 的 Spearman ρ 为 0.955，超过 0.9 的判定线，按预案纳入相关性处理敏感性分析而不作删除，折扣后系统偏差维度的权重由 0.25 升至 0.333，排序仍未改变。

表 7 LLH-GBID 综合排序的四项灵敏度分析

Tab.7 Four sensitivity analyses of the LLH-GBID composite ranking

建模方法	主排名	q 敏感性	权重扰动	权重扰动	基准敏感性	相关性处理	重采样
		平均排名	第一名概率/%	排名区间	排名区间	一致性	第一名频率/%
SVR	1	1.0	100.0	1~1	1~1	一致	80.0
PFLR	2	2.0	0.0	2~2	2~2	一致	20.0
FPCR	3	3.0	0.0	3~3	3~3	一致	0.0
PLSR	4	4.0	0.0	4~4	4~4	一致	0.0
1D-CNN	5	5.0	0.0	5~5	5~5	一致	0.0
RF	6	6.0	0.0	6~6	6~6	一致	0.0

注：q 敏感性为 $(q_B, q_W) \in \{(2,2), (3,2), (2,3), (3,3)\}$ 四种配置；权重敏感性为维度权重 $\pm 20\%$ 扰动与 2 000 组两级 Dirichlet 随机权重（ $\kappa_B = \kappa_W = 10$ ）；基准敏感性为基准值由固定基准改取候选集最差值；相关性处理为原始等权、相关性折扣权重与 Mahalanobis 去相关三种方式的排序一致性；重采样第一名频率由 2 000 次 percentile bootstrap 给出。

由表 8 可知，五种划分方式下按 GBIDS 的排序完全一致，均为 SVR、PFLR、FPCR、PLSR 由高到低，与按 R^2 排序的结果相同；同一划分内 PFLR 模型相对 PLSR 模型的 R^2 依次高出 0.033、0.042、0.044、0.059 与 0.043，SVR 模型相对 PFLR 模型依次高出 0.015、0.033、0.022、0.035 与 0.035。值得一并指出的是，改用重叠且不覆盖全体的重复随机划分，四个方法的 GBIDS 均比嵌套交叉验证低 0.5~1.6，排序却未改变，即换协议改变的是精度的绝对水平，而不是方法之间的高下。该结果表明，3.3 节关于方法优劣的两条结论既不依赖于样本划分方式，也不依赖于所选的单项指标。

表 8 五种样本划分方式下各建模方法的综合指数得分

Tab.8 Composite index score of each modelling method under five sample partitioning schemes

样本划分方式	训练集/ 测试集	PLSR	SVR	FPCR	PFLR	按 GBIDS 的排序
嵌套交叉验证	1 040/260	64.8	70.9	66.9	69.7	SVR > PFLR > FPCR > PLSR
随机 70%	910/390	63.2	70.2	65.3	68.3	SVR > PFLR > FPCR > PLSR
随机 75%	975/325	64.4	71.4	67.2	69.9	SVR > PFLR > FPCR > PLSR
SPXY 75%	975/325	65.2	74.9	68.5	70.4	SVR > PFLR > FPCR > PLSR
Kennard-Stone 75%	975/325	64.3	70.8	67.1	67.6	SVR > PFLR > FPCR > PLSR

注：候选网格与选参方式均与表 3 相同；嵌套交叉验证为 5 个外层折的均值，两种重复随机划分为 5 次的均值，SPXY 与 Kennard-Stone 为确定性算法，各只有 1 种划分，不作统计推断；各划分方式内的 GBIDS 由该划分自身的四项指标计算，故只可在同一行内横向比较。

划分方式改变的是精度的绝对水平而非方法之间的排序。以 SVR 模型为例，SPXY 划分下 $R^2=0.861$ 、 $RMSE=0.547$ °Brix，Kennard-Stone 划分下为 0.784 与 0.721 °Brix，嵌套交叉验证居中（0.811，0.714 °Brix），但两端成因不同：SPXY 同时按光谱与 SSC 取样，两端的样品都进入训练集，测试集只剩分布内部的样品，故 RMSE 显著下降；Kennard-Stone 仅按光谱距离取样，其 RMSE 与随机划分相当。两种确定性划分所留测试集的 SSC 标准差分别为 1.47 与 1.55 °Brix，均小于嵌套交叉验证各外层折的约 1.65 °Brix，而 R^2 与 RPD 均以该标准差为分母：SPXY 的 RMSE 降幅足以抵过分母的减小，Kennard-Stone 则不能，其 R^2 因而最低。由此可知，不同划分方式下报告的 R^2 与 RPD 不可直接比较，但在同一划分方式内部作方法比较不受影响。还需说明该综合评价的边界：GBIDS 是 0—100 综合指数得分而非准确率，LLH-GBID 为条件相对评价框架，其结果依赖指标体系、两级权重、基准值与参数设定，不构成唯一的真理排序，也不具备跨研究、跨数据集的绝对可比性；本节的作用仅限于检验 3.3 节的排序是否依赖于单一指标与单一划分方式，结论是不依赖。

4 结论

结合近红外透射光谱技术，基于函数型数据分析的统计建模思想，建立惩罚函数型线性回归模型与函数型主成分回归模型，并在统一协议下与离散建模方法比较，实现三个产地红富士苹果可溶性固形物含量的预测，得到如下主要结论：

（1）在统一协议（同一预处理、同一批外层 5 折与内层 5 折、各 12 组候选）下，惩罚函数型线性回归模型以傅里叶基、80 个基函数取得 $R^2=0.796$ 、 $RMSE=0.741$ °Brix、 $RPD=2.24$ ，优于使用全部 2 048 个波段的偏最小二乘回归模型（0.763、0.803），5 个外层折中 4 折占优，即基函数展开把维度压缩到约 1/25 而未损失精度。

（2）支持向量回归模型在全样本（ $R^2=0.811$ 、 $RMSE=0.714$ °Brix、 $RPD=2.32$ ）及所考察的全部训练集样本量、两种超参数策略下均不低于两种函数型模型，全样本配对比较中 5 折里 4 折占优；该排序在嵌套交叉验证与随机、SPXY、Kennard-Stone 三类共五种样本划分方式下均不改变；按 LLH-GBID 综合评价框架以 R^2 、MAE、绝对误差 90% 分位数与平均偏差四个维度衡量，六个方法的 0—100 综合指数得分依次为 70.9、69.7、66.9、64.8、59.9 与 57.5，排序与按 R^2 一致，且在短板参数、两级权重、基准值与相关性处理四项灵敏度分析下均不改变。但排序稳定不等于每一处差距都成立：按实际等价区间 $\epsilon=0.02$ 作贝叶斯相关 t 检验，支持向量回归模型实质优于偏最小二乘回归、随机森林与一维卷积网络模型的概率不低于 0.995，优于函数型主成分回归模型为 0.908；而它与惩罚函数型线性回归模型有 0.794 的概率落在等价区间之内，两者在本数据上难分高下。故函数型方法的精度优势是相对偏最小二乘回归模型而言的，而非相对全部离散方法。此外，在同一预处理下若不给对照方法同等的调参预算，支持向量回归模型的 R^2 仅为 0.713、低于偏最小二乘回归模型，方法排序会被颠倒，说明横向优劣结论对调参预算是否对等高度敏感。

（3）小样本下交叉验证难以为函数型模型选对超参数，其代价大于模型类别的差异。训练集样本量为 80 时，由固定超参数改为交叉验证选择使函数型主成分回归模型的 R^2 由 0.443 降至 0.094，落差 0.349，而支持向量回归模型的同一落差仅为 0.018。这并非因为函数型模型的超参数更敏感，12 组候选之间的 R^2 极差 SVR 为 0.567，反大于 FPCR 的

0.389，而是因为交叉验证选出的配置与该网格最优之间的差距，FPCR 达 0.380，而 SVR 仅 0.061。因此在 $N=30\sim80$ 区间，函数型模型宜固定一个保守的超参数；两种策略的交叉点因模型而异（FPCR 位于 $N\approx120\sim200$ 之间，PFLR 在 $N=120$ 时交叉验证已略占优），该建议不宜跨模型外推。

（4）回归系数函数的极值集中于 868~957 nm，该窗口跨越 900 nm 这一常规划分界线按区间切分建模会将其割裂。长波区整段建模失效并非信号质量所致，而是预处理后该区间的变异分散于许多近乎独立的方向（1 000~1 250 nm 的有效维数为 11.4，590~900 nm 仅为 2.5），缺少可供潜变量方法提取的共同成分。

（5）跨产地直接迁移存在负迁移与方向不对称性（目标域留出 40 个样本时，山东→新疆 $R^2=-0.677$ ，新疆→山东 $R^2=0.085$ ）；在目标产地采集 40 个样本重新标定，可将山东→新疆的 R^2 提升至 0.424。

然而，本研究的样本涵盖单一品种（红富士）的三个产地与两个年份，结论对其他品种的适用性尚待验证；精度最高的支持向量回归模型其 RPD 为 2.32，函数型模型约为 2.1，均属于可用于粗略筛分而尚不足以精确定量的水平，若用于分级生产还需进一步提高精度。表 4 中固定超参数的取值为事先设定，其合理范围仅由 $N=80$ 的逐候选分析给出，换数据后是否仍然适用尚待验证。此外，本研究对函数型模型只考察了 B 样条与傅里叶两种基函数族及粗糙惩罚一种正则化方式，是否存在能够缩小其与核方法差距的函数型模型设定，是一个值得深入研究的问题。

参考文献：

- [1] RAM B G, ODUOR P, IGATHINATHANE C, et al. A systematic review of hyperspectral imaging in precision agriculture: Analysis of its current state and future prospects[J]. Computers and Electronics in Agriculture, 2024, 222: 109037.
- [2] BLASCO J, GORLA G, MUNERA S, et al. Non-destructive spectral systems (NDSS) for modern inspection systems in real-time: Challenges and industrial perspectives[J]. TrAC Trends in Analytical Chemistry, 2025, 191: 118369.
- [3] 张子申, 程红, 耿文娟, 等. 高光谱成像技术在水果品质检测中的应用研究进展[J]. 智慧农业(中英文), 2025, 7(5): 52-66.
ZHANG Z S, CHENG H, GENG W J, et al. Research progress on the application of hyperspectral imaging technology in fruit quality detection[J]. Smart Agriculture, 2025, 7(5): 52-66. (in Chinese)
- [4] 班兆军, 高喧翔, 马肆恒, 等. 基于高光谱和深度学习的苹果品质无损检测方法[J]. 江苏农业学报, 2024, 40(8): 1446-1454.
BAN Z J, GAO X X, MA S H, et al. Nondestructive detection method of apple quality based on hyperspectral imaging and deep learning[J]. Jiangsu Journal of Agricultural Sciences, 2024, 40(8): 1446-1454. (in Chinese)
- [5] 彭彦昆. 农畜产品品质安全光学无损快速检测技术[M]. 北京: 科学出版社, 2016.
- [6] MA T, ZHAO J, INAGAKI T, et al. Rapid and nondestructive prediction of firmness, soluble solids content, and pH in kiwifruit using Vis-NIR spatially resolved spectroscopy[J]. Postharvest Biology and Technology, 2022, 186: 111841.
- [7] 李鹏, 张萌, 李传宗, 等. 高光谱成像结合宽度学习系统的青枣可溶性固形物含量检测[J]. 中国食品学

报, 2025, 25(8): 324-334.

LI P, ZHANG M, LI C Z, et al. Detection of soluble solids content in green jujube by hyperspectral imaging combined with broad learning system[J]. Journal of Chinese Institute of Food Science and Technology, 2025, 25(8): 324-334. (in Chinese)

- [8] 郭俊先, 马永杰, 郭志明, 等. 流形学习方法及近红外透射光谱的新疆冰糖心红富士水心鉴别[J]. 光谱学与光谱分析, 2020, 40(8): 2415-2420.

GUO J X, MA Y J, GUO Z M, et al. Watercore identification of Xinjiang Fuji apple based on manifold learning algorithm and near infrared transmission spectroscopy[J]. Spectroscopy and Spectral Analysis, 2020, 40(8): 2415-2420. (in Chinese)

- [9] MA T, XIA Y, INAGAKI T, et al. Rapid and nondestructive evaluation of soluble solids content (SSC) and firmness in apple using Vis-NIR spatially resolved spectroscopy[J]. Postharvest Biology and Technology, 2021, 173: 111417.

- [10] ACQUARELLI J, VAN LAARHOVEN T, GERRETZEN J, et al. Convolutional neural networks for vibrational spectroscopic data analysis[J]. Analytica Chimica Acta, 2017, 954: 22-31.

- [11] XIAO Y, ZHOU L, ZHAO Y, et al. Deep learning-based regression of food quality attributes using near-infrared spectroscopy and hyperspectral imaging: A review[J]. Food Chemistry, 2025, 493: 145932.

- [12] RAMSAY J O, SILVERMAN B W. Functional data analysis[M]. 2nd ed. New York: Springer, 2005.

- [13] LI H, XIAO G, XIA T, et al. Hyperspectral image classification using functional data analysis[J]. IEEE Transactions on Cybernetics, 2014, 44(9): 1544-1555.

- [14] SEIFI MAJDAR R, GHASSEMIAN H. Spectral-spatial classification of hyperspectral images using functional data analysis[J]. Remote Sensing Letters, 2017, 8(5): 488-497.

- [15] 黄威, 高林妹, 郭文雯, 等. 基于光谱成像的人血和两种动物血痕迹的函数型数据分析[J]. 刑事技术, 2021, 46(6): 551-558.

HUANG W, GAO L M, GUO W W, et al. Functional data analysis of human blood and two kinds of animal blood traces based on spectral imaging[J]. Forensic Science and Technology, 2021, 46(6): 551-558. (in Chinese)

- [16] COSTA L, MCBREEN J, AMPATZIDIS Y, et al. Using UAV-based hyperspectral imaging and functional regression to assist in predicting grain yield and related traits in wheat under heat-related stress environments[J]. Precision Agriculture, 2022, 23(2): 622-642.

- [17] 黄华, 刘亚, 马毅航, 等. 基于可见/近红外光谱和函数型线性回归模型的成熟期苹果可溶性固形物含量预测[J]. 光谱学与光谱分析, 2024, 44(7): 1905-1912.

HUANG H, LIU Y, MA Y H, et al. Prediction of soluble solid contents in apples using Vis-NIRS and functional linear regression model[J]. Spectroscopy and Spectral Analysis, 2024, 44(7): 1905-1912. (in Chinese)

- [18] DELAIGLE A, HALL P. Achieving near perfect classification for functional data[J]. Journal of the Royal Statistical Society: Series B, 2012, 74(2): 267-286.

- [19] 黄华, 南梦迪, 李政浩, 等. 分数阶微分预处理及 PCA-SRDA 的多模型融合对红富士苹果产地溯源[J]. 光谱学与光谱分析, 2022, 42(10): 3249-3255.
- HUANG H, NAN M D, LI Z H, et al. Multi-model fusion based on fractional differential preprocessing and PCA-SRDA for the origin traceability of Red Fuji apples[J]. Spectroscopy and Spectral Analysis, 2022, 42(10): 3249-3255. (in Chinese)
- [20] FANG L, WEI K, FENG L, et al. Optical absorption and scattering properties at 900-1 650 nm and their relationships with soluble solid content and soluble sugars in apple flesh during storage[J]. Foods, 2020, 9(12): 1881.
- [21] LIU Y, ZHOU S, HAN W, et al. Convolutional neural network for hyperspectral data analysis and effective wavelengths selection[J]. Analytica Chimica Acta, 2019, 1086: 46-54.
- [22] WANG Z, MAO X, KIM J K, et al. Selection bias adjustment by functional transfer learning via reproducing kernel Hilbert space[J]. Journal of Business & Economic Statistics, 2025, 44(1): 177-187.