

苹果可溶性固形物含量的函数型回归建模与小样本超参数选择

李盼林¹, 杨双泽¹, 李宇畅¹, 黄华^{1,2}

(1.新疆农业大学数理学院, 新疆乌鲁木齐 830052; 2.新疆农业大学数值模拟与数据分析研究中心, 新疆乌鲁木齐 830052)

摘 要: 苹果可溶性固形物含量 (SSC) 的光谱标定依赖破坏性测定、样本量往往受限。以三个产地两个年份共 1 300 个红富士苹果为试材, 采集 590~1 250 nm 近红外透射光谱, 建立惩罚函数型线性回归 (PFLR) 与函数型主成分回归 (FPCR) 模型, 与偏最小二乘回归 (PLSR)、支持向量回归 (SVR) 等 4 种离散方法在等调参预算的统一协议下比较。PFLR 仅用 80 个基函数即达到不低于全部 2 048 个波段 PLSR 的精度 (0.797 与 0.763, 配对检验未达显著), 属等精度降维。真正的分化在超参数选择: 样本量为 80 时改固定超参数为交叉验证选参, FPCR 的 R^2 由 0.443 降至 0.094 而 SVR 仅降 0.018, 根源是交叉验证在小样本下挑不出好配置, 而非函数型超参数更敏感。跨年份使用时 R^2 多为负, 但扣除整体偏差后回升、相关系数不变, 失效主要是标定水平漂移。故小样本下函数型建模可替代 PLSR, 宜固定保守超参数, 跨批次使用前须重新校正标定水平。

关键词: 函数型数据分析; 近红外光谱; 可溶性固形物含量; 小样本; 超参数选择; 跨批次验证

中图分类号: S661.1; O212.7 **文献标志码:** A

Functional regression modelling of soluble solids content in apple and hyperparameter selection with small calibration sets

LI Pan-lin¹, YANG Shuang-ze¹, LI Yu-chang¹, HUANG Hua^{1,2}

(1. College of Mathematics and Physics, Xinjiang Agricultural University, Urumqi Xinjiang 830052, China; 2. Research Center of Numerical Simulation and Data Analysis, Xinjiang Agricultural University, Urumqi Xinjiang 830052, China)

Abstract: Calibrating a spectral model for soluble solids content (SSC) in apple requires destructive measurement, so the training set is often small. Near-infrared transmittance spectra (590-1 250 nm) of 1 300 Fuji apples from three producing areas and two years were collected. Penalized functional linear regression (PFLR) and functional principal component regression (FPCR) were compared with four discrete methods, including partial least squares regression (PLSR) and support vector regression (SVR), under a unified protocol at an equal tuning budget. PFLR with only 80 basis functions matched PLSR using all 2 048 wavelengths (0.797 versus 0.763, not significant in a paired

收稿日期:

基金项目: 新疆维吾尔自治区自然科学基金面上项目 (项目编号待公示后补); 2026 年新疆农业大学大学生创新项目 (S202610758116、DXSCX2026349、DXSCX2026350)。

作者简介: 李盼林 (2004—), 男, 研究方向为函数型数据分析与光谱建模, E-mail: panlinryan@gmail.com。

通讯作者简介: 黄华 (1981—), 男, 教授, 研究方向为高维数据分析与机器学习, E-mail: huanghua@xjau.edu.cn。

test), that is, dimension reduction at comparable accuracy. The classes differed mainly in hyperparameter selection: at a training set size of 80, replacing fixed hyperparameters with cross-validated selection lowered the R^2 of FPCR from 0.443 to 0.094 but that of SVR by only 0.018, because cross-validation fails to pick a good configuration on small samples rather than because functional hyperparameters are more sensitive. Across collection years, R^2 was mostly negative but recovered once the overall bias was removed, with the correlation unchanged, so the failure is mainly a drift in calibration level. Under the conditions of this dataset (Fuji apples, three producing areas, two years, one instrument), functional modelling can replace PLSR on small calibration sets, but conservative fixed hyperparameters are preferable and the calibration level must be recorrected before use on a new batch.

Key words: functional data analysis; near-infrared spectroscopy; soluble solids content; small sample; hyperparameter selection; cross-batch validation

0 引言

可溶性固形物含量 (soluble solids content, SSC) 是反映苹果品质和成熟度的主要指标之一, 直接决定果实商品等级, 而传统测定依赖折光仪对果肉汁液作破坏性测量。可见/近红外光谱技术利用含氢官能团的倍频与合频吸收作定量分析, 具有快速、无损、可在线部署的特点, 其在工业实时检测中的现状与挑战已有系统评述[1], 在苹果、猕猴桃等果品的 SSC 检测中亦有应用[2-3], 新疆本地亦已开展基于近红外透射光谱的红富士苹果品质研究[4]。

在光谱定量建模中, 偏最小二乘回归 (partial least squares regression, PLSR) 通过提取潜变量克服波段间的强共线性, 是该领域的常规方法, 在苹果 SSC 检测中亦有应用[5]; 近年来卷积神经网络等深度学习方法也被引入光谱回归任务[6]。上述方法都把光谱视为离散的高维向量, 忽略了相邻波段之间固有的连续性与光滑性。函数型数据分析 (functional data analysis, FDA) 为此提供了自然的数学语言[7]: 它把每条光谱视为定义在波长区间上的连续函数, 已被用于血迹光谱判别[8]等任务; 文献[9]以新疆阿克苏红富士苹果建立函数型线性回归模型, 验证了该类模型用于苹果 SSC 预测的有效性。

已有研究的方法比较大多在样本充足的条件下进行, 对训练集样本量受限这一实际约束关注较少。该约束在苹果 SSC 检测中尤为突出: 每增加一个标定样本即意味着破坏一枚果实, 更换产地或年份时标定往往需要重做。函数型方法以光滑性先验换取更少的自由参数, 理论上应在小样本下更为稳健, 但基函数个数、平滑参数等超参数本身也需估计, 小样本下这些超参数能否被可靠选出, 尚鲜有研究报道。

基于此, 以新疆阿克苏、山东烟台、陕西洛川三个产地两个年份的红富士苹果为研究对象, 构建惩罚函数型线性回归模型与函数型主成分回归模型, 以 PLSR、支持向量回归 (support vector regression, SVR)、随机森林 (random forest, RF) 与一维卷积神经网络 (1D-CNN) 模型为对照。方法之间的横向比较只有在预处理、数据划分、选参方式与候选配置数都相同的条件下才有意义, 故全样本比较在统一协议下进行; 在此基础上考察训练集样本量与超参数选择策略对方法优劣的影响, 分析有效波段, 并以采集年份作外部集检验跨批次表现, 以期在标定样本受限条件下的建模方法选择提供依据。

1 函数型数据分析建模方法

1.1 光谱的函数型表征

设第 i 个样品在波长 λ 处的光谱值为 $x_i(\lambda)$, 函数型数据分析假定它是关于波长的连续光滑函数, 在一组基函数 $\{\phi_k(\lambda)\}$ 上展开为

$$x_i(\lambda) = \sum_{k=1}^L c_{ik} \varphi_k(\lambda) \quad (1)$$

式中： L 为基函数个数； c_{ik} 为展开系数，由带粗糙惩罚的最小二乘估计

$$\hat{c}_i = \operatorname{argmin}_c \{\|x_i - \Phi c\|^2 + \lambda_s c' R c\} \quad (2)$$

式中： Φ 为基函数在各采样波长处取值构成的矩阵； R 为二阶导数的内积矩阵， $R_{jk} = \int \varphi_j''(\lambda) \varphi_k''(\lambda) d\lambda$ ； λ_s 为平滑参数。若不加该惩罚， L 较大时展开系数会转而拟合采样噪声。本研究并列比较三次 B 样条基（局部支撑，对吸收峰更灵活）与傅里叶基（全局，对平缓趋势更紧凑），近红外光谱两类形态兼有，故一并考察（见 3.1 节）。 L 取 20、40、60、80，上限取 80 是因为此时维度已由 2 048 个波长点压缩到约 1/25，再增大将失去降维的意义。

1.2 惩罚函数型线性回归

函数型线性回归假定响应变量与函数型自变量之间满足

$$y_i = \alpha + \int \beta(\lambda) x_i(\lambda) d\lambda + \varepsilon_i \quad (3)$$

式中： $\beta(\lambda)$ 为待估的回归系数函数。将其在同一组基函数上展开为 $\beta(\lambda) = \sum_k b_k \varphi_k(\lambda)$ ，积分项可写作 $c_i' J b$ ，其中 J 为基函数的 Gram 矩阵。记设计矩阵 $Z = C J$ ，系数向量由带粗糙惩罚的广义最小二乘估计

$$\hat{b} = (Z' Z + \lambda_\beta s R)^{-1} Z' (y - \bar{y}) \quad (4)$$

式中： λ_β 为平滑参数； $s = \operatorname{tr}(Z' Z) / \operatorname{tr}(R)$ 为尺度因子。引入尺度因子是因为波长归一化后傅里叶基的 $\operatorname{tr}(R)$ 比 $\operatorname{tr}(J)$ 高 7~8 个数量级，若以绝对值设定惩罚强度，惩罚项将压制数据项而使系数函数退化为零。

1.3 函数型主成分回归

对展开系数矩阵 C 在函数内积意义下作主成分分解（以 Gram 矩阵 J 的 Cholesky 因子对 C 作变换后进行奇异值分解），取前 K 个函数型主成分得分建立多元线性回归， K 为待选超参数。并列考察 PFLR 与 FPCR，是因为二者代表函数型回归的两条路线：前者直接估计整条回归系数函数、以粗糙惩罚控制复杂度，其超参数 λ_β 是连续的；后者先作无监督降维再回归，其超参数 K 是离散的成分个数。两类超参数在小样本下是否同样难以选准，正是本研究要回答的问题之一。

2 试验部分

本文的总体流程如图 1 所示，分四段：三个产地两个年份的样品经光谱采集与预处理择优（区①），分别按函数型与离散两条路线表征建模（区②），在同一批折与同一调参预算下作嵌套交叉验证（区③），再经小样本、有效波段、样本划分与综合评价、跨批次四条线检验结论成立的条件（区④）。

2.1 试验材料与光谱采集

试验样品为红富士苹果，由本课题组采自新疆阿克苏、山东烟台与陕西洛川三个产地，分两个年份按相同方案采集，尚未公开发布；这三个产地的红富士苹果此前已用于基于光谱的产地溯源研究[10]。样品于室温 20 °C 下静置 24 h 后采集光谱。设备选用美国海洋光学公司 USB2000+ 型光纤光谱仪，光源为 JCR12V 100 W 卤钨灯，采用近红外透射方式，积分时间 120 ms、平均次数 3、平滑度 5，所得光谱覆盖 590.7~1 249.6 nm，共 2 048 个波长点。SSC 选用日本 ATAGO 公司 PR-101 型数字折光仪（精度 ± 0.1 °Brix）在光谱采集后立即作破坏性测定。以 (5, 25) °Brix 剔除异常后两个年份分别保留 629 个与 671 个样品，

合计 1 300 个（新疆 470、山东 416、陕西 414），全部样品为 $(13.42 \pm 1.66)^\circ\text{Brix}$ ；三个产地的均值分别为 14.48、12.60、13.06 $^\circ\text{Brix}$ ，1%~99% 分位区间互不重合，构成 3.6 节跨批次验证的背景。




图 1 研究流程与嵌套评价协议：① 数据与预处理；② 两条建模路线；③ 嵌套交叉验证，深蓝为外层测试折、浅蓝为内层验证折；④ 四条检验线，卡片编号即对应小节。各卡片内的微缩图由该步骤的产物绘制

Fig.1 Workflow and nested evaluation protocol: (1) data and preprocessing; (2) two modelling routes; (3) nested cross-validation (dark blue: outer test fold; light blue: inner validation fold); (4) four robustness lines numbered by subsection

2.2 光谱预处理

为抑制果实个体间光程差异与组织散射引起的基线漂移，比较 5 种预处理方案：不做处理、标准正态变量变换（standard normal variate, SNV）、多元散射校正（multiplicative scatter correction, MSC）、Savitzky-Golay 一阶导数（窗宽 15、二次多项式，记为 SG-1D）以及 SNV 与 SG-1D 的串联。图 1 区①给出三个产地的平均光谱：原始光谱在 590~800 nm 的产地间基线差异经 SNV 与一阶导数处理后被有效抑制。

2.3 对照模型与评价指标

离散建模对照按建模机理选取四类代表，以便把精度差异归因到机理：PLSR 代表线性潜变量方法，是光谱定量分析的行业基准；SVR（径向基核）代表核方法，用以判断差异是

否来自非线性；RF 代表树集成，不对波段间的平滑性作任何假定；1D-CNN 的卷积核沿波长滑动，是与函数型方法机理上最接近的对照。

除特别说明外，模型精度一律以嵌套交叉验证评价，其结构见图 1 区③：外层把 1300 个样本随机等分为 5 折，每次以其中 4 折（1040 个）训练、余下 1 折（260 个）测试；在每个外层训练折内部再等分为 5 折作内层交叉验证，各候选配置分别算 5 折的均方根误差均值、取最小者为选中配置，再用整个外层训练折重新拟合该配置，最后在对应的外层测试折上评价。不按比例作随机划分，是因为在同一次划分上既选参又报告精度会把选参的乐观偏倚计入最终精度，嵌套的两层把这两件事分开。本文报告的均值 $\pm$ 标准差、置信区间与配对检验，样本量均为 5 个外层折；划分方式是否影响结论在 3.2 节检验。随机折把两个年份的样品混在同一折里，它估计的是「同一批采集条件之内」的精度，跨批次表现在 3.4 节单独验证。例外是 3.3 节的小样本试验：训练集须由指定的 N 个样本构成，故每个 N 重复随机抽样 20 次取平均，内层取 4 折。

模型性能以测试集的决定系数 R^2 、均方根误差 RMSE 和相对分析误差 RPD 评价，其中 RPD 为测试集 SSC 参考值的标准差 s_y 与 RMSE 之比。三者在同一测试集上互为严格单调变换（ $R^2=1-(RMSE/s_y)^2$ ， $RPD=s_y/RMSE$ ），单靠这一组指标无法反映模型在误差分布其他方面的差别，故另构造一个综合评价指数，下文记为 LLH-GBID。其出发点是 DISO 指数：把模型的若干指标看作空间中的一点，以到理想点的欧氏距离衡量综合性能[11]。直接套用有两处不适配：其三项指标中有一项由另两项决定[12]，且各项取值范围不一致而使距离含有隐含权重（详见附录 A1）。故本文按评价含义划分 4 个维度、每维只取 1 项彼此不构成函数关系的指标：整体拟合取 R^2 ，平均误差取 MAE，大误差风险取绝对误差的 90% 分位数 P_{90} ，系统偏差取平均偏差 $bias$ ；把每项按方向映射为区间 $[0, 1]$ 的效用值 u_j （1 对应理论最优，0 对应以训练集均值预测的无技能基准； $bias$ 按目标型处理，容差 $0.25s_y$ ），记缺口 $d_j=1-u_j$ ，两级聚合为

$$D_a = [\sum_{j \in J_a} v_{j|a} d_j^{q_w}]^{1/q_w}, \text{ GBID} = [\sum_a W_a D_a^{q_B}]^{1/q_B} \quad (5)$$

两级权重均取等权，主分析取 $q_B=q_w=2$ ；定义 0—100 得分 GBIDS=100(1-GBID)，并设非补偿性准入门槛（ R^2 的效用不低于 0.5）。该框架为条件相对评价，仅用于同一试验条件下的方法比较，全部参数在计算任何综合指数之前一次锁定。

3 结果与讨论

3.1 预处理与基函数设定

方法之间的比较只有在条件相同时才有意义，故先把预处理与基设定这两项条件定下来。先在 5 折交叉验证下考察 5 种预处理与 4 种建模方法的组合（PLSR 的潜变量数在训练折内选取，其余三法用默认设置）。预处理的影响与方法存在交互（SVR 在 MSC 下最好、PLSR 在 SNV+SG-1D 下最优），而后续统一协议要同时容纳六个方法，故按四法平均择优：SNV+SG-1D 的四法平均 R^2 为 0.691，高于其余四种的 0.563~0.668，且是唯一使 RF 与 1D-CNN 都达到 0.63 以上的预处理（逐项见附录 A4）。这一选择用到了后来被当作测试折的数据，其影响在附录 A4 复核。

其次定基设定。傅里叶基与 B 样条基在 $L=40、60、80$ 下总体接近（PFLR 的 R^2 为 0.759~0.797 与 0.762~0.795）， $L=20$ 时因基函数过少而欠拟合；傅里叶基在 $L=80$ 时最优（ $R^2=0.797$ 、 $RMSE=0.739^\circ\text{Brix}$ ），FPCR 在同样八种设定下与 PFLR 八格中有七格相差不超过 0.005，仅 B 样条 $L=60$ 一格相差 0.014。后续取傅里叶基、 $L=80$ ，两个函数型模型共用同一组基设定，以使二者的差别只来自正则化方式。3.3 节的小样本试验改取 B 样条基、

L=40，因为该节 N 最小为 20，L=80 已远超训练样本量。

3.2 等预算下的方法比较与统计判定

条件既已统一，先回答函数型建模能否替代离散方法这一问。六个方法在此共用 2.3 节的同一批外层折与内层折、同为 SNV+SG-1D 预处理，候选配置数一律为 12 组，即各方法所获的调参预算在数量上相同；两个函数型模型的基个数固定为 L=80，12 组候选全部留给各自的正则化参数。候选数相同并不等于搜索空间等价，其边界见附录 A1。网格经两轮边界诊断与扩张后已不构成截断（附录 A1）。结果如表 1 所示。

表 1 统一协议下各建模方法的预测精度

Tab.1 Prediction accuracy of each modelling method under the unified protocol

建模方法	数据表征	R ²	RMSE/°Brix	RPD
SVR	离散	0.799±0.042	0.735±0.076	2.27±0.23
PFLR（傅里叶，L=80）	函数型	0.797±0.039	0.739±0.067	2.25±0.21
FPCR（傅里叶，L=80）	函数型	0.783±0.041	0.764±0.066	2.18±0.19
PLSR	离散	0.763±0.018	0.803±0.047	2.06±0.07
1D-CNN	离散	0.725±0.022	0.867±0.069	1.91±0.08
RF	离散	0.678±0.025	0.937±0.075	1.77±0.07

注：SNV+SG-1D 预处理；嵌套交叉验证（外层 5 折、内层 5 折），表中为 5 个外层折的均值 ± 标准差，标准差按这 5 折的总体标准差计（除以 5）；各方法的 12 组候选见附录表 A1。

由表 1 可知，SVR 的精度最高（R²=0.799，RMSE=0.735 °Brix，RPD=2.27），函数型方法中 PFLR 最好（0.797，0.739，2.25），两者相差 0.002。逐折配对比较，PFLR 相对 PLSR 平均高出 0.034、5 折中 4 折占优，相对 FPCR 高出 0.014、5 折全占优。即函数型建模用 80 个基函数把维度压缩到约 1/25，其平均精度高于使用全部 2 048 个波段的 PLSR，但该差距经 Holm 校正后未达显著（见本节后半），本文亦未预设非劣界值作等价检验，故只能说二者处于同一精度水平而不能断言孰优；相对 SVR 的差距已小于逐折波动，是否构成实质差异见本节后半。

条件统一的必要性可由调参前后的对照看出：3.1 节各方法沿用默认超参数时，SVR、RF 与 1D-CNN 的 R² 为 0.713、0.655 与 0.632，均低于 PLSR 的 0.763；获得同等的 12 组候选后升至 0.799、0.678 与 0.725，SVR 由 PLSR 之下抬到之上，即调参预算是否对等直接改变了排序。1D-CNN 调参后仍仅高于 RF，与其可训练参数（35 万至 114 万）远多于每折 1 040 个训练样本有关。

以上比较均建立在 5 折嵌套交叉验证与单项指标之上，其结论是否依赖于这两项设定，需要单独检验。划分方面另换四种方式：按 70% 与 75% 两种比例作重复随机划分（各 5 次）、以 SPXY 与 Kennard-Stone 算法各选取 75%（两者的差别在于是否使用参考值取样）；四种新划分只考察表 1 中精度居前的四个方法。指标方面按 2.3 节的 LLH-GBID 框架另取 MAE、P90 与 bias，与 R² 构成 4 个维度：六个方法的 GBIDS 依次为 SVR 70.4、PFLR 69.6、FPCR 68.8、PLSR 64.8、1D-CNN 61.5 与 RF 57.6（bootstrap 95% 置信区间宽 1.7~4.3），综合排序与前文按 R² 的排序一致，前三名之间的间距（0.8 与 0.8）明显小于第三、四名之间的间距（4.0）。




图 2 综合评价的统计判定与稳健性: (a) 各方法相对 SVR 的 GBID 差值与 95% 置信区间 (实心为 Holm 校正后显著); (b) 同一批差值的贝叶斯后验分区 ($\epsilon=0.02$); (c) 九种设定下按 GBIDS 的名次 (浅色区为四项灵敏度分析, 右侧为四种替代划分); (d) 五种划分下各方法在该划分内的 R^2

Fig.2 Statistical judgement and robustness of the composite ranking: (a) GBID difference relative to SVR with 95% CI (filled: significant after Holm correction); (b) Bayesian posterior partition ($\epsilon=0.02$); (c) rank under nine settings (shaded: sensitivity analyses; right: alternative partitions); (d) within-partition R^2 under five partitions

次序之外还需判断每一处差距是否成立, 结果如图 2 所示。图 2(a) 以综合最优的 SVR 为参照给出其余五个方法的 GBID 差值与 95% bootstrap 置信区间, 配对检验取 Nadeau-Bengio 修正 (外层折的训练折两两重叠达 3/4, 按独立样本算方差会低估不确定性) 并按 Holm 校正; 「未达显著」不足以区分「确实相近」与「样本量不足」, 故另作贝叶斯相关 t 检验、以 $\epsilon=0.02$ 为实际等价区间, 后验三分区见图 2(b)。两个面板并读: SVR 相对 PLSR 与 RF 的优势在两种检验下都成立; 它与 FPCR、PFLR 的差值置信区间跨过 0、且有过半概率落在等价区间内, 领先并不构成实质差异; 1D-CNN 一行则配对检验未达显著而贝叶斯检验判为 SVR 实质更优。对全部 15 个方法对在折级 R^2 上重做配对检验, Holm 校正后达到显著的只有 1 对; PFLR 与 PLSR 的 R^2 之差为 0.0337、5 折中 PFLR 占优 4 折, 但校正后 $p=1.000$ 、未达显著。故本文把该处论断限定为「用 80 个基函数取得了与全波段 PLSR 同一水平的精度」, 既不称函数型模型更准, 也不作非劣声明, 后者需预设界值的等价检验、本文未做。

图 2(c) 给出这一排序在九种设定下的名次, 即四项评价灵敏度分析 (短板参数配置、随机与扰动权重、基准值取法、相关性处理) 与四种替代划分: 六个方法的名次无一处变动, 两两 Kendall τ 全为 1.000; 但排序稳定不等于前两名可以区分, 2000 次重采样中 SVR 与 PFLR 居首的频率为 60% 与 40%。图 2(d) 给出五种划分下的精度绝对水平: 水平随划分变动而次序不变。两种确定性划分所留测试集的 SSC 标准差 (1.47 与 1.55 °Brix) 小于外层折的约 1.65 °Brix, 而 R^2 以该标准差为分母, 故不同划分下的 R^2 不可直接比较, 同一划分内的方法比较则不受影响。预处理选择的影响另作复核 (附录 A4): 五种预处理下 SVR

均排第一、PLSR 均排末位，把预处理并入折内选择后四个方法的排序仍与表 1 一致。

3.3 小样本下的超参数选择失效

上一节的比较用的是全部 1 300 个样本，而破坏性标定的实际约束恰在样本量：每增加一个标定样本即毁掉一枚果实。函数型方法以光滑性先验换取更少的自由参数，本应在此占优，故本节把样本量本身作为变量。将训练集样本量 N 由 20 逐步增至 400，每个 N 重复抽样 20 次，各模型的精度演变如图 3 所示，各样本量下的数值列于附录表 A2。离散对照同时列入 PLSR 与 SVR，因为 3.2 节已表明 SVR 是本数据上最强的离散方法。




图 3 训练集样本量与超参数选择策略对预测精度的影响：(a) 固定超参数；(b) 交叉验证选参；(c) 同一次抽样下两种策略的 R^2 差值（阴影为 20 次重抽的标准误）

Fig.3 Effect of training set size and hyperparameter selection: (a) fixed hyperparameters; (b) cross-validated selection; (c) paired difference in R^2 (shaded: standard error over 20 resamples)

以固定超参数比较，函数型方法确实明显优于 PLSR： $N=80$ 时 FPCR 为 0.443、PLSR 为 0.290。但把 SVR 纳入对照后这一优势不再成立。此处 SVR 的输入与 3.2 节统一协议一致，为预处理后的光谱、不再额外标准化，该口径的敏感性见附录 A2；按此口径，SVR 在每一个样本量、两种超参数策略下都不低于两种函数型模型（如 $N=20$ 时为 0.158，而 FPCR 与 PFLR 为 -0.115 与 -0.556）。故函数型建模在小样本下的精度优势是相对 PLSR 而言的，而 PLSR 恰是这一区间中最弱的离散方法。

随模型类别真正分化的不是精度，而是交叉验证能否在小样本下选对超参数。当 K 与 λ_β 改由训练集内的 4 折交叉验证选择时，FPCR 在 $N=80$ 时的 R^2 由 0.443 降至 0.094、落差 0.349，PFLR 由 0.357 降至 0.238、落差 0.119，而同一样本量下 SVR 的两种策略之差仅为 0.018。由图 3(c) 可见，FPCR 的落差在 $N=30\sim 80$ 区间始终最大，且要到 $N=200$ 才转为交叉验证占优，而 SVR 与 PFLR 在 $N=120$ 时即已转正。

该差别并非源于函数型模型的超参数更为敏感。在 $N=80$ 下把各方法的 12 组候选逐个跑出，候选之间的 R^2 极差 SVR 为 0.567，反而大于 FPCR 的 0.389 与 PFLR 的 0.376；差别在于交叉验证能否把好的那一档挑出来：交叉验证选出的配置与网格最优之差，SVR 为 0.061、PFLR 为 0.170，FPCR 则达 0.380（最优 0.474、选出 0.094），20 次重抽中有 10 次选中网格上表现最差的 $K=20$ ，直接原因是小样本下误差估计本身不稳定（附录 A2），而 FPCR 在 $K=8\sim 15$ 之间均可达 0.385~0.474，故「保守」应理解为取中等偏小的 K 。综上，在 $N=30\sim 80$ 区间函数型模型宜固定一个保守的超参数，两种策略的交叉点因模型而异、不宜跨模型外推。

3.4 跨批次外部验证与失效分解

以上各节都在同一批样品内部划分，模型见过测试样品所属产地与年份的采集条件；换

产地、换年份后还能不能用，需要完全不参与训练的集合。先看跨产地（按产地划分而不沿用随机折，否则训练折里已含目标产地的样本）：以山东样本建立的模型直接用于新疆样本时 R^2 为 -0.677 ，出现明显的负迁移；以陕西样本建模直用于新疆同为负迁移（ -0.473 ）。反方向为 0.085 ，不对称性与两地 SSC 分布的位置关系一致（以山东建模时有 20.6% 的新疆样本高于训练集的 99% 分位、模型须向上外推）；三个产地的六个有向组合未跑全，故不对称性只在山东↔新疆这一对上得到双向验证。函数型迁移学习为这类跨域问题提供了可参考的框架[13]，其在光谱数据上的适用性尚待检验。若在目标产地采集 40 个标定样本重新建模（ 15 次重抽平均），以 PLSR 重建可将山东→新疆的 R^2 提升至 0.424 ，以交叉验证选参的 PFLR 重建则仅为 0.265 ，与 3.3 节一致。故更换产地时宜采集少量目标产地样本重新标定，且宜采用固定超参数。




图 4 模型离开训练分布后的失效分解：(a) 跨年 R^2 （空心）与扣除整体偏差后的 R^2 （实心），右侧为预测-实测相关系数；(b) 共形预测区间的校准，曲线为同分布的经验覆盖率，倒三角为跨年时名义 0.90 的实际覆盖率

Fig.4 Failure decomposition outside the training distribution: (a) cross-year R^2 before (open) and after (filled) removing the overall bias, with predicted-measured correlation; (b) conformal interval calibration within distribution (curves) and across years at nominal 0.90 (triangles)

再以采集年份作外部集：两个年份是两次独立采集，SSC 分布为 12.92 ± 1.47 与 13.89 ± 1.68 °Brix (Welch $t = -11.11$, $p < 0.001$)，自变量与因变量同时偏移。在训练年份内按同一协议选参并重拟合，再对另一年份一次性预测，两个方向各做一次，结果如图 4 所示。六个方法的跨年 R^2 全部低于同年 R^2 （后者为 $0.608 \sim 0.822$ ），其中 11 次（共 12 次）为负值。但 R^2 为负并不等于模型没有学到光谱与含量的关系：由图 4(a) 可知，跨年偏差的绝对值达 $1.119 \sim 2.403$ °Brix，方向与两个年份的含量高低一致，扣除这一整体偏移后，按方法对两个方向取平均的 R^2 回升到 $0.014 \sim 0.445$ ；但逐方向看 12 项中仍有 2 项为负（全体范围 $-0.600 \sim 0.628$ ），且这 2 项恰为两个函数型模型在 $2019 \rightarrow 2018$ 方向上（FPCR -0.205 、PFLR -0.600 ）。预测值与实测值的相关系数在去偏前后不变，说明跨年误差中相当大的一部分来自标定水平的整体漂移而非判别能力的丧失。需说明的是，此处去偏用的是外部集自身的真实平均残差、属事后分解；「用少量新批次样品重新校正截距即可」是由该分解推出的处置建议，本文未作不同校正样本量的独立验证，尚待检验。图 4(a) 同时显示同年占优的两个函数型模型在去偏后的跨年指标上退化幅度最大，次序变为 SVR 与 PLSR 领先：函数型建模「以更强的先验换更少的自由参数」这一优势的成立条件较窄，一旦离开训练分布，平

滑性先验反而使系数函数难以适应新的批次条件。

预测区间在同一处发生同样的失效。图 4(b) 给出分裂共形区间的校准（构造方式见附录 A5）：同分布条件下六个方法在 50%~95% 六个名义水平上的经验覆盖率与名义值几乎一致（平均绝对偏差 ≤ 0.0018 ），而以 2018 年折外残差定出的 90% 区间用于 2019 年时实际覆盖率大幅低于名义值，区间同样需要在新批次上重新校准；以 2018 年样品的主成分重构误差作分布外分数，可在本研究的两个年份之间区分批次（年份判别 AUC 为 0.929）；但样本只涵盖两个批次，该分数能否对未知新批次可靠报警尚未验证。标签置换负控（1 000 次重跑， $p=0.0010$ ）表明流程本身不产生虚假信号；折外残差最大的样品指向对高糖区间补充标定样本而非更换建模方法（附录 A6）。

3.5 回归系数函数与有效波段

以上三节回答了函数型建模在什么条件下可用、何时不可用；本节转向它另一处不依赖精度的价值，即回归系数函数可直接读出各波长的贡献。如图 5 所示，PFLR 模型的回归系数函数其绝对值在 868~957 nm 区间最为集中，在 1 125~1 153 nm 存在次级极值。该窗口邻近水的 O—H 伸缩二级倍频吸收带，文献[14]报道苹果果肉在 900~1 650 nm 的吸收与散射同 SSC 及可溶性糖含量相关，故系数主峰的位置在化学上可解释；但该文献未把水与糖的贡献分离，本数据同样不足以作此区分。




图 5 PFLR 模型的回归系数函数（阴影为极值窗口，虚线为 900 nm 常规划分界线）

Fig.5 Regression coefficient function of the PFLR model (shaded: windows of extrema; dashed: the conventional 900 nm boundary)

以约 100 nm 为步长将全波段划分为 6 个子区间分别建模：700~800 nm 单独建模的 R^2 最高（0.682），590~700 nm 与 800~900 nm 为 0.345 与 0.309，而 900 nm 以上均不超过 0.194；按整段建模，590~900 nm 可达 0.761，900~1 250 nm 仅为 0.171。这与回归系数函数的极值位置并不矛盾：系数主峰位于 868~957 nm，恰好跨越 900 nm 这一常规划分界线，按此切分会将该信息窗口一分为二。长波区整段建模失效的原因不在信号质量而在预处理后的协方差结构（附录 A3）。综上，PFLR 系数函数的主极值窗口位于跨越可见与近红外分界的 868~957 nm，而单区间精度最高的是 700~800 nm。二者不重合，说明系数极值窗口标示的是该模型赋权最重之处，并不等同于唯一的有效信息区。

4 结论

本文以近红外透射光谱预测三个产地红富士苹果的可溶性固形物含量，建立惩罚函数型线性回归与函数型主成分回归模型，并在统一协议下与四种离散建模方法比较，主要结论如下：

（1）基函数展开把维度压缩到约 1/25 而未以精度为代价，但函数型方法的精度优势是相对偏最小二乘回归而言的。统一协议下惩罚函数型线性回归以 80 个傅里叶基取得

$R^2=0.797$ 、 $RMSE=0.739$ °Brix, 不低于使用全部 2 048 个波段的偏最小二乘回归 (0.763、0.803), 但配对 t 检验 Holm 校正后 $p=1.000$ 、未达显著; 支持向量回归在全样本 (0.799)、全部训练集样本量与两种超参数策略下均不低于两种函数型模型, 该排序在五种样本划分与四项灵敏度分析下均不改变, 但它与两个函数型模型的差值有过半概率落在实际等价区间内。故本文的论断是等精度降维, 而非函数型模型更准; 若不给对照方法同等的调参预算, 该排序即被颠倒。

(2) 小样本下交叉验证难以为函数型模型选对超参数, 其代价大于模型类别的差异。训练集样本量为 80 时, 由固定超参数改为交叉验证选择使函数型主成分回归的 R^2 由 0.443 降至 0.094, 而支持向量回归仅 0.018; 根源不是函数型模型的超参数更敏感 (12 组候选之间的 R^2 极差前者 0.389、后者 0.567), 而是交叉验证选出的配置与网格最优之间的差距 (0.380 对 0.061)。故在 $N=30\sim80$ 区间函数型模型宜固定一个保守的超参数, 两种策略的交叉点因模型而异, 不宜跨模型外推。回归系数函数的极值集中于 868~957 nm, 跨越 900 nm 这一常规划分界线, 按区间切分建模会将其割裂。

(3) 模型在离开训练分布后精度优势不保持。跨产地直接迁移存在负迁移与方向不对称性 (山东→新疆 $R^2=-0.677$, 反向 0.085), 采集 40 个目标产地样本重新标定可将前者提升至 0.424; 以采集年份作外部集时六个方法的跨年 R^2 多数为负, 其中相当大的一部分来自标定水平的整体漂移: 按方法平均的去偏后 R^2 回升至 0.014~0.445、相关系数保持在 0.431~0.793, 但逐方向仍有 2 项为负且恰为两个函数型模型, 即去偏后函数型退化幅度最大; 共形预测区间跨年使用时明显失准。故报告函数型建模的精度时应同时报告跨批次表现, 并在新批次上重新校准。标签置换负控 (1 000 次, $p=0.0010$) 表明以上精度不是流程制造的。

本研究的局限有三: 样本涵盖单一品种 (红富士), 对其他品种的适用性尚待验证; 预处理、基设定与候选网格三层选择发生在同一批外层折上, 三层已在附录 A4 一并嵌套进折内复核, 六个方法的排序与表 1 逐项一致 (其中 1D-CNN 的复核在 GPU 上完成, 与表 1 的 CPU 训练含设备差异); 外部集为同一课题组、同一台仪器的另一年份, 对更换仪器的情形只能作参考。能否以其他基函数族或正则化方式缩小函数型模型与核方法的差距, 值得进一步研究。

参考文献:

- [1] BLASCO J, GORLA G, MUNERA S, et al. Non-destructive spectral systems (NDSS) for modern inspection systems in real-time: challenges and industrial perspectives[J]. TrAC Trends in Analytical Chemistry, 2025, 191: 118369.
- [2] 班兆军, 高喧翔, 马肆恒, 等. 基于高光谱和深度学习的苹果品质无损检测方法[J]. 江苏农业学报, 2024, 40(8): 1446-1454.
BAN Z J, GAO X X, MA Y H, et al. Non-destructive detection method of apple quality based on hyperspectral and deep learning[J]. Jiangsu Journal of Agricultural Sciences, 2024, 40(8): 1446-1454. (in Chinese)
- [3] MA T, ZHAO J, INAGAKI T, et al. Rapid and nondestructive prediction of firmness, soluble solids content, and pH in kiwifruit using Vis-NIR spatially resolved spectroscopy[J]. Postharvest Biology and Technology, 2022, 186: 111841.
- [4] 郭俊先, 马永杰, 郭志明, 等. 流形学习方法及近红外透射光谱的新疆冰糖心红富士水心鉴别[J]. 光谱学与光谱分析, 2020, 40(8): 2415-2420.

- GUO J X, MA Y J, GUO Z M, et al. Watercore identification of Xinjiang Fuji apple based on manifold learning algorithm and near infrared transmission spectroscopy[J]. Spectroscopy and Spectral Analysis, 2020, 40(8): 2415-2420. (in Chinese)
- [5] MA T, XIA Y, INAGAKI T, et al. Rapid and nondestructive evaluation of soluble solids content (SSC) and firmness in apple using Vis-NIR spatially resolved spectroscopy[J]. Postharvest Biology and Technology, 2021, 173: 111417.
- [6] ACQUARELLI J, VAN LAARHOVEN T, GERRETZEN J, et al. Convolutional neural networks for vibrational spectroscopic data analysis[J]. Analytica Chimica Acta, 2017, 954: 22-31.
- [7] RAMSAY J O, SILVERMAN B W. Functional data analysis[M]. 2nd ed. New York: Springer, 2005.
- [8] 黄威, 高林妹, 郭文雯, 等. 基于光谱成像的人血和两种动物血痕迹的函数型数据分析[J]. 刑事技术, 2021, 46(6): 551-558.
- HUANG W, GAO L M, GUO W W, et al. Analysis into functional data of spectral images from bloodstains of human and two species of animal[J]. Forensic Science and Technology, 2021, 46(6): 551-558. (in Chinese)
- [9] 黄华, 刘亚, 马毅航, 等. 基于可见/近红外光谱和函数型线性回归模型的成熟期苹果可溶性固形物含量预测[J]. 光谱学与光谱分析, 2024, 44(7): 1905-1912.
- HUANG H, LIU Y, MA Y H, et al. Prediction of soluble solid contents in apples using Vis-NIRS and functional linear regression model[J]. Spectroscopy and Spectral Analysis, 2024, 44(7): 1905-1912. (in Chinese)
- [10] 黄华, 南梦迪, 李政浩, 等. 分数阶微分预处理及 PCA-SRDA 的多模型融合对红富士苹果产地溯源[J]. 光谱学与光谱分析, 2022, 42(10): 3249-3255.
- HUANG H, NAN M D, LI Z H, et al. Multi-model fusion based on fractional differential preprocessing and PCA-SRDA for the origin traceability of Red Fuji apples[J]. Spectroscopy and Spectral Analysis, 2022, 42(10): 3249-3255. (in Chinese)
- [11] HU Z, CHEN X, ZHOU Q, et al. DISO: A rethink of Taylor diagram[J]. International Journal of Climatology, 2019, 39(5): 2825-2832.
- [12] XU Z, HAN Y. Short communication comments on 'DISO: A rethink of Taylor diagram'[J]. International Journal of Climatology, 2020, 40(4): 2506-2510.
- [13] WANG Z, MAO X, KIM J K, et al. Selection bias adjustment by functional transfer learning via reproducing kernel Hilbert space[J]. Journal of Business & Economic Statistics, 2026, 44(1): 177-187.
- [14] FANG L, WEI K, FENG L, et al. Optical absorption and scattering properties at 900-1 650 nm and their relationships with soluble solid content and soluble sugars in apple flesh during storage[J]. Foods, 2020, 9(12): 1881.

附录 A 候选网格与补充核验

A1 各方法的候选网格

第一轮网格（表 A1 左列）跑完后作边界诊断：SVR 的 $C=1\ 000$ 、FPCR 的 $K=30$ 与

1D-CNN 的层数 4 在 5 个外层折中全部被选中，RF 的树数 800 在 3 折被选中，四者均为各自网格的上边界，此时把网格内的最优当作该方法的能力构成低估。重定规则在看第一轮结果之前即已写定，对四个方法一律适用：沿被截断的那一维平移或扩张，使第一轮选中值落入新网格内部；候选数仍为 12；扩张到该超参数的结构上限为止（FPCR 的 $K \leq L-1=79$ ；1D-CNN 每层把特征图长度降为 1/4，第 6 层即为 0，层数上限为 5）；只删从未被选中的那一端取值。LLH-GBID 直接套用 DISO 的两处不适配为：其一，DISO 的三项指标中有一项由另两项决定，相关指标各占一个坐标轴等于把同一信息重复计权；其二，除以标签标准差只消去物理单位，各项取值范围仍不一致，距离中含有一组未经声明的隐含权重。两个函数型模型的基个数固定为 $L=80$ （3.1 节），12 个候选全部留给各自的正则化参数。候选数相同并不等于搜索空间等价：各方法的网格跨度与超参数性质本就不同（连续的正则化系数与离散的成分个数不可直接类比），且函数型模型的基族与 L 是在同一批外层折上先行选定的，这一层未嵌套进外层评价，其影响见结论中的局限性。取 12 是因为它在各方法各自合理的参数范围内都能自然构成（如 SVR 为 4×3 、RF 为 3×4 ），既保证预算相等，又不必把某一方法的网格外扩到无意义的区域。重定对各方法的影响方向并不一致（FPCR 与 1D-CNN 的 R^2 提高 0.019 与 0.015，PFLR 提高 0.001，SVR 反而下降 0.012），若规则是按结果定制的不会得到这样的分布。第二轮网格见表 A1 右列，表 1 与 3.3~3.6 节均用第二轮网格。

表 A1 统一协议下各建模方法的两轮候选配置

Tab.A1 Candidate configurations of each modelling method in the two grid rounds under the unified protocol

建模方法	第一轮候选（12 组）	第二轮候选（12 组，本文采用）
PLSR	潜变量数 2, 4, ..., 24	同第一轮（选中值 12~20 均在内部）
SVR	$C \in \{1, 10, 10^2, 10^3\} \times \text{gamma} \in \{\text{scale}, 10^{-3}, 10^{-4}\}$	$C \in \{10, 10^2, 10^3, 10^4\} \times \text{gamma}$ 同左
RF	树数 $\in \{200, 400, 800\} \times$ 特征比例 $\in \{\sqrt{p}, 0.1, 0.3, 1.0\}$	树数 $\in \{400, 800, 1\ 600\} \times$ 特征比例同左
1D-CNN	(宽度, 层数) $\in \{(16, 3), (32, 3), (16, 4)\} \times$ 学习率 $\in \{10^{-3}, 3 \times 10^{-4}\} \times$ 丢弃率 $\in \{0.2, 0.4\}$	宽度 $\in \{16, 32\} \times$ 层数 $\in \{3, 4, 5\} \times$ 学习率同左，丢弃率固定 0.2
FPCR	$L \in \{40, 80\} \times K \in \{5, 10, 15, 20, 25, 30\}$	$L=80, K \in \{5, 10, 15, 20, 25, 30, 40, 50, 60, 70, 75, 79\}$
PFLR	$L \in \{40, 80\} \times \lambda_\beta \in \{10^{-8}, 10^{-6}, 10^{-4}, 10^{-2}, 1, 10^2\}$	$L=80, \lambda_\beta \in \{10^{-10}, 10^{-9}, \dots, 10^1\}$

A2 小样本试验的精度数值

3.3 节各训练集样本量、两种超参数选择策略下的 R^2 列于表 A2，图 3(a)、(b) 即由该表绘制。表中 SVR 的输入与 3.2 节统一协议一致，为预处理后的光谱、不再额外标准化；若另加标准化，两者在小样本端互有胜负：N=20 时标准化更好（0.225 对 0.158）、N=50 时相反（0.366 对 0.413），按标准化口径 N=50 一档 FPCR 的 0.373 将略高于 SVR，即正文「SVR 在每一个样本量上均不低于函数型模型」以不额外标准化为前提。交叉验证在 N=80 时为 FPCR 选错 K 的直接原因是误差估计本身不稳定：此时 4 折交叉验证每折仅约 20 个样本，所选 K 处 4 折 MSE 的相对标准差中位为 26%，各候选的交叉验证均值之差常被这一波动淹没。

表 A2 不同训练集样本量与超参数选择策略下的预测精度 (R^2)Tab.A2 Prediction accuracy (R^2) under different training set sizes and hyperparameter selection strategies

N	PLSR	SVR	SVR	FPCR	FPCR	PFLR	PFLR
		固定	交叉验证	固定	交叉验证	固定	交叉验证
20	0.005	0.158	0.042	-0.115	-0.026	-0.556	-0.349
30	0.055	0.262	0.154	0.167	-0.020	0.051	-0.060
50	0.192	0.413	0.356	0.373	0.115	0.266	0.183
80	0.290	0.493	0.475	0.443	0.094	0.357	0.238
120	0.326	0.547	0.640	0.478	0.391	0.444	0.468
200	0.468	0.629	0.735	0.497	0.641	0.502	0.633
400	0.654	0.689	0.780	0.512	0.665	0.500	0.687

注：B 样条基， $L=40$ ；每个样本量重复抽样 20 次取平均，测试集为其余样本中的 400 个；固定超参数取 FPCR 的 $K=10$ 、PFLR 的 $\lambda_\beta=10^{-3}$ 、SVR 的 $C=100$ 与 $\gamma='scale'$ ，均在试验前设定；负值表示预测劣于用均值预测。

A3 长波区整段建模失效的原因

3.5 节中 900~1 250 nm 整段建模的 R^2 仅为 0.171，其原因不是信号质量：原始强度下 900 nm 以上各区间的信噪比为 513~814，高于可见光区的 168~480，且不存在信号饱和。差别出现在预处理之后：在实际送入模型的 SNV+SG-1D 光谱上，590~900 nm 有 61.0% 的波段与 SSC 的相关系数绝对值超过 0.2、该区间协方差谱的有效维数（取协方差谱的指数熵）仅为 2.5，即数百个波段承载的是少数几个方向一致的变异；而 1 000~1 250 nm 相应比例降至 14.2%、有效维数升至 11.4，变异分散在许多近乎独立的方向上，缺少可供潜变量方法提取的共同成分，而不是没有任何与 SSC 相关的波段（该区间单波段相关系数的最大值仍有 0.298）。

A4 预处理选择的复核

3.1 节按四个模型的平均值选定 SNV+SG-1D，其影响以两种方式复核。其一，换预处理重跑：五种预处理下 SVR 均排第一、PLSR 均排末位，四种替代预处理中有 2 种给出完全相同的排序，另外两种仅使 FPCR 与 PFLR 互换次序；且 SNV+SG-1D 并非对某一个方法最有利的预处理（SVR 在 SNV 下可达 0.840，高于 SNV+SG-1D 下的 0.801）。其二，把预处理并入超参数，在每个外层训练折内由内层 5 折从 5 种预处理 $\times$ 12 组超参共 60 个组合中选优，外层测试折不参与任何一次选择：四个方法的 R^2 为 SVR 0.840、PFLR 0.799、FPCR 0.796、PLSR 0.755，排序与表 1 一致，与固定 SNV+SG-1D 逐一对照的变化为 -0.009~+0.039。其三，把基设定与候选网格也一并嵌套进折内：在每个外层训练折内由内层 5 折从 5 种预处理 $\times$ 4 种基设定（两个基族 $\times L \in \{40, 80\}$ ） $\times$ 12 组超参中选优，其中网格先按 3.2 节的重定规则在折内作一次边界诊断与扩张；外层测试折不参与任何一次选择，也不参与网格的形状。四个方法的 R^2 为 SVR 0.840、PFLR 0.799、FPCR 0.791、PLSR 0.755，排序仍与表 1 一致，与表 1 逐一对照的变化为 -0.008~+0.041。这一层复核并非走过场：折内边界诊断在 SVR 的 5 折、FPCR 的 4 折、PFLR 的 3 折上都触发了网格重定；基设定的折内选择也未必复现 3.1 节的结论：FPCR 有 2 折、PFLR 有 1 折选中 B 样条基而非傅里叶基，但 L 一律为 80。即这三层选择虽确实发生在同一批外层折上，其对方法排序与两条核心论断的影响可由该独立复核界定为零。RF 与 1D-CNN 亦按同一口径补做了第三项检验（远程单卡补跑，RF 用时 19.2 h；1D-CNN 约需 2 400 次拟合，以 8 个进程并行计算

内层格点得分、再由单进程据此完成三层选择，墙钟 2.5 h)。至此六个方法齐备，三层全嵌套后的排序为 SVR > PFLR > FPCR > PLSR > 1D-CNN > RF，与表 1 逐项一致，六法与表 1 对照的变化为 -0.008~+0.041 (其中 PLSR 与 1D-CNN 仅相差 0.005，二者的先后不宜视为稳健)。RF 的 R^2 为 0.678，与表 1 的 0.678 相差 -0.000，5 折均独立选中 SNV+SG-1D，折内边界诊断在 3 折触发网格重定；1D-CNN 的 R^2 为 0.750，与表 1 的 0.725 相差 +0.026，5 折全部触发网格重定，且没有一折选中 3.1 节定下的 SNV+SG-1D (依次为 MSC、原始、MSC、MSC、原始)，对该方法而言这一层复核尤其不是走过场。需说明计算设备：1D-CNN 的这次复核在 GPU 上完成，而表 1 的 1D-CNN 在 CPU 上训练。网络结构、优化器、学习率调度、随机种子与训练轮数逐项一致，但 dropout 在两种设备上取自不同的随机数流，同配置下的折外预测因此有差异 (本项目实测同配置 R^2 为 0.6516 对 0.6540)，故该行与表 1 之差含设备差异在内，不宜逐位解读。

A5 预测区间与分布外检测

图 4(b) 的预测区间用分裂共形方法构造：对每个外层折的样品，取其余 4 折的折外绝对残差作校准集、以其分位数为半宽。选它而非正态假设下的 $\pm 1.96\sigma$ ，是因为折外残差既不服从正态也不同方差。同分布条件下六个方法在 50%~95% 六个名义水平上的经验覆盖率与名义值几乎一致 (平均绝对偏差 ≤ 0.0018)，而以 2018 年折外残差定出的 90% 区间用于 2019 年时实际覆盖率大幅低于名义值。配套的分布外检测以 2018 年样品的主成分重构误差作分数：它能可靠识别批次层面的差异 (年份判别 AUC 为 0.929)，但不能预测单个样品预测得好不好，适合用作「该批次是否需要重新标定」的警报。

A6 标签置换负控与失败样本分析

标签置换负控：将含量标签随机打乱后把完全相同的流程重跑 1 000 次，4 个方法的零分布均值均为负 (-0.348~-0.050)、最大值 (-0.007) 也远低于各自的观测值 ($p=0.0010$)，说明流程本身不产生虚假信号；RF 与 1D-CNN 单次 5 折需 230 s 与 2 600 s，1 000 次置换超出算力预算，未纳入。失败样本分析：取每个方法折外绝对残差最大的 20 个样品，六个方法合计 120 人次实际只落在 57 个样品上，可见问题主要在样品一侧；这些样品的含量集中于分布两端 (45.6% 落在两尾各 10% 区间内，随机应为 20%，且低端残差为正、高端为负，即回归的向均值收缩)，并集中于新疆阿克苏 2018 年这一单元格 (富集 2.69 倍)，成因是该产地含量均值最高 (14.48 °Brix) 且分布最宽，其光谱异常度反而低于山东烟台。对实际应用而言，这指向对高糖区间补充标定样本，而不是更换建模方法。