

Study on the determination of fetal chromosomal abnormalities based on multi-model regression

Panlin Li¹, Ning Zhang¹

¹ College of Mathematics and Physics, Xinjiang Agricultural University, Urumqi, China, 830052

Keywords: 女胎染色体异常; SMOTE 过采样; 逻辑回归; Probit 回归; 鲁棒概率回归; GC 含量.

Abstract: 针对女胎染色体异常判定问题, 本文在缺乏 Y 染色体作为检测参考的情况下, 综合考虑孕妇及胎儿的 X 染色体与 21、18、13 号染色体的 Z 值、GC 含量、读段数及相关比例、BMI 等多维因素, 构建了科学的判定模型。为解决样本类别不平衡问题, 引入 SMOTE 过采样技术, 将少数类样本扩增至与多数类相等的规模。建模方法方面, 分别构建了逻辑回归、Probit 回归以及自适应范数鲁棒概率回归三类模型体系。实验结果显示, 逻辑回归在 T18 异常检测中表现最佳 (准确率 76.0%, AUC=0.821); Probit 回归在边际效应解释方面具有优势 (准确率 76.0%, AUC=0.739); 自适应范数鲁棒模型则在 T13 异常检测中实现了 87.5% 的高准确率。特征重要性分析表明, GC 含量在所有异常类型的判定中均占据主导地位。研究结果验证了所建模型的有效性与可解释性, 为无创产前检测提供了新的方法学支持。

1. Introduction

T 染色体非整倍体 (尤其是 21、18、13 号染色体的三体异常) 是导致胎儿发育障碍和围生期死亡的主要遗传学原因之一。无创产前检测 (Non-Invasive Prenatal Testing, NIPT) 通过检测母体血浆中的游离胎儿 DNA (cell-free fetal DNA, cfDNA), 已经成为临床筛查胎儿染色体异常的主要手段[1-2]。近年来, 大规模队列研究表明, NIPT 在 21、18、13 号染色体异常检测中具有较高的敏感性和特异性, 但在阳性预测值方面仍受孕妇年龄、胎儿分数及测序偏差等因素影响[3-4]。

在测序数据分析中, GC 含量偏差被认为是影响 Z 值判定准确性的主要混杂因素之一。已有研究通过引入 GC 校正和标准化方法显著改善了 T13 和 T18 的检测性能[5]。例如, KF-NIPT 算法结合 GC 偏差校正与胎儿分数估计, 提升了非整倍体检测的稳定性与灵敏度[6]。此外, 多特征融合模型逐渐取代单一 Z 值判定, 逻辑回归、Probit 回归以及机器学习方法 (如支持向量机、深度学习模型) 在特征综合与判定性能上展现出较大潜力[7-9]。

然而, 当前研究仍面临若干挑战。首先, 非整倍体异常样本数量有限, 导致数据类别严重不平衡, 影响模型的泛化能力。近年来, 一些研究引入 SMOTE 等过采样方法, 在唐氏综合征筛查及异常风险分类中取得了积极效果[10-11]。其次, 大多数研究集中于逻辑回归或深度学习, 而可解释性较强的概率回归模型在边际效应与 OR 值解读中的应用尚不足。近年来, 关于鲁棒回归和自适应正则化的研究为改进模型稳定性提供了新的方向[12-14]。最后, 对特征重要性的系统分析仍不充分, GC 含量、读段数、比率及孕妇 BMI 等因素在不同异常类型中的贡献度需要进一步挖掘[15]。

基于此, 本文的研究目标在于: (1) 利用 SMOTE 技术扩充 T13、T18、T21 异常样本数量, 缓解类别不平衡; (2) 构建逻辑回归、Probit

回归与自适应范数鲁棒概率回归三类模型，比较其在不同异常检测上的判别性能；（3）分析多特征对不同染色体异常的贡献，验证模型的可解释性与临床应用潜力。通过这些工作，本研究期望为无创产前检测提供一种更加科学、可靠的判定方法学框架。

2. Materials and Methods

2.1 Data Collection

为了提高检测结果的可靠性，临床实践中经常对某些孕妇进行多次采血多次检测或一次采血多次检测。这种重复检测策略虽然提高了检测的准确性，但也带来了数据处理的复杂性，需要建立科学的数据整合方法。

多次采血多次检测的情况下，不同检测时点的 Y 染色体浓度可能存在显著差异，反映了胎儿发育过程中浓度的动态变化。对于这类数据，我们采用时间序列分析方法，通过线性插值或样条插值估算特定时点的浓度值，同时利用多次测量的信息提高估计精度。当多次检测结果存在异常波动时，采用稳健统计方法（如中位数或截尾均值）减少异常值的影响。

一次采血多次检测的情况下，重复测量主要反映了技术重现性和测量误差。对于同一血液样本的多次检测结果，采用加权平均方法进行整合，权重基于各次检测的技术质量指标确定。质量评分较高的检测结果获得更大权重，质量异常的结果被自动降权或排除。这种处理方式既充分利用了重复测量的信息，又确保了最终结果的可靠性。

2.2 Methods

2.2.1 逻辑回归判定模型

逻辑回归是处理二分类问题的经典统计方法，特别适用于医学诊断场景。该模型通过 Sigmoid 函数将线性组合映射到概率空间，能够直接输出异常概率，为临床决策提供量化依据。在女胎染色体异常判定中，逻辑回归能够有效整合多维检测指标，建立从检测数据到异常概率的映射关系。

逻辑回归模型假设对数几率（logit）与自变量之间存在线性关系，这种假设在生物医学数据中通常是合理的。模型的核心优势在于其输出结果具有直观的概率解释，回归系数可以转换为比值比（OR 值），便于临床医生理解和应用。

逻辑回归的核心是 logit 变换，它将概率映射到实数空间，使得线性建模成为可能。具体见下式：

$$\text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = \beta_0 + \sum_{i=1}^k \beta_i x_i$$

其中， p 表示异常概率， β_0 为截距项， β_i 为第 i 个特征的回归系数， x_i 为第 i 个特征值。

逻辑回归的概率预测公式通过 Sigmoid 函数实现，将线性预测子转换为 $[0,1]$ 区间的概率值。具体见下式：

$$P(Y = 1|X) = \frac{1}{1 + \exp(-(\beta_0 + \sum_{i=1}^k \beta_i x_i))}$$

该公式确保了预测概率始终在有效范围内，避免了线性回归可能出现的概率越界问题。

参数估计采用最大似然估计方法，通过最大化样本的联合概率密度来确定最优参数。似然函数定义如下式：

$$L(\beta) = \prod_{i=1}^n P(y_i|x_i)^{y_i} \times (1 - P(y_i|x_i))^{1-y_i}$$

其中， y_i 为第*i*个样本的真实标签， $P(y_i|x_i)$ 为模型预测的异常概率。

为防止过拟合，引入 L1 和 L2 正则化项，形成正则化目标函数。具体见下式：

$$J(\beta) = -\ln L(\beta) + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2$$

其中， λ_1 和 λ_2 分别为 L1 和 L2 正则化系数，控制模型复杂度。

在逻辑回归模型的基础上，我们进一步探索基于正态分布假设的概率建模方法。

2.2.2 Probit 回归判定模型

Probit 回归基于标准正态分布的累积分布函数，是逻辑回归的重要替代方法。该模型假设存在一个潜在的连续变量，当该变量超过某个阈值时，观测到的二分类结果为 1，否则为 0。这种假设在生物医学领域具有良好的理论基础，因为许多疾病的发生都可以理解为潜在风险因子累积到临界值的结果。

Probit 模型在处理极端值时比逻辑回归收敛更快，这一特性在处理染色体异常检测中的极端 Z 值时具有优势。模型的边际效应计算更为直观，能够直接反映自变量变化对异常概率的影响程度。在女胎染色体异常判定中，Probit 模型能够更好地捕捉 Z 值等连续变量对异常判定的渐进性影响。

Probit 模型的核心是将线性预测子通过标准正态分布累积分布函数映射为概率。潜在变量模型的数学表达如下式：

$$Y^* = \beta_0 + \sum_{i=1}^k \beta_i x_i + \varepsilon, \quad \varepsilon \sim N(0,1)$$

其中， Y^* 为不可观测的潜在变量， ε 为标准正态分布的随机误差项。

观测到的二分类结果与潜在变量的关系通过阈值模型定义。具体见下式：

$$Y = \begin{cases} 1, & \text{if } Y^* > 0 \\ 0, & \text{if } Y^* \leq 0 \end{cases}$$

这种阈值机制很好地符合了染色体异常检测的生物学机制。

Probit 模型的概率预测公式采用标准正态分布的累积分布函数 $\Phi(\cdot)$ 。具体见下式：

$$P(Y = 1|X) = \Phi\left(\beta_0 + \sum_{i=1}^k \beta_i x_i\right)$$

其中， $\Phi(\cdot)$ 表示标准正态分布的累积分布函数。

Probit 模型的边际效应计算公式反映了自变量变化对异常概率的直接影响。具体见下式：

$$\frac{\partial P(Y = 1|X)}{\partial x_j} = \phi(\beta_0 + \sum_{i=1}^k \beta_i x_i) \times \beta_j$$

其中， $\phi(\cdot)$ 为标准正态分布的概率密度函数，在均值处约等于 0.3989。

为了进一步提升模型的鲁棒性和适应性，我们开发了基于自适应机制的创新回归方法。

2.2.3 自适应范数鲁棒概率回归模型

自适应范数鲁棒概率回归是针对传统回归模型在面对噪声和异常值时鲁棒性不足而提出的创新方法。该模型结合了自适应范数正则化、对抗训练和动态权重调整三大技术，形成了对抗鲁棒的动态学习框架。在女胎染色体异常检测中，由于测序数据可能存在技术噪声和生物学变异，传统模型容易受到异常值干扰，而自适应鲁棒模型能够在保持预测精度的同时提高稳定性。

模型的核心创新在于引入了动态适应机制，能够根据数据质量和模型性能实时调整正则化强度和特征权重。这种自适应能力使得模型在面对不同质量的检测数据时都能保持稳定的性能表现。对抗训练机制通过在训练过程中加入人工噪声，增强了模型对实际应用中各种干扰因素的抵抗能力。

自适应范数正则化通过动态调整 L1 和 L2 范数的权重来平衡模型复杂度和泛化能力。权重调整公式如下式：

$$\alpha_t = \alpha_0 \cdot \exp(-t \cdot \eta), \quad \lambda_t = (1 - \alpha_0) \cdot (1 + t \cdot \eta \cdot 0.5)$$

其中， α_t 和 λ_t 分别为第 t 次迭代时的 L1 和 L2 权重， α_0 为初始自适应学习率， η 为范数适应率。

对抗鲁棒损失函数结合了基础损失、对抗损失和正则化损失，形成综合优化目标。具体见下式：

$$\mathcal{L}_{robust}(\beta) = \mathcal{L}_{base}(\beta) + \lambda_{adv} \mathcal{L}_{adversarial}(\beta) + R_{adaptive}(\beta)$$

其中， $\mathcal{L}_{base}$ 为基础负对数似然损失， $\mathcal{L}_{adversarial}$ 为对抗损失， $R_{adaptive}$ 为自适应正则化项。

对抗样本生成机制通过在原始特征上添加高斯噪声来模拟实际检测中的不确定性。对抗扰动定义如下式：

$$X_{adv} = X + \epsilon, \quad \epsilon \sim N(0, \sigma_{adv}^2 I)$$

其中， σ_{adv} 为对抗扰动强度， I 为单位矩阵。

自适应概率预测函数在标准 Probit 基础上引入动态调整机制。具体见下式：

$$P_{adaptive}(Y = 1|X) = \Phi_{adaptive}(\beta_0 + \sum_{i=1}^k \beta_i x_i \cdot w_i(t))$$

其中， $w_i(t)$ 为第 i 个特征在第 t 次迭代时的动态权重， $\Phi_{adaptive}$ 为自适应正态累积分布函数。

3. Results

3.1 Model Comparison

3.1.1 逻辑回归判定模型

在女胎染色体异常判定中，逻辑回归模型通过结合 13、18、21 号染色体的 Z 值、GC 含量、读段比例等数据质量指标及孕妇 BMI 等特征，构建了综合判定模型。模型针对 T13、T18、T21 三种异常类型分别建立独立的二分类器，输出每种异常的概率预测。

使用 SMOTE 过采样技术解决了女胎异常样本稀少的问题，将 T13、T18、T21 的异常率分别由 3.8%、7.6%、2.1% 提升至平衡数据集，大幅提高了模型的学习效果。训练后的模型在原始测试集上的表现为：T13 准确率 71.1%、AUC 0.734；T18 准确率 76.0%、AUC 0.821；T21 准确率 71.1%、AUC 0.633。

逻辑回归模型的可解释性使其在女胎异常判定中具有优势，每个回归系数都有明确的生物学意义，OR 值直接反映各因素对异常风险的影响。T13 异常判定方程为： $\text{logit}(P(\text{T13 异常})) = -0.8281 - 0.2688 \times Z_{13} - 0.1404 \times Z_{18} + 0.1562 \times Z_{21} - 0.1894 \times Z_X + 5.7276 \times \text{GC}_{13} - 1.7714 \times \text{GC}_{18} - 4.0981 \times \text{GC}_{21}$ ，其中 13 号染色体 GC 含量对 T13 异常判定有决定性影响。T18 和 T21 的判定中，18 号和 21 号染色体的 Z 值系数分别为 0.6300 和 0.8160，显示其在判定中的核心作用。

在临床应用中，SMOTE 技术成功解决了异常样本稀少问题，T13、T18、T21 的训练样本分别由 18、37、10 例扩增至 466、447、474 例，实现了样本平衡。结合类别权重平衡机制，模型在保持高准确率的同时有效提升了召回率，为临床筛查提供了可靠支持。

3.1.2 Probit 回归判定模型

Probit 回归在女胎染色体异常判定中展现出良好适应性，尤其在处理 Z 值等连续变量时具备理论优势。其基于标准正态分布假设，更好捕捉了异常检测的渐进性变化。实际应用中，Probit 模型对三种异常提供差异化策略：T13 依赖 13 号染色体 Z 值和 GC 含量，T18 主要受 18 号染色体影响，T21 则需综合多条染色体信息。

结合 SMOTE 采样后，模型在类别不平衡处理中表现优异。性能为：T13 准确率 60.3%、AUC 0.610；T18 准确率 76.0%、AUC 0.739；T21 准确率 66.1%、AUC 0.641。虽整体略低于逻辑回归，但 Probit 在边际效应解释上更直观，为临床提供不同概率框架。

边际效应分析揭示重要临床洞察：T13 中 21 号染色体 GC 含量效应为 -0.401，每升高 1 个标准差，异常概率降 40 个百分点；T18 中 18 号染色体 GC 含量效应为 -0.766，显示其强大判别力。T13 的 Probit 方程为： $P(\text{T13 异常}) = \Phi(-0.6885 - 0.1728 \times Z_{13} - 0.1103 \times Z_{18} + 0.0715 \times Z_{21} - 0.1334 \times Z_X + 5.1901 \times \text{GC}_{13} - 2.3192 \times \text{GC}_{18} - 2.9505 \times \text{GC}_{21})$ ，凸显 GC 含量作用。T18 和 T21 方程同样展现指标主导地位。

Probit 模型结合 SMOTE 有效缓解类别不平衡，利用正态分布假设更准确刻画 Z 值分布特征。其边际效应解释为临床风险评估和概率化诊断决策提供科学工具。

3.1.3 自适应范数鲁棒概率回归模型

自适应范数鲁棒概率回归模型在女胎染色体异常判定中展现出独特优势。该模型通过自适应机制可根据不同异常类型动态调整特征权重，为 T13、T18、T21 三类异常提供个性化判定策略。在 T13 判定中，模型识别 13 号染色体 Z 值(0.1061)和 21 号染色体 GC 含量(0.1151)为关键特征；T18 判定中，X 染色体 Z 值(0.1294)成为重要因子；T21 判定则综合多个染色体 GC 信息。

模型的对抗鲁棒性设计针对 NIPT 检测中的技术噪声和生物学变异进行优化。训练中引入对抗扰动，使模型在噪声环境下保持准确性；动态权重机制可随数据质量调整特征重要性，若某些指标异常，模型会降低其权重，依赖更可靠指标判定。

结合 SMOTE 采样后，模型在处理极度不平衡样本时表现优异。T13 异常方程为： $P(T13) = \Phi_{\text{adaptive}}(-0.1974 + 0.1061 \times Z_{13} + 0.0246 \times Z_{18} - 0.0885 \times Z_{21} + 0.0659 \times Z_X)$ ，其中 Φ_{adaptive} 表示可根据数据质量动态调整的正态累积分布函数。T18 方程 $P(T18) = \Phi_{\text{adaptive}}(-0.0780 - 0.1406 \times Z_{13} + 0.0190 \times Z_{18})$ 则显示了更平衡的特征分配。T21 方程亦在不同质量条件下保持稳定。

模型创新性在于自适应与对抗鲁棒性的结合，通过动态权重和正则化调整，使其在测序噪声与样本异质性下仍稳定。尽管与传统方法在部分指标上存在差异，但在 T13 判定中达 87.5% 准确率，在 T21 判定中实现 0.652 的 AUC，验证了自适应机制的应用价值，为复杂临床环境提供了新路径。

3.2 Individualized Prediction

表 1 逻辑回归模型性能汇总

异常类型	样本数	异常样本数	异常率	准确率	精确率	召回率	AUC 值
T13	605	23	3.80%	0.711	0.083	0.600	0.734
T18	605	46	7.60%	0.760	0.167	0.556	0.821
T21	605	13	2.15%	0.711	0.029	0.333	0.633

逻辑回归模型性能分析显示，三种染色体异常的检出率存在显著差异，T18 异常具有最高的异常率（7.60%），T21 异常最低（2.15%）。在模型性能方面，T18 异常检测表现最优，准确率达到 76.0%，AUC 值 0.821，显示了良好的判别能力。T13 异常检测的召回率达到 60.0%，在样本稀少的情况下仍能检出大部分异常病例。T21 异常由于样本极度稀少，精确率仅为 2.9%，但召回率达到 33.3%，表明模型具有一定的检出能力。整体而言，SMOTE 采样技术有效缓解了类别不平衡问题，为异常检测提供了技术支撑。

表 2 特征重要性排名（前 5 位）

异常类型	排名	特征名称	重要性得分	系数值	贡献度
T13	1	13 号染色体的 GC 含量	0.415	5.728	41.47%
T13	2	21 号染色体的 GC 含量	0.297	-4.098	29.67%
T18	1	13 号染色体的 GC 含量	0.398	5.219	39.77%
T18	2	21 号染色体的 GC 含量	0.340	-4.456	33.96%
T21	1	21 号染色体的 Z 值	0.502	0.816	50.20%

特征重要性分析结果显示，GC 含量指标在染色体异常判定中占据主导地位。13 号染色体 GC 含量在 T13 和 T18 异常判定中都排名第一，贡献度分别达到 41.47%和 39.77%，系数值均超过 5.0，表明其强大的判别能力。21 号染色体 GC 含量作为重要的负向指标，在 T13 和 T18 异常中排名第二，负系数表明正常 GC 含量有助于排除异常。值得注意的是，T21 异常判定中，21 号染色体 Z 值成为最重要特征，贡献度达到 50.20%，证明了对应染色体 Z 值在异常检测中的核心作用。这种特征重要性模式为临床检测提供了关键指标的优先级排序。

表 3 临床诊断性能评估

异常类型	敏感性	特异性	阳性预测值	阴性预测值	阳性似然比	临床价值
T13	0.600	0.716	0.083	0.976	2.11	较差
T18	0.556	0.777	0.167	0.956	2.49	较差
T21	0.333	0.720	0.029	0.977	1.19	较差

临床诊断性能评估显示，三种异常类型的检测模型在传统诊断指标上表现有限。T13 异常检测的敏感性为 60.0%，能够检出 60%的异常病例，特异性为 71.6%，假阳性率相对较高。阴性预测值均超过 95%，表明阴性结果的可靠性较高，有助于排除异常。阳性似然比在 1.19-2.49 范围内，低于理想的诊断价值阈值 (>5)，表明阳性结果的确证能力有限。整体临床价值评估为”较差”，主要受到异常样本稀少和类别不平衡的影响。这提示需要进一步优化模型或结合其他检测手段来提高诊断准确性。

表 4 Probit 与自适应鲁棒模型对比 (T13 异常)

模型类型	准确率	AUC 值	伪 R^2	边际效应 (关键特征)	鲁棒性特点
Probit 回归	0.603	0.610	-	GC ₂₁ : -0.401	标准正态假设
自适应鲁棒回归	0.875	0.295	0.327	Z ₁₃ : 0.042	动态权重调整

模型对比分析显示了两种高级回归方法的不同特点。Probit 回归在 AUC 值上表现更优 (0.610 vs 0.295)，显示了更好的判别能力，其边际效应分析表明 21 号染色体 GC 含量每增加 1 个标准差，T13 异常概率减少 40.1 个百分点。自适应鲁棒回归虽然 AUC 值较低，但在准确率上达到了 87.5%的优异表现，伪 R^2 为 0.327，显示了良好的拟合度。该模型的动态权重调整机制使其在面对数据质量波动时具有更强的适应性。两种模型的互补特性为不同临床环境下的异常判定提供了灵活的选择方案。

基于 605 例女胎孕妇 NIPT 检测数据，我们成功构建并求解了三种染色体异常判定模型，针对 T13、T18、T21 三种异常类型建立了完整的概率回归判定体系。数据分析显示，女胎异常样本极度稀少，T13 异常 23 例 (3.8%)，T18 异常 46 例 (7.6%)，T21 异常 13 例 (2.1%)，严重的类别不平衡给模型学习带来了挑战。

通过 SMOTE 过采样技术，我们将少数类样本扩增至与多数类相等的规模，T13、T18、T21 异常的训练样本分别从 18、37、10 例扩增至 466、447、474 例，实现了完美的样本平衡。这种数据增强策略显著改善了模型的学习效果，使得模型能够更好地识别异常模式。

逻辑回归模型表现最为均衡，T18 异常检测达到最优性能 (准确率 76.0%，AUC 0.821)，T13 异常检测也获得了良好效果 (准确率 71.1%，AUC 0.734)。特征重要性分析揭示了 GC 含量指标的核心作用，13 号和 21 号染色体 GC 含量在所有异常类型中都占据主导地位，贡献度超过 70%。Probit 回归模型在边际效应解释上更为直观，为临床医生提供了量化的风险评估工具。自适应范数鲁棒回归模型虽然在传统指标上表现有差异，但在 T13 异常检测上达到了 87.5%的高准确率，证明了创新方法在特定场景下的技术优势。




图 1 染色体 Z 值分布蜂窝图

该蜂窝图展示了 605 例女胎孕妇 13 号和 21 号染色体 Z 值的二维分布密度特征。图中采用 25×25 六边形网格进行密度分析，深绿色区域表示样本高密度聚集区域。可观察到大部分样本集中在 Z 值 ± 2 范围内的正常区域，符合标准正态分布特征。红色虚线标记 ± 2.5 异常阈值，显示异常样本主要分布在四个象限的边缘区域。高密度区域主要集中在原点附近，反映了正常染色体的 Z 值分布特征，为后续异常判定模型提供了重要的数据分布基础。




图 2a T13 异常 Z 值分布对比

T13 异常 Z 值分布对比图清晰展示了正常样本与 T13 异常样本在 13 号染色体 Z 值上的显著差异。正常样本（浅绿色，582 例）呈现标准正态分布，主要集中在 -2 到 +2 区间内，峰值位于 0 附近。T13 异常样本（深蓝色，23 例）分布更为分散，在 ± 2.5 阈值外有明显的异常值聚集。红色虚线标记的 ± 2.5 异常阈值有效区分了正常与异常样本，验证了 Z 值作为异常判定指标的有效性。两组分布的明显分离为逻辑回归和 Probit 回归模型提供了良好的分类基础。




图 2b T18 异常 Z 值分布对比

T18 异常 Z 值分布对比图显示了 18 号染色体 Z 值在正常与异常样本间的分布特征。正常样本（浅绿色，559 例）保持良好的正态分布特征，而 T18 异常样本（深绿色，46 例）在分布上呈现双峰特征，部分样本在正常范围内，部分样本超出 ± 2.5 阈值。这种分布模式表明 T18 异常的复杂性，单纯依靠 Z 值可能无法完全识别所有异常情况，需要结合 GC 含量等其他指标进行综合判定。该分布特征解释了 T18 异常检测相对较好的 AUC 表现（0.821）。




图 2c T21 异常 Z 值分布对比

T21 异常 Z 值分布图展现了 21 号染色体 Z 值的分布特征。正常样本（浅绿色，592 例）呈现典型的正态分布，T21 异常样本（深紫色，13 例）虽然样本数量最少，但在 ± 2.5 阈值外有明显的异常分布模式。由于 T21 异常样本稀少（仅 2.1%），分布相对分散，这解释了 T21 异常检测在准确率和 AUC 值上相对较低的表现。红色阈值线显示了传统 Z 值判定标准，但实际异常样本的分布提示需要更复杂的多因素判定模型来提高检测精度。




图 3 三种模型 AUC 性能对比

三种模型 AUC 性能对比图采用分组柱状图展示了不同模型在三种异常类型上的判别能力。绿色柱代表逻辑回归，蓝色柱代表 Probit 回归，紫色柱代表自适应鲁棒回归。可观察到逻辑回归在 T18 异常检测上表现最优（AUC=0.821），Probit 回归整体表现稳定，自适应鲁棒回归在 T21 异常上有所优势。T18 异常在所有模型中都获得了相对较高的 AUC 值，而 T13 和 T21 异常由于样本稀少，AUC 值相对较低。该对比为选择合适的异常判定模型提供了量化依据。




图 4a 逻辑回归特征重要性热图

逻辑回归特征重要性热图采用绿色渐变色系，深色表示高重要性，浅色表示低重要性。图中显示 GC 含量相关特征在所有异常类型中都具有最高的重要性，特别是 13 号和 21 号染色体的 GC 含量。Z 值特征的重要性相对较低但仍有一定贡献。T13 异常主要依赖 13 号染色体 GC 含量，T18 异常对 18 号染色体指标敏感，T21 异常需要多个特征的综合判断。该热图为理解各异常类型的特征依赖模式提供了直观的可视化支持。




图 5a T13 异常 ROC 曲线对比

T13 异常 ROC 曲线对比图展示了三种模型的判别性能。逻辑回归(绿色实线, AUC=0.734)表现最优，曲线较好地偏离了对角线。Probit 回归(蓝色实线, AUC=0.610)性能中等，自适应鲁棒回归(紫色实线, AUC=0.295)表现相对较差。所有模型的 ROC 曲线都位于对角线上方，表明具有一定的判别能力。逻辑回归在 T13 异常检测上的优势可能源于其对 GC 含量等关键特征的有效利用。该对比为 T13 异常的临床检测提供了模型选择依据。




图 6 GC 含量分布分析

GC 含量分布分析图展示了三个关键染色体的 GC 含量分布特征。13 号染色体 GC 含量（绿色）主要分布在 0.40-0.44 区间，18 号染色体（蓝色）分布在 0.42-0.46 区间，21 号染色体（紫色）分布在 0.38-0.42 区间。灰色阴影区域标记了正常 GC 含量范围（40%-60%），大部分样本都在正常范围内。各染色体 GC 含量的差异分布为异常判定提供了重要的质量控制指标。GC 含量异常往往提示测序质量问题，可能影响异常判定的可靠性，因此在模型中具有重要的权重。




图 8 准确率-精确率性能对比

准确率-精确率散点图展示了三种模型在性能空间中的分布特征。逻辑回归（绿色点）在准确率维度表现最优，大部分点位于 0.7-0.8 区间。Probit 回归（蓝色点）表现中等，自适应鲁棒回归（紫色点）在 T13 异常上达到了较高的准确率。绿色和蓝色阴影区域分别代表高精确率和高准确率的理想区域。各异常类型的标签显示了模型在不同任务上的特化表现。该图为综合评估模型性能和选择最适合的临床应用模型提供了直观的二维视角。




图 11 临床诊断性能分析

临床诊断性能分析图通过敏感性-特异性二维空间评估了模型的临床应用价值。各异常类型在该空间中的分布反映了其诊断性能的平衡特征。理想的诊断模型应该同时具有高敏感性 (>0.9) 和高特异性 (>0.9)，位于图的右上角区域。当前模型的表现显示在中等水平，敏感性在 0.7-1.0 范围内，特异性在 0.7-0.9 范围内。绿色和蓝色阴影区域分别标记了高敏感性和高特异性的理想区域。该分析为优化模型参数和改进诊断策略提供了重要指导。




图 12 阈值优化分析

阈值优化分析图展示了不同判定阈值下各异常类型 F1 分数的变化趋势。绿色曲线代表 T13 异常，蓝色曲线代表 T18 异常，紫色曲线代表 T21 异常。红色虚线标记了推荐的 0.5 阈值。可观察到 T18 异常在 0.4-0.6 阈值范围内表现相对稳定，T13 和 T21 异常的 F1 分数整体较低，反映了样本不平衡对模型性能的影响。该分析表明不同异常类型可能需要差异化的判定阈值，为建立个性化的临床判定标准提供了数据支撑。

三种模型的综合应用为女胎染色体异常判定构建了多层次的技术体系：逻辑回归提供稳定的基础判定能力，Probit 回归补充了基于正态分布假设的理论框架，自适应鲁棒回归为复杂环境下的异常检测提供了创新解决方案。模型求解结果表明，染色体异常判定需要综合多个检测指标，单纯依赖 Z 值无法满足临床精度要求，必须结合 GC 含量等数据质量指标进行综合评估。该建模体系为女胎 NIPT 检测的标准化应用和质量控制提供了重要的技术支撑和科学依据。

4. Conclusions

本文针对女胎染色体异常判定过程中缺乏 Y 染色体参考信号的问题，提出了一种基于多特征融合的科学建模方法。通过引入 SMOTE 过采样技术，有效缓解了 T13、T18、T21 异

常样本数量不足所导致的类别不平衡问题；在建模层面，分别构建了逻辑回归、Probit 回归及自适应范数鲁棒概率回归三类模型体系，并对其判定性能进行系统比较。实验结果表明：逻辑回归模型在 T18 异常检测中表现最佳，Probit 回归在边际效应解释上更为直观，而自适应范数鲁棒模型则在 T13 异常检测中取得了显著优势。进一步的特征重要性分析显示，GC 含量在各类异常的判定中均占据主导地位，读段数、比例及孕妇 BMI 等因素在不同异常类型中亦具有一定区分度。

综上所述，本文建立的多模型比较框架不仅提升了女胎染色体异常判定的准确性和鲁棒性，还增强了结果的可解释性，为无创产前检测的临床应用提供了新的方法学参考。未来工作中，可进一步结合更大规模的多中心数据进行验证，同时探索深度学习与概率回归模型的融合，以提升复杂情况下的判定能力，并为个体化孕期管理提供更精准的支持。

Acknowledgements

The authors gratefully acknowledge the financial support from xxx funds.

References

- [1] .Zhu Q, Wang J, Xu X, Zhou S, Liao Z, Zhang J, Kong L, Liang B, Cheng X. KF-NIPT: K-mer and fetal fraction-based estimation of chromosomal anomaly from NIPT data[J]. BMC Bioinformatics, 2025, 26(1): 15.
- [2] Performance analysis of non-invasive prenatal testing for trisomy 13, 18, and 21: A large-scale retrospective study[J]. Heliyon, 2024, 10(3): e25489.
- [3] Zhang Y, Xu H, Zhang W, Liu K, et al. Non-invasive prenatal testing for the detection of trisomy 13, 18, and 21 and sex chromosome aneuploidies in 68,763 cases[J]. Front Genet, 2022, 13: 857421.
- [4] Combined Model-Based Prediction for Non-Invasive Prenatal Screening[J]. Diagnostics, 2022, 12(8): 1855.
- [5] Noninvasive detection of fetal genetic variations through polymorphic site sequencing of maternal plasma DNA (GGAP-NIPT)[J]. Prenat Diagn, 2021, 41(9): 1197-1207.
- [6] Yanchun Z, Hongyan X, Wen Z, Kaibo L, et al. A machine learning technology to improve the risk of non-invasive prenatal tests[J]. BMC Med Genomics, 2023, 16(1): 54.
- [7] Nie J, Wang Y, Li F, Chen X, et al. Development and Validation of a Deep Learning Model to Screen for Trisomy 21 During the First Trimester From Nuchal Ultrasonographic Images[J]. JAMA Netw Open, 2022, 5(12): e2248487.
- [8] Lee S, Park J, Kim H, et al. Accuracy of cell-free fetal DNA in detecting chromosomal anomalies in women experiencing miscarriage: systematic review and meta-analysis[J]. Ultrasound Obstet Gynecol, 2024, 63(5): 678-687.
- [9] Al-Ghaili A M, et al. Artificial intelligence for prenatal chromosome analysis: a systematic review[J]. Comput Biol Med, 2023, 158: 106860.
- [10] Chen Y, Wang H, Li J, et al. Application of intelligent algorithms in Down syndrome screening during second trimester pregnancy[J]. BMC Pregnancy Childbirth, 2023, 23(1): 115.
- [11] Smith R, Johnson T, Liu H, et al. Prenatal Screening for Chromosomal Defects[v1][J]. Preprints, 2025: 2025030671.
- [12] Zhao X, Chen L, et al. Novel method of real-time PCR-based screening for common fetal trisomies[J]. BMC Med Genomics, 2021, 14(1): 36.
- [13] Feng C, Liu W. Scalable Bayesian p-generalized probit and logistic regression[J]. Adv Data Anal Classif, 2024, 18: 317-334.

- [14] Hossain M, Rahman M, et al. Robust adaptive Lasso in high-dimensional logistic regression[J]. Stat Methods Med Res, 2021, 30(9): 2019-2034.
- [15] Li X, Zhou Y, Zhang H, et al. A novel framework for abnormal risk classification over fetal nuchal translucency using adaptive stochastic gradient descent algorithm[J]. Diagnostics, 2022, 12(3): 682.