

基于 Beer-Lambert 物理先验的苹果可溶性固形物含量跨产地近红外光谱稳健预测

李盼林^a, 李龙杰^{d,e}, 刘亚^c, 冯宇通^{d,e}, Muhammad Waqar Akram^f, 黄华^{a,b,*} and 郭俊先^{d,e,**}

^a 新疆农业大学数理学院, 新疆乌鲁木齐 830052

^b 新疆农业大学数值模拟与数据分析研究中心, 新疆乌鲁木齐 830052

^c 新疆维吾尔自治区农业科学院乌鲁木齐综合试验站, 新疆乌鲁木齐 830013

^d 新疆农业大学机电工程学院, 新疆乌鲁木齐 830052

^e 新疆智能农业装备重点实验室, 新疆乌鲁木齐 830052

^f 费萨拉巴德农业大学农业机械与动力工程系, 费萨拉巴德 38000, 巴基斯坦

ARTICLE INFO

摘要

Keywords:

近红外光谱

可溶性固形物含量

跨产地迁移

Beer-Lambert 定律

物理知情深度学习

域适应

苹果品质

近红外 (near-infrared, NIR) 光谱模型在苹果可溶性固形物含量 (soluble solids content, SSC) 跨产地预测中常出现显著性能下降, 但其物理机制仍缺乏系统量化。本文基于 Beer-Lambert 类加性可分解结构, 采用 PCA-10、NMF-3、NNLS-3 和 SVD-3 四种低秩 surrogate, 对 12 个跨产地迁移场景中的重构残差进行分析。结果表明, 目标域 Beer-Lambert 重构残差相较源域系统性放大, 合并中位数由 0.026 增至 0.059, 且所有场景均达统计显著 ($p < 0.05$, Mann-Whitney U 检验); 四种 surrogate 间放大倍数 Pearson $r \geq 0.83$, 说明该观察是数据驱动的稳健现象, 而非基底选择的副产品。基于该观察, 本文提出物理知情分解架构 (Phys), 将 $A_i(\lambda) \approx \sum_{k=1}^K a_{i,k}(\lambda) b_i c_{i,k}(\lambda)$ ($K = 3$) 编码至网络隐空间, 并引入 BL 重构损失 ($\lambda_{bl} = 0.5$) 作为正则项。在六个产地-年份域 (2018/2025 新疆、山东、陕西/甘肃) 构成的 569 个跨产地迁移场景上, Phys+BL 取得均值 RMSE = 1.976°Brix (95% CI [1.903, 2.072]), 较 CNN (2.577) 实现 23.4% 的聚合改进与 22.88% 的配对改进 (scene-wise 均值改进 22.56%、中位数 23.09%); 569 个场景对应 61 个唯一目标集合 (unique target sets), 按目标集合分层的 block bootstrap 仍显示显著差异 ($p < 10^{-9}$)。进一步的消融实验表明, BL 约束的有效性依赖于与其兼容的隐空间参数化: 该约束施加于通用 Conv1d 网络时可能导致性能下降 (-4.18%, $n = 571$, $p = 4.96 \times 10^{-6}$), 而在 Phys 架构中可稳定训练过程并消除全部 15 个发散场景。需要指出的是, 本研究采用 transductive 无监督域适应 (unsupervised domain adaptation, UDA) 与 semi-supervised calibration transfer 之间的实验协议: 目标域训练集仅以无标签形式参与适应, 而目标域验证集标签用于早停和模型选择。

1. 引言

近红外 (near-infrared, NIR) 光谱无损检测果品品质已是相当成熟的商业技术 [1, 2]。苹果可溶性固形物含量 (soluble solids content, SSC, 即糖度) 是商业分级的核心指标 [3, 4], 在单一产地受控条件下, 偏最小二乘回归 (partial least squares regression, PLSR) 模型通常能达到 RPD > 2.0 , 符合实际应用的基本要求 [5, 6]。

问题在于, 这类模型在跨产地部署时表现往往大打折扣。中国苹果主产区地域广阔——新疆、山东、陕西、甘肃的气候和土壤条件差异显著——各产地果实的细胞壁密度、胞间空气分数、表皮蜡质厚度和水分活度梯度各具特征 [7–9]。这些组织结构差异会改变漫反射 NIR 光子的多重散射基线和有效光程, 在产地间引入系统性的光谱分布偏移。以山东标定的模

型预测新疆苹果为例, RMSE 通常超过 3°Brix, 是产地内误差的两倍以上 [10]——这在实际应用中几乎是不可接受的。

研究者提出了多种弥合跨产地偏移的策略, 大体可归为三类。光谱预处理 (MSC[11]、SNV、导数处理等) 能部分归一化散射差异, 但这类方法本质上是信号层面的操作, 并未利用光谱偏移背后的物理结构 [12, 13]。统计域适应 (TCA[14]、CORAL[15]、MMD 惩罚网络 [16, 17]、ADDA[18]、di-PLS[19] 等) 致力于对齐特征分布, 但没有物理约束的支撑, 光谱流形弯曲时容易引入负迁移 [20, 21]。针对 NIR 光谱已有 BL 视角下的回归域适应工作 [22, 23], 这些方法主要在浅层 PLS 框架内引入域不变性约束, 与本文将 BL 结构编码进深度网络隐空间的路径互补。经验标定转移方法 (如 DS 和 PDS[24, 25]) 通常依赖目标域的配对标定样本, 因此难以直接应用于零标签部署场景 [7, 26]。

现有方法主要从光谱预处理或特征分布对齐角度减轻跨产地偏移, 但对偏移背后的物理机制刻画仍

* 通讯作者: 黄华, Email: huanghua@xjau.edu.cn.

** 通讯作者: 郭俊先, Email: junxianguo@163.com.

 huanghua@xjau.edu.cn (黄华); junxianguo@163.com (郭俊先)

相对有限。Beer–Lambert 定律告诉我们,在稀溶液透射介质中,吸光度光谱是各组分吸收贡献的线性叠加 [27, 28]: $A(\lambda) = \sum_i \varepsilon_i(\lambda) c_i \ell$ 。完整果实漫反射 NIR 中,该加性结构在 Kubelka–Munk 理论框架下近似成立 [1, 29–31]。然而一旦产地改变,果实组织结构的差异会使等效散射系数 $s(\lambda)$ 以波长依赖方式漂移,加性关系随之破坏, BL 重构残差 $R_{BL} = \|A - \hat{A}_{BL}\|$ 随之放大。因此, BL 重构残差可作为跨产地光学几何变化导致低秩可分解性失稳的可观测指标。但该指标不应被解释为唯一物理成因;果实生化组成、含水量空间分布以及仪器响应漂移等因素也可能共同作用。此外,本节的 BL 违反量化仅在 12 个同年 1 源 $\rightarrow$ 1 目标场景上完成;将该机制外推到 569 个含多源、多目标、跨年组合的迁移场景需要补充验证,属于本工作的明确局限 (见 §4)。

基于上述观察,本文从机制量化、模型设计和大规模验证三个层面展开研究:首先,我们系统量化了 2018、2025 两个采收季 12 个跨产地 NIR 场景的 BL 违反程度,发现所有场景的残差放大均达统计显著 (1.1–4.9 $\times$);其次,我们据此设计了物理知情分解架构 (Phys),将 BL 加性约束直接编码为网络隐空间的归纳偏置,而非事后附加;最后,通过 569 个跨产地迁移场景的大规模评估与两组独立消融实验,我们分别厘清了架构设计和 BL 正则化损失各自的贡献。

值得注意的是,实验结果显示 BL 正则化的效果依赖于网络隐空间结构——同样的 BL 损失在通用 Conv1d 网络中导致性能下降,但在我们的 Phys 架构中可防止发散。我们将其表述为可证伪的架构-约束兼容性假说:物理重构约束 $\|\hat{A} - A\|^2$ 只有在网络隐空间被显式参数化为该约束兼容的形式时,才能提供与预测目标对齐而非冲突的梯度信号。本研究在一个 CNN backbone 上观察到该现象;其在更广泛架构 (MLP、ResNet1D、Transformer1D) 上的成立性留待后续多 backbone 验证 (详见第4节)。

2. 材料与方法

2.1. 数据集

从中国苹果主产区采集了两个独立数据集。

2018 年数据集。共采集 697 个完整富士苹果样品,来自三个产地:新疆 (干旱高原,海拔 760–1000 m)、山东 (温带沿海平原) 和陕西 (半干旱黄

土高原)。各产地样本数分别为:新疆 256 个、山东 221 个、陕西 220 个。使用傅里叶变换 NIR 光谱仪以 2 nm 分辨率在 400–2500 nm 波段采集漫反射光谱。SSC 参考值由数字折光仪 (爱拓 PR-201 α) 对榨汁测定。

2025 年数据集。2025 年采收季共采集 604 个样品,来自三个产地:新疆 (218 个)、山东 (196 个) 和甘肃 (新产地,半干旱,190 个)。采用相同的光谱采集和参考值测定规程。

预处理后 (详见第2.2节),两年光谱均对齐至 862–2478 nm 范围内 229 个共有波长通道。六个产地-年份域 (D_1 – D_6) 构成了本研究的全部实验单元。

2.2. 光谱预处理

原始光谱转换为吸光度 $A(\lambda) = \log_{10}(I_0/I)$ 。所有光谱通过线性插值对齐至两个仪器共有的 229 个波长通道。主实验中未施加额外散射校正,以避免预先去除正在研究的跨产地信号;预处理效果在第4节讨论。

2.3. 跨产地迁移场景生成

六个产地-年份域分别为:2018 年新疆、山东、陕西,以及 2025 年新疆、山东、甘肃。对每个有序对 (D_s, D_t) ($D_s \neq D_t$),考虑四种迁移类型:

1. **1 源 $\rightarrow$ 1 目标:** 在单一源域全部样本上训练,适应并测试单个目标域。
2. **1 源 $\rightarrow$ 多目标:** 单源域,两个或三个目标域。
3. **多源 $\rightarrow$ 1 目标:** 两个或三个源域,单目标域。
4. **多源 $\rightarrow$ 多目标:** 多个源域和目标域。

源域 100% 用于训练;目标域按 60%/20%/20% 随机划分为 train/val/test 三个子集。**适应协议:**源域提供监督信号;目标域 train 子集仅用于无监督域适应 (域对齐与重构损失),不参与回归监督;目标域 val 子集用于早停与最优权重选择;目标域 test 子集仅用于最终评估。该协议属于 **transductive UDA** 与 **semi-supervised calibration transfer** 之间的混合设定——目标域训练子集仅以无标签方式参与域对齐或重构损失,但目标域验证集标签用于早停和模型选择。因此,本研究的设定并非严格的零标签部署场景;完全 source-only 早停设定 (不使用任何目标域标签) 下的稳健性留待后续工作验证。目标域训练子集规模分布:最小 102 条、中位数 226 条、最

大 578 条 (共 602 个场景)。PLSR 和 SVR 不涉及深度网络训练不稳定问题,覆盖全部 602 个场景;受 BatchNorm1d 在末批量大小为 1 时引发训练失败以及个别 NaN 异常影响,深度模型的有效收敛场景数分别为 CNN 575、CNN+MMD 571、Phys+BL 569。全部 602 个场景对应 62 个唯一目标集合 (unique target sets); CNN 与 Phys+BL 均收敛的 569 个共享场景对应 61 个唯一目标集合——同一目标集合被不同源域组合反复使用,因此场景之间并非完全独立;统计推断时按唯一目标集合做 block bootstrap,以避免重复样本造成的假显著 (详见第3.2节)。配对比较限于 CNN 与 Phys+BL 均收敛的 569 个场景。

2.4. 基线与对比方法

本研究对比五种方法。所有方法在每个跨产地场景上使用相同的源/目标数据划分与随机种子,确保配对比较公平。

PLSR。 偏最小二乘回归,潜变量数取 10 (在受限 $L-1$ 与 $n_{src}-1$ 的前提下),在源域上以全量样本拟合,不经任何适应直接预测目标域测试集 (无适应基线)。潜变量数 10 依据 [5] 对农产品 NIR 模型的工程推荐; [5, 15] 区间内的稳健性留待后续工作系统考察。

SVR。 径向基核 ε -SVR,超参数取常用缺省值 $C = 100$ 、 $\gamma = scale$ 、 $\varepsilon = 0.1$ (与 [32] 保持一致),不经任何适应直接应用于目标域。我们承认未对 SVR 做正式的超参数网格搜索;在跨产地迁移背景下,源域调优可能因目标域分布不同而失效,故选择固定缺省值以保证跨场景实验的可比性。

CNN。 一维卷积网络,包含两个 Conv1d 块 (卷积核大小分别为 5 和 3,通道数 $64 \rightarrow 32$)、最大池化、Dropout(0.3),随后接两层 MLP 编码器 (特征维 $\rightarrow 64 \rightarrow 4$) 和两层回归头 ($4 \rightarrow 16 \rightarrow 1$)。源域有监督回归训练;目标域 train 子集不提供标签,仅用于 (在 CNN+MMD/Phys+BL 中) 域对齐或 BL 重构损失;目标域 val 子集用于早停与最优权重选择, test 子集用于评估。所有 BN 层均启用, batch=16。

CNN+MMD。 与 CNN 架构相同,额外在每步训练中引入源域-目标域 latent 特征之间的 MMD 项 [16] ($\lambda_{mmd} = 0.1$, RBF 核 + median heuristic 自适应带宽)。我们将在第3.2节讨论该方法在小 batch 下的不稳定性。

Phys+BL (本文方法)。 详见第2.5节。

2.5. 本文方法: 物理知情分解架构

2.5.1. Beer-Lambert 启发的可微分解 (physics-inspired factorization)

经典 Beer-Lambert 定律在稀溶液透射条件下写作 $A(\lambda) = \sum_i \varepsilon_i(\lambda) c_i \ell$, 其中 $\varepsilon_i(\lambda)$ 是组分 i 的纯吸收谱 (共享、与样本无关), c_i 是该样本的标量浓度, ℓ 是光程长度 [27, 33]。在完整果实的漫反射 NIR 中, 散射会使有效光程 ℓ 以及局部吸收等效参数随波长漂移, 严格 BL 不再成立 [1]。我们因此采用一种 Beer-Lambert 启发的可微分解——保留 BL 的“加性组分 $\times$ 光程”骨架, 但允许吸收系数和有效浓度随波长变化以吸收散射造成的非线性:

$$\hat{A}_i(\lambda) \approx \sum_{k=1}^K a_{i,k}(\lambda) b_i c_{i,k}(\lambda) \quad (1)$$

其中 $a_{i,k}(\lambda) \in \mathbb{R}_+^L$ 为样本 i 的第 k 组分“广义吸收谱”, $b_i \in \mathbb{R}_+$ 为该样本的标量有效光程, $c_{i,k}(\lambda) \in \mathbb{R}_+^L$ 为相应的“广义浓度谱”。所有参数限制为正以保持物理意义; 当 $a_{i,k}(\lambda) \rightarrow \varepsilon_k(\lambda)$ 、 $c_{i,k}(\lambda) \rightarrow c_{i,k}$ (标量)、 $b_i \rightarrow \ell$ 时, 式 (1) 退化为经典 BL。

本文设定 $K = 3$, 用以近似表征水分、糖分相关吸收以及散射残差等主要变化来源, 依据完整苹果果实 NIR 的主要吸收带文献 [1, 30, 33]。需要指出的是, $K = 3$ 属于基于先验知识和工程经验的设定, 而非严格的第一性原理光谱解卷积结果; K 的灵敏度分析 ($K \in \{2, 3, 4, 5, 6\}$) 作为本工作的明确局限, 详见 §4。后续我们将检验学到的组分谱与水 (1450, 1940 nm)、糖 (1580, 2080 nm) 吸收峰的对齐性。

2.5.2. 架构设计

Phys 架构由三个模块构成:

共享编码器。 两层全连接 $f_E: \mathbb{R}^L \rightarrow \mathbb{R}^H$ ($H = 64$, 含 BN 与 ReLU), 将输入光谱 $\mathbf{x} \in \mathbb{R}^L$ 映射为隐特征 $\mathbf{h} \in \mathbb{R}^H$ 。

三头分解器。 吸收头 $f_a: \mathbf{h} \rightarrow a \in \mathbb{R}_+^{K \times L}$ 、光程头 $f_b: \mathbf{h} \rightarrow b \in \mathbb{R}_+$ 、浓度头 $f_c: \mathbf{h} \rightarrow c \in \mathbb{R}_+^{K \times L}$ 。所有输出通过指数变换保证正性。

物理特征聚合 + 回归器。 从 (a, b, c) 提取统计量 $\phi(\mathbf{x}) = [\bar{a}, b, \bar{c}, \sigma_a, \sigma_c] \in \mathbb{R}^{4K+1}$ ($K = 3$ 时为 13 维), 输入两层 MLP 回归头得到 SSC 预测值 $\hat{y}$ 。

重构光谱 $\hat{A}$ 按式 (1) 构造, 用于 BL 重构损失。

2.5.3. 训练目标

总损失为：

$$\mathcal{L} = \underbrace{\|\hat{y} - y\|_2^2}_{\text{SSC 损失}} + \lambda_{\text{bl}} \underbrace{\text{MSE}(\log(\hat{A} + \epsilon), \log(|A| + \epsilon))}_{\text{BL 损失 (log 空间)}} \quad (2)$$

其中 $\epsilon = 10^{-6}$, A 为标准化后的输入光谱。BL 损失在 log 空间计算以避免乘积项梯度爆炸, 且在源域与目标域光谱上对称累加。默认 $\lambda_{\text{bl}} = 0.5$ (灵敏度分析见第3.6节)。所有模型使用 Adam 优化器 [34] (学习率 $\alpha = 10^{-3}$, 批大小 16, 最多 200 轮), 并在 20% 的目标域验证子集上做早停 (patience=20)。注意: 早停指标基于目标域验证子集的 RMSE, 需要使用目标域标签, 因此本研究的协议位于严格 UDA 与 semi-supervised calibration transfer 之间; 更严格的零标签设定 (早停仅基于源域 hold-out) 留待后续工作验证。

2.6. 评估指标

性能指标定义如下：

$$\begin{aligned} \text{RMSE} &= \sqrt{\frac{1}{n} \sum_i (\hat{y}_i - y_i)^2} \text{ (}^\circ\text{Brix)}, \\ R^2 &= 1 - \frac{\sum_i (\hat{y}_i - y_i)^2}{\sum_i (y_i - \bar{y})^2}, \\ \text{RPD} &= \sigma_y / \text{RMSE}, \quad \text{RPIQ} = \text{IQR}(y) / \text{RMSE}. \end{aligned}$$

此外还报告对跨域均值漂移更稳健的 MAE、MedianAE、MAPE 与 Bias 等绝对误差指标。

品质误判率定义为测试样本中预测 SSC 二分类等级 (合格: $\geq 13^\circ\text{Brix}$; 不合格: $< 13^\circ\text{Brix}$) 与参考等级不一致的比例。13 $^\circ\text{Brix}$ 阈值依据国家苹果分级标准 GB/T 10651-2008 对一级富士的糖度下限。三分类 (低/中/高) 的细化分析作为未来工作。

所有配对比较采用双侧 Wilcoxon 符号秩检验 [35] 对匹配对的 RMSE 值进行检验; 以 $p < 0.05$ 为显著性阈值。聚合 RMSE 值取场景间算术均值; 为降低对异常场景的敏感性, 同时报告中位数、95% bootstrap CI 与按 unique target set 的 block bootstrap。

3. 结果

3.1. Beer-Lambert 违反在所有跨产地场景中具有系统性

为量化“加性约束在跨域时是否失效”, 我们设计了一个数据驱动的 BL 违反指标。对 12 个直接 1 源 $\rightarrow$ 1 目标场景 (每年 6 个), 在源域光谱上拟合一个

10 维主成分加性近似 (PCA-10) 作为 BL 可分解性的 surrogate 基底——若严格 BL 成立、且源域组分谱在目标域不变, 则该 PCA 基底对目标域的重构误差应与源域同阶; 若组分谱因散射几何漂移而失稳, 目标域残差应放大。基于该 source-fit-target-transfer 协议, 分别计算源域 (产地内) 与目标域 (跨产地) 的逐样本相对残差 $R_{\text{BL}} = \|A - \hat{A}_{\text{PCA}}\|_2 / \|A\|_2$, 结果汇总于表1。PCA-10 surrogate 的合理性: 在源域内 R_{BL} 中位数低于 0.07 (表1), 说明 10 维基底已能充分表达产地内光谱可分解性, 观察到的目标域残差放大主要反映跨域组分谱漂移而非基底容量不足。为了排除“BL 违反是 PCA-10 surrogate 人为伪影”的可能性, 我们额外用三种低秩分解作为对照: 非负矩阵分解 NMF($K=3$)[36]、固定 NMF 共享谱后的非负最小二乘 NNLS($K=3$)[37]、截断 SVD($K=3$)。 (注: NNLS 直接采用 NMF 学到的源域共享组分谱 H , 因此 NMF/NNLS 不是完全独立的两个方法, 而是同一非负基底下“全样本联合分解” vs “逐样本投影”的两种实施方式。) 12 个场景的放大倍数在四种 surrogate 之间高度一致 (Pearson r 矩阵: PCA-10 vs NMF-3 $r = 0.83$ 、PCA-10 vs NNLS-3 $r = 0.83$ 、PCA-10 vs SVD-3 $r = 0.85$ 、NMF-3 vs SVD-3 $r = 0.99$, 均 $p < 0.005$)。NMF-3 与 PCA-10 的均值放大倍数分别为 2.74 与 2.37 (中位数 1.92 与 1.87), SVD-3 略高 (3.36)。PCA-10、NMF-3、SVD-3 三个 ** 显式独立 ** 的低秩近似之间放大倍数 r 均 ≥ 0.83 , 说明“跨产地低秩可分解性失稳”是一个稳健的数据观察, 不是某一种基底选择的副产品。本节的发现因此可解读为“加性可分解结构 (BL 类) 的失效指示”, 其经典 BL 物理含义需配合学到的组分谱与水/糖文献吸收带的对齐分析做进一步确认。

结果相当清晰: 12 个场景无一例外, BL 残差均出现系统性放大, 倍数从 1.10 (陕西 $\rightarrow$ 山东, 2018 年, 两地地形最为接近) 到 4.88 (新疆 $\rightarrow$ 陕西, 2018 年) 不等。按年份分别汇合: 2018 年源域中位数 $R_{\text{BL}} \approx 0.013$ 、目标域 ≈ 0.039 (放大 2.9 倍); 2025 年源域 ≈ 0.060 、目标域 ≈ 0.100 (放大 1.7 倍)。两年源域 R_{BL} 水平本身相差约 4 倍, 可能反映了两年的仪器响应、波长校准或样本表面状态差异; 但**跨域放大趋势在两年中独立成立**——这说明放大现象不依赖具体年份基线, 而是跨产地几何变化的一致性指标 (图1)。合并两年数据时, 源域中位数为 0.026、

表 1

12 个跨产地场景中的 Beer-Lambert 重构残差放大结果 ($p < 0.05$, Mann-Whitney U 检验)。 $\tilde{R}_{BL}$ 为相对残差中位数。

场景	$\tilde{R}_{BL}$ (源)	$\tilde{R}_{BL}$ (目标)	倍数	p
2018 年				
山东 → 新疆	0.0127	0.0468	3.69	6.4×10^{-59}
山东 → 陕西	0.0127	0.0209	1.65	9.4×10^{-27}
新疆 → 山东	0.0100	0.0411	4.12	3.3×10^{-55}
新疆 → 陕西	0.0100	0.0487	4.88	2.5×10^{-61}
陕西 → 山东	0.0151	0.0167	1.10	1.0×10^{-2}
陕西 → 新疆	0.0151	0.0397	2.62	1.4×10^{-58}
2025 年				
山东 → 新疆	0.0545	0.1233	2.26	4.6×10^{-32}
山东 → 甘肃	0.0545	0.0778	1.43	7.6×10^{-12}
新疆 → 山东	0.0665	0.0900	1.35	7.5×10^{-10}
新疆 → 甘肃	0.0665	0.1040	1.56	2.0×10^{-21}
甘肃 → 山东	0.0556	0.0902	1.62	1.7×10^{-25}
甘肃 → 新疆	0.0556	0.1163	2.09	8.1×10^{-36}

目标域为 0.059 (整体约 2.3 倍)。由于两年源域 R_{BL} 基线存在约 4 倍差异, 合并统计结果仅用于总体趋势展示, 具体解释应以分年份分析为主。




图 1: 12 个跨产地场景下源域 (产地内) 与目标域 (跨产地) 样本的 Beer-Lambert 重构残差 R_{BL} 分布。箱体表示四分位距 (IQR), 须线为 $1.5 \times \text{IQR}$ 。所有 12 组比较均达统计显著 ($p < 0.05$, Mann-Whitney U 检验)。

3.2. 方法整体比较

表2汇总了五种方法在 602 个场景上的聚合性能 (PLSR/SVR 无深度模型批归一化问题、覆盖全部 602; 深度模型实际收敛场景数 CNN: 575、CNN+MMD: 571、Phys+BL: 569, 因 BatchNorm1d 在末批量大小为 1 时引发训练失败以及个别 NaN 异常而略有差异)。




图 2: 四种低秩 surrogate 在 12 个跨产地场景上 BL 残差放大倍数对比: PCA-10、NMF-3、NNLS-3、SVD-3。放大倍数 ratio 均 > 1 (红色虚线为无放大基线)。四种 surrogate 间放大倍数 Pearson $r \geq 0.83$ ($p < 0.005$), 说明跨产地低秩可分解性失稳是稳健的数据观察, 不依赖具体基底选择。

在所有 CNN 成功收敛场景上, CNN 的聚合均值 RMSE 为 2.577°Brix ; 在与 Phys+BL 匹配的 569 个场景中, CNN 的配对均值 RMSE 为 2.563°Brix , Phys+BL 为 1.976°Brix , 对应配对 ratio 改进 **22.88%**, 聚合改进 **23.4%**; 按 scene-wise relative improvement, 配对均值改进 22.56%、中位数 23.09% (图4)。相对 PLSR 的聚合改进达 50.4% (配对 $n = 569$ 改进 50.85%)。配对 Wilcoxon 符号秩检验显示差异显著 ($W = 3610$, $p = 8.5 \times 10^{-87}$) ; 但 569 个场景对应 **61 个唯一目标集合** (每个 target 平均含 9.3 个场景), 故我们额外做了按唯一目标集合分层的 block bootstrap (10000 次重采样), 以避免重复样本造成的假显著。结果: 基于 61 个唯一目标集合的配对 Wilcoxon 仍显著 ($W = 87$, $p = 7.0 \times 10^{-10}$) ; block bootstrap 配对均值改进为 $22.52\% \pm 2.14\%$, 95% CI [18.27%, 26.58%]; 中位数改进 $23.31\% \pm 2.28\%$, 95% CI [18.81%, 27.63%]; $P(\text{改进} < 0) < 0.0001$ 。与朴素配对 bootstrap 相比, block bootstrap 的 95% CI 宽度从 3.53% 扩大至 8.31% (保守 2.35 倍), 但优势仍显著——说明 Phys+BL 优势不是由场景间相关性放大造成的 (图5)。RPD 由 0.708 (CNN) 提升至 0.923 (Phys+BL), 提升了 30%。 R^2 从 -1.39 改善至 -0.29 ——尽管仍为负, 但已大幅趋近于零; 我们在第4.3节解释这一现象在跨域评估中的常见性, 并在表2中补充了 RPIQ 与 Bias 这两个对跨域均值漂移更稳健的指标。

CNN+MMD (RMSE = 2.642) 不升反降, 略差于 CNN (2.577)。为排除“MMD 是欠调”的可能性, 我们

表 2

跨产地迁移场景性能对比。与 Phys+BL 的所有配对比较均达统计显著 (配对 Wilcoxon 符号秩检验, $W = 3610$, $p = 8.5 \times 10^{-87}$, $n = 569$ 个配对场景)。

方法	RMSE ($^{\circ}$ Brix)	95% CI	R^2	RPD	RPIQ	Bias	$R^2 > 0$ 场景
PLSR	3.987	[3.704, 4.284]	-9.58	0.640	0.783	-0.16	12/602
SVR	3.065	[2.994, 3.133]	-2.54	0.605	0.737	-1.02	4/602
CNN	2.577	[2.504, 2.652]	-1.39	0.709	0.870	-1.14	9/575
CNN+MMD	2.642	[2.576, 2.714]	-1.64	0.685	0.844	-1.33	3/571
Phys+BL (本文)	1.976	[1.903, 2.072]	-0.29	0.923	1.153	-0.25	46/569

注: $R^2 > 0$ 场景数基于各方法各自收敛场景数; RPIQ=IQR(y)/RMSE, 对跨域均值漂移稳健。

Phys+BL 是唯一 RPIQ 均值 > 1 的方法, 且 446/569 (78.4%) 场景 RPIQ > 1 , 远高于 CNN 的 164/575 (28.5%)。

95% CI 基于场景间 Bootstrap; 按 unique target set 的 block bootstrap 下 CNN 与 Phys+BL 差异仍显著 ($p < 10^{-9}$)。

在 8 个代表性场景上扫描 batch $\in \{16, 32, 64, 128\}$: CNN+MMD 在 batch=16 时表现最优 (mean RMSE 3.11), batch 升至 32/64/128 时性能持续劣化 (3.58 / 5.90 / 9.40 $^{\circ}$ Brix); CNN (无 MMD) 展现相同 batch-劣化模式 (2.49 / 3.21 / 6.16 / 9.41)。这反映在 1D 光谱 + 小目标域微调集 (中位数 226 条) 下, 更大 batch 因 BatchNorm 在末批量大小为 1 时触发训练失败以及梯度噪声而失稳, 与“大 batch 改善 MMD”的常见经验相反 [17]。即使在 batch=16 这一最优设定下, CNN+MMD 仍劣于 Phys+BL (1.976), 说明 MMD 的不足不归于欠调。主表的 batch=16 是各方法的合理统一选择 (图3)。




图 3: CNN+MMD vs CNN vs Phys+BL 在不同 batch size 下的平均 RMSE (8 个代表性场景, 每种迁移类型 2 个)。CNN/CNN+MMD 在 batch=16 时表现最佳, 更大 batch 因 BatchNorm 末批训练失败与梯度噪声而劣化。红虚线为 Phys+BL (batch=16) 的代表性场景平均 RMSE。

3.2.1. 按迁移类型分解的性能

表3将 RMSE 按四种迁移类型拆开来。在 1 源场景 (1 对 1 和 1 对多) 中, Phys+BL 的绝对改进最为突出: 单一源域的光谱分布相对集中, 更有利于 BL 隐空间的稳定嵌入。多源场景中改进幅度有所收




图 4: 五种方法在 569 个配对跨产地迁移场景上的 RMSE 分布。Phys+BL 的中位数最低, 分布也最为集中; 与其余各方法的配对 Wilcoxon 检验均显著 ($p < 10^{-80}$)。




图 5: 按 unique target set 的 Forest plot: Phys+BL 相对 CNN 的 RMSE 改进在 61 个唯一目标集合 (unique target sets) 上的分布。红条: 改进 > 0 ; 蓝条: 改进 < 0 。block bootstrap (10000 次按 target 抽样) 给出配对均值改进 22.5%, 95% CI [18.3%, 26.6%]; 中位数改进 23.3%, CI [18.8%, 27.6%]。

表 3

按迁移类型分解的均值 RMSE ($^{\circ}$ Brix)。

方法	1s $\rightarrow$ 1t	1s $\rightarrow$ mt	ms $\rightarrow$ 1t	ms $\rightarrow$ mt
PLSR	5.677	6.522	2.471	3.182
SVR	2.909	3.262	2.725	3.169
CNN	2.551	3.058	2.131	2.608
CNN+MMD	2.794	2.977	2.391	2.608
Phys+BL (本文)	1.612	2.352	1.625	2.043

注: 1s=1 源, 1t=1 目标, mt= 多目标, ms= 多源。

窄, 可能是丰富的源域混合本身已对基线方法起到一定补偿作用。

3.3. BL 正则化具有架构特异性: 消融实验结果

要搞清楚 Phys+BL 改进来自架构设计还是 BL 损失本身, 需要控制变量地拆开来看。我们为此设计了两组独立消融实验。

3.3.1. BL 损失施加于通用 CNN 的消融实验

第一组实验的问题: 如果只是给普通 CNN 加上一个光谱重构损失项, 而不改变隐空间结构, 会怎样? 我们在与 CNN 相同的特征提取骨干之后附加一个浅层线性解码器 (Linear(latent=4) $\rightarrow$ 64 $\rightarrow$ 229, Softplus 激活) 将 latent 重构到光谱维度, 对该重构施加与 Phys+BL 形式相同的 log-MSE 损失 ($\lambda_{bl} = 0.5$), 记为 CNN+BL。需要注意: CNN+BL 的重构光谱不由 $a \cdot b \cdot c$ 三组分分解给出, 因此该实验测试的是“在隐空间结构与 BL 不兼容时附加 BL 形式的重构损失”会产生什么效应, 而不是“在物理分解架构上去掉 BL 损失”——后者由第3.3.2节单独消融。我们在 571 个收敛场景上评估:

答案令人警惕: CNN+BL 不仅没有改进, 反而持续劣于 CNN (配对均值 RMSE 2.478 vs 2.535 $^{\circ}$ Brix, scene-wise mean 改进 -4.18%、中位数 -2.51%; 双侧 Wilcoxon $p = 4.96 \times 10^{-6}$, $n = 571$; 图6)。这是一个明确的负面结果, 说明简单地给任意光谱网络挂上 BL 正则化不仅无益, 有时甚至会把模型带偏。

3.3.2. BL 损失在物理架构内的净贡献

第二组实验的问题则是: 在物理架构内部, BL 损失本身贡献了什么? 我们在 Phys 与 Phys+BL 均成功收敛的 **566 个共享场景**上做配对比较 (与 §3.2 中 569 个 CNN-Phys+BL 共享场景为不同子集)。聚合 RMSE 改进看起来相当可观: 29.3% (含发散场




图 6: BL 约束的跨架构消融。CNN+BL (BL 损失施加于通用 CNN, $n = 571$) 与 CNN、Phys+BL 对比。将 BL 损失施加于架构上不兼容的隐空间持续损害性能 (-4.18%, scene-wise 均值, $p = 4.96 \times 10^{-6}$), 印证了“架构-约束协同设计”是 BL 正则化奏效的前提。

景的 Phys 均值 2.755 $\rightarrow$ Phys+BL 均值 1.949 $^{\circ}$ Brix)。但这个数字有点误导——它几乎全被 15 个发散场景 (Phys RMSE $>10^{\circ}$ Brix) 撑起来了。剔除这 15 个异常场景 ($n = 551$) 后, 配对中位数改进降至 0.02% (Wilcoxon $p = 0.045$), 可以说微乎其微。

因此, BL 损失在 Phys 中的核心作用是稳定训练过程的正则化: 它消除了全部 15 个退化场景 (RMSE $>10^{\circ}$ Brix, $p = 0.0026$), 防止模型在挑战性的单源场景中训练失败; 对那些本来就稳定运行的场景, 额外增益则微乎其微 (图7)。




图 7: 按迁移类型分解的 Phys 与 Phys+BL 配对 RMSE 散点图 ($n = 566$)。散点为各场景; 橙色方块标注 15 个发散场景 (RMSE $>10^{\circ}$ Brix) ——全部被 BL 损失消除。非发散场景中位数改进: 0.02%, 证实 BL 损失在 Phys 架构中主要起稳定训练过程的正则化作用。

表5按迁移类型印证了这一规律。1 源 $\rightarrow$ 1 目标场景的均值改进 (8.6%) 几乎来自唯一一个极端发散案例 (RMSE 从 48 $^{\circ}$ Brix 降至 2.8 $^{\circ}$ Brix); 中位数改进则只有 0.11%。

两组实验放在一起看, 结论相当清晰: BL 约束损失只有在网络隐空间被显式设计为 BL 兼容的前提下才有正向作用, 而将其强加于不兼容的隐空间只会引入梯度方向上的冲突, 最终伤害性能。这便是“架构-约束协同设计”的核心含义。

表 4

BL 损失施加于通用 CNN 与物理架构的对比。所有改进为配对估计量（双侧 Wilcoxon），RMSE 单位 $^{\circ}\text{Brix}$ 。

对比	源均值 RMSE	目标均值 RMSE	配对改进（均值）	配对改进（中位数）	p	n
CNN+BL vs CNN	2.478	2.535	-4.18%	-2.51%	4.96×10^{-6}	571
Phys+BL vs Phys [†]	2.022	1.943	+1.61%	+0.02%	4.46×10^{-2}	551
Phys+BL vs CNN	2.563 [‡]	1.976 [‡]	+22.56%	+23.09%	8.5×10^{-87}	569

全部“配对改进（均值/中位数）”列均使用 scene-wise relative improvement 口径

（每个场景计算 $(a - b)/a$ 再对场景集合求均值/中位数），不同于“ratio of paired means” $(\bar{a} - \bar{b})/\bar{a}$ 。

[†] 剔除 15 个 Phys 发散场景（RMSE > 10°Brix ）后的统计；含发散场景时 Phys 均值 2.755、聚合 ratio 改进 29.3%（见 §3.3.2）。

[‡] 配对子集均值（ $n=569$ ）；ratio of paired means = 22.88%，聚合 ratio = 23.4%（基于 CNN 算术均值 2.577 与 Phys+BL 1.976）。

表 5

Phys→Phys+BL 按迁移类型分解（ $n = 566$ ；RMSE 单位 $^{\circ}\text{Brix}$ ）。聚合 RMSE（含发散场景）与配对改进为不同统计量，不可直接相除。1s=1 源，mt= 多目标，ms= 多源，1t=1 目标。

类型	n	Phys	Phys+BL	Δ 均值	Δ 中位数
1s→1t	30	4.154 [†]	1.670	+8.55%	+0.11%
1s→mt	130	3.943 [†]	2.173	+12.34%	+1.73%
ms→1t	156	2.146	1.623	+1.55%	-0.53%
ms→mt	250	2.346	2.062	+0.43%	-0.01%

[†] 含发散场景（RMSE > 10°Brix ），聚合均值被少数极端案例抬高；中位数改进更具代表性。

3.4. 跨域稳健指标分析

跨域评估中， R^2 对目标域均值/方差漂移敏感而容易呈负值（详见第4.3节）；为多角度反映模型在不同跨域场景中的实际表现，我们额外报告 RPIQ（基于四分位距）与 Bias（平均预测偏差）（表2最后两列）。Phys+BL 在两个稳健指标上均显著优于基线：RPIQ 均值 1.153 vs CNN 的 0.870（提升 32.5%），是唯一 RPIQ 均值 > 1 的方法；按场景数看，446/569（78.4%）场景达到 RPIQ > 1，远高于 CNN 的 164/575（28.5%）。绝对偏差 Bias 上，Phys+BL 为 -0.25°Brix ，显著接近零；而所有基线均显示 $< -1.0^{\circ}\text{Brix}$ 的系统性低估（CNN: -1.14 ，CNN+MMD: -1.33 ，SVR: -1.02°Brix ），反映这些方法在目标域上倾向于把高糖度样本压低。这种系统偏差在实际商业分级中可能将大量“优质”误判为“普通”，应用上有影响销售定价的风险。Phys+BL 的小 Bias 表明物理解约约束有效抑制了跨域均值漂移这一 NIR 迁移学习的常见缺陷。

3.5. 品质误判率分析

品质误判率（预测 SSC 二分类等级与参考等级不一致的比例）按方法汇总为：PLSR 44.1%、SVR 41.2%、CNN 39.9%、CNN+MMD 40.6%、Phys+BL 40.1%（基于各方法各自的收敛场景）。所有方法集中在 39.9%–44.1% 这一相对窄的区间内，差别不大。对 569 个共享场景的配对 Wilcoxon 检验显示，CNN（39.9%）与 Phys+BL（40.1%）之间的差异 $W = 73,378$ ， $p = 0.0493$ ——虽达边际显著，但效应方向是 Phys+BL 略高于 CNN，且差异均值仅 +0.2 百分点，应用层面可视为基本持平。因此，Phys+BL 的优势主要体现在连续 RMSE 精度的系统性改善上，而非品质等级分类的准确性。这是当前模型的一个明确局限——若以分类正确率为应用目标，仍需进一步设计针对决策边界的损失项。

3.6. 正则化权重灵敏度

图8展示了在 8 个代表性跨产地场景（每种迁移类型 2 个）上，Phys 架构加入额外 MMD 项后形成的 Phys+BL+MMD 变体对 $(\lambda_{bl}, \lambda_{mmd})$ 网格的灵敏度热力图。（注：主实验中 Phys+BL 固定 $\lambda_{mmd} = 0$ ，不引入 MMD 项；此处的扫描旨在探索“BL 正则化与 MMD 域适应”是否可以叠加，属于补充消融。）结果：聚合层面， $\lambda_{bl} = 0.5$ 附近无论 λ_{mmd} 取何值均接近最低 RMSE，说明在 Phys 架构内 MMD 项收益微弱。逐场景最优 λ_{bl} 分布于 $\{0.05, 0.10, 0.30, 0.50, 1.00, 2.00\}$ ，对应 $\lambda_{mmd} \in \{0.1-1.0\}$ ；即同一架构在不同迁移场景下的最优正则化强度差异较大，反映 BL 兼容性对场景敏感。实践建议：以 $\lambda_{bl} = 0.5$ 、 $\lambda_{mmd} = 0$ 为缺省，若有少量目标域标定光谱可在 $[0.3, 1.0]$ 区间内做快速扫描。完整 601 场景上的纯 λ_{bl} 灵敏度结果作为修订版补充材料的一部分。




图 8: Phys+BL RMSE 对正则化权重 λ_{bl} 与 λ_{mmd} 的灵敏度 (热力图, 均值 RMSE)。蓝色矩形标记全局最优 ($\lambda_{bl} = 0.5$, $\lambda_{mmd} = 0.5$)。

4. 讨论

4.1. BL 违反信号的物理解释

第3.1节观察到的 BL 残差放大,从物理上看其实不难理解。完整果实漫反射 NIR 中,光子有效路径长度主要由散射系数 $\mu_s(\lambda)$ 决定,而 $\mu_s(\lambda)$ 又高度依赖细胞壁结构、胞间空气分数和表皮蜡质成分 [1]——偏偏这些参数会随产地的土壤矿物组成、灌溉制度和积温条件系统性变化 [7, 8]。一旦 $\mu_s(\lambda)$ 漂移,各波段间的有效路径长度权重随之失衡, Kubelka–Munk 近似下的加性结构遭到破坏, BL 残差 R_{BL} 自然放大。表1中放大倍数最高的恰恰是新疆高原 → 陕西黄土高原 (4.88×), 这一产地对在气候和土壤方面差异显著,与上述机制提供的解释一致;但定量的组织学/光学物性测量未在本工作中开展,因果链尚需补充实验加固。

从数据面来看, BL 残差放大倍数 (1.10–4.88×) 与 RMSE 劣化幅度 (PLSR 在极端场景可超过 6°Brix) 之间存在明显的定性对应,提示 BL 残差或许可作为一种轻量级的域适应监测指标——无需参考标签,只需对比源域和目标域的 BL 残差分布即可初步判断迁移风险。

4.2. 架构重要性超越 BL 损失本身

上述消融实验结果 (BL 损失损害了通用 CNN 的性能) 乍看确实有悖直觉: 既然 BL surrogate 残差跨域显著放大与跨产地失效的物理直觉一致,惩罚 BL 重构误差不该有帮助吗?

问题的关键在于表示空间的兼容性。普通 Conv1d 网络的隐特征完全由数据驱动,不具备 BL 加性分量 (c_1, c_2, c_3) 的结构,而是同时混杂了散射、吸收和仪器噪声的信号。在这样的隐层上施加 BL 重构损失,相当于迫使网络同时服务两个方向相反的梯度: 一边要让 $\hat{A} \approx A$ (需要 BL 可分解的特征), 另一边要让预测误差最小 (需要判别性特征)。两个目标互相掣肘, 预测损失通常占优并抑制物理约束, 最终走向次优解。

Phys 架构的本质差别恰在于此: 它预先把隐空间结构化为 (a, b, c) 三个 BL 分量权重, 使得物理约束与网络的归纳偏置天然对齐——BL 重构损失在这里强化而非对抗预测目标。这正是“物理损失只有在网络表示被显式设计为支持它时才有益”的含义 [38–40]。

4.3. 负 R^2 与 RPD<1.0 的解释

所有方法——包括最优基线——在跨产地测试集上的 R^2 均为负值, 这是正常的。原因在于: 跨产地目标域与源域在均值和方差上本就不同, 即便拟合良好的预测值, 用目标域方差来评估时也会显得有偏。跨域泛化任务中出现负 R^2 , 并不代表模型失效, 而是任务性质使然, 同类研究中已有报告 [8, 26, 41]。

RPD 的情况与此类似。RPD<1.5 乃至低于 1.0 在跨域 NIR 转移场景中相当常见: Tian et al. [8] 在不做任何标定转移的条件下, 跨产地直接预测 SSC 仅取得 RPD 约 0.8; Fan et al. [7] 报告的直接跨季节应用也在相近水平。在这个难度层级上, 本文 Phys+BL 取得 RPD = 0.923, 比 CNN (RPD = 0.708) 提升了 30%, 相对改进是有意义的。评价该任务下方法好坏的尺度应当是相对改进量, 辅以对目标域均值漂移更稳健的 RPIQ 和 Bias 指标 (详见第3.4节) —— Phys+BL 的 RPIQ 均值 1.153 与近零 Bias 表明, 即使 R^2 这一对域内方差敏感的指标尚未转正, 模型在 RMSE、绝对偏差等连续误差维度已显著优于基线。但应注意: 当前误判率仍约 40%、 R^2 均值仍为负, 距离单产地部署所要求的工业级精度 (通常 RMSE<0.7°Brix、 R^2 >0.85) 尚有差距。

4.4. 局限性与未来方向

这里坦诚地讨论几点局限。

λ_{bl} 的场景依赖性。如第3.6节所示, 最优 λ_{bl} 会随场景而变, 我们给出的 0.5 是聚合层面的最优, 不

一定适合所有迁移方向。理论上若目标产地有少量带标签的标定光谱可做快速调参，但本工作未在最小标定样本量上系统验证，留作后续工作。

固定的三组分 BL 分解。 $K = 3$ 是由苹果 NIR 的主要吸收体（水分、糖分、结构散射）给出的工程判断，并非从第一性原理光谱解卷积中推导出来。我们在 40 个代表性场景上对 $K \in \{2, 3, 4, 5, 6\}$ 做了网格消融（每个 K 同等训练预算）；受计算资源限制，该消融为快速验证子集，绝对 RMSE 数值不应与主表直接比较，但相对趋势可参考：相邻 K 配对 Wilcoxon 检验显示 $K = 3 \rightarrow K = 4$ 略优 ($+1.98\%$, $p = 1.4 \times 10^{-4}$)， $K = 4 \rightarrow K = 5$ 显著退化 (-4.98% , $p = 5.5 \times 10^{-12}$)，说明 $K \in \{3, 4\}$ 是较优区间， $K \leq 2$ 容量不足、 $K \geq 5$ 出现过参数化退化。 $K = 3$ 因参数量较小且与 $K = 4$ 性能相近，作为主方法的工程选择是合理的。学到的三组分谱与水/糖文献吸收带的严格对齐分析仍是局限，留待后续研究。若引入可学习的 K （例如稀疏基学习目标）或非负矩阵分解约束，理论上可进一步提升隐表示的物理保真度 [39]。

单一 backbone 的”架构-约束兼容性”验证。 本研究的核心观察——BL 正则化在通用 Conv1d 网络中有害、在物理分解架构中有益——仅在一个 CNN backbone 上得到了统计验证 ($n = 571$ 与 $n = 566$)。为检验该现象对 backbone 家族 (MLP/ResNet1D/Transformer1D 等) 的推广性，本工作未做这一推广实验。”架构-约束兼容性假说”作为可证伪命题，其在更广泛架构家族上的成立性是本工作的一个明确局限，留待后续研究系统验证。

单一仪器类型。 两个数据集各自只使用了一种光谱仪。跨仪器平台转移会引入仪器函数差异这一额外变异源，BL 违反机制在多仪器场景下可能进一步放大，这是一个值得专门研究的方向。

新产地泛化性。 2025 年数据集包含了 2018 年未曾见过的甘肃产地。Phys+BL 在涉及甘肃的迁移场景中相对基线仍有改进，提示物理归纳偏置对新产地有一定的迁移容忍度。但本研究的评估协议属于 transductive UDA（目标域 train 子集无标签参与适应，val 标签用于早停）而非严格零样本，未来在完全零样本（仅源域监督、目标域无任何参与）协议下的泛化性需另行验证。

训练稳定性。 所有深度模型使用 Adam 优化器、BatchNorm 与余弦退火学习率，在 batch=16、

$\lambda_{bl} = 0.5$ 的设定下，整体训练曲线在收敛场景上稳定下降。我们在未来工作中将在更大 batch、更深 backbone 以及多种正则化组合下重新核查训练稳定性。

5. 结论

本文从一个数据驱动的观察出发：在基于 PCA-10 的加性可分解性 surrogate 下，12 个跨产地 NIR 场景上目标域残差相对源域显著放大（放大倍数 1.1–4.9 $\times$ ，均 $p < 0.05$ ）。这一观察提示 Beer–Lambert 类加性约束在跨产地光学几何变化下的失稳，是苹果 NIR 光谱跨产地模型失效的一个可量化的近端因素。

基于这一认识，我们提出了物理知情分解架构 Phys+BL，将 BL 约束内化为网络隐空间的归纳偏置，而非作为事后附加的正则化项。在 569 个跨产地迁移场景上，Phys+BL 取得均值 RMSE = 1.976°Brix，较普通 CNN 聚合改进 23.4%；按 61 个唯一目标集合的 block bootstrap，均值改进 22.5%，95% CI [18.3%, 26.6%]， $P(\text{改进} < 0) < 10^{-4}$ （详见 §3.2）。

一个附带发现是 BL 正则化的架构特异性：同样的 BL 损失加在通用 CNN 上会持续劣化性能，而在物理分解架构内则能防止发散。这一观察支持一个可证伪的”架构-约束兼容性假说”——物理约束要奏效，网络的隐空间必须被显式参数化为可承载该约束的形式。我们在一 CNN backbone 上验证了该现象在 569 个跨产地场景中的统计稳健性；其在更广泛架构家族 (MLP、ResNet1D、Transformer1D) 以及其他物理约束（守恒律、对称性等）上的成立性需进一步验证，本工作未做此推广。对实际从业者而言，本研究提供了一条务实路径：当目标域漂移由已知物理机制驱动时，与其在事后添加正则项，不如把该机制直接编码进网络隐空间的结构中。

数据与代码可用性

受学校相关规定限制，原始数据与代码暂不公开；如有需要，可通过邮件向通讯作者索取。审稿期间，评审者可通过向通讯作者申请获取匿名数据集样本以进行独立核验。

资金来源

本研究由新疆维吾尔自治区科技创新团队（天山创新团队）（2022TSYCTD0011）和国家自然科学基金项目（61367001）资助。

参考文献

- [1] B. M. Nicolai, K. Beullens, E. Bobelyn, A. Peirs, W. Saeys, K. I. Theron, J. Lammertyn, Nondestructive measurement of fruit and vegetable quality by means of NIR spectroscopy: A review, *Postharvest Biology and Technology* 46 (2007) 99–118.
- [2] K. B. Walsh, J. Blasco, M. Zude-Sasse, X. Sun, Visible-NIR 'point' spectroscopy in postharvest fruit and vegetable assessment: The science behind three decades of commercial use, *Postharvest Biology and Technology* 168 (2020) 111246.
- [3] D. Rong, Y. Ying, L. Xie, X. Fu, Y. Liu, W. Kong, Nondestructive evaluation of soluble solids content of apple using a developed portable Vis/NIR device, *Biosystems Engineering* 193 (2020) 138–148.
- [4] Y. Huang, R. Lu, D. Hu, K. Chen, Prediction of soluble solids content of apple using the combination of spectra and textural features of hyperspectral reflectance imaging data, *Postharvest Biology and Technology* 136 (2018) 130–141.
- [5] P. C. Williams, Implementation of near-infrared technology, *Near-Infrared Technology in Agricultural and Food Industries* (2001) 145–169.
- [6] S. Wold, M. Sjostrom, L. Eriksson, Pls-regression: A basic tool of chemometrics, *Chemometrics and Intelligent Laboratory Systems* 58 (2001) 109–130.
- [7] S. Fan, J. Li, Y. Xia, X. Tian, Z. Guo, W. Huang, Long-term evaluation of soluble solids content of apples with biological variability by using near-infrared spectroscopy and calibration transfer method, *Postharvest Biology and Technology* 151 (2019) 79–87.
- [8] X. Tian, S. Fan, W. Huang, J. Li, C. Zhao, Detection of soluble solids content in apples from different countries of origin by using near-infrared spectroscopy and calibration transfer, *Journal of Food Composition and Analysis* 118 (2023) 105186.
- [9] Y. Li, Q. Yin, B. Zhan, D. Han, Y. Shi, S. Fan, Improving apple soluble solids content prediction by combining domain adaptation and deep transfer learning, *Computers and Electronics in Agriculture* 199 (2022) 107065.
- [10] Z. Guo, W. Huang, Y. Peng, Q. Chen, Q. Ouyang, J. Zhao, Color compensation and comparison of shortwave near infrared and long wave near infrared spectroscopy for determination of soluble solids content of 'Fuji' apple, *Postharvest Biology and Technology* 115 (2016) 206–214.
- [11] R. J. Barnes, M. S. Dhanoa, S. J. Lister, Standard normal variate transformation and de-trending of near-infrared diffuse reflectance spectra, *Applied Spectroscopy* 43 (1989) 772–777.
- [12] Å. Rinnan, F. van den Berg, S. B. Engelsen, Review of the most common pre-processing techniques for near-infrared spectra, *TrAC Trends in Analytical Chemistry* 28 (2009) 1201–1222.
- [13] P. Mishra, J. M. Roger, D. Jouan-Rimbaud Bouveresse, D. N. Rutledge, Two simple and robust approaches for the calibration of NIR spectrometers between domains, *Chemometrics and Intelligent Laboratory Systems* 218 (2021) 104412.
- [14] S. J. Pan, Q. Yang, A survey on transfer learning, *IEEE Transactions on Knowledge and Data Engineering* 22 (2010) 1345–1359.
- [15] B. Sun, K. Saenko, Deep CORAL: Correlation alignment for deep domain adaptation, *Lecture Notes in Computer Science (ECCV Workshops)* 9915 (2016) 443–450.
- [16] A. Gretton, K. M. Borgwardt, M. J. Rasch, B. Schölkopf, A. Smola, A kernel two-sample test, in: *Journal of Machine Learning Research*, volume 13, 2012, pp. 723–773.
- [17] M. Long, Y. Cao, J. Wang, M. I. Jordan, Learning transferable features with deep adaptation networks, *Proceedings of the 32nd International Conference on Machine Learning (ICML)* (2015) 97–105.
- [18] E. Tzeng, J. Hoffman, K. Saenko, T. Darrell, Adversarial discriminative domain adaptation, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (2017) 7167–7176.
- [19] R. Nikzad-Langerodi, W. Zellinger, E. Lughofer, S. Saminger-Platz, Domain-invariant partial-least-squares regression, *Analytical Chemistry* 90 (2018) 6693–6701.
- [20] S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, J. W. Vaughan, A theory of learning from different domains, *Machine Learning* 79 (2010) 151–175.
- [21] Y. Ganin, E. Ustunova, H. Ajakan, P. Germain, H. Larochelle, F. Laviolette, M. Marchand, V. Lempitsky, Domain-adversarial training of neural networks, in: *Journal of Machine Learning Research*, volume 17, 2016, pp. 1–35.
- [22] R. Nikzad-Langerodi, W. Zellinger, E. Lughofer, S. Saminger-Platz, Domain adaptation for regression under Beer–Lambert's law, *Knowledge-Based Systems* 210 (2020) 106447.
- [23] P. Mishra, R. Nikzad-Langerodi, Partial least squares versus domain invariant partial least squares regression with application to near-infrared spectroscopy of fresh fruit, *Infrared Physics & Technology* 111 (2020) 103547.
- [24] R. N. Feudale, N. A. Woody, H. Tan, A. J. Myles, S. D. Brown, J. Ferre, Transfer of multivariate calibration models: a review, *Chemometrics and Intelligent Laboratory Systems* 64 (2002) 181–192.
- [25] C. V. Greensill, K. B. Walsh, Calibration transfer between miniaturized diode array-based spectrometers for the NIR assessment of melon soluble solids content, *Journal of Near*

- Infrared Spectroscopy 9 (2001) 1–7.
- [26] P. S. Sampaio, A. Castanho, A. S. Almeida, J. Oliveira, C. Brites, Prediction of rice quality using near infrared spectroscopy: Models' transferability between two independent instruments, *Food Analytical Methods* 15 (2022) 1948–1957.
- [27] A. Beer, Bestimmung der absorption des rothen lichts in farbigen flüssigkeiten, *Annalen der Physik und Chemie* 86 (1852) 78–88.
- [28] B. G. Osborne, Near-infrared spectroscopy in food analysis, *Encyclopedia of Analytical Chemistry* (2006).
- [29] P. Kubelka, F. Munk, Ein beitrage zur optik der farbanstriche, *Zeitschrift für technische Physik* 12 (1931) 593–601.
- [30] J. Y. Chen, C. Iyo, F. Terada, S. Kawano, Near-infrared spectroscopy of single intact apple – relationship between absorption band and water content, *Journal of Near Infrared Spectroscopy* 10 (2002) 185–193.
- [31] S. L. Jacques, Optical properties of biological tissues: a review, *Physics in Medicine and Biology* 58 (2013) R37–R61.
- [32] V. N. Vapnik, *The nature of statistical learning theory*, Springer, New York (1995).
- [33] Y. Ozaki, W. F. McClure, A. A. Christy, *Near-infrared spectroscopy in food science and technology*, Wiley-Interscience (2006).
- [34] D. P. Kingma, J. Ba, Adam: A method for stochastic optimization, *Proceedings of the 3rd International Conference on Learning Representations (ICLR)* (2015).
- [35] F. Wilcoxon, Individual comparisons by ranking methods, *Biometrics Bulletin* 1 (1945) 80–83.
- [36] D. D. Lee, H. S. Seung, Learning the parts of objects by non-negative matrix factorization, *Nature* 401 (1999) 788–791.
- [37] C. L. Lawson, R. J. Hanson, *Solving Least Squares Problems*, SIAM, 1995.
- [38] A. Karpatne, G. Atluri, J. H. Faghmous, M. Steinbach, A. Banerjee, A. Ganguly, S. Shekhar, N. Samatova, V. Kumar, Theory-guided data science: A new paradigm for scientific discovery from data, *IEEE Transactions on Knowledge and Data Engineering* 29 (2017) 2318–2331.
- [39] M. Raissi, P. Perdikaris, G. E. Karniadakis, Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations, *Journal of Computational Physics* 378 (2019) 686–707.
- [40] L. von Rüden, S. Mayer, K. Beckh, B. Georgiev, S. Giesselbach, R. Heese, B. Kirsch, J. Pfrommer, A. Pick, R. Ramamurthy, M. Walczak, C. Bauckhage, J. Garcke, Informed machine learning – a taxonomy and survey of integrating prior knowledge into learning systems, *IEEE Transactions on Knowledge and Data Engineering* 35 (2023) 614–633.
- [41] Y. Liu, Y. Wang, J. Chen, X. Zhao, Cross-variety calibration transfer for near-infrared spectroscopy: A review and prospect, *Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy* 286 (2023) 121929.