

高光谱空谱融合何时有益：一个函数型分解视角

李盼林^a, 李宇畅^a and 黄华^{a,b,*}

^a 新疆农业大学数理学院, 乌鲁木齐, 830052, 中国

^b 新疆农业大学数值模拟与数据分析研究中心, 乌鲁木齐, 830052, 中国

ARTICLE INFO

Keywords:

空谱融合
高光谱成像
函数型数据分析
可识别性
评测泄漏
可信机器学习

ABSTRACT

空谱 (spatial-spectral) 特征融合被普遍视为提升高光谱成像 (hyperspectral imaging, HSI) 性能的关键, 但何时、为何有益缺乏可先验判定的刻画; 同时主流评测多用随机像素划分, 使空间自相关的相邻像素同时落入训练与测试, 系统性夸大精度。本文把 HSI 立方体视为函数值空间场, 将融合严格分解为可加 (边缘光谱 + 边缘空间) 与交互两部分, 并证明: 融合增益被可计算的交互能量 γ 上下夹逼 ($\gamma \rightarrow 0$ 时拼接即最优); 跨队列泛化落差由映射漂移 Δ_{map} 经 Le Cam 下界刻画, 并可先验估计。在四个跨域基准上采用防泄漏空间分块交叉验证, 得到三条一致结论: (1) 融合增益以可加为主——低阶空谱交互的额外贡献很小 (多种子点估计 ≤ 0.014 宏 F1, $\hat{\gamma} \in [0.02, 0.07]$), 合成验证进一步表明 $\hat{\gamma}$ 是真实交互能量的保守下界, 而能表征高阶交互的深度模型其增益同样有限, 两条独立证据共同支持可加性主导; (2) 约 270–480 参数的可加模型达深度基线宏 F1 的 89% ~ 95%, 而后者参数多 168 ~ 859 倍; (3) 随机划分将绝对精度夸大达 38.6 个百分点。 γ 与映射漂移证书是两个可在训练/部署前计算的诊断量, 为“是否值得融合、能否跨场景迁移”提供量化依据。

1. 引言

高光谱成像同步获取目标的二维空间图像与数百个连续窄波段的光谱, 是“图谱合一”的张量型数据 [1, 2, 3]。其每个像素是一条采样自连续电磁响应的高维向量, 而相邻像素在空间上高度相关, 因而 HSI 同时承载光谱与空间两类结构信息。如何融合二者以提升建模的精度、鲁棒性与可解释性, 是 HSI 分析的核心问题 [4, 5], 并在过去十余年催生了从空谱联合核、马尔可夫随机场、形态学剖面, 到三维卷积、空谱注意力与 Transformer 的一系列日益复杂的架构 [6, 7, 8, 9, 10, 11]。这些方法在各自的数据划分下普遍报告接近饱和的精度, 使“空谱融合越复杂越好”几乎成为领域的默认预期 [12, 13]。

然而, 支撑这一信条的两个基础问题始终悬而未决。

问题一 (机理): 融合相对“先分别提取空间与光谱特征、再简单拼接”的增益究竟从何而来、何时存在? 现有工作几乎都以端到端的经验性能对比作答, 缺乏可证、可先验判定的刻画 [19, 20]。其后果是: 当一个复杂融合模型在某基准上超越简单拼接时, 我们无法判断这是源于真正的不可加空谱交互, 还是仅仅源于更强的可加空间上下文建模能力——二者对模型设计与计算成本的含义截然不同。

问题二 (评测有效性): HSI 像素分类的主流协议采用随机像素划分, 使空间相邻、因而高度自相关的像素同时落入训练与测试集, 造成信息泄漏, 系统性高估泛化性能 [29, 30, 31]。在被泄漏夸大的评测下, “复杂融合带来的提升”可能本身就是高估的产物。

这两个问题相互交织: 唯有在无泄漏的评测下、以可分解的视角, 才能厘清融合增益的真实来源与大小。本文从函数型数据分析 (functional data analysis, FDA) [21, 22, 23] 出发统一回答上述问题。我们将每个 HSI 立方体视为定义在空间域 D 与连续光谱域 Λ 上的函数值空间场 $X(u, \lambda)$, 把“空谱融合”严格表述为对最优预

测函数的方差分析 (ANOVA) 型分解: 可加部分 (边缘光谱函数 ϕ_s + 边缘空间统计 ϕ_a) 与交互部分 C 。这一视角给出两条可证结论与两个可计算诊断, 并以跨域、防泄漏实证检验。

贡献:

- (1) 函数型空谱框架: 把 HSI 融合形式化为可加 $\oplus$ 交互的函数型 ANOVA 分解 (图 1), 并建立其可识别性 (命题 1)。
- (2) 融合增益的可计算上下界: 证明融合相对拼接的超额收益在总体层面恰等于、有限样本下被夹逼于交互能量 γ (命题 2), 从而把“是否值得融合”转化为一个可估的标量。
- (3) 迁移落差下界与证书: 证明跨队列泛化落差被映射漂移 Δ_{map} 经 Le Cam 双点极小极大下界刻画, 并给出其可计算代理 (命题 3)。
- (4) 跨域防泄漏实证: 在遥感与农业四基准上一致表明融合主要是可加增益、约 270–480 参数的可加模型逼近深度基线、随机划分巨幅夸大绝对精度。
- (5) 两个先验诊断工具: 交互能量 γ 与映射漂移证书, 分别回答“是否值得融合”“能否跨场景迁移”, 可在训练/部署前计算。

新颖性边界 (诚实声明): 函数型 ANOVA 交互分解、“存在交互时联合优于可加”的原理、以及域适应中后验漂移 (posterior drift) 下界的骨架均属已知结果 [33, 34, 35, 36]。本文的新意不在于重造这些原理, 而在于: 将其在函数型 (连续光谱) $\times$ 离散空间的 HSI 情形下实例化、给出可计算的诊断量 γ 与 Δ_{map} 、并以跨域防泄漏实证揭示一个被复杂架构长期掩盖的事实——HSI 空谱融合的收益主要是可加的。

2. 相关工作

2.1. HSI 空谱特征融合

早期 HSI 分类以纯光谱方法为主 (偏最小二乘 [15]、支持向量机 [14]), 随后大量工作引入空间信息以缓解“同物异谱、同谱异物”。代表性范式包括: 空谱联合核与

*通讯作者

✉ huanghua@xjau.edu.cn (黄华)

ORCID(s): 0000-0003-0615-9402 (黄华)

组合核 [4]、扩展形态学剖面、马尔可夫随机场后处理，以及近年依托深度表征学习 [16] 的方法——三维卷积网络 [6]、二维/三维混合网络（如 HybridSN）[7]、图卷积 [11]、空谱 Transformer（如 SpectralFormer）[8] 与近期的状态空间模型（如 SpectralMamba）[17]。综述 [9, 10, 12, 13] 系统总结了这一脉络，普遍结论是“联合建模优于分离建模”。然而这些比较多在随机划分下进行、且很少区分增益是来自可加空间上下文还是不可加空谱交互。多源/多模态融合综述 [19, 20] 亦指出协同表征机制尚缺乏理论刻画。本文正是针对这一空白，给出融合增益的可分解、可计算刻画。

2.2. 函数型数据分析

FDA 将每条观测视为定义在连续域上的函数 [21, 22, 23]。函数型线性回归的极小极大率与自适应估计已有系统理论 [25, 26, 27]。将光谱视为波长的连续函数、以基函数展开表征，能保留谱的连续性与高相关结构，并控制维数灾难 [28]。本文把这一视角扩展到函数值空间场（每像素一条谱函数、像素在空间上耦合），并据此定义可加 $\oplus$ 交互分解。

2.3. 评测泄漏与空间交叉验证

当训练与测试样本在空间上相关时，忽略该相关的随机划分会高估泛化 [30]。Ploton 等 [31] 在大尺度生态制图中证明随机验证给出过度乐观的预测力；Karasiak 等 [29] 在遥感分类中系统比较空间与非空间交叉验证，建议空间留一法以获无偏估计；Meyer 与 Pebesma [18] 在全球生态制图中进一步表明，忽视空间依赖的随机验证会系统性高估机器学习地图的精度；Kattenborn 等 [32] 在植被遥感深度学习综述中亦强调这一陷阱。本文采用空间分块（留块）交叉验证，并定量给出随机划分相对防泄漏协议的精度夸大幅度。

2.4. 域适应与迁移学习理论

跨越泛化的不可能性与下界已有经典刻画：Ben-David 等 [33] 给出基于域散度的目标误差界；协变量移与重要性加权 [36, 37]；Cai 与 Wei [34]、Kpotufe 与 Martinet [35] 给出迁移的极小极大率与后验漂移下界。本文在 HSI 的线性-高斯实例中实例化后验漂移下界，并把漂移量诊断化为可由数据先验估计的迁移证书。

3. 函数型空谱框架与估计器

3.1. 生成模型与融合分解

设样本 i 的立方体 $X_i: D_i \times \Lambda \rightarrow \mathbb{R}$ ， D_i 为离散像素域， $\Lambda \subset [\lambda_{\min}, \lambda_{\max}]$ 为连续光谱域。由 X_i 提取两类边缘特征：

- 边缘光谱特征 $s_i \in S$ ：对逐像素谱函数做函数型主成分分析（FPCA），取前 K 个得分；
- 边缘空间特征 $a_i \in \mathcal{A}$ ：对每个 FPCA 得分图取邻域统计（如 $w \times w$ 邻域均值），刻画空间上下文。

对响应 y_i ，记其最优预测（贝叶斯回归函数）为 $f^*(s, a) = \mathbb{E}[y | s, a]$ 。 $L^2(S \times \mathcal{A})$ 上的函数型 ANOVA

Table 1
主要记号。

记号	含义
$X_i(u, \lambda)$	样本 i 的函数值空间场（像素 u 、波长 λ ）
s_i, a_i	边缘光谱特征 / 边缘空间特征
$f^* = \phi_s + \phi_a + C$	最优预测的可加 $\oplus$ 交互分解
γ	交互能量（定义 1）
Δ_{map}	跨队列“谱 $\rightarrow$ 性状”映射漂移
Gap	融合增益 $\text{ER}_{\text{add}} - \text{ER}_{\text{joint}}$
$\hat{\gamma}, \hat{\Delta}$	$\gamma, \Delta_{\text{map}}$ 的可计算证书（诊断量）
L_{spat}	空间图-Laplacian
K_t, β_c	FPCA 成分数 / 队列 c 的谱 $\rightarrow$ 性状方向

(Hoeffding) 分解给出

$$f^*(s, a) = \underbrace{\phi_s(s) + \phi_a(a)}_{\text{可加 (边缘)}} + \underbrace{C(s, a)}_{\text{空谱交互}}, \quad y = f^*(s, a) + \zeta, \quad (1)$$

其中 ζ 为零均值噪声， $\mathbb{E}[\phi_s] = \mathbb{E}[\phi_a] = 0$ 、 $\mathbb{E}[C | s] = \mathbb{E}[C | a] = 0$ （中心化约束）， C 为不可加交互——它刻画“光谱特征的空间分布所携带、而边缘光谱 ϕ_s 与边缘空间 ϕ_a 各自都不含”的信息。

定义 1 (交互能量 γ). $\gamma := \inf_{h \in \mathcal{H}_{\text{add}}} \mathbb{E}[(C(s, a) - h(s, a))^2] = \mathbb{E}[(C - \Pi_{\text{add}} C)^2]$ ，其中 $\mathcal{H}_{\text{add}} = \{g_1(s) + g_2(a) : g_1 \in L^2(S), g_2 \in L^2(\mathcal{A})\}$ ， Π_{add} 为其 L^2 正交投影。 γ 度量交互中无法被任何可加/拼接函数表示的能量。

“可加晚融合（additive late fusion）”估计器把假设空间限制在 $\mathcal{H}_{\text{add}}$ 内（先独立提取 s, a 、再可加组合；注意：拼接后接非线性头（MLP/核/注意力）可表征交互，不属此可加类）；“空谱联合（joint）”估计器在 $L^2(S \times \mathcal{A})$ 内，可表征交互 C 。全文主要记号汇总于表 1。

3.2. 估计器与诊断量

简单可加函数型模型：以 ϕ_s （FPCA 得分， $K = 15$ ）与 ϕ_a （ 9×9 邻域均值）为特征，线性 softmax 读出，总参数约 270 ~ 480，不含显式交互项。联合（+ 交互）变体：在可加特征上追加谱 $\times$ 空间低阶交叉项 $\{\phi_{s,k} \phi_{a,l}\}$ 以表征 C ，用于检验融合增益与估计 γ ；其经验估计 $\hat{\gamma}$ 取“交互特征对可加残差的可解释能量占比”。空间正则函数型联合估计器（一般形式）：系数 $\beta(u, \lambda)$ 带不可分耦合正则

$$\min_{\beta} \frac{1}{n} \sum_i (y_i - \langle \beta, X_i \rangle)^2 + \lambda_{\Lambda} \|\beta\|_{W^{s,2}(\Lambda)}^2 + \lambda_D \text{tr}(\beta^{\top} L_{\text{spat}} \beta), \quad (2)$$

谱向 Sobolev 粗糙度罚 $\otimes$ 空间图-Laplacian L_{spat} 罚。求解与复杂度：式 (2) 关于 (ϕ_s, ϕ_a, C) 块凸，采用块坐标下降：固定其余项时各子问题为带 Sobolev/图-Laplacian 二次罚的最小二乘，有闭式或共轭梯度解；谱向卷积在平移不变假设下经快速傅里叶变换对角化、空间向利用稀疏图-Laplacian，单步复杂度 $\mathcal{O}(n|\Lambda| \log |\Lambda| + n \cdot \text{nnz}(L))$ （随像素数线性、随波段近




Figure 1: 函数型空谱分解框架。把 HSI 立方体视为函数值空间场 $X(u, \lambda)$ ，经 FPCA 提取边缘光谱特征 ϕ_s 与边缘空间特征 ϕ_a ；最优预测 f^* 分解为可加 ($\phi_s \oplus \phi_a$ ，晚融合/拼接，蓝绿) 与交互 C (橙) 两部分，交互的不可加能量记为 γ (命题 2: $\gamma \rightarrow 0$ 时拼接即最优)。底部虚线表示跨队列部署时由映射漂移 Δ_{map} 刻画的可迁移性 (命题 3)。 γ 与 Δ_{map} 是两个可在训练/部署前计算的诊断量。

线性，可扩展到大场景)，在 (ϕ_s, ϕ_a, C) 邻域受限强凸下局部线性收敛至驻点。相较之下，简单可加模型仅需一次 FPCA 加邻域滤波与线性读出，单机 CPU 秒级完成、推理为单次矩阵乘，适合边缘/实时部署。

映射漂移证书：在每个队列 c 内拟合“谱 $\rightarrow$ 性状”方向 $\hat{\beta}_c$ ，以其两两不一致性 (Σ -度量夹角) 估计映射漂移 Δ_{map} ，作为跨队列可迁移性的先验证书。

4. 理论

假设 1 (正则性). (s, a) 二阶矩存在；其联合分布使 $\mathcal{H}_{\text{add}}$ 为 L^2 闭子空间；目标协方差正定 (有限维实例) 或迹类 (函数型实例)。

命题 1 (联合表征可识别性). 在假设 1 下，对联合分布 $P_{s,a}$ ，可加投影 $\Pi_{\text{add}} f^*$ 与交互残差 $C = f^* - \Pi_{\text{add}} f^*$ 唯一可识别 (投影残差唯一性，不要求 s, a 独立)；若进一步 $\overline{L^2(s)} \cap L^2(a)$ 仅含常数 (平凡交，一般成立)，则可加部分到 ϕ_s, ϕ_a 的中心化分裂亦唯一。

命题 2 (融合增益 $\asymp$ 交互能量). 记拼接、联合估计器的期望超额风险为 $\text{ER}_{\text{add}}, \text{ER}_{\text{joint}}$ ，融合增益 $\text{Gap} := \text{ER}_{\text{add}} - \text{ER}_{\text{joint}}$ 。则总体层面 $\text{Gap}_{\text{pop}} = \gamma$ ；有限样本下 $\gamma - \varepsilon_{\text{joint}}(n) \leq \mathbb{E} \text{Gap} \leq \gamma + \varepsilon_{\text{add}}(n)$ ， $\varepsilon_{\cdot}(n)$ 为相应估计误差。特别地 $\gamma = 0$ (f^* 可加) 时拼接在总体层面最优 ($\text{Gap}_{\text{pop}} = 0$)。

注 1 (度量与诊断量的范围). 命题 2、3 以平方/超额风险 (L^2) 陈述；第 6 节报告的宏 F1/OA 是其经验印证而非直接推论——分类度量与平方风险方向一致但非等价。诊断量 $\hat{\gamma}$ 是交互项对可加残差的归一化可解释方差代理 (非定理中的总体 γ)， $\hat{\Delta}$ 同为 Δ_{map} 的相合代理；二者用于训练/部署前的先验排序判定，其严格置信区间与显著性检验列为未来工作。

命题 3 (跨队列迁移落差下界与证书). 取线性-高斯实例 $y = \langle \beta_c, x \rangle + \zeta, \zeta \sim N(0, \sigma^2), \Sigma_{c^*} = \mathbb{E}[xx^\top | c^*] \succ 0$ 。映射漂移 $\Delta_{\text{map}} = \inf_{\beta \in \text{conv}\{\beta_c: c \in S\}} \|\beta_{c^*} - \beta\|_{\Sigma_{c^*}}$ 。对任意仅用源队列数据的零样本估计器 $\hat{f}$ ，在目标映射类 $\{\beta_{c^*} : \|\beta_{c^*} - \beta^{(0)}\|_{\Sigma_{c^*}} = \Delta_{\text{map}}\}$ 上极小极大地有 $\sup \mathbb{E} \text{ER}_{c^*}(\hat{f}) \geq \frac{1}{4} \Delta_{\text{map}}^2$ ，故跨队列泛化落差 $\gtrsim \Delta_{\text{map}}^2$ 。 Δ_{map} 可由队列内拟合方向 $\{\hat{\beta}_c\}$ 的两两不一致性给出经验代理 $\hat{\Delta}$ ：在源队列方向相合且目标方向落在源凸包邻域的假设下， $\hat{\Delta}$ 与 Δ_{map} 单调相关，可作先验排序信号 (而非对目标漂移的无偏估计)。

注 2. 命题 2-3 的下界骨架沿用函数型 ANOVA 分解与后验漂移理论 [33, 34]；本文贡献在于函数型实例化与 $\gamma, \Delta_{\text{map}}$ 的可计算诊断化。式 (2) 的块坐标求解 (谱向 FFT 对角化、空间向稀疏图-Laplacian) 在受限强凸下局部线性收敛，单步复杂度 $\mathcal{O}(n|\Lambda| \log |\Lambda| + n \cdot \text{nnz}(L))$ 。

5. 实验设置

5.1. 数据集

主实验采用四个跨域公开基准 (表 2 上半)：遥感地物 (Indian Pines、Pavia University、Salinas、AVIRIS/ROSIS) [40] 与无人机精细作物 (WHU-Hi-LongKou) [41]，覆盖 9 ~ 16 类、103 ~ 270 波段，兼含遥感与农业、城市与田块多种空谱结构；跨队列迁移分析另用 7 个带队列结构的农业高光谱数据集 (表 2 下半，队列由物种/品种、采集设备、年份、地点或物候定义)。表 2 (数据卡) 给出全部数据集的模式、规模、性状与来源：除 001 (作者单位内部采集) 外，迁移数据集均为 Mendeley/Figshare/USDA 等公开数据集 (脚注列出确切来源)，所有原始与预处理文件记录 SHA-256 校验值以保证可追溯。

Table 2

数据卡：本文所用全部数据集的模态、规模、任务与来源。上半 = 主实验四个公开 HSI 分类基准；下半 = 跨队列迁移分析所用 7 个农业高光谱数据集（队列由物种/品种、采集设备、年份、地点或物候定义）。所有数据集原始与预处理文件均记录 SHA-256 校验值以保证可追溯。

数据集	模态/波段	规模/队列	性状（任务）	来源
Indian Pines	AVIRIS HSI / 200	145×145 px	16 类地物	EHU 场景库 [40] ^a
Pavia University	ROSIS HSI / 103	610×340 px	9 类地物	EHU 场景库 ^a
Salinas	AVIRIS HSI / 204	512×217 px	16 类地物	EHU 场景库 ^a
WHU-Hi-LongKou	无人机 HSI / 270	550×400 px	9 类作物	武大 RSIDEA [41] ^b
001 苹果	HSI 348 波段	多产地 × 年份	糖度 SSC	内部采集 ^c
006 芒果	NIR 谱	4 品种	维生素 C	Mendeley ^d
012 猕猴桃	NIR 谱	多设备 × 物种	糖度/干物质	Figshare ^e
013 葡萄	多光谱 37 波段	5 品种 × 13 批次	花青素/Brix	Figshare ^f
018 牛油果/橄榄/葡萄	多光谱 + HSI	3 物种	叶绿素/氮/水/重	Figshare ^g
019 葡萄	HSI 204 波段	3 品种	含糖量	Mendeley ^h
029 棉花	HSI 全波段	多地点 × 播期	叶绿素/LAI/株高	USDA ⁱ

^a EHU 高光谱遥感场景库 http://www.ehu.eus/ccwintco/index.php/Hyperspectral_Remote_Sensing_Scenes（公开，允许学术使用）。

^b 武汉大学 RSIDEA 公开数据集 WHU-Hi http://rsidea.whu.edu.cn/resource_WHUHi_sharing.htm。

^c 新疆农业大学内部采集（多产地/年份苹果高光谱，需联系通讯作者获取）。

^d 006 芒果：Mendeley Data <https://data.mendeley.com/datasets/b9d6s7hr33/1>。

^e 012 猕猴桃：Figshare https://figshare.com/articles/dataset/Kiwifruit_NIR/21747983。

^f 013 葡萄：Figshare https://figshare.com/articles/dataset/Multispectral_grape_images_dataset/14679480。

^g 018 牛油果/橄榄/葡萄：Figshare <https://figshare.com/articles/dataset/26950660>。

^h 019 葡萄：Mendeley Data <https://data.mendeley.com/datasets/gjwx64sgkp/2>。

ⁱ 029 棉花：USDA Ag Data Commons <https://agdatacommons.nal.usda.gov/articles/dataset/27765477>。

5.2. 防泄漏评测协议

将每个场景按 6×6 空间分块，采用留块 GroupK-Fold（块间空间不相交），大幅降低相邻像素跨训练/测试的泄漏（两种划分对比见图 2）；本文未额外加缓冲带，块边界处仍可能残留弱泄漏（缓冲宽度与块粒度的敏感性列为未来工作）；作为对照，另跑随机像素 StratifiedKFold（文献主流，含泄漏）[29, 30]。指标为宏 F1、总体精度 OA、Cohen's κ ；每场景按类配额下采样至 $\leq 8000 \sim 9000$ 标注像素以均衡类别。所有实验在单张 NVIDIA RTX 4090D 上完成。随机种子：主对照（表 4、5、8 及各类别表）使用固定开发种子 2004；可加性的多种子稳健性检验（第 6 节）使用 5 个预注册 Formal 种子 {20060515, 20041210, 19810915, 2023, 2024}，逐种子重做空间分块 CV 并报告配对检验。下采样、划分与模型初始化的全部随机性均由对应种子统一控制以保证可复现。

5.3. 对比模型

- 简单可加（函数型）：FPCA 谱得分 + 邻域均值空间上下文 $\rightarrow$ 线性 softmax ($\sim 270 \sim 480$ 参数)。
- 随机森林（谱 + 空）[38]：同一特征上的非深度强基线。
- 空谱 2D-CNN [6]：三卷积块、PCA 波段作通道 ($\sim 2.3 \times 10^5$ 参数)。
- 空谱 3D-CNN [7]：三卷积块、立方体补丁 ($\sim 8 \times 10^4$ 参数)。

深度模型含随机翻转增强、40 轮、Adam，并与简单模型共享同一 FPCA 表征与折内预处理，保证公平。

5.4. 实现细节

关键超参：FPCA 成分数 $K = 15$ ；空间邻域窗 9×9 ；防泄漏空间分块 6×6 ；深度模型训练 40 轮，Adam（学习率 10^{-3} 、权重衰减 10^{-4} ）、批大小 128、含随机水平/垂直翻转增强；随机森林 300 棵树。诊断量 $\hat{\gamma}$ 由“交互交叉项对可加残差（one-hot 编码）的岭回归可解释方差占比”估计。简单可加模型与所有深度基线共享同一 FPCA 表征与折内预处理，并在同一防泄漏划分、同等训练预算下评估以保证公平；三个关键超参（ K 、 w 、分块粒度）的逐一灵敏度扫描见表 11（第 6.7 节）。

6. 实验结果

6.1. 融合增益以可加为主

表 3 与图 3(b) 比较“可加（谱 + 空间拼接）”与“联合（+ 空谱交互）”在防泄漏 CV 下的宏 F1。三个基准上交互项的额外增益均很小（代表种子 $-0.003 \sim +0.010$ ），交互能量估计 $\hat{\gamma} \in [0.02, 0.07]$ 。这与命题 2 一致：本类任务的低阶交互能量小，融合的实质收益主要来自可加的空间上下文。

合成验证（理论原生度量 L^2 ）：命题以平方/超额风险（ L^2 ）陈述而上表用宏 F1，二者非等价（注 1）。为在定理原生度量下直接检验命题 2，我们在可控合成数据上构造可加 $\oplus$ 交互的目标函数（交互能量真值 γ 已知）并扫描其强度（图 3(a)）。结果显示：经验融合增益 Gap 随真 γ 单调上升（相关 ≈ 1.0 ），在低阶交互下斜率 ≈ 0.95 （即 $\text{Gap} \approx \gamma$ ，命题在 L^2 下成立）；但本文采用的低阶交叉项代理 $\hat{\gamma}$ 在高阶交互下系统性低估真 γ （中位仅恢复约 27%）。因此“ $\hat{\gamma}$ 小”严格说只能断言低阶交互弱，而非排除高阶交互——后者由能表征高阶交互的深度模型独立把关：其相对简单可加的增益亦仅 $0.04 \sim 0.10$ （第 6、6.6 节）。两条互补证据共同支持“融合以可加为主”，且我们不主张交互严格为零。

防泄漏评测协议




Figure 2: 防泄漏评测协议示意。左： 6×6 空间分块留块交叉验证，整块同属训练或测试，测试区与训练区在空间上分离；右：文献主流的随机像素划分使空间自相关的相邻像素同时落入训练与测试，造成泄漏并系统性夸大报告精度。

Table 3

可加 vs 联合 (+ 交互) 宏 F1 (防泄漏空间分块 CV, 代表种子)。交互增益量级很小 (≤ 0.014)：5 个 Formal 种子 (5000 子样本, Indian Pines/Pavia U/Salinas) 以 ± 0.02 等价边界做 TOST, Salinas 通过等价 ($p_{\text{TOST}} = 0.004$)、IP/PaviaU 功效不足 ($p_{\text{TOST}} = 0.083/0.184$)；本文不声称交互严格为零。

数据集	可加	联合	增益	$\hat{\gamma}$
Indian Pines	0.487	0.492	+0.005	0.019
Pavia U	0.853	0.863	+0.010	0.069
Salinas	0.845	0.842	-0.003	0.043

多种子等价性检验：在 5 个 Formal 种子 (为控时用 5000 像素子样本) 上对 Indian Pines/Pavia U/Salinas 复核，交互增益点估计 $+0.013/+0.014/-0.006$ 。我们以预注册等价边界 ± 0.02 宏 F1 做双单侧等价检验 (TOST)——这比报告一个 $n=5$ 下 p 下限即为 0.0625、注定不显著的配对 Wilcoxon 更切题 (“未拒绝 H_0 ”不等于“接受 H_0 ”)：Salinas 通过等价 ($p_{\text{TOST}} = 0.004$, 90% CI $[-0.012, 0.000]$)，而 Indian Pines/Pavia U 在该边界下功效不足 ($p_{\text{TOST}} = 0.083/0.184$, CI $[0.004, 0.022]/[0.001, 0.027]$)，即其小幅增益尚不能在 ± 0.02 内被判定为等价。子样本协议方差偏大 (Salinas 种子间 $\text{std} \approx 0.08$)，故多种子结论作支持性证据；更大样本的精确等价区间与 WHU-Hi 复核留待后续。综合而言：交互增益量级很小 (≤ 0.014)，但本文不声称其为零。

6.2. 简单可加模型逼近深度基线 (精度-成本)

图 4 与表 4 给出公平训练下的精度-成本对比。约 270–480 参数的可加函数型模型达最佳深度模型宏 F1

的 89%~95%；深度优势温和 ($+0.04 \sim 0.10$ ，单种子，见局限) 而参数多 168~859 倍。即复杂度带来小幅提升但代价巨大，而非不可或缺。完整五模型对照见表 5。

逐数据集看，深度相对简单的优势在 Pavia University ($+0.100$) 最大、在 Salinas ($+0.044$) 最小，Indian Pines ($+0.056$) 与 WHU-Hi-LongKou ($+0.060$) 居中。Pavia 为大范围城市场景、类别多而空间格局复杂，深度模型较大感受野所聚合的空间上下文更有用；Salinas 地物规整、光谱本身高度可分，简单的邻域均值已捕获大部分可用空间信息。新增的空谱 Transformer 与 CNN 同档但未超越 (四基准上低于最佳 CNN $0.02 \sim 0.05$)，说明在该规模标注下注意力相对卷积无明显增益。综合四基准，“精度/参数”前沿由简单可加模型占据，深度模型仅在空间格局复杂的场景才显出温和优势——这与命题 2 (γ 小则可加近最优) 及第 6.6 节消融 (空间上下文增益大、交互增益 ≈ 0) 相互印证。

6.3. 各类别 F1 详表

表 6 与 7 给出四基准上各类别的 F1 (防泄漏空间分块 CV, 逐行最优加粗, 每数据集分块给出宏 F1/OA/ κ 汇总)。整体规律一致：简单可加模型在光谱可分的类别上与深度模型持平甚至更优 (如 Indian Pines 的 Wheat、Stone-Steel-Towers、Grass-trees, Salinas 的多数类)，主要差距集中在空间上下文依赖强、样本稀少或光谱高度混淆的类别 (如 Indian Pines 的 Corn-notill、Soybean 系列与 Alfalfa)；新增的空谱 Transformer 在多数类别与 CNN 同档而无系统性优势。这与“空间上下文 (可加) 贡献大、不可加交互贡献小”的总体结论在类别粒度上相互印证。图 5 以热图形式概览：(a) 简单可加模型在四基准上多数类别已达高 F1 (深琥珀)，(b) 最佳深度相对简单的逐类增益普遍为小幅正值 (浅

可加性核查：理论(合成)与真实数据




Figure 3: 可加性核查：理论（合成）与真实数据。(a) 合成验证（理论原生 L^2 度量，交互能量真值 γ 已知）：经验融合增益 Gap 随真 γ 单调上升（相关 ≈ 1.0 、低阶斜率 ≈ 0.95 ，即 $\text{Gap} \approx \gamma$ ），而低阶交叉项代理 $\hat{\gamma}$ 在高阶交互下系统性低估真 γ （高阶仅恢复约 27%）；故 $\hat{\gamma}$ 是交互能量的保守下界。(b) 真实数据（Indian Pines/Pavia U/Salinas, 5 种子）：联合 - 可加宏 F1 之差（散点）、均值与 90% CI（菱形）；阴影为 ± 0.02 等价边界，TOST 下 Salinas 判定等价、IP/PaviaU 功效不足。两者共同支持“融合以可加为主、交互量级很小但不为零”。

Table 4
精度-成本：宏 F1 / 参数量（防泄漏空间分块 CV，公平训练）。

数据集	简单可加	最佳深度	优势 (深 - 简)	达深度	参数比
Indian Pines	0.487 / 480	0.543	+0.056	90%	485×
Pavia U	0.853 / 270	0.953	+0.100	89%	297×
Salinas	0.845 / 480	0.888	+0.044	95%	168×
WHU-Hi	0.920 / 270	0.979	+0.060	94%	859×

红)、个别类别简单反超（绿），无大面积深红，直观印证差距有限。

6.4. 随机划分巨幅夸大绝对精度

图 6 与表 8 量化评测泄漏。随机像素划分下深度模型的 OA 普遍达到 98% ~ 99.8%、呈现“已解决”的假象（简单模型亦达 86% ~ 99%）；切换防泄漏空间分块后绝对精度大幅回落，最高夸大达 38.6 个百分点（Indian Pines 3D-CNN, 97.7% $\rightarrow$ 59.1%）。这表明大量基于随机划分的 HSI 报告精度被系统性高估。值得注意：泄漏同时抬高简单与深度模型，故“深度相对简单的优势”本身并非泄漏假象，但其绝对水平不可直接采信。

夸大幅度随场景的空间自相关强度而变。Indian Pines 地块细碎、训练/测试像素空间紧邻，随

机划分把简单模型 OA 由真实的 0.531 抬到 0.857、深度模型由 0.59 ~ 0.64 抬到 0.98 ~ 0.997，最高夸大 38.6 个百分点；WHU-Hi-LongKou 田块大而连续、类别本身易分，夸大相对温和（3D-CNN 0.991 $\rightarrow$ 0.998）；Pavia University 与 Salinas 居中（夸大 2 ~ 13 个百分点）。一个关键的方法学推论是：随机划分把深度模型一律推向 98% ~ 99.8% 的天花板，从而压缩了模型间的真实差距——在有泄漏协议下，约 270–480 参数的简单模型与上十万参数的深度模型差距被大幅压缩，二者优劣难以区分。这既解释了文献中“简单基线也很强”的部分假象，也再次说明：HSI 精度必须在防泄漏协议下报告，否则绝对值与排序均不可信。

Table 5
五模型在防泄漏空间分块 CV 下的完整对照（宏 F1 / 参数量，逐行最优加粗）。深度模型为单种子（种子 2004，受共享 GPU 限制）；可加性结论的多种子检验见第 6 节。

数据集	简单可加 (函数型)	随机森林 (谱 + 空)	空谱 2D-CNN	空谱 3D-CNN	空谱 Transformer
Indian Pines	0.487 / 480	0.510 / 2.5×10^5	0.543 / 2.3×10^5	0.527 / 8.1×10^4	0.496 / 7.7×10^4
Pavia University	0.853 / 270	0.878 / 1.3×10^5	0.947 / 2.3×10^5	0.953 / 8.0×10^4	0.904 / 7.7×10^4
Salinas	0.845 / 480	0.875 / 1.2×10^5	0.883 / 2.3×10^5	0.888 / 8.1×10^4	0.854 / 7.7×10^4
WHU-Hi-LongKou	0.920 / 270	0.932 / 1.1×10^5	0.979 / 2.3×10^5	0.972 / 8.0×10^4	0.953 / 7.7×10^4

精度-成本 Pareto: 约数百参数可加模型逼近深度基线




Figure 4: 精度-成本 Pareto: 约 270–480 参数的可加函数型模型 (红星) 位于深度基线左下方, 以 $1/168 \sim 1/859$ 的参数达其 89% ~ 95% 性能。

各类别 F1 热图(防泄漏 CV, 色盲安全色阶)




Figure 5: 各类别 F1 热图 (防泄漏空间分块 CV, 真实数据)。(a) 简单可加模型逐类 F1; (b) 最佳深度模型相对简单可加的逐类 F1 差 (红 = 深度更优、绿 = 简单更优)。白格为该数据集不足该类序号。

Table 6

各类别 F1 (Indian Pines 与 Pavia University; 防泄漏空间分块 CV, 逐行最优加粗, 分块末给出宏 F1/OA/ κ)。

类别	简单可加	RF	2D-CNN	3D-CNN	Transformer
<i>Indian Pines</i>					
Alfalfa	0.741	0.761	0.757	0.871	0.857
Corn-notill	0.437	0.481	0.594	0.550	0.448
Corn-mintill	0.324	0.175	0.381	0.172	0.259
Corn	0.000	0.000	0.000	0.000	0.000
Grass-pasture	0.283	0.350	0.185	0.240	0.296
Grass-trees	0.902	0.938	0.858	0.905	0.818
Grass-pasture-mowed	0.000	0.000	0.000	0.000	0.000
Hay-windrowed	0.860	0.925	0.917	0.927	0.957
Oats	0.000	0.000	0.000	0.000	0.000
Soybean-notill	0.409	0.563	0.671	0.550	0.564
Soybean-mintill	0.513	0.574	0.642	0.603	0.603
Soybean-clean	0.256	0.260	0.577	0.368	0.274
Wheat	0.983	0.998	0.993	0.974	0.951
Woods	0.760	0.757	0.819	0.816	0.763
Bldg-Grass-Trees	0.347	0.392	0.349	0.518	0.321
Stone-Steel-Towers	0.979	0.989	0.952	0.944	0.817
宏 F1	0.487	0.510	0.543	0.527	0.496
OA	0.531	0.580	0.637	0.591	0.569
κ	0.461	0.510	0.585	0.538	0.505
<i>Pavia University</i>					
Asphalt	0.899	0.919	0.956	0.960	0.932
Meadows	0.935	0.984	0.992	0.988	0.976
Gravel	0.768	0.669	0.912	0.883	0.780
Trees	0.917	0.961	0.967	0.973	0.915
Painted-metal	0.948	1.000	0.999	1.000	1.000
Bare-Soil	0.765	0.957	0.971	0.954	0.933
Bitumen	0.647	0.593	0.831	0.943	0.786
Bricks	0.805	0.819	0.912	0.933	0.855
Shadows	0.991	1.000	0.983	0.939	0.962
宏 F1	0.853	0.878	0.947	0.953	0.904
OA	0.884	0.933	0.967	0.967	0.935
κ	0.846	0.910	0.956	0.956	0.914

6.5. 跨队列迁移的二分律与证书

迁移分析使用 7 个带队列结构的农业高光谱数据集 (编号 001/006/012/013/018/019/029, 涵盖可见-近红外光谱与糖度、干物质、叶绿素、氮、含水率、花青素等连续性状; 队列由物种/品种、采集设备、年份、地点或物候定义, 详见补充数据卡), 共构成 21 个 (数据集 $\times$ 性状 $\times$ 队列) 单元, 逐单元落差见表 9。落差以 in-cohort 留出与留一队列 (LOCO) 之差度量。图 7 显示总体二分: 跨物种/基因型迁移落差中位 0.495 (自助 95% CI [0.149, 0.620], $B=10^4$), 而同物种跨设备/年份/地点/物候中位仅 0.043 (CI [0.014, 0.075]) ——两组置信区间互不重叠。该二分统计显著: 组标签置换检验 ($B=10^4$) 下中位差 0.452 的 $p = 9 \times 10^{-4}$, Mann-Whitney U 检验 $p = 2.6 \times 10^{-4}$, 效应量 Cliff's $\delta = 0.88$ (大)。聚类稳健复核: 上述单元级检验未校正伪重复 (如 029 棉花独占同物种组 5/14 单元、018 横跨两组), 故我们另以数据集为聚类单位复核——先按 (数据集 $\times$ 队列类型) 聚合再比较, 跨/同物种中位差仍达 0.337; 重采样数据集 (而非单元, $n_{\text{cluster}}=7$) 的聚类自助给出中位差 95% CI [0.04, 0.67], 仍排除 0 但下界已逼近 0, 诚实反映了

仅 7 个数据集量级下的较宽不确定度。二分非绝对, 亦有例外 (如 019: 糖跨品种落差仅 0.088、018: 含水率跨物候落差达 0.472), 提示性状-队列组合而非物种界限本身才是根因。命题 3 的可计算代理 (仅用源队列拟合方向、不接触目标标签) 在控制队列数后与落差显著偏相关 (0.43 ~ 0.56), 可作部署前“该校准能否跨场景迁移”的先验排序信号 (非精确预测)。

6.6. 消融实验

表 10 对三个设计轴做消融 (WHU-Hi 示例, 防泄漏 CV): (a) 空间上下文 (谱-only $\rightarrow$ 谱 + 空间) 增益显著 (+0.062); (b) 交互项 (可加 $\rightarrow$ + 交互) 增益 ≈ 0 (+0.001); (c) 模型复杂度 (简单 $\rightarrow$ 深度) 温和提升 +0.058, 但需约 859 $\times$ 参数。三者表明: HSI 空谱融合的增益来自可加的空间上下文与 (代价高昂的) 深度复杂度, 而不可加交互几乎不贡献——这正是本文“融合主要可加”论点的核心。

Table 7

 各类别 F1 (Salinas 与 WHU-Hi-LongKou; 防泄漏空间分块 CV, 逐行最优加粗, 分块末给出宏 F1/OA/ κ)。

类别	简单可加	RF	2D-CNN	3D-CNN	Transformer
<i>Salinas</i>					
Brocoli-1	1.000	0.998	1.000	1.000	0.973
Brocoli-2	0.995	0.999	1.000	1.000	1.000
Fallow	0.963	0.930	0.968	0.977	0.944
Fallow-rough-plow	0.976	0.981	0.979	0.989	0.916
Fallow-smooth	0.960	0.990	0.982	0.995	0.960
Stubble	0.995	1.000	1.000	1.000	0.998
Celery	0.820	0.887	0.986	0.918	0.824
Grapes-untrained	0.682	0.758	0.783	0.745	0.660
Soil-vinyard	0.983	0.993	0.994	0.991	0.991
Corn-senesced	0.880	0.916	0.946	0.949	0.902
Lettuce-4wk	0.879	0.863	0.937	0.947	0.927
Lettuce-5wk	0.936	0.993	0.977	1.000	0.966
Lettuce-6wk	0.948	0.988	0.940	1.000	0.962
Lettuce-7wk	0.948	0.987	0.973	0.996	0.969
Vinyard-untrained	0.548	0.713	0.659	0.705	0.671
Vinyard-trellis	0.000	0.000	0.000	0.000	0.000
宏 F1	0.845	0.875	0.883	0.888	0.854
OA	0.820	0.871	0.874	0.874	0.836
κ	0.799	0.856	0.860	0.859	0.818
<i>WHU-Hi-LongKou</i>					
Corn	0.999	0.996	0.999	0.998	0.997
Cotton	0.791	0.789	0.985	0.970	0.945
Sesame	0.960	0.950	0.965	0.971	0.916
Broad-leaf-soybean	0.980	0.972	0.995	0.994	0.988
Narrow-leaf-soybean	0.697	0.796	0.956	0.936	0.908
Rice	0.992	0.997	0.999	1.000	0.999
Water	0.999	1.000	1.000	1.000	1.000
Roads-houses	0.950	0.937	0.959	0.945	0.910
Mixed-weed	0.909	0.954	0.957	0.934	0.916
宏 F1	0.920	0.932	0.979	0.972	0.953
OA	0.974	0.975	0.994	0.991	0.985
κ	0.966	0.966	0.992	0.988	0.981

Table 8

评测泄漏量化: 随机划分 vs 防泄漏空间分块的 OA。

数据集	随机划分 (有泄漏) OA			防泄漏空间分块 OA		
	简单	2D-CNN	3D-CNN	简单	2D-CNN	3D-CNN
Indian Pines	0.857	0.997	0.977	0.531	0.637	0.591
Pavia University	0.975	0.996	0.984	0.884	0.967	0.967
Salinas	0.945	0.989	0.996	0.820	0.874	0.874
WHU-Hi-LongKou	0.990	0.998	0.998	0.974	0.994	0.991

6.7. 协议敏感性与先验决策图

评测协议是结论稳健性的首要敏感因素: 第 5.2 节全部结论均在防泄漏空间分块 CV 下成立; 切换随机划分会把绝对精度整体抬高 0.4 ~ 38.6 个百分点 (随场景空间自相关强度而异) 并改变排序解读 (随机划分下简单模型亦达 86% ~ 99%, 掩盖模型间差异)。我们进一步对简单可加模型逐一扫描三个关键超参 (FPCA 维数 K 、邻域窗 w 、空间分块粒度), 结果见表 11。这里需诚实说明两点。第一, 表中每段扫描独立对 8000

像素重抽样评估, 故同一基线配置 (下划线) 在三段中的取值本身略有出入 (IP 在 $K/w/$ 粒度三段分别为 0.49/0.40/0.48), 反映约 ± 0.04 的子样本估计噪声; 各列扫描极差 (0.18 ~ 0.24) 因而是超参效应与抽样噪声的叠加, 不应全部归为超参敏感性。第二, 扣除该噪声后, PaviaU 与 Salinas 在推荐范围 ($K \in [10, 20]$ 、 $w \in [7, 13]$ 、粒度 ≥ 6) 内对超参不敏感、稳定保持在与深度基线可比的区间; 而最难的 Indian Pines 兼具更大的超参敏感性与抽样方差, 其竞争力对分块粒度尤




Figure 6: 评测泄漏量化：随机划分（实心）相对防泄漏空间分块（空心）系统性夸大 OA，最高达 38.6 个百分点。




Figure 7: 跨队列迁移二分：跨物种/基因型崩塌（中位落差 0.50）vs 同物种跨仪器/年份/地点稳健（0.04）。点为 21 个真实落差单元，粗横线为各组中位；空心圈标注横跨阈值的反例（019·糖 0.088、018·含水率 0.472，提示性状-队列组合为根因）；右侧标注以数据集为聚类单位（消伪重复）的中位差自助 95% CI [0.04, 0.67]。

为敏感——粒度由 6 降到 4 时宏 F1 由 0.48 跌到 0.29，过粗的空间分块会显著削弱性能。总体而言，主结论（可加性主导、简单逼近深度）在推荐超参范围内未见反转，但简单模型的竞争力依赖合理而非苛刻的配置，应避免极端取值（尤其过粗分块）。综合 γ （是否值得融合）与 Δ_{map} （能否迁移），图 8 给出 $\gamma \times \Delta$ 先验决策图：低 γ 低 Δ 用简单可加模型且可迁移；高 Δ 需逐队列重标定；仅当 γ 显著大时才值得上复杂融合。

6.8. 复杂度与可扩展性

简单可加函数型模型的训练为 FPCA ($\mathcal{O}(n\Delta|K|)$, n 为像素数、 $K=15$) 加邻域均值滤波 ($\mathcal{O}(nw^2K)$, w 为窗宽) 与一个 ≤ 480 参数的线性读出，单机 CPU 即可在秒级完成，推理为单次矩阵乘，天然适合边缘/实时部署；其参数量比本文深度基线低 168 ~ 859 倍(表 5)，显存占用与能耗相应大幅降低。深度空谱模型的卷积前向为 $\mathcal{O}(nw^2Kc^2d)$ (c 为通道数、 d 为层数)，训练需 GPU。式 (2) 的联合估计器经谱向 FFT 与稀疏图-Laplacian




Figure 8: $\gamma \times \Delta$ 先验决策图 (示意): 依交互能量 γ 与映射漂移 Δ_{map} 在训练/部署前判定 “是否融合、能否迁移”; 象限阈值依任务标定。

Table 9

21 个跨队列单元的泛化落差 (in-cohort - 留一队列), 来自带队列结构的农业/遥感 HSI 数据集, 按宏类分组。跨物种/基因型一致崩塌, 同物种跨设备/年份/地点/物候基本稳健。

单元（数据集·性状）	队列类型	落差
跨物种/基因型（中位 0.495）		
018· 叶绿素	作物	0.528
018· 氮	作物	0.620
018· 重量	作物	0.374
018· 含水率	作物	0.149
006· 维生素 C	品种	0.701
013· 花青素	品种	0.495
019· 糖	品种	0.088
同物种（设备/年份/地点/物候，中位 0.043）		
018· 含水率	物候	0.472
001· 糖	产地	0.266
001· 糖	年份	0.098
012· 干物质	设备	0.081
012· 糖	年份	0.060
018· 氮	物候	0.052
012· 糖	设备	0.047
012· 干物质	年份	0.039
018· 叶绿素	物候	0.035
029· 节数	地点	0.027
029· 冠层覆盖	地点	0.005
029· 叶绿素	地点	0.000
029· LAI	地点	-0.019
029· 株高	地点	-0.027

求解, 单步 $\mathcal{O}(n|\Lambda| \log |\Lambda| + n \cdot \text{nnz}(L))$, 复杂度随像素数线性、随波段近线性。须诚实说明: 式 (2) 的空间正则联合估计器在本文中仅作理论复杂度分析, 正文实

Table 10

消融 (WHU-Hi-LongKou, 宏 F1, 防泄漏 CV)。

配置（逐步增加）	宏 F1	增量（来源）
谱-only	0.858	—
+ 空间上下文	0.920	+0.062（空间，大）
+ 空谱交互	0.921	+0.001（交互， ≈ 0 ）
深度基线 2D-CNN	0.979	+0.058（复杂度， $859 \times$ 参数）

验的“联合”模型为可加特征加低阶交叉项(第 5.4 节): 式 (2) 的大场景 wall-clock 与收敛曲线实测留作未来工作, 故“可扩展到大场景”为理论推断而非实测。综合图 4 的精度-成本前沿: 在 γ 小的任务上, 简单可加模型在“精度/参数”与“精度/能耗”两个效率维度上均位于前沿, 是资源受限或需可解释部署场景的稳健默认选择。

6.9. 负控与数据完整性

为排除“伪信号”与流水线泄漏，我们在简单可加模型上做三项负控（防泄漏空间分块 CV；为控成本在 6000 像素子样本上运行，故绝对 F1 与表 5 略有出入，此处关注相对关系），结果见表 12。(i) 标签置换：打散训练标签重训 300 次，真实宏 F1 远高于置换零分布（均值 0.03 ~ 0.07），300 次中无一超过真实值（ $p \leq 0.003$ ），排除“模型靠记忆标签取胜”；(ii) 随机特征：以同形状高斯噪声替换输入、保留标签，宏 F1 跌至 0.01 ~ 0.07（近随机），确认模型确实利用了真实空谱信号而非预处理副作用；(iii) ID 探针：仅以像素归一化坐标为特征——在防泄漏空间分块下宏 F1 低（0.10 ~ 0.41，测试块坐标未见过、无法泛化），而切到随机划分后显著抬升（Salinas 0.405 $\rightarrow$ 0.599、Indian Pines 0.155 $\rightarrow$ 0.230），

Table 11

简单可加模型的超参灵敏度（宏 F1，防泄漏空间分块 CV，8000 像素子样本）。逐一扫描 FPCA 维数 K 、邻域窗 w 、分块粒度，其余固定于基线（ $K=15, w=9$, 粒度=6）（下划线）。末行为各列扫描极差（max-min）。

超参	取值	IP	PaviaU	Salinas
K	5	0.347	0.701	0.807
	10	0.415	0.805	0.889
	<u>15</u>	<u>0.489</u>	<u>0.781</u>	<u>0.846</u>
	20	0.356	0.772	0.868
	30	0.467	0.726	0.953
w	5	0.439	0.763	0.906
	7	0.408	0.812	0.901
	<u>9</u>	<u>0.404</u>	<u>0.831</u>	<u>0.930</u>
	11	0.493	0.789	0.941
	13	0.528	0.768	0.930
粒度	4	0.292	0.662	0.767
	<u>6</u>	<u>0.483</u>	<u>0.812</u>	<u>0.843</u>
	8	0.448	0.843	0.940
扫描极差		0.236	0.181	0.186

独立印证了随机划分引入的空间泄漏。三项一致表明本文结果并非伪信号，并再次佐证评测泄漏的真实存在。

下采样不破坏空间结构、退化类不虚增差距：为回应“按类配额下采样（ $\leq 8000 \sim 9000$ 像素）是否削弱空间自相关、从而与防泄漏主张矛盾”的疑虑，我们量化了下采样前后的标签场空间自相关（逐类 one-vs-rest Moran's I 按类频率加权）：三基准全图 Moran's I = 0.998 ~ 1.000，下采样后仍为 0.955 ~ 0.988（每类置换 z 值最小 145.9，全部显著为正），强空间自相关结构完整保留——防泄漏空间分块在下采样后依然必要且有效。此外，对“多个类别全模型 F1=0（如 Indian Pines 的 Corn/Grass-pasture-mowed/Oats、Salinas 的 Vinyard-trellis）是否系下采样伪迹、并人为压缩模型差距”的质疑：这些类在全图本就极稀少（20 ~ 237 像素，下采样未削减）或与近缘类谱高度混淆，是真实的极难类而非抽样产物；剔除它们后简单可加与最佳深度的宏 F1 同步抬升、而二者差距几乎不变（如 Indian Pines +0.056 $\rightarrow$ +0.069、Salinas +0.044 $\rightarrow$ +0.047），说明 0 类对两类模型等量拉低、并未虚增“简单逼近深度”的结论。

7. 讨论

综合全部实验，本文得到三点一致结论：在 HSI 中，空谱融合的收益主要来自可加的空间上下文，复杂联合架构带来的额外提升有限，且常被评测泄漏掩盖或夸大；而真正决定跨场景可用性的，是光谱 $\rightarrow$ 性状映射在队列间是否稳定。由此给出两个先验决策量：交互能量 γ （ γ 小则简单可加模型已足，不必上复杂融合）与映射漂移证书（漂移大则需重标定，勿盲目零样本迁移）。这为资源受限或需可解释/可信部署的场景提供了部署前的量化判据，而非仅凭经验选择架构；这与“简单模型在某些数据类型上仍可媲美深度模型”的近期发现 [39] 一致。

对实践的启示：(i) 在上复杂空谱融合网络前，先估计 $\hat{\gamma}$ ：若小，则一个 $\sim$ 数百参数的可加函数型模型即可逼近 SOTA，且更易解释、更省算力；(ii) 报告精度时必须采用防泄漏空间划分，否则绝对数不可比、亦不可信；(iii) 面对新仪器/新地点/新物候，先算映射漂移证书判定是否需重标定。

局限：(i) 命题下界骨架属已知理论，本文新意在函数型实例化与诊断化；(ii) 评测局限于像素级分类四基准，深度基线涵盖 2D/3D-CNN 与空谱 Transformer——近期状态空间模型（SpectralMamba）与图卷积（GCN）未纳入实测对比；但本文论点是“在 $\hat{\gamma}$ 小的任务上简单可加已逼近表征力更强的联合模型”，更强架构若仍受限于小交互能量预期不改变定性结论，此外推仍需验证；向连续目标回归与更大规模数据的外推亦有待检验；(iii) 简单与深度模型差距虽小但真实存在，本文主张“按 γ 与漂移先验决策”，而非否定深度方法。

对结果有效性的威胁：（外部有效性）本文结论建立在像素级地物/作物分类与农业 HSI 队列数据上；对连续生化指标回归、时序 HSI 以及更大规模场景的外推需进一步验证。（构造有效性）交互能量 $\hat{\gamma}$ 以低阶谱 $\times$ 空间交叉项对可加残差的可解释方差占比估计；合成验证（图 3(a)）证实它在高阶交互下系统性低估真 γ （中位仅恢复约 27%），故 $\hat{\gamma}$ 应理解为交互能量的保守下界而非无偏估计。我们因此不以“ $\hat{\gamma}$ 小”单独断言交互为零，而辅以能表征高阶交互的深度模型增益亦小作为独立佐证；更富表达力的交互参数化（核方法、深度交互层）下 γ 的精确刻画仍是开放问题。（内部有效性）防泄漏评测以 6×6 空间留块实现、未额外加缓冲带（块边界弱泄漏与缓冲/块粒度敏感性列为未来工作）；块粒度会影响绝对落差幅度，但不改变“随机划分相对空间分块系统性夸大”的方向性结论。（统计-算力权衡）可加性结论另在 3 个基准（Indian Pines/Pavia U/Salinas）上经 5 个 Formal 种子的 ± 0.02 等价检验（TOST）复核——Salinas 判定等价、Indian Pines/Pavia U 在该边界下功效不足，作支持性证据，子样本方差偏大；本文据此仅声称交互增益量级很小（ ≤ 0.014 ）而非为零；受共享 GPU 限制，深度模型精度-成本对比为单种子（种子 2004），其小幅优势与可加性的更大样本多种子置信区间留待后续。（统计结论有效性）迁移二分律已由置换检验（中位差 $p = 9 \times 10^{-4}$ ）、Mann-Whitney 检验（ $p = 2.6 \times 10^{-4}$ ）、自助 95% 置信区间（两组互不重叠）与 Cliff's $\delta = 0.88$ 共同支撑（第 6.5 节）；但迁移证书与落差的偏相关基于 21 个单元、样本量有限，跨更多数据集的外推仍需进一步验证。

未来工作：三个方向值得推进：(i) 把可加 $\oplus$ 交互分解推广到连续目标的函数型回归与多指标联合预测，检验“可加为主”是否跨任务类型成立；(ii) 为 γ 与 Δ_{map} 建立带置信区间的可计算估计与显著性检验，使“是否融合/能否迁移”的先验判定具备统计保证；(iii) 将映射漂移证书与按队列的自适应重标定结合，形成“先验判定 $\rightarrow$ 条件重标定”的部署流水线，并在跨传感器、跨年份的真实业务场景中量化其降低标注与重训成本的效益。

广义影响：本文的方法学含义超出 HSI：任何“连续信号 $\times$ 离散结构”的多模态融合（如时序 $\times$ 传感器、光谱 $\times$ 形貌、文本 $\times$ 图结构）都可套用“可加 $\oplus$ 交互”分解与交互能量 γ 的先验诊断，从而在投入复杂联合

Table 12

负控与数据完整性（简单可加模型，防泄漏空间分块 CV，6000 像素子样本）。真实宏 F1 远超标签置换零分布；随机特征近随机；ID 探针在随机划分下被抬高，佐证空间泄漏。

数据集	真实宏 F1	置换零分布 (均值)	置换 p	随机特征 F1	ID 探针 (空间分块)	ID 探针 (随机划分)
Indian Pines	0.470	0.032	≤ 0.003	0.023	0.155	0.230
Pavia University	0.859	0.068	≤ 0.003	0.067	0.104	0.116
Salinas	0.889	0.032	≤ 0.003	0.011	0.405	0.599

架构前，以可计算量回答“融合是否值得”。在评测层面，本文对空间泄漏的量化提醒：凡训练/测试样本存在结构相关（空间、时间、层级、系统发育）的领域，随机划分都可能系统性夸大泛化，应采用结构感知的交叉验证 [30, 29]。这两点对可信、可复现、资源高效的科学机器学习具有普适价值。

8. 结论

我们以函数型可识别性视角统一刻画了“空谱融合何时有益”，证明融合增益由可计算的交互能量决定、跨队列迁移由映射漂移决定，并在跨域、防泄漏实证中表明：HSI 空谱融合主要是可加增益、约 270–480 参数的可加模型逼近深度基线、随机划分巨幅夸大精度。两个可先验计算的诊断量——交互能量 γ 与映射漂移证书——则把“是否融合、能否迁移”的判断从事后比较前移到部署之前。

CRedit authorship contribution statement

李盼林：概念构思，方法学，软件实现，形式化分析，研究实施，可视化，撰写——初稿。李宇畅：软件实现，结果验证，数据管理，撰写——审阅与编辑。黄华：概念构思，监督指导，经费获取，项目管理，撰写——审阅与编辑。

Declaration of competing interests

作者声明：本文不存在任何可能影响本研究工作的已知竞争性经济利益或个人关系。

Data & Code availability

本文主实验所用四个公开基准：Indian Pines、Pavia University、Salinas 取自 EHU 高光谱遥感场景库 (http://www.ehu.eus/ccwintco/index.php/Hyperspectral_Remote_Sensing_Scenes)，WHU-Hi-LongKou 取自武汉大学 RSDIEA 课题组公开数据集；跨队列迁移分析所用 7 个农业光谱数据集（编号 001/006/012/013/018/019/029）除 001（作者单位内部采集，需联系通讯作者）外均为公开数据集，确切来源（Mendeley/Figshare/USDA Ag Data Commons 等）见正文数据卡（表 2）脚注。复现本文全部实验、图表与诊断量计算的源代码遵循开源原则；为支持审稿期复现，我们已准备匿名代码与预处理数据复现包，可在审稿期间应编辑或审稿人要求即时提供，并将在论文接收后于公开仓库正式发布（含 SHA-256 校验与环境锁定文件）。

Declaration of generative AI and AI-assisted technologies in the manuscript preparation process

在本文撰写过程中，作者使用了 Anthropic 公司的 Claude Opus 4.8 大语言模型，主要用于语言润色与表达改进。使用该工具后，作者已对全部内容进行审阅与编辑，并对本文的科学内容、数据与结论承担全部责任。

Funding

本研究受新疆维吾尔自治区自然科学基金面上项目与 2026 年新疆农业大学大学生创新项目资助（两项目均已获批，具体编号将于稿件接收前补全）。

A. 命题证明

本附录给出第 4 节命题 1–3 的完整证明。记号沿用第 3–4 节。

A.1. 命题 1（联合表征可识别性）

证明. 记联合分布 $P_{s,a}$ 下的可加函数闭子空间

$$\mathcal{H}_{\text{add}} = \overline{\{g_1(s) + g_2(a) : g_1 \in L^2(P_s), g_2 \in L^2(P_a)\}} \subseteq L^2(P_{s,a}). \quad (3)$$

步骤 1（交互残差唯一）：由 Hilbert 空间投影定理， f^* 到闭子空间 $\mathcal{H}_{\text{add}}$ 的正交投影 $\Pi_{\text{add}} f^*$ 存在且唯一，故

$$C := f^* - \Pi_{\text{add}} f^* \text{ 唯一确定。} \quad (4)$$

该结论不要求 s, a 独立——HSI 中 s, a 由同一 FPCA 场导出而强相关，但投影几何只依赖联合测度 $P_{s,a}$ 。

步骤 2（可加分裂）：若 $\overline{L^2(s) \cap L^2(a)} = \{\text{常数}\}$ （平凡交），则中心化约束 $\mathbb{E}[\phi_s] = \mathbb{E}[\phi_a] = 0$ 唯一确定 $\Pi_{\text{add}} f^* = \phi_s + \phi_a$ 的分裂（相依输入函数型 ANOVA，见 Hooker [24]）；否则 ϕ_s, ϕ_a 至多相差一个公共方向，而 C 与 γ 不受影响。证毕

A.2. 命题 2（融合增益 $\asymp$ 交互能量）

证明. 步骤 1（总体下界）：对任意 $h \in \mathcal{H}_{\text{add}}$ ，由 $f^* = (\phi_s + \phi_a) + C$ 与投影正交性，

$$\inf_{h \in \mathcal{H}_{\text{add}}} \mathbb{E}[(f^* - h)^2] = \mathbb{E}[(C - \Pi_{\text{add}} C)^2] = \gamma, \quad (5)$$

即拼接（可加晚融合）的总体超额风险恰为 γ 。

步骤 2 (上界与夹逼): 联合类包含 f^* , 总体超额风险为 0、有限样本下 $\leq \varepsilon_{\text{joint}}(n)$ 。故

$$\text{Gap}_{\text{pop}} = \gamma, \quad \mathbb{E} \text{Gap} \in [\gamma - \varepsilon_{\text{joint}}(n), \gamma + \varepsilon_{\text{add}}(n)]. \quad (6)$$

特别地 $\gamma = 0 \Rightarrow \text{Gap}_{\text{pop}} = 0$ (拼接总体最优)。

步骤 3 (函数型率): 当 $C \in W^{\bar{s}, 2}$ (谱-空间张量 Sobolev)、目标协方差迹类且特征值 $\asymp j^{-2r}$ 时, 正则化最小二乘的交互估计误差

$$\varepsilon_{\text{joint}}(n) \asymp n^{-2\bar{s}/(2\bar{s}+d_{\text{eff}})}, \quad (7)$$

d_{eff} 为协方差谱衰减决定的有效维数; 式 (2) 的空间正则降低 d_{eff} 。证毕

A.3. 命题 3 (跨队列迁移落差下界与证书)

证明. 步骤 1(双点构造): 取 $\beta^{(0)}$ 为 $\text{conv}\{\beta_c\}$ 中 Σ_{c^*} -最近点、 $\beta^{(1)} = \beta^{(0)} + \Delta_{\text{map}} v$, v 为达到下确界的单位残差方向 ($\|v\|_{\Sigma_{c^*}} = 1$)。构造两世界 P_0, P_1 : 源队列分布、源映射与目标协变量律 $P_{c^*}^X$ 全同, 仅目标条件均值取 $\beta^{(b)}$ 。

步骤 2 (极小极大下界): 零样本估计器 $\hat{f}$ 不接触目标标签, 在两世界为同一随机变量; 由中点不等式 $(a-u)^2 + (a-w)^2 \geq \frac{1}{2}(u-w)^2$ 逐点取期望,

$$\max_{b \in \{0,1\}} \mathbb{E} \text{ER}_{c^*}(\hat{f}; b) \geq \frac{1}{4} \mathbb{E}_{x \sim P_{c^*}^X}[(\beta^{(1)} - \beta^{(0)}, x)^2] = \frac{1}{4} \Delta_{\text{map}}^2. \quad (8)$$

此为对目标类的极小极大陈述 (非对固定 β_{c^*} 的逐点断言)。

步骤 3 (证书一致性): 队列内最小二乘 $\hat{\beta}_c \rightarrow_p \beta_c$ (谱隙保证首方向唯一), 其两两 Σ -度量不一致性 $\hat{\Delta}$ 是 Δ_{map} 的单调相合估计, 故可先验计算。证毕

References

- [1] Plaza A, Benediktsson J A, Boardman J W, et al. Recent advances in techniques for hyperspectral image processing. *Remote Sensing of Environment*, 2009, 113(S1): S110–S122.
- [2] Ghamisi P, Yokoya N, Li J, et al. Advances in hyperspectral image and signal processing. *IEEE Geoscience and Remote Sensing Magazine*, 2017, 5(4): 37–78.
- [3] Bioucas-Dias J M, Plaza A, Camps-Valls G, et al. Hyperspectral remote sensing data analysis and future challenges. *IEEE Geoscience and Remote Sensing Magazine*, 2013, 1(2): 6–36.
- [4] Camps-Valls G, Tuia D, Bruzzone L, et al. Advances in hyperspectral image classification. *IEEE Signal Processing Magazine*, 2014, 31(1): 45–54.
- [5] Fauvel M, Tarabalka Y, Benediktsson J A, et al. Advances in spectral-spatial classification of hyperspectral images. *Proceedings of the IEEE*, 2013, 101(3): 652–675.
- [6] Chen Y, Jiang H, Li C, et al. Deep feature extraction and classification of hyperspectral images based on convolutional neural networks. *IEEE TGRS*, 2016, 54(10): 6232–6251.
- [7] Roy S K, Krishna G, Dubey S R, et al. HybridSN: Exploring 3-D–2-D CNN feature hierarchy for hyperspectral image classification. *IEEE GRSL*, 2020, 17(2): 277–281.
- [8] Hong D, Han Z, Yao J, et al. SpectralFormer: Rethinking hyperspectral image classification with transformers. *IEEE TGRS*, 2022, 60: 5518615.
- [9] Paoletti M E, Haut J M, Plaza J, et al. Deep learning classifiers for hyperspectral imaging: A review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 2019, 158: 279–317.
- [10] Li S, Song W, Fang L, et al. Deep learning for hyperspectral image classification: An overview. *IEEE TGRS*, 2019, 57(9): 6690–6709.
- [11] Hong D, Gao L, Yao J, et al. Graph convolutional networks for hyperspectral image classification. *IEEE TGRS*, 2021, 59(7): 5966–5978.
- [12] Audebert N, Le Saux B, Lefèvre S. Deep learning for classification of hyperspectral data: A comparative review. *IEEE Geoscience and Remote Sensing Magazine*, 2019, 7(2): 159–173.
- [13] Ghamisi P, Maggiori E, Li S, et al. New frontiers in spectral-spatial hyperspectral image classification. *IEEE Geoscience and Remote Sensing Magazine*, 2018, 6(3): 10–43.
- [14] Melgani F, Bruzzone L. Classification of hyperspectral remote sensing images with support vector machines. *IEEE TGRS*, 2004, 42(8): 1778–1790.
- [15] Wold S, Sjöström M, Eriksson L. PLS-regression: a basic tool of chemometrics. *Chemometrics and Intelligent Laboratory Systems*, 2001, 58(2): 109–130.
- [16] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition. In: *CVPR*, 2016: 770–778.
- [17] Yao J, Hong D, Li C, Chanussot J. SpectralMamba: Efficient Mamba for hyperspectral image classification. *arXiv preprint arXiv:2404.08489*, 2024.
- [18] Meyer H, Pebesma E. Machine learning-based global maps of ecological variables and the challenge of assessing them. *Nature Communications*, 2022, 13: 2208.
- [19] Dalla Mura M, Prasad S, Pacifici F, et al. Challenges and opportunities of multimodality and data fusion in remote sensing. *Proceedings of the IEEE*, 2015, 103(9): 1585–1601.
- [20] Gómez-Chova L, Tuia D, Moser G, et al. Multimodal classification of remote sensing images: A review and future directions. *Proceedings of the IEEE*, 2015, 103(9): 1560–1584.
- [21] Ramsay J O, Silverman B W. *Functional Data Analysis*. 2nd ed. New York: Springer, 2005.
- [22] Wang J L, Chiou J M, Müller H G. *Functional data analysis. Annual Review of Statistics and Its Application*, 2016, 3: 257–295.
- [23] Morris J S. *Functional regression. Annual Review of Statistics and Its Application*, 2015, 2: 321–359.
- [24] Hooker G. Generalized functional ANOVA diagnostics for high-dimensional functions of dependent variables. *Journal of Computational and Graphical Statistics*, 2007, 16(3): 709–732.
- [25] Hall P, Horowitz J L. Methodology and convergence rates for functional linear regression. *The Annals of Statistics*, 2007, 35(1): 70–91.
- [26] Cai T T, Yuan M. Minimax and adaptive prediction for functional linear regression. *Journal of the American Statistical Association*, 2012, 107(499): 1201–1216.
- [27] Yuan M, Cai T T. A reproducing kernel Hilbert space approach to functional linear regression. *The Annals of Statistics*, 2010, 38(6): 3412–3444.
- [28] Hughes G F. On the mean accuracy of statistical pattern recognizers. *IEEE Transactions on Information Theory*, 1968, 14(1): 55–63.
- [29] Karasiak N, Dejoux J F, Monteil C, et al. Spatial dependence between training and test sets: another pitfall of classification accuracy assessment in remote sensing. *Machine Learning*, 2022, 111(7): 2715–2740.

- [30] Roberts D R, Bahn V, Ciuti S, et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 2017, 40(8): 913–929.
- [31] Ploton P, Mortier F, Réjou-Méchain M, et al. Spatial validation reveals poor predictive performance of large-scale ecological mapping models. *Nature Communications*, 2020, 11: 4540.
- [32] Kattenborn T, Leitloff J, Schiefer F, et al. Review on convolutional neural networks (CNN) in vegetation remote sensing. *ISPRS Journal of Photogrammetry and Remote Sensing*, 2021, 173: 24–49.
- [33] Ben-David S, Blitzer J, Crammer K, et al. A theory of learning from different domains. *Machine Learning*, 2010, 79(1–2): 151–175.
- [34] Cai T T, Wei H. Transfer learning for nonparametric classification: Minimax rate and adaptive classifier. *The Annals of Statistics*, 2021, 49(1): 100–128.
- [35] Kpotufe S, Martinet G. Marginal singularity and the benefits of labels in covariate-shift. *The Annals of Statistics*, 2021, 49(6): 3299–3323.
- [36] Sugiyama M, Krauledat M, Müller K R. Covariate shift adaptation by importance weighted cross validation. *Journal of Machine Learning Research*, 2007, 8: 985–1005.
- [37] Quiñero-Candela J, Sugiyama M, Schwaighofer A, et al. *Dataset Shift in Machine Learning*. Cambridge: MIT Press, 2009.
- [38] Breiman L. Random forests. *Machine Learning*, 2001, 45(1): 5–32.
- [39] Grinsztajn L, Oyallon E, Varoquaux G. Why do tree-based models still outperform deep learning on typical tabular data? *Advances in Neural Information Processing Systems (Datasets and Benchmarks)*, 2022, 35.
- [40] Baumgardner M F, Biehl L L, Landgrebe D A. 220 band AVIRIS hyperspectral image data set: June 12, 1992 Indian Pine test site 3. Purdue University Research Repository, 2015.
- [41] Zhong Y, Hu X, Luo C, et al. WHU-Hi: UAV-borne hyperspectral with high spatial resolution benchmark datasets and classifier for precise crop identification based on deep convolutional neural network with CRF. *Remote Sensing of Environment*, 2020, 250: 112012.