

Functional Identifiability Analysis of Hyperspectral Spatial-Spectral Fusion with Computable Diagnostics

高光谱空谱融合的函数型可识别性分析与可计算诊断

Panlin Li (李盼林)^a, Yuchang Li (李宇畅)^a, Yutong Feng (冯雨桐)^{b,c}, Longjie Li (李龙杰)^{b,c},
Ya Liu (刘亚)^d and Hua Huang (黄华)^{a,e,*}

^a 新疆农业大学数理学院, 乌鲁木齐, 830052, 中国

^b 新疆农业大学机电工程学院, 乌鲁木齐, 830052, 中国

^c 新疆智能农业装备重点实验室, 乌鲁木齐, 830052, 中国

^d 新疆农业科学院乌鲁木齐综合实验站, 乌鲁木齐, 830013, 中国

^e 新疆农业大学数值模拟与数据分析研究中心, 乌鲁木齐, 830052, 中国

ARTICLE INFO

Keywords:

空谱融合
高光谱成像
函数型数据分析
可识别性
评测泄漏
可信机器学习

ABSTRACT

空谱 (spatial-spectral) 特征融合被普遍视为提升高光谱成像 (HSI) 性能的关键, 但其何时有益、为何有益, 缺乏可先验判定的刻画。主流评测多采用随机像素划分——空间相邻的像素同时落入训练与测试, 造成信息泄漏, 系统性夸大精度。本文将 HSI 立方体建模为函数值空间场, 将融合分解为可加 (边缘光谱 + 边缘空间) 与交互两部分。理论表明: 融合增益被可计算的交互能量 γ 上下夹逼 ($\gamma \rightarrow 0$ 时拼接即最优), 进而将 γ 分解为二阶 (谱 $\times$ 空间逐像素) 与高阶 (跨多像素/波段联合非线性) 分量, 揭示交互的阶次结构; 跨队列泛化落差由映射漂移 Δ_{map} 经 Le Cam 下界刻画、并可先验估计。在四个跨域基准上采用防泄漏空间分块交叉验证, 得到三项发现: (1) 将空谱交互能量按阶分解, 二阶 (谱 $\times$ 空间逐像素) 项压倒性主导 ($\rho_2 = 0.54 \sim 0.80$), 高阶贡献始终显著低于二阶——说明在所检验的特征化下, 低阶可加-双线性模型已逼近理论最优; (2) 约 270–480 参数的可加模型达深度最优宏 F1 的 73% ~ 93% ($K_{\text{outer}}=5$), 而后者参数多 168 ~ 859 倍; (3) 随机划分相对 8×8 空间分块仍系统性高估 OA (最高 +7.5 百分点), 但夸大程度随分块粒度增加而减小。 $\hat{\gamma}$ 与映射漂移证书是两个可在训练/部署前计算的诊断量, 为评估融合必要性与跨场景可迁移性提供量化参考。

1. 引言

高光谱成像同步获取目标的二维空间图像与数百个连续窄波段的光谱, 是“图谱合一”的张量型数据 [1, 2, 3]。其每个像素是一条采样自连续电磁响应的高维向量, 而相邻像素在空间上高度相关, 因而 HSI 同时承载光谱与空间两类结构信息。如何融合二者以提升建模的精度、鲁棒性与可解释性, 是 HSI 分析的核心问题 [4, 5], 并在过去十余年催生了从空谱联合核、马尔可夫随机场、形态学剖面, 到三维卷积、空谱注意力与 Transformer 的一系列日益复杂的架构 [6, 7, 8, 9, 10, 11]。这些方法在各自的数据划分下普遍报告接近饱和的精度, 使“空谱融合越复杂越好”几乎成为领域的默认预期 [12, 13]。

然而, 支撑这一信条的两个基础问题始终悬而未决。

问题一 (机理): 融合相对简单拼接的增益究竟从何而来、何时存在? 能否将其可分解为可加分量与不可加交互分量、并可先验计算? 现有工作几乎都以端到端性能对比作答, 缺乏可证、可先验判定的刻画 [23, 24]。其后果是: 当复杂融合模型超越简单拼接时, 无法判断这源于真正的不可加空谱交互, 还是仅仅源于更强的可加空间上下文建模——二者对模型设计与计算成本的含义截然不同。

问题二 (评测有效性): HSI 像素分类的主流协议采用随机像素划分, 使空间相邻、因而高度自相关的像

素同时落入训练与测试集, 造成信息泄漏, 系统性高估泛化性能 [33, 34, 35]。在被泄漏夸大的评测下, “复杂融合带来的提升”可能本身就是高估的产物。

这两个问题相互交织: 唯有在无泄漏的评测下、以可分解的视角, 才能厘清融合增益的真实来源与大小。本文从函数型数据分析 (functional data analysis, FDA) [25, 26, 27] 出发统一回答上述问题。我们将每个 HSI 立方体视为定义在空间域 D 与连续光谱域 Λ 上的函数值空间场 $X(u, \lambda)$, 把“空谱融合”严格表述为对最优预测函数的方差分析 (ANOVA) 型分解: 可加部分 (边缘光谱函数 ϕ_s + 边缘空间统计 ϕ_a) 与交互部分 C 。这一视角给出两条可证结论与两个可计算诊断, 并以跨域、防泄漏实证检验。

贡献:

- (1) 函数型空谱框架: 将 HSI 立方体建模为函数值空间场, 把融合形式化为可加 $\oplus$ 交互的函数型 ANOVA 分解 (图 1), 并建立其在相依输入下的可识别性 (命题 1)。
- (2) 融合增益与交互能量的关系 (含多阶分解): 基于 ANOVA/Hoeffding 分解的正交投影性质, 给出融合超额收益被总交互能量 γ 夹逼的定量关系 (命题 2), 进而将 γ 按阶分解为二阶 $\gamma_{(2)}$ 与高阶 $\gamma_{(3+)}$ (命题 3) —— $\rho_2 = \gamma_{(2)}/\gamma$ 越高, 浅层可加-双线性模型越逼近理论最优, 深度模型的结构增益空间越小。
- (3) 迁移落差下界与证书: 基于已知后验漂移下界理论 [38, 39], 在 HSI 线性-高斯实例中给出跨队列泛

*通讯作者

✉ huanghua@xjau.edu.cn (H. Huang (黄华))

ORCID(s): 0000-0003-0615-9402 (H. Huang (黄华))

化落差经映射漂移 Δ_{map} 的 Le Cam 下界与可计算代理 (命题 4)。

- (4) 跨境防泄漏实证：在遥感与农业四基准上，防泄漏评测揭示在所检验的特征化方式下可加空间上下文贡献了增益的主要部分，低阶显式空谱交互收益有限 (≤ 0.022 宏 F1)，约 270–480 参数的可加函数型模型达深度最优 75% ~ 93%，随机划分系统性高估 OA (+0.9 ~ +7.5 百分点, $K_{\text{outer}}=5$)。
- (5) 两个可先验计算的诊断量：低阶交互能量代理 $\hat{\gamma}$ 与映射漂移证书 $\hat{\Delta}$ ，分别为“是否需要复杂融合”“能否跨场景迁移”提供训练/部署前可计算的量化参考——不声称普遍性，而是提供可操作的筛查工具。

新颖性边界 (诚实声明)：函数型 ANOVA 交互分解由 Hoeffding (1948) 建立、经 Hooker (2007) [28] 推广至相依输入，其“可加残差能量 = 交互能量”的正交投影性质是已知结果；域适应中后验漂移下界的骨架源自 Ben-David 等 (2010) [38] 与 Cai 和 Wei (2021) [39]；空间评测泄漏由 Karasiak 等 (2022) [33] 与 Ploton 等 (2020) [35] 系统提出。本文的新意不在于重造这些原理，而在于：(1) 将函数型 ANOVA 分解首次应用于 HSI 空谱融合问题，在函数值空间场 (连续光谱 $\times$ 离散空间) 上实例化可加 $\oplus$ 交互分解；(2) 给出两个可计算的诊断量 $\hat{\gamma}$ 与 $\hat{\Delta}$ ——前者将交互能量转化为可由数据估计的筛查信号，后者将映射漂移化为可先验计算的迁移证书；(3) 以跨境防泄漏实证揭示：在所测基准与特征化方式下，可加空间上下文的贡献远大于显式低阶空谱交互，并首次量化随机划分相对空间分块的精度夸大幅度 (最高 +38.6 百分点)。三个层级的创新构成一个从“已知原理 $\rightarrow$ 可计算工具 $\rightarrow$ 可操作经验规律”的完整链条。

2. 相关工作

2.1. HSI 空谱特征融合

早期光谱分析以化学计量学回归为主 (如偏最小二乘 [15])，早期 HSI 分类则依赖纯光谱分类器 (如支持向量机 [14])，随后大量工作引入空间信息以缓解“同物异谱、同谱异物”。代表性范式包括：空谱联合核与组合核 [4]、扩展形态学剖面、马尔可夫随机场后处理，以及近年依托通用深度架构 (如残差网络 [16]) 的深度表征学习方法——三维卷积网络 [6]、二维/三维混合网络 (如 HybridSN) [7]、图卷积 [11]、空谱 Transformer (如 SpectralFormer) [8]、近期的状态空间模型 (如 SpectralMamba [17]、MambaHSI [18])、双上下文 Transformer (DCN-T [19])、多模态融合 Transformer [21] 以及光谱遥感基础模型 (SpectralGPT [20])。综述 [9, 10, 12, 13] 系统总结了这一脉络，普遍结论是“联合建模优于分离建模”。然而这些比较多在随机划分下进行、且很少区分增益是来自可加空间上下文还是不可加空谱交互。多源/多模态融合综述 [23, 24] 亦指出协同表征机制尚缺乏理论刻画。本文正是针对这一空白，给出融合增益的可分解、可计算刻画。

2.2. 函数型数据分析

FDA 将每条观测视为定义在连续域上的函数 [25, 26, 27]。函数型线性回归的极小极大率与自适应估计已

有系统理论 [29, 30, 31]。将光谱视为波长的连续函数、以基函数展开表征，能保留谱的连续性与高相关结构，并缓解高维小样本下的 Hughes 现象 (维数灾难) [32]。本文把这一视角扩展到函数值空间场 (每像素一条谱函数、像素在空间上耦合)，并据此定义可加 $\oplus$ 交互分解。

2.3. 评测泄漏与空间交叉验证

当训练与测试样本在空间上相关时，忽略该相关的随机划分会高估泛化 [34]。Ploton 等 [35] 在大尺度生态制图中证明随机验证给出过度乐观的预测力；Karasiak 等 [33] 在遥感分类中系统比较空间与非空间交叉验证，建议空间留一法以获无偏估计；Meyer 与 Pebesma [22] 在全球生态制图中进一步表明，忽视空间依赖的随机验证会系统性高估机器学习地图的精度；Kattenborn 等 [36] 在植被遥感深度学习综述中亦强调这一陷阱；Kapoor 与 Narayanan [37] 进一步指出，数据泄漏是机器学习驱动科学中跨 17 个学科、波及数百篇研究的系统性可复现性危机，凸显结构感知评测的普遍必要性。本文采用空间分块 (留块) 交叉验证，并定量给出随机划分相对防泄漏协议的精度夸大幅度。

2.4. 域适应与迁移学习理论

跨域泛化的不可能性与下界已有经典刻画：Ben-David 等 [38] 给出基于域散度的目标误差界；协变量移与重要性加权 [41, 42]；Cai 与 Wei [39]、Kpotufe 与 Martinet [40] 给出迁移的极小极大率与后验漂移下界。本文在 HSI 的线性-高斯实例中实例化后验漂移下界，并把漂移量诊断化为可由数据先验估计的迁移证书。

3. 函数型空谱框架与估计器

3.1. 生成模型与融合分解

设样本 i 的立方体 $X_i: D_i \times \Lambda \rightarrow \mathbb{R}$ ， D_i 为离散像素域， $\Lambda \subset [\lambda_{\min}, \lambda_{\max}]$ 为连续光谱域。由 X_i 提取两类边缘特征：

- 边缘光谱特征 $s_i \in S$ ：对逐像素谱函数做函数型主成分分析 (FPCA)，取前 K 个得分；
- 边缘空间特征 $a_i \in \mathcal{A}$ ：对每个 FPCA 得分图取邻域统计 (如 $w \times w$ 邻域均值)，刻画空间上下文。

对响应 y_i ，记其最优预测 (贝叶斯回归函数) 为 $f^*(s, a) = \mathbb{E}[y | s, a]$ 。 $L^2(S \times \mathcal{A})$ 上的函数型 ANOVA (Hoeffding) 分解给出

$$f^*(s, a) = \underbrace{\phi_s(s)}_{\text{可加 (边缘)}} + \underbrace{\phi_a(a)}_{\text{空谱交互}} + C(s, a), \quad y = f^*(s, a) + \zeta, \quad (1)$$

其中 ζ 为零均值噪声， $\mathbb{E}[\phi_s] = \mathbb{E}[\phi_a] = 0$ 、 $\mathbb{E}[C | s] = \mathbb{E}[C | a] = 0$ (中心化约束)， C 为不可加交互——它刻画“光谱特征的空间分布所携带、而边缘光谱 ϕ_s 与边缘空间 ϕ_a 各自都不含”的信息。

定义 1 (交互能量 γ)。 $\gamma := \mathbb{E}[(C - \Pi_{\text{add}} C)^2]$ ，其中 Π_{add} 为到可加函数空间 $\mathcal{H}_{\text{add}} = \{g_1(s) + g_2(a)\}$ 的

函数型空谱分解：可加 ⊕ 交互




Figure 1: 函数型空谱分解框架。把 HSI 立方体视为函数值空间场 $X(u, \lambda)$ ，经 FPCA 提取边缘光谱特征 ϕ_s 与边缘空间特征 ϕ_a ；最优预测 f^* 分解为可加 ($\phi_s \oplus \phi_a$ ，晚融合/拼接，蓝绿) 与交互 C (橙) 两部分，交互的不可加能量记为 γ (命题 2: $\gamma \rightarrow 0$ 时拼接即最优)。底部虚线表示跨队列表部署时由映射漂移 Δ_{map} 刻画的可迁移性 (命题 4)。 γ 与 Δ_{map} 是两个可在训练/部署前计算的诊断量。

Table 1
主要记号。

记号	含义
$X_i(u, \lambda)$	样本 i 的函数值空间场 (像素 u 、波长 λ)
s_i, a_i	边缘光谱特征 / 边缘空间特征
$f^* = \phi_s + \phi_a + C$	最优预测的可加 ⊕ 交互分解
γ	交互能量 (定义 1)
Δ_{map}	跨队列表“谱 → 性状”映射漂移
Gap	融合增益 $\text{ER}_{\text{add}} - \text{ER}_{\text{joint}}$
$\hat{\gamma}, \hat{\Delta}$	$\gamma, \Delta_{\text{map}}$ 的可计算证书 (诊断量)
L_{spat}	空间图-Laplacian
K_t, β_c	FPCA 成分数 / 队列 c 的谱 → 性状方向

L^2 正交投影。 γ 度量交互中无法被任何可加/拼接函数表示的能量。

“可加晚融合 (additive late fusion)”估计器把假设空间限制在 $\mathcal{H}_{\text{add}}$ 内 (先独立提取 s, a 、再可加组合; 注意: 拼接后接非线性头 (MLP/核/注意力) 可表征交互, 不属此可加类); “空谱联合 (joint)”估计器在 $L^2(\mathcal{S} \times \mathcal{A})$ 内, 可表征交互 C 。全文主要记号汇总于表 1。

3.2. 估计器与诊断量

简单可加函数型模型: 以 ϕ_s (FPCA 得分, $K = 15$) 与 ϕ_a (9×9 邻域均值) 为特征, 线性 softmax 读出, 总参数约 270 ~ 480, 不含显式交互项。联合 (+ 交互) 变体: 在可加特征上追加谱 × 空间低阶交叉项 $\{\phi_{s,k}\phi_{a,l}\}$ 以表征 C , 用于检验融合增益与估计 γ ; 其经验估计 $\hat{\gamma}$ 取“交互特征对可加残差的可解释能量占比”。空间正则函数型联合估计器 (一般形式): 系数 $\beta(u, \lambda)$ 带不可分

耦合正则

$$\min_{\beta} \frac{1}{n} \sum_i (y_i - \langle \beta, X_i \rangle)^2 + \lambda_{\Lambda} \|\beta\|_{W^{s,2}(\Lambda)}^2 + \lambda_D \text{tr}(\beta^{\top} L_{\text{spat}} \beta), \quad (2)$$

谱向 Sobolev 粗糙度罚 $\otimes$ 空间图-Laplacian L_{spat} 罚。求解与复杂度: 式 (2) 关于 (ϕ_s, ϕ_a, C) 块凸, 采用块坐标下降: 固定其余项时各子问题为带 Sobolev/图-Laplacian 二次罚的最小二乘, 有闭式或共轭梯度解; 谱向卷积在平移不变假设下经快速傅里叶变换对角化、空间向利用稀疏图-Laplacian, 单步复杂度 $\mathcal{O}(n|\Lambda| \log |\Lambda| + n \cdot \text{nnz}(L))$ (随像素数线性、随波段近线性), 在 (ϕ_s, ϕ_a, C) 邻域受限强凸下局部线性收敛至驻点。相较之下, 简单可加模型仅需一次 FPCA 加邻域滤波与线性读出, 单机 CPU 秒级完成、推理为单次矩阵乘, 适合边缘/实时部署。

映射漂移证书: 在每个队列 c 内拟合“谱 → 性状”方向 β_c , 以其两两不一致性 (Σ -度量夹角) 估计映射漂移 Δ_{map} , 作为跨队列表可迁移性的先验证书。

4. 理论

假设 1 (正则性). (s, a) 二阶矩存在; 其联合分布使 $\mathcal{H}_{\text{add}}$ 为 L^2 闭子空间; 目标协方差正定 (有限维实例) 或迹类 (函数型实例)。

命题 1 (联合表征可识别性). 在假设 1 下, 对联合分布 $P_{s,a}$, 可加投影 $\Pi_{\text{add}} f^*$ 与交互残差 $C = f^* - \Pi_{\text{add}} f^*$ 唯一可识别 (投影残差唯一性, 不要求 s, a 独立); 若进一步 $L^2(s) \cap L^2(a)$ 仅含常数 (平凡交, 一般成立), 则可加部分到 ϕ_s, ϕ_a 的中心化分裂亦唯一。

命题 2 (融合增益与交互能量的关系). 记可加、联合估计器的期望超额风险为 $\text{ER}_{\text{add}}, \text{ER}_{\text{joint}}$, 融合增益

$\text{Gap} := \text{ER}_{\text{add}} - \text{ER}_{\text{joint}}$ 。由 *ANOVA/Hoeffding* 分解 [28] 的正交投影性质，总体层面有 $\text{Gap}_{\text{pop}} = \gamma$ ；有限样本下

$$\gamma - \varepsilon_{\text{joint}}(n) \leq \mathbb{E} \text{Gap} \leq \gamma + \varepsilon_{\text{add}}(n),$$

$\varepsilon(n)$ 为估计误差。 $\gamma = 0$ 时拼接总体最优。上述关系在 L^2 平方风险下严格成立；其经验推广至分类任务时依赖具体特征化方式（如本文的 *FPCA+* 邻域均值低阶交叉项），不暗示对任意特征化或数据普适。本文贡献在于将已知 *ANOVA* 分解实例化为 *HSI* 中可计算的 $\hat{\gamma}$ ，而非重造该理论。

注 1 (度量与诊断量的范围)。命题 2、4 以平方/超额风险 (L^2) 陈述；第 6 节报告的宏 $\text{F1/OA}/\kappa$ 是其经验印证而非直接推论——分类度量 (0-1 损失) 与平方风险在方向上一致但非等价 (平方风险的微小变化可能在 F1 上不完全可辨，反之亦然)。为弥合此间隙，第 6 节另设合成验证在 L^2 原生度量下直接检验命题，作为命题严格检验；真实数据分类实验作为经验佐证。诊断量 $\hat{\gamma}$ 是交互项对可加残差的归一化可解释方差代理 (非定理中的总体 γ)， $\hat{\Delta}$ 同为 Δ_{map} 的相合代理；二者用于训练/部署前的先验排序判定，其严格置信区间与显著性检验、以及与分类校准度量 (如 Brier score) 的连接列为未来工作。

4.1. 多阶交互分解：交互能量的阶次结构

命题 2 将融合增益刻画为总交互能量 γ 的函数，但 γ 本身是一个标量黑箱——它回答“交互是否为零”，却无法区分交互来自简单的谱 $\times$ 空间逐像素耦合 (二阶)，还是跨多像素 $\times$ 跨多波段联合非线性 (高阶)。这一区分具有深刻的实践含义：若交互以二阶为主，则浅层可加-双线性模型已理论最优，深度模型的额外增益只能来自更强的低阶表征；若高阶项显著，深度层级化表征才有结构性的不可替代优势。

定义 2 (交互能量的阶次分解)。将 *Hoeffding* 分解 [28] 按参与变量的阶数聚合：

$$f^*(s, a) = \underbrace{\phi_s(s) + \phi_a(a)}_{\text{一阶 (可加)}} + \underbrace{C_{(2)}(s, a)}_{\text{二阶}} + \underbrace{\sum_{k=3}^d C_{(k)}(s, a)}_{\text{高阶 } (\geq 3 \text{ 阶})},$$

其中 $C_{(2)}(s, a) = \sum_{i \in \mathcal{S}, j \in \mathcal{A}} f_{ij}(s_i, a_j)$ 仅含一个谱特征 $\times$ 一个空间特征的成对交互， $C_{(k)}$ 含 k 个特征的非线性联合效应。由 *Hoeffding* 分解的正交性，各阶在 L^2 中互相正交：

$$\gamma = \gamma_{(2)} + \gamma_{(3+)} := \mathbb{E}[C_{(2)}^2] + \mathbb{E}\left[\left(\sum_{k \geq 3} C_{(k)}\right)^2\right]. \quad (3)$$

定义 3 (二阶占比)。 $\rho_2 := \gamma_{(2)}/\gamma$ ，度量二阶交互在总交互能量中的比重。 $\rho_2 \rightarrow 1$ 时交互以谱 $\times$ 空间逐像素耦合为主，浅层可加-双线性模型逼近理论最优； $\rho_{(3+)} := 1 - \rho_2$ 显著大于零时，深度模型的层级化表征有结构性增益空间。

命题 3 (多阶分解下的融合增益)。在定义 2 的分解下，命题 2 的 Gap 可进一步写为：

$$\mathbb{E} \text{Gap} = \gamma_{(2)} + \gamma_{(3+)} - \varepsilon_{\text{joint}}(n) + \varepsilon_{\text{add}}(n), \quad (4)$$

其中 $\varepsilon_{\text{joint}}(n)$ 随交互阶数 k 增长而增大 (k 阶交互的有效维数 $d_k \leq \binom{d_s + d_a}{k}$ 更大，非参数估计收敛更慢)。因此：

- (i) 若 $\gamma_{(3+)} \approx 0$ ($\rho_2 \approx 1$)，截断至二阶的可加-双线性模型已逼近总体最优，深度优势的理论上界被 $\gamma_{(3+)}$ 控制在近零；
- (ii) 若 $\gamma_{(3+)}$ 显著且 $\gamma_{(2)}$ 也被充分估计，则需要表征高阶交互的模型 (如深度网络) 方可逼近贝叶斯风险。
- (iii) 对任意 K 阶截断，若 $\gamma_{(k)} \leq c\rho^k$ ($\rho < 1$ ，指数衰减)，截断相对误差 $\leq c\rho^K/(1 - \rho)$ ——即浅层模型的最优性可由交互能量的衰减速率 ρ 先验保证。

该命题将“深度模型是否有结构性优势”从经验争论转化为可先验计算的问题：在训练/部署前，估计 ρ_2 。 ρ_2 越高，浅层越接近理论最优，深度增益的空间越小。

交互能量的估计与收敛率。采用函数型主成分基对 $\hat{C}$ 做截断展开 $\hat{C}_{J_n}(s, a) = \sum_{j=1}^{J_n} \hat{\theta}_j \psi_j(s, a)$ ，其中 $J_n \asymp n^{2r/(2r+d_{\text{eff}})}$ 为最优截断， r 为谱-空间张量 Sobolev 光滑度， d_{eff} 为有效维数 (受图-Laplacian 正则控制)。交互能量的估计量为 $\hat{\gamma} = \|\hat{C}_{J_n}\|_{L^2}^2$ ，其收敛率为

$$|\hat{\gamma} - \gamma| = \mathcal{O}_p(n^{-\frac{2r}{2r+d_{\text{eff}}}}), \quad (5)$$

各阶分量 $\hat{\gamma}_{(k)}$ 的独立收敛率为 $\mathcal{O}_p(n^{-2r_k/(2r_k+d_k)})$ ，其中 $d_k \leq \binom{d_s+d_a}{k}$ 。由于高阶项 d_k 更大而 $\gamma_{(k)}$ 本身更小 (衰减)，总 $\hat{\gamma}$ 的收敛率由低阶项主导。

交互能量的假设检验。构造 $H_0: \gamma = 0$ (拼接已最优) 的检验：在 H_0 下 γ 的估计量 $\hat{\gamma}$ 经适当标准化后渐近服从卡方分布。基于距离协方差 (distance covariance) 的检验统计量 $T_n = n \cdot \hat{\Gamma}_{\text{dist}}/\hat{\sigma}^2$ 在 H_0 下渐近 χ^2 ，分布自由、不依赖矩假设。实证中 Fisher 合并跨折 p 值提供保守检验。

域适应 bound：从交互到迁移。记源域 P 与目标域 Q 的边缘分布满足 $W_2(p, q) \leq \Delta_{\text{map}}$ ， f^* 含 K 阶截断交互分解且各阶 Lipschitz 常数为 L_k ，则存在自适应估计器 $\hat{f}_{\text{adapt}}$ 满足

$$\mathbb{E} \text{ER}_Q(\hat{f}_{\text{adapt}}) \leq \mathbb{E} \text{ER}_Q(\hat{f}_{\text{src}}) + \Phi(\Delta_{\text{map}}), \quad (6)$$

其中 $\Phi(\Delta) = c \cdot \gamma_{(3+)}^{1/2} \cdot \Delta \cdot \sqrt{\log d_{\text{eff}}}$ ，在 $\Delta_{\text{map}} \rightarrow 0$ 时趋于零。该 bound 揭示：高阶交互能量 $\gamma_{(3+)}$ 是分布偏移效应的放大器——当 $\gamma_{(3+)}$ 大时跨域迁移显著退化；当 $\gamma_{(3+)} \approx 0$ 时可套用经典 Ben-David 型 bound。由此 Δ_{map} 不仅用于先验筛查，还可指导自适应重标定，从“不可能性”转向“可能性”。

注 2 (多重特征化方式)。命题 3 基于 *Hoeffding* 分解的 L^2 正交性，不要求 $s \perp a$ 。本文提供五种互补特征化以

交叉验证交互分解结论:(1) **Hoeffding ANOVA** (主方法): 无需独立假设, 通过 L^2 正交投影正交分解各阶能量; (2) **Sobol-R²** 方差归因 (偏 R^2 分解): 将预测方差按特征组分配, 在 $s \not\perp a$ 时作为辅助验证; (3) 互信息分解 (高斯信道): $\gamma_{\text{MI}} = I(s, a; y) - I(s; y) - I(a; y)$, 度量“联合超越各自之和的信息”, 在高斯假设下与方差型 γ 近似线性对应 $\gamma_{\text{MI}} \approx \Gamma / (2\sigma^2(1 + \text{SNR}_s)(1 + \text{SNR}_a))$; (4) 距离协方差检验: 分布自由, $H_0: \gamma = 0$ 的严格统计检验; (5) 集成 **Hessian** 范数: $\Gamma_{\text{hess}} = \mathbb{E}[\|\partial^2 \hat{f}_\theta / \partial s \partial a^\top\|_F^2]$, 对已训练模型事后估计其二阶交互强度——纯可加模型 Hessian 交叉块为零。五种特征化在第 6.2 节中一致验证在所检验的特征化下二阶交互压倒性主导的结论。

命题 4 (跨队列迁移落差下界). 取线性-高斯实例 $y = \langle \beta_c, x \rangle + \zeta$ ($\zeta \sim N(0, \sigma^2)$)。记源队列映射凸包 $\mathcal{C} = \text{conv}\{\beta_c : c \in S\}$, 定义映射漂移

$$\Delta_{\text{map}} = \inf_{\beta \in \mathcal{C}} \|\beta_{c^*} - \beta\|_{\Sigma_{c^*}}.$$

对仅用源数据的零样本估计器 $\hat{f}$, 极小极大下界 $\sup \mathbb{E} \text{ER}_{c^*}(\hat{f}) \geq \frac{1}{4} \Delta_{\text{map}}^2$ 。故跨队列泛化落差 $\gtrsim \Delta_{\text{map}}$, 其可计算代理 $\hat{\Delta}$ 提供迁移排序信号。

注 3. 命题 2 在 L^2 平方风险下严格成立, 命题 4 在线性-高斯实例中成立; 两者的下界骨架均属已知理论 [38, 39, 28]。本文贡献在于函数型 HSI 实例化与 $\gamma, \Delta_{\text{map}}$ 的可计算诊断化, 而非宣称对任意数据分布或特征化的普适性。式 (2) 的块坐标求解在受限强凸下局部线性收敛, 单步复杂度 $\mathcal{O}(n|\Lambda| \log |\Lambda| + n \cdot \text{nnz}(L))$ 。

5. 实验设置

5.1. 数据集

主实验采用四个跨域公开基准 (表 2 上半): 遥感地物 (Indian Pines、Pavia University、Salinas、AVIRIS/ROSIS) [45] 与无人机精细作物 (WHU-Hi-LongKou) [46], 覆盖 9 ~ 16 类、103 ~ 270 波段, 兼含遥感与农业、城市与田块多种空谱结构; 跨队列迁移分析另用 7 个带队列结构的农业高光谱数据集 (表 2 下半, 队列由物种/品种、采集设备、年份、地点或物候定义)。表 2 (数据卡) 给出全部数据集的模式、规模、性状与来源: 除 001 (作者单位内部采集) 外, 迁移数据集均为 Mendeley/Figshare/USDA 等公开数据集 (脚注列出确切来源), 所有原始与预处理文件记录 SHA-256 校验值以保证可追溯。

5.2. 防泄漏评测协议

将每个场景按 6×6 空间分块, 采用留块 GroupK-Fold (块间空间不相交) 以大幅降低相邻像素跨训练/测试的泄漏 (两种划分对比见图 2); 块边界处仍可能残留弱泄漏, 第 6.8 节通过缓冲带扫描量化了其规模。作为对照, 另跑随机像素 StratifiedKFold (文献主流, 含泄漏) [33, 34]。指标为宏 F1、总体精度 OA、Cohen's κ ; 每场景按类配额下采样至 $\leq 8000 \sim 9000$ 标注像素以均衡类别。所有实验在单张 NVIDIA RTX 4090 上完成。随机种子: 全部实验均使用 5 个预注册 Formal 种子 {20060515, 20041210, 19810915, 2023, 2024}, 逐种

子独立重做空间分块 CV; 下采样、划分与模型初始化的全部随机性由对应种子统一控制以保证可复现。

5.3. 对比模型

- 简单可加 (函数型): FPCA 谱得分 + 邻域均值空间上下文 $\rightarrow$ 线性 softmax ($\sim 270 \sim 480$ 参数)。
- 随机森林 (谱 + 空) [43]: 同一特征上的非深度强基线。
- 空谱 **2D-CNN** [6]: 三卷积块、PCA 波段作通道 ($\sim 2.3 \times 10^5$ 参数)。
- 空谱 **3D-CNN** [7]: 三卷积块、立方体补丁 ($\sim 8 \times 10^4$ 参数)。

深度模型含随机翻转增强、50 轮、Adam, 与简单模型共享同一 FPCA 表征与折内预处理。

5.4. 综合评价框架: LLH-GBID

为在同一实验条件下综合比较多模型的分类表现, 本文采用 LLH-GBID (Generalized Balanced Ideal Distance) 综合评价框架。LLH-GBID 是一种条件相对综合评价方法——将原始指标按评价含义划分为维度并转换为 $[0, 1]$ 效用值, 再以分层 L_q 理想距离聚合为综合分数。其核心步骤为:

指标效用化: 各指标按方向 (效益型/成本型/目标型) 转换为效用值 $u_j = \text{clip}((x_j - L_j) / (I_j - L_j)) \in [0, 1]$ 。理想值 I_j 取理论最优 ($I = 1$), 基准值 L_j 取各类别等概率随机猜测水平: $L_{F1} = L_{OA} = 1/K$, $L_\kappa = 0$ (K 为类别数)。 $u_j = 0$ 表示未达基准, $u_j = 1$ 表示达到理想。

两级权重: 维度等权 $W_d = 1/2$ (整体分类能力 D1: OA、 κ ; 类别识别能力 D2: 宏 F1), 维度内等权 (D1 内 OA 与 κ 各 $v = 1/2$, D2 仅宏 F1 故 $v = 1$)。指标缺口 $d_j = 1 - u_j$, 维度内缺口距离 $D_d^{(q_W)} = [\sum_{j \in J_d} v_{j|d} d_j^{q_W}]^{1/q_W}$, 综合理想距离

$$\text{GBID}_{q_B, q_W} = \left[\sum_{d=1}^D W_d (D_d^{(q_W)})^{q_B} \right]^{1/q_B} \in [0, 1]. \quad (7)$$

其中 q_W 和 q_B 分别控制维度内和维度间的短板敏感性。主分析取 $q_B = q_W = 2$ (标准加权欧氏理想距离), 此时 $\text{GBID}_{2,2} = [\sum_j w_j (1 - u_j)^2]^{1/2}$ 精确分解为

$$\text{GBID}_{2,2}^2 = (1 - \bar{u})^2 + C_B^2 + C_W^2, \quad (8)$$

其中 $\bar{u}$ 为加权平均效用, $(1 - \bar{u})^2$ 度量平均水平与理想的差距, $C_B^2 = \sum_d W_d (U_d - \bar{u})^2$ 为维度间不均衡, $C_W^2 = \sum_d W_d \sum_{j \in J_d} v_{j|d} (u_j - U_d)^2$ 为维度内不均衡。定义 0-100 综合指数 $\text{GBIDS} = 100(1 - \text{GBID})$ 。

非补偿性准入门槛: 全部三个指标均设为门槛指标 ($J_{\text{crit}} = \{F1, OA, \kappa\}$), 阈值为 $u_j^{\min} = 0$ (不低于随机基准)。当前候选集中所有模型均通过门槛。采用软否决: 未通过门槛的模型置于结果表末位且不得标注为综合最优。

LLH-GBID 为条件相对评价框架。GBIDS 是 0-100 综合指数得分, 不是准确率或概率。其绝对数值仅在相

Table 2

数据卡：本文所用全部数据集的模态、规模、任务与来源。上半 = 主实验四个公开 HSI 分类基准；下半 = 跨队列迁移分析所用 7 个农业高光谱数据集（队列由物种/品种、采集设备、年份、地点或物候定义）。所有数据集原始与预处理文件均记录 SHA-256 校验值以保证可追溯。

数据集	模态/波段	规模/队列	性状（任务）	来源
Indian Pines	AVIRIS HSI / 200	145×145 px	16 类地物	EHU 场景库 [45] ^a
Pavia University	ROSIS HSI / 103	610×340 px	9 类地物	EHU 场景库 ^a
Salinas	AVIRIS HSI / 204	512×217 px	16 类地物	EHU 场景库 ^a
WHU-Hi-LongKou	无人机 HSI / 270	550×400 px	9 类作物	武大 RSIDEA [46] ^b
001 苹果	HSI 348 波段	多产地 × 年份	糖度 SSC	内部采集 ^c
006 芒果	NIR 谱	4 品种	维生素 C	Mendeley ^d
012 猕猴桃	NIR 谱	多设备 × 物种	糖度/干物质	Figshare ^e
013 葡萄	多光谱 37 波段	5 品种 × 13 批次	花青素/Brix	Figshare ^f
018 牛油果/橄榄/葡萄	多光谱 +HSI	3 物种	叶绿素/氮/水/重	Figshare ^g
019 葡萄	HSI 204 波段	3 品种	含糖量	Mendeley ^h
029 棉花	HSI 全波段	多地点 × 播期	叶绿素/LAI/株高	USDA ⁱ

^a EHU 高光谱遥感场景库 http://www.ehu.es/ccwintco/index.php/Hyperspectral_Remote_Sensing_Scenes（公开，允许学术使用）。

^b 武汉大学 RSIDEA 公开数据集 WHU-Hi http://rsidea.whu.edu.cn/resource_WHUHi_sharing.htm。

^c 新疆农业大学内部采集（多产地/年份苹果高光谱，需联系通讯作者获取）。

^d 006 芒果：Mendeley Data <https://data.mendeley.com/datasets/b9d6s7hr33/1>。

^e 012 猕猴桃：Figshare https://figshare.com/articles/dataset/Kiwifruit_NIR/21747983。

^f 013 葡萄：Figshare https://figshare.com/articles/dataset/Multispectral_grape_images_dataset/14679480。

^g 018 牛油果/橄榄/葡萄：Figshare <https://figshare.com/articles/dataset/26950660>。

^h 019 葡萄：Mendeley Data <https://data.mendeley.com/datasets/gjwx64sgkp/2>。

ⁱ 029 棉花：USDA Ag Data Commons <https://agdatacommons.nal.usda.gov/articles/dataset/27765477>。

防泄漏评测协议




Figure 2: 防泄漏评测协议示意。左：6×6 空间分块留块交叉验证，整块同属训练或测试，测试区与训练区在空间上分离；右：文献主流的随机像素划分使空间自相关的相邻像素同时落入训练与测试，造成泄漏并系统性夸大报告精度。

同评价体系（同一数据集、同一指标、同一基准、同一权重）内有排序意义，不用于跨数据集或跨实验的绝对比较。完整的权重、基准、门槛与稳健性分析配置已预注册并在补充材料中提供。

5.5. 实现细节

关键超参：FPCA 成分数 $K = 15$ ；空间邻域窗 9×9 ；防泄漏空间分块 6×6 ；深度模型训练 50 轮，Adam（学

习率 10^{-3} 、权重衰减 10^{-4} ）、批大小 128、随机水平/垂直翻转增强。诊断量 $\hat{\gamma}$ 由交互交叉项对可加残差的岭回归可解释方差占比估计。所有模型共享同一 FPCA 表征与防泄漏划分、同等训练预算。三个关键超参（ K 、 w 、分块粒度）的逐一灵敏度扫描见表 15。

Table 3

可加 vs 联合 (+ 交互) 宏 F1 (防泄漏空间分块 CV, 5 种子 mean $\pm$ std)。交互增益均 ≤ 0.022 , Salinas 与 WHU 上联合略低于可加。

数据集	可加	联合	增益	$\hat{\gamma}$
Indian Pines	.398 _{.022}	.401 _{.026}	+.003	.133
Pavia U	.715 _{.036}	.737 _{.039}	+.022	.131
Salinas	.819 _{.040}	.818 _{.033}	-.000	.220
WHU-Hi	.834 _{.019}	.825 _{.011}	-.008	.182

6. 实验结果

6.1. 可加空间上下文贡献主要增益, 低阶显式交互收益有限

表 3 比较“可加 (谱 + 空间拼接)”与“联合 (+ 空谱交互)”在防泄漏 CV 下的宏 F1 (5 种子 mean $\pm$ std)。在所检验的 FPCA+ 邻域均值特征化方式下, 四基准上低阶显式空谱交叉项的额外增益均极小: Indian Pines +0.003、PaviaU +0.022、Salinas -0.000、WHU-Hi-LongKou -0.008——后两个数据集上联合反而略低于简单可加。交互能量估计 $\hat{\gamma} \in [0.13, 0.22]$ (5 种子均值), 高于此前 pilot 阶段子样本估计, 反映了更大训练集下交互项“可解释能量”占比的变化。这与命题 2 一致: 当可加投影残差在分类决策边界上贡献有限时, 拼接已接近最优。需要强调: 这一观察针对的是特定特征化下的低阶显式交互, 不等于原始 HSI 立方体中所有形式的空谱交互均弱——不同特征化通道 (如全波段核交互、深度隐式表征) 可能捕获不同的交互结构。

合成验证 (理论原生度量 L^2): 命题以平方/超额风险 (L^2) 陈述而上表用宏 F1, 二者非等价 (注 1)。为在定理原生度量下直接检验命题 2, 我们在可控合成数据上构造可加 $\oplus$ 交互的目标函数 (交互能量真值 γ 已知) 并扫描其强度 (图 3(a))。结果显示: 经验融合增益 Gap 随真 γ 单调上升 (相关 ≈ 1.0), 在低阶交互下斜率 ≈ 0.95 (即 $\text{Gap} \approx \gamma$, 命题在 L^2 下成立); 但本文采用的低阶交叉项代理 $\hat{\gamma}$ 在高阶交互下系统性低估真 γ (中位仅恢复约 27%)。因此“ $\hat{\gamma}$ 小”严格说只能断言低阶交互弱, 而非排除高阶交互——后者由能表征高阶交互的深度模型独立把关: 其相对简单可加的增益亦仅 0.04 $\sim$ 0.10 (第 6、6.7 节)。我们将二者设计为 AND 逻辑门筛查: $\hat{\gamma}$ 小且深度增益小 $\rightarrow$ 交互确实弱 (联合判定); $\hat{\gamma}$ 大 $\rightarrow$ 需进一步查 (高召回、低精度筛查信号)。在当前数据上, 两个条件同时满足, 提示交互量级有限, 且我们不主张交互严格为零或该判定对所有数据普适。

多种子稳健性: 表 3 的 5 种子结果一致表明交互增益 ≤ 0.022 、两数据集上为负。 $\hat{\gamma}$ 未能通过 AND 逻辑门筛查 (四基准 $\hat{\gamma} \in [0.13, 0.22]$, 均 > 0.1): 在当前特征化下, 低阶交互的“可解释能量”本身并非微不足道, 但该能量未转化为分类 F1 的增益——联合 (+ 交互) 相对简单可加的宏 F1 差异在 5 种子尺度上接近于零。因此 $\hat{\gamma} \wedge$ (深度增益小) 的联合判定中, 第一条未通过——提示低阶交互存在但与分类决策边界的方向不完全对齐, 而非交互本身为零。

6.2. 交互能量的阶次分解: 二阶项压倒性主导

本节实证检验命题 3 的核心预测: 在所检验的 FPCA+ 邻域均值特征化方式下, 空谱交互的能量主要来自二阶 (谱 $\times$ 空间逐像素) 耦合, 还是来自高阶 (跨多像素/波段联合非线性)? 答案直接决定“浅层可加-双线性模型是否已达理论天花板”。

6.2.1. 多阶交互能量的跨域估计

对每个数据集与每个种子 (5 个预注册 Formal 种子), 我们在折内用 Hoeffding 型回归方差分解估计各阶交互能量 (方法细节见 §4.1)。具体而言: 以 Ridge 回归拟合可加模型 (1 阶), 再加所有 $s_i \times a_j$ ($i, j = 1, \dots, 15$) 成对交叉项得 2 阶模型, 随机采样三阶交叉项 ($s_i \times a_j \times a_k$) 得 3 阶代理; 各阶增量的可解释方差归一化后即 $\gamma_{(2)}$ 与 $\gamma_{(3+)}$ 。跨种子平均结果汇总于表 4 与图 4。

6.2.2. 核心发现

(1) 二阶交互压倒性主导。三基准上 ρ_2 的中位为 0.734 (范围 0.544 $\sim$ 0.799, 5 种子 mean), 即总交互能量的 54% $\sim$ 80% 由二阶 (谱 $\times$ 空间逐像素) 耦合贡献。Salinas Valley 的二阶占比最高 ($\rho_2 = 0.80$), Indian Pines 最低 ($\rho_2 = 0.54$)——后者地块细碎、类别间空间交错, 残存更多高阶结构; Pavia University 居中 ($\rho_2 = 0.73$)。跨种子标准差较小 (0.05 $\sim$ 0.19), 估计稳健。

(2) 高阶交互能量绝对值始终很小。跨四基准, $\gamma_{(3+)}$ 均 ≤ 0.008 , 相较于一阶可加能量 ($\gamma_{(1)} \in [0.03, 0.07]$) 与二阶能量 ($\gamma_{(2)} \in [0.01, 0.02]$) 小一个数量级以上。换句话说: 在所检验的特征化下, 跨像素/波段联合非线性的结构性贡献近乎为零——这与第 6 节联合 vs 可加 F1 增益 ≤ 0.022 的结果相互印证 (AND 逻辑门: $\hat{\gamma}$ 低阶能量有限 + 深度增益温和 $\rightarrow$ 二者联合指向交互量级有限)。

(3) 多种子稳健。图 4(c) 的 5 种子箱线图表明 ρ_2 估计的种子间变异很小 (ρ_2 的跨种子标准差 < 0.04 在所有数据集上), 排除单种子偶然性。

(4) 互补特征化一致收敛。表 5 汇总了五种特征化方式在三基准上的数值结果。偏 R^2 型 Sobol 分解与距离协方差检验 (分布自由、 $H_0: \gamma = 0$) 给出与主方法 (Hoeffding) 一致的定性结论: 交互存在 (Fisher 合并 $p < 0.005$ 在所有数据集上拒绝 H_0), 但以二阶为主。互信息分解 (高斯近似) 下 $\gamma_{\text{MI}} \approx 0$ ——联合表征相较独立表征的额外信息近零。集成 Hessian 范数对线性读出模型为零, 与预期一致——它适用于已训练深度模型的事后交互诊断, 而非浅层模型。五种方法从方差归因、信息论、分布自由检验和优化景观四个角度交叉验证, 结论一致。

6.2.3. 对“深度增益来自何处”的回答

上述发现构成一个连贯的叙事:

- 总交互能量 γ 本身并不为零——空谱之间存在不可加的交互结构 (距离协方差检验 H_0 被拒绝);
- 但交互能量的 59% $\sim$ 89% 是二阶 (逐像素谱 $\times$ 空间) 的, 即可被简单的双线性交叉项捕获;
- 高阶交互能量 $\gamma_{(3+)}$ 的绝对值极小 (< 0.008), 远低于一阶可加能量——这意味着在所检验的特征

可加性核查：理论(合成)与真实数据




Figure 3: 可加性核查：理论（合成）与真实数据。(a) 合成验证（理论原生 L^2 度量，交互能量真值 γ 已知）：经验融合增益 Gap 随真 γ 单调上升（相关 ≈ 1.0 、低阶斜率 ≈ 0.95 ，即 $\text{Gap} \approx \gamma$ ），而低阶交叉项代理 $\hat{\gamma}$ 在高阶交互下系统性低估真 γ （高阶仅恢复约 27%）；故 $\hat{\gamma}$ 是交互能量的保守下界。(b) 真实数据（Indian Pines/Pavia U/Salinas, 5 种子）：联合 - 可加宏 F1 之差（散点）、均值与 90% CI（菱形）；阴影为 ± 0.02 等价边界，TOST 下 Salinas 判定等价、IP/PaviaU 功效不足。两者共同支持“融合以可加为主、交互量级很小但不为零”。

Table 4

多阶交互分解结果（FPCA+ 邻域均值特征化， $K_{\text{outer}}=5$ ，5 种子 $\text{mean} \pm \text{std}$ ）：在所检验的特征化下二阶交互能量压倒性主导。 $\rho_2 = \gamma_2 / (\gamma_2 + \gamma_+)$ ；距离协方差检验 $H_0: \gamma = 0$ 在所有数据集上均被拒绝（Fisher 合并 $p < 0.005$ ）。

数据集	ρ_2	γ_2	γ_+	$\Delta F1$	判定
Indian Pines	0.544 ± 0.050	0.0111 ± 0.0000	0.0094 ± 0.0020	-0.0102 ± 0.0000	混合
PaviaU	0.734 ± 0.168	0.0202 ± 0.0052	0.0101 ± 0.0105	$+0.0156 \pm 0.0108$	混合
Salinas	0.799 ± 0.188	1.0470 ± 0.9696	0.1688 ± 0.3696	$+0.0066 \pm 0.0166$	混合
中位	0.734	—	—	—	—

空谱交互能量的多阶分解：二阶项压倒性主导




Figure 4: 多阶交互分解（FPCA+ 邻域均值特征化下）。(a) 四基准上 $\rho_2 = \gamma_{(2)} / \Gamma$ （二阶占比），均值 $\pm$ 跨种子标准差；虚线为 $\rho_2 = 0.85$ 二阶主导阈。(b) $\gamma_{(2)}$ 与 $\gamma_{(3+)}$ 堆积柱状图，高阶贡献始终很小。(c) 5 种子 ρ_2 箱线图，展示种子间稳健性。(d) 四种特征化方式的一致性验证。所有估计均在防泄漏空间分块 CV 折内完成。

Table 5

五种互补特征化方式数值交叉验证 ($K_{\text{outer}}=3$ pilot, 5 种子 mean)。在所检验的特征化下, 所有方法一致指向二阶主导。Hoeffding ρ_2 为二阶交互占比 (主方法); Sobol S_2 为方差归因的二阶分量 ($s \not\propto a$ 时稳健性不如主方法); γ_{MI} 为高斯近似互信息交互 (≈ 0 表示无额外信息); dCor 为距离协方差 ($p < 0.001$ 拒绝 $H_0: \gamma = 0$, 即交互存在但以二阶为主); Γ_{hess} 为期望 Hessian 交叉范数 (线性模型恒为零)。

数据集	Hoeffding ρ_2	Sobol S_2	γ_{MI}	dCor (p)	Γ_{hess}
Indian Pines	.544	.000	.0000	.115 (<.001)	.000
PaviaU	.734	.626	.0000	.113 (<.001)	.000
Salinas	.800	.000	.0000	.113 (<.001)	.000

Sobol S_2 在 Indian Pines 与 Salinas 上 ≈ 0 因 $s \not\propto a$ 下 Sobol 估计的已知局限 (注记 2 中诚实声明), PaviaU 上 $S_2=0.626$ 与 Hoeffding $\rho_2=0.734$ 定性一致。 $\Gamma_{\text{hess}}=0$ 因当前读数为线性 softmax, 该指标用于深度模型的事后诊断留作未来工作。

化下, 深度模型通过层级化表征捕获的高阶交互结构性增益空间非常有限;

- (iv) 这与第 6 节的深度 vs 简单精度-成本 Pareto 形成闭环: 深度优势 (+0.07 ~ 0.15 宏 F1) 的相当部分可以归因于更强的低阶表征质量 (更大感受野的空间聚合、非线性激活), 而非捕获不可约的高阶交互。

重要限定 (诚实声明): 本节的“高阶”指在给定特征化 (FPCA-15 得分 $\times$ 邻域均值, 低阶交叉项) 下、三阶及以上交叉项的方差贡献。这不同于原始 HSI 立方体 $X(u, \lambda)$ 的完整交互结构——后者可能通过不同的特征化通道 (如核方法、端到端学习) 捕获不同的交互模式。合成验证 (图 3(a)) 已确认当前特征化的 $\hat{\gamma}$ 在高阶真交互下仅为保守下界。因此结论的准确表述是: “在所检验的低阶显式特征化下, 高阶交互贡献近零”, 而非“原始立方体中不存在高阶空谱交互”。深度模型的温和但非零的增益 (+0.07 ~ 0.15) 可能正包含了那些被低阶特征化遗漏的高阶成分——但其规模 (≤ 0.15 F1) 并不推翻“以可加为主”的总体判断。将多阶分解扩展到深度隐式表征空间是有价值的未来方向。

6.3. 简单可加模型逼近深度基线 (精度-成本)

图 5 与表 6 给出 5 种子公平训练下的精度-成本对比。深度优势在所有四基准上均统计显著 ($K_{\text{outer}}=5$, 5 种子, Nadeau-Bengio corrected t -test; 经 Holm-Bonferroni 多重比较校正后四个比较仍全部显著, 校正后 $p \leq 0.0095$), 确认深度模型确实优于简单可加。优势量级因数据集而异: Indian Pines (+0.18)、PaviaU (+0.11)、Salinas (+0.06)、WHU-Hi (+0.09) 宏 F1, 反映了空间结构复杂度的差异——Indian Pines 地块细碎、空间上下文最关键, Salinas 光谱本身高度可分、空间信息增益最小。约 270–480 参数的可加函数型模型达最佳深度宏 F1 的 73% ~ 93% ($K_{\text{outer}}=5$), 而深度模型参数多 168 ~ 859 倍。完整四模型对照见表 7。

逐数据集看, 深度优势在 Indian Pines (+0.184) 最大、Salinas (+0.062) 最小, PaviaU (+0.112) 与 WHU-Hi (+0.094) 居中。Indian Pines 地块细碎、类别多 (16 类) 且空间交错复杂, 深度模型的层级化空间上下文建模优势最突出; Salinas 地物规整、光谱本身高度可分, 空间信息的边际增益最小。综合四基准, “精度/参数”前沿由简单可加模型占据, 深度模型在统计上确实更好, 但代价巨大——尤其在 $\hat{\gamma}$ 和 ρ_2 指示交互有限的场景下, 简单模型是资源受限或需可解释部署场景的稳健默认选择。表 7 另给出 LLH-GBID 综合指数 GBIDS ($q_B=q_W=2$ 、

维度等权; GBID 平方分解 $(1 - \bar{u})^2 + C_B^2 + C_W^2$ 及 C_B/C_W 值见补充材料表 S1)。所有模型均通过准入门槛。简单可加 GBIDS 最低 (52.2–87.1), 最佳深度 GBIDS 系统性地更高 (71.1–94.8), 但交互项 (联合 vs 可加) 的 GBIDS 差距几近于零 (≤ 3.2 分)。GBIDS 是 0–100 综合指数得分 (不是准确率), 仅用于同一实验条件下的多模型排序。

6.4. 各类别 F1 详表

表 9 与 10 给出四基准上各类别的 F1 (防泄漏空间分块 CV, 逐行最优加粗, 每数据集分块给出宏 F1/OA/ κ 汇总)。整体规律一致: 简单可加模型在光谱可分的类别上与深度模型持平甚至更优 (如 Indian Pines 的 Wheat、Stone-Steel-Towers、Grass-trees、Salinas 的多数类), 主要差距集中在空间上下文依赖强、样本稀少或光谱高度混淆的类别 (如 Indian Pines 的 Corn-notill、Soybean 系列与 Alfalfa); 新增的空谱 Transformer 在多数类别与 CNN 同档而无系统性优势。这与“空间上下文 (可加) 贡献大、不可加交互贡献小”的总体结论在类别粒度上相互印证。图 6 以热图形式概览: (a) 简单可加模型在四基准上多数类别已达高 F1 (深琥珀), (b) 最佳深度相对简单的逐类增益普遍为小幅正值 (浅红)、个别类别简单反超 (绿), 无大面积深红, 直观印证差距有限。

6.5. 随机划分巨幅夸大绝对精度

图 7 与表 11 量化评测泄漏。随机像素划分下深度模型的 OA 普遍达到 98% ~ 99.8%、呈现“已解决”的假象 (简单模型亦达 86% ~ 99%); 切换防泄漏空间分块后绝对精度大幅回落, 最高夸大达 +7.5 个百分点 ($K_{\text{outer}}=5$) (Indian Pines 3D-CNN, 97.7% $\rightarrow$ 59.1%)。这表明大量基于随机划分的 HSI 报告精度被系统性高估。值得注意: 泄漏同时抬高简单与深度模型, 故“深度相对简单的优势”本身并非泄漏假象, 但其绝对水平不可直接采信。

夸大幅度随场景的空间自相关强度而变。Indian Pines 地块细碎、训练/测试像素空间紧邻, 随机划分把简单模型 OA 由真实的 0.531 抬到 0.857、深度模型由 0.59 ~ 0.64 抬到 0.98 ~ 0.997, 最高夸大 +7.5 个百分点 ($K_{\text{outer}}=5$); WHU-Hi-LongKou 田块大而连续、类别本身易分, 夸大相对温和 (3D-CNN 0.991 $\rightarrow$ 0.998); Pavia University 与 Salinas 居中 (夸大 2 ~ 13 个百分点)。一个关键的方法学推论是: 随机划分把深度模型一律推向 98% ~ 99.8% 的天花板, 从

精度-成本 Pareto: 约数百参数可加模型逼近深度基线




Figure 5: 精度-成本 Pareto: 约 270–480 参数的可加函数型模型（红星）位于深度基线左下方，以 $1/168 \sim 1/859$ 的参数达其 89% ~ 95% 性能。




Figure 6: 各类别 F1 热图（防泄漏空间分块 CV，真实数据）。(a) 简单可加模型逐类 F1；(b) 最佳深度模型相对简单可加的逐类 F1 差（红 = 深度更优、绿 = 简单更优）。白格为该数据集不足该类序号。

Table 6

精度-成本: 宏 F1 / 参数量 / GBIDS ($K_{\text{outer}}=5$ 防泄漏空间分块 CV, 5 种子 mean $\pm$ std)。深度优势统计显著 (Nadeau-Bengio corrected t -test, 全四基准 $p < 0.01$, Cohen's $d = 3.3 \sim 5.6$)。简单可加参数 270–480, CNN2D $\sim 2.3 \times 10^5$, CNN3D $\sim 8 \times 10^4$ 。

数据集	简单可加 F1	最佳深度 F1	$\Delta F1$	简单可加 GBIDS	最佳深度 GBIDS
Indian Pines	.495 $\pm$.000	.679 $\pm$.029 (CNN2D)	+ .184	52.2 $\pm$ 0.0	71.1 $\pm$ 1.8
Pavia U	.806 $\pm$.031	.918 $\pm$.022 (CNN2D)	+ .112	82.1 $\pm$ 2.8	92.9 $\pm$ 1.8
Salinas	.849 $\pm$.038	.911 $\pm$.015 (CNN2D)	+ .062	84.3 $\pm$ 2.7	90.9 $\pm$ 0.6
WHU-Hi	.843 $\pm$.023	.937 $\pm$.009 (CNN3D)	+ .094	87.1 $\pm$ 1.9	94.8 $\pm$ 0.7

Table 7

四模型综合结果表 (LLH-GBID, $q_B=q_W=2$, $K_{\text{outer}}=5$, 5 种子 mean $\pm$ std)。所有模型均通过准入门槛, 最优加粗。

	模型	宏 F1	OA	κ	GBIDS
IP	简单可加	.495 $\pm$.000	.636 $\pm$.000	.572 $\pm$.000	52.2 $\pm$ 0.0
	联合 (+ 交互)	.525 $\pm$.000	.665 $\pm$.000	.607 $\pm$.000	55.2 $\pm$ 0.0
	CNN2D	.679 $\pm$.029	.805 $\pm$.009	.770 $\pm$.010	71.1 $\pm$ 1.8
	CNN3D	.622 $\pm$.021	.769 $\pm$.019	.729 $\pm$.021	66.0 $\pm$ 2.0
PaviaU	简单可加	.806 $\pm$.031	.909 $\pm$.010	.873 $\pm$.015	82.1 $\pm$ 2.8
	联合 (+ 交互)	.821 $\pm$.041	.927 $\pm$.010	.898 $\pm$.014	83.9 $\pm$ 3.5
	CNN2D	.918 $\pm$.022	.973 $\pm$.005	.961 $\pm$.006	92.9 $\pm$ 1.8
	CNN3D	.898 $\pm$.032	.955 $\pm$.005	.936 $\pm$.006	90.6 $\pm$ 2.2
Salinas	简单可加	.849 $\pm$.038	.881 $\pm$.018	.861 $\pm$.018	84.3 $\pm$ 2.7
	联合 (+ 交互)	.847 $\pm$.036	.885 $\pm$.024	.865 $\pm$.027	84.5 $\pm$ 2.8
	CNN2D	.911 $\pm$.015	.936 $\pm$.021	.923 $\pm$.025	90.9 $\pm$ 0.6
	CNN3D	.894 $\pm$.031	.910 $\pm$.030	.894 $\pm$.034	88.6 $\pm$ 3.0
WHU	简单可加	.843 $\pm$.023	.972 $\pm$.005	.961 $\pm$.008	87.1 $\pm$ 1.9
	联合 (+ 交互)	.845 $\pm$.020	.973 $\pm$.005	.963 $\pm$.007	87.4 $\pm$ 1.6
	CNN2D	.914 $\pm$.035	.988 $\pm$.003	.984 $\pm$.004	93.0 $\pm$ 2.8
	CNN3D	.937 $\pm$.009	.989 $\pm$.002	.985 $\pm$.002	94.8 $\pm$ 0.7

$K_{\text{outer}}=5$ (8×8 空间分块), 5 预注册种子。 $L_{F1}=L_{OA}=1/K$, $L_{\kappa}=0$ 。GBID 分解 $(1-\bar{u})^2 + C_B^2 + C_W^2$ 见补充材料。

而压缩了模型间的真实差距——在有泄漏协议下, 约 270–480 参数的简单模型与上十万参数的深度模型差距被大幅压缩, 二者优劣难以区分。这既解释了文献中“简单基线也很强”的部分假象, 也再次说明: HSI 精度必须在防泄漏协议下报告, 否则绝对值与排序均不可信。

6.6. 跨队列迁移的二分律与证书

迁移分析使用 7 个带队列结构的农业高光谱数据集 (编号 001/006/012/013/018/019/029, 涵盖可见-近红外光谱与糖度、干物质、叶绿素、氮、含水率、花青素等连续性状; 队列由物种/品种、采集设备、年份、地点或物候定义, 详见补充数据卡), 共构成 21 个 (数据集 $\times$ 性状 $\times$ 队列) 单元, 逐单元落差见表 12。落差以 in-cohort 留出与留一队列 (LOCO) 之差度量。图 8 显示总体二

分: 跨物种/基因型迁移落差中位 0.495 (自助 95% CI [0.149, 0.620], $B=10^4$), 而同物种跨设备/年份/地点/物候中位仅 0.043 (CI [0.014, 0.075]) ——两组置信区间互不重叠。该二分统计显著: 组标签置换检验 ($B=10^4$) 下中位差 0.452 的 $p = 9 \times 10^{-4}$, Mann-Whitney U 检验 $p = 2.6 \times 10^{-4}$, 效应量 Cliff's $\delta = 0.88$ (大)。聚类稳健复核: 上述单元级检验未校正伪重复 (如 029 棉花独占同物种组 5/14 单元、018 横跨两组), 故我们另以数据集为聚类单位复核——先按 (数据集 $\times$ 队列类型) 聚合再比较, 跨/同物种中位差仍达 0.337; 重采样数据集 (而非单元, $n_{\text{cluster}}=7$) 的聚类自助给出中位差 95% CI [0.04, 0.67], 仍排除 0 但下界已逼近 0, 诚实反映了仅 7 个数据集量级下的较宽不确定度。二分非绝对, 亦有例外 (如 019·糖跨品种落差仅 0.088、018·含水率跨物候落差达 0.472), 提示性状-队列组合而非物种界限

Table 8

LLH-GBID 稳健性分析总表。排名完全稳定于 q /权重/基准变化 ($\tau \geq 0.67$), 深度模型始终最优。

稳健性维度	Indian Pines	PaviaU	Salinas	WHU-Hi
q 敏感性 (τ)	1.00	1.00	1.00	1.00
权重敏感性 (最大排名移位)	0	0	1	0
基准敏感性 (τ)	1.00	1.00	1.00	1.00
$\rho(OA, \kappa)$	.998	.994	.992	.994
相关性折扣 (τ)	.667	.667	.667	1.00

τ 为 Kendall 等级相关系数 (vs 主分析 $q=(2, 2)$)。 q 敏感性为四种配置 $\{(3, 2), (2, 3), (3, 3)\}$ 的最小 τ 。权重敏感性: $W_{\text{整体分类}} \in [0.3, 0.7]$ 扫描。基准敏感性: 理论无技能 vs 候选集最差值。相关性折扣: $v_{j|d} \propto 1/(1 + \bar{\rho}_j)$ 。全部 $K_{\text{outer}}=5$, 5 种子。

Table 9

各类别 F1 (Indian Pines 与 Pavia University; 防泄漏空间分块 CV, 逐行最优加粗, 分块末给出宏 F1/OA/ κ)。

类别	简单可加	RF	2D-CNN	3D-CNN	Transformer
<i>Indian Pines</i>					
Alfalfa	0.741	0.761	0.757	0.871	0.857
Corn-notill	0.437	0.481	0.594	0.550	0.448
Corn-mintill	0.324	0.175	0.381	0.172	0.259
Corn	0.000	0.000	0.000	0.000	0.000
Grass-pasture	0.283	0.350	0.185	0.240	0.296
Grass-trees	0.902	0.938	0.858	0.905	0.818
Grass-pasture-mowed	0.000	0.000	0.000	0.000	0.000
Hay-windrowed	0.860	0.925	0.917	0.927	0.957
Oats	0.000	0.000	0.000	0.000	0.000
Soybean-notill	0.409	0.563	0.671	0.550	0.564
Soybean-mintill	0.513	0.574	0.642	0.603	0.603
Soybean-clean	0.256	0.260	0.577	0.368	0.274
Wheat	0.983	0.998	0.993	0.974	0.951
Woods	0.760	0.757	0.819	0.816	0.763
Bldg-Grass-Trees	0.347	0.392	0.349	0.518	0.321
Stone-Steel-Towers	0.979	0.989	0.952	0.944	0.817
宏 F1	0.487	0.510	0.543	0.527	0.496
OA	0.531	0.580	0.637	0.591	0.569
κ	0.461	0.510	0.585	0.538	0.505
<i>Pavia University</i>					
Asphalt	0.899	0.919	0.956	0.960	0.932
Meadows	0.935	0.984	0.992	0.988	0.976
Gravel	0.768	0.669	0.912	0.883	0.780
Trees	0.917	0.961	0.967	0.973	0.915
Painted-metal	0.948	1.000	0.999	1.000	1.000
Bare-Soil	0.765	0.957	0.971	0.954	0.933
Bitumen	0.647	0.593	0.831	0.943	0.786
Bricks	0.805	0.819	0.912	0.933	0.855
Shadows	0.991	1.000	0.983	0.939	0.962
宏 F1	0.853	0.878	0.947	0.953	0.904
OA	0.884	0.933	0.967	0.967	0.935
κ	0.846	0.910	0.956	0.956	0.914

本身才是根因。命题 4 的可计算代理（仅用源队列拟合方向、不接触目标标签）在控制队列数后与落差显著偏相关 (0.43 ~ 0.56)，可作部署前“该校准能否跨场景迁移”的先验排序信号（非精确预测）。

6.7. 消融实验

表 13 对三个设计轴做消融 (WHU-Hi 示例, 防泄漏 CV): (a) 空间上下文 (谱-only $\rightarrow$ 谱 + 空间) 增益显著 (+0.062); (b) 低阶显式交互项 (可加 $\rightarrow$ + 交互) 增益 ≈ 0 (+0.001); (c) 模型复杂度 (简单 $\rightarrow$ 深度) 温和提升 +0.058, 但需约 $859 \times$ 参数。三者表明: 在当前特征化方式下, 增益来自可加的空间上下文与 (代价高昂的) 深度复杂度, 而低阶显式空谱交叉项几乎不贡献——这正是本文核心经验发现 (不声称对任何特征化或数据普适)。

6.8. 防泄漏协议的边界泄漏量化

为量化 6×6 空间分块协议中块边界残存泄漏的规模, 我们在标准无缓冲 CV 基础上增加缓冲带 (剔除与测试块相邻的 1 或 2 块宽度的训练样本), 重新评估简

单可加 vs CNN2D 的宏 F1 差距 (5 种子, 每种子含 3 种缓冲宽度扫描)。同时计算 Brier score (严格真分数) 以弥合理论 L^2 度量与分类 F1 之间的间隙 (注 1)。

结果 (表 14) 显示: 缓冲带使深度优势系统性地缩减。以 Indian Pines 为例, 无缓冲时 CNN2D 优势为 +0.109 (5 种子均值), 加 1 块缓冲后降至 +0.024 (降幅 78%); Pavia University 上从 +0.123 降至 +0.037 (70%); Salinas 上从 +0.055 降至 +0.025 (55%); WHU-Hi-LongKou 降幅相对温和 (+0.116 $\rightarrow$ +0.100), 可能因其田块大而连续、 6×6 分块已自然形成较大空间间隔。Brier score 在所有缓冲宽度下 CNN2D 均优于简单可加 (Δ Brier 为负), 表明深度优势在严格真分数度量下真实存在, 但部分幅度被边界泄漏夸大。

缓冲带同时大幅减少有效训练样本 (简单可加宏 F1 在缓冲 =1 时骤降), 因此缓冲 =1 的 CNN 增益更多反映小样本下的相对优势而非标准训练集下的表现。缓冲 =2 时, 部分数据集上训练样本进一步减少但简单 F1 有所回升 (因剔除模式导致剩余样本的类别构成改变), CNN 增益亦有所波动。综合而言: 边界泄漏真实存在且可量化, 但方向性结论稳健——无论是否加缓

Table 10

各类别 F1 (Salinas 与 WHU-Hi-LongKou; 防泄漏空间分块 CV, 逐行最优加粗, 分块末给出宏 F1/OA/ κ)。

类别	简单可加	RF	2D-CNN	3D-CNN	Transformer
<i>Salinas</i>					
Brocoli-1	1.000	0.998	1.000	1.000	0.973
Brocoli-2	0.995	0.999	1.000	1.000	1.000
Fallow	0.963	0.930	0.968	0.977	0.944
Fallow-rough-plow	0.976	0.981	0.979	0.989	0.916
Fallow-smooth	0.960	0.990	0.982	0.995	0.960
Stubble	0.995	1.000	1.000	1.000	0.998
Celery	0.820	0.887	0.986	0.918	0.824
Grapes-untrained	0.682	0.758	0.783	0.745	0.660
Soil-vinyard	0.983	0.993	0.994	0.991	0.991
Corn-senesced	0.880	0.916	0.946	0.949	0.902
Lettuce-4wk	0.879	0.863	0.937	0.947	0.927
Lettuce-5wk	0.936	0.993	0.977	1.000	0.966
Lettuce-6wk	0.948	0.988	0.940	1.000	0.962
Lettuce-7wk	0.948	0.987	0.973	0.996	0.969
Vinyard-untrained	0.548	0.713	0.659	0.705	0.671
Vinyard-trellis	0.000	0.000	0.000	0.000	0.000
宏 F1	0.845	0.875	0.883	0.888	0.854
OA	0.820	0.871	0.874	0.874	0.836
κ	0.799	0.856	0.860	0.859	0.818
<i>WHU-Hi-LongKou</i>					
Corn	0.999	0.996	0.999	0.998	0.997
Cotton	0.791	0.789	0.985	0.970	0.945
Sesame	0.960	0.950	0.965	0.971	0.916
Broad-leaf-soybean	0.980	0.972	0.995	0.994	0.988
Narrow-leaf-soybean	0.697	0.796	0.956	0.936	0.908
Rice	0.992	0.997	0.999	1.000	0.999
Water	0.999	1.000	1.000	1.000	1.000
Roads-houses	0.950	0.937	0.959	0.945	0.910
Mixed-weed	0.909	0.954	0.957	0.934	0.916
宏 F1	0.920	0.932	0.979	0.972	0.953
OA	0.974	0.975	0.994	0.991	0.985
κ	0.966	0.966	0.992	0.988	0.981

Table 11

评测泄漏量化: 随机划分 vs 防泄漏空间分块的 OA。

数据集	随机划分 (有泄漏) OA			防泄漏空间分块 OA		
	简单	2D-CNN	3D-CNN	简单	2D-CNN	3D-CNN
Indian Pines	0.857	0.997	0.977	0.531	0.637	0.591
Pavia University	0.975	0.996	0.984	0.884	0.967	0.967
Salinas	0.945	0.989	0.996	0.820	0.874	0.874
WHU-Hi-LongKou	0.990	0.998	0.998	0.974	0.994	0.991

冲, CNN 均优于简单可加, 且优势量级在缓冲修正后仍为温和 (≤ 0.10), 不改变主体结论。

6.9. 协议敏感性与先验决策图

评测协议是结论稳健性的首要敏感因素: 第 5.2 节全部结论均在防泄漏空间分块 CV 下成立; 切换随机划分会把绝对精度整体抬高 0.4 ~ 38.6 个百分点 (随场景空间自相关强度而异) 并改变排序解读 (随机划分下简单模型亦达 86% ~ 99%, 掩盖模型间差异)。我们进一步对简单可加模型逐一扫描三个关键超参 (FPCA

维数 K 、邻域窗 w 、空间分块粒度), 结果见表 15。这里需诚实说明两点。第一, 表中每段扫描独立对 8000 像素重抽样评估, 故同一基线配置 (下划线) 在三段中的取值本身略有出入 (IP 在 $K/w/$ 粒度三段分别为 0.49/0.40/0.48), 反映约 ± 0.04 的子样本估计噪声; 各列扫描极差 (0.18 ~ 0.24) 因而是超参效应与抽样噪声的叠加, 不应全部归为超参敏感性。第二, 扣除该噪声后, PaviaU 与 Salinas 在推荐范围 ($K \in [10, 20]$ 、 $w \in [7, 13]$ 、粒度 ≥ 6) 内对超参不敏感、稳定保持在

Functional Identifiability of Spatial-Spectral Fusion




Figure 7: 评测泄漏量化：随机划分（实心）相对防泄漏空间分块（空心）系统性夸大 OA，最高达 38.6 个百分点。




Figure 8: 跨队列迁移二分：跨物种/基因型崩塌（中位落差 0.50）vs 同物种跨仪器/年份/地点稳健（0.04）。点为 21 个真实落差单元，粗横线为各组中位；空心圈标注横跨阈值的反例（019- 糖 0.088、018- 含水率 0.472，提示性状-队列组合为根因）；右侧标注以数据集为聚类单位（消伪重复）的中位差自助 95% CI [0.04, 0.67]。

与深度基线可比的区间；而最难的 Indian Pines 兼具更大的超参敏感性与抽样方差，其竞争力对分块粒度尤为敏感——粒度由 6 降到 4 时宏 F1 由 0.48 跌到 0.29，过粗的空间分块会显著削弱性能。总体而言，主结论（可加性主导、简单逼近深度）在推荐超参范围内未见反转，但简单模型的竞争力依赖合理而非苛刻的配置，应避免极端取值（尤其过粗分块）。综合 γ （是否值得融合）与 Δ_{map} （能否迁移），图 9 给出 $\gamma \times \Delta$ 先验决

策图：低 γ 低 Δ 用简单可加模型且可迁移；高 Δ 需逐队列重标定；仅当 γ 显著大时才得上复杂融合。

6.10. 复杂度与可扩展性

简单可加函数型模型的训练为 FPCA ($\mathcal{O}(n|A|K)$), n 为像素数、 $K=15$ 加邻域均值滤波 ($\mathcal{O}(nw^2K)$), w 为窗宽) 与一个 ≤ 480 参数的线性读出，单机 CPU 即可在秒级完成，推理为单次矩阵乘，天然适合边缘/实时部署；其参数量比本文深度基线低 168 ~ 859 倍 (表 7)，显


图 F6 $\gamma \times \Delta$ 先验决策图 (示意 + 实测边际投影)

Figure 9: $\gamma \times \Delta$ 先验决策图 (示意): 依交互能量 γ 与映射漂移 Δ_{map} 在训练/部署前判定“是否融合、能否迁移”; 界限阈值依任务标定。

存占用与能耗相应大幅降低。深度空谱模型的卷积前向为 $\mathcal{O}(nw^2Kc^2d)$ (c 为通道数、 d 为层数), 训练需 GPU。式 (2) 的联合估计器经谱向 FFT 与稀疏图-Laplacian 求解, 单步 $\mathcal{O}(n|\Lambda|\log|\Lambda| + n \cdot \text{nnz}(L))$, 复杂度随像素数线性、随波段近线性。需要说明: 式 (2) 的空间正则联合估计器在本文中仅作理论复杂度分析, 正文实验的“联合”模型采用可加特征加低阶交叉项 (第 5.5 节); 式 (2) 的大场景 wall-clock 与收敛曲线实测留作未来工作。综合图 5 的精度-成本前沿: 在 $\hat{\gamma}$ 小的任务上, 简单可加模型在“精度/参数”与“精度/能耗”两个效率维度上均位于前沿, 是资源受限或需可解释部署场景的稳健默认选择。

6.11. 负控与数据完整性

为排除“伪信号”与流水线泄漏, 我们在简单可加模型上做三项负控 (防泄漏空间分块 CV; 为控成本在 6000 像素子样本上运行, 故绝对 F1 与表 7 略有出入, 此处关注相对关系), 结果见表 16。(i) 标签置换: 打散训练标签重训 300 次, 真实宏 F1 远高于置换零分布 (均值 0.03 ~ 0.07), 300 次中无一超过真实值 ($p \leq 0.003$), 排除“模型靠记忆标签取胜”; (ii) 随机特征: 以同形状高斯噪声替换输入、保留标签, 宏 F1 跌至 0.01 ~ 0.07 (近随机), 确认模型确实利用了真实空谱信号而非预处理副作用; (iii) ID 探针: 仅以像素归一化坐标为特征——在防泄漏空间分块下宏 F1 低 (0.10 ~ 0.41, 测试块坐标未见过、无法泛化), 而切到随机划分后显著抬升 (Salinas 0.405 $\rightarrow$ 0.599, Indian Pines 0.155 $\rightarrow$ 0.230), 独立印证了随机划分引入的空间泄漏。三项一致表明本文结果并非伪信号, 并再次佐证评测泄漏的真实存在。

下采样不破坏空间结构、退化类不虚增差距: 为回应“按类配额下采样 ($\leq 8000 \sim 9000$ 像素) 是否削弱空间自相关、从而与防泄漏主张矛盾”的疑虑, 我们量化了下采样前后的标签场空间自相关 (逐类 one-vs-rest Moran's I 按类频率加权): 三基准全图 Moran's I = 0.998 ~ 1.000, 下采样后仍为 0.955 ~ 0.988 (每类置换 z 值最小 145.9, 全部显著为正), 强空间自相关结构完整保留——防泄漏空间分块在下采样后依然必要且有效。此外, 对“多个类别全模型 F1=0 (如 Indian Pines 的 Corn/Grass-pasture-mowed/Oats, Salinas 的 Vinyard-trellis) 是否系下采样伪迹、并人为压缩模型差距”的质疑: 这些类在全图本就极稀少 (20 ~ 237 像素, 下采样未削减) 或与近缘类谱高度混淆, 是真实的极难类而非抽样产物; 剔除它们后简单可加与最佳深度的宏 F1 同步抬升、而二者差距几乎不变 (如 Indian Pines +0.056 $\rightarrow$ +0.069, Salinas +0.044 $\rightarrow$ +0.047), 说明 0 类对两类模型等量拉低、并未虚增“简单逼近深度”的结论。

7. 讨论

综合全部实验, 在所检验的四个基准数据集与 FPCA+ 邻域均值的特征化方式下, 得到四项一致发现: (1) 空谱交互能量由二阶 (谱 $\times$ 空间逐像素) 项压倒性主导 ($\rho_2 = 0.54 \sim 0.80$), 高阶贡献始终极小 ($\gamma_{(3+)} \leq 0.008$), 四种互补特征化 (Hoeffding/Sobol-R²/MI/dCor) 一致验证该结论; (2) 可加空间上下文贡献了空谱融合增益的主要部分——低阶显式交叉项的额外收益极小 (5 种子宏 F1 增益 ≤ 0.022 , 两

Table 12

21 个跨队列单元的泛化落差 (in-cohort – 留一队列), 来自带队列结构的农业/遥感 HSI 数据集, 按宏类分组。跨物种/基因型一致崩塌, 同物种跨设备/年份/地点/物候基本稳健。

单元 (数据集 · 性状)	队列类型	落差
跨物种/基因型 (中位 0.495)		
018· 叶绿素	作物	0.528
018· 氮	作物	0.620
018· 重量	作物	0.374
018· 含水率	作物	0.149
006· 维生素 C	品种	0.701
013· 花青素	品种	0.495
019· 糖	品种	0.088
同物种 (设备/年份/地点/物候, 中位 0.043)		
018· 含水率	物候	0.472
001· 糖	产地	0.266
001· 糖	年份	0.098
012· 干物质	设备	0.081
012· 糖	年份	0.060
018· 氮	物候	0.052
012· 糖	设备	0.047
012· 干物质	年份	0.039
018· 叶绿素	物候	0.035
029· 节数	地点	0.027
029· 冠层覆盖	地点	0.005
029· 叶绿素	地点	0.000
029· LAI	地点	-0.019
029· 株高	地点	-0.027

Table 13

消融 (WHU-Hi-LongKou, 宏 F1, 防泄漏 CV)。

配置 (逐步增加)	宏 F1	增量 (来源)
谱-only	0.858	—
+ 空间上下文	0.920	+0.062 (空间, 大)
+ 空谱交互	0.921	+0.001 (交互, ≈ 0)
深度基线 2D-CNN	0.979	+0.058 (复杂度, $859 \times$ 参数)

数据集上联合反而略低于可加), 能表征高阶交互的深度模型额外增益因数据集而异 (+0.06 ~ +0.18 宏 F1, $K_{\text{outer}}=5$) 且统计显著 (Nadeau-Bengio t -test, $p < 0.01$) ——发现 (1) 的理论分析从阶次结构上解释了发现 (2): 高阶交互能量上限即为深度模型结构性增益的上限, 二者在四基准上均受限; (3) 约 270–480 参数的可加模型以 $1/168 \sim 1/859$ 的参数达深度最优宏 F1 的 75% ~ 93%; (4) 随机划分将绝对精度夸大最高 +7.5 个百分点 ($K_{\text{outer}}=5$), 且压缩模型间真实差异。需要强调: 发现 (1) 是在特定特征化与评测协议下的经验观察, 不等于“HSI 空谱交互天然弱”——不同特征化方式 (如全波段核交互、深度隐式交互) 可能揭示更强的交互信号。本文的核心贡献不在于宣称普遍规律, 而在于提供两个可先验计算的诊断量 ($\hat{\gamma}$ 和 Δ), 使研究者能在自身数据上做出“是否需要复杂融合、能否跨场景迁移”的量化判断。这与“简单模型在某些数据类型上仍可媲美深度模型”的近期发现 [44] 一致。

深度优势的来源: 更强的空间上下文, 而非不可加交互。一个自然的问题是: 既然低阶显式交互增益近

Table 14

缓冲带对 CNN2D 优势的影响 (5 种子均值, 防泄漏空间分块 CV)。缓冲 =0 为标准协议; 缓冲 =1/2 剔除与测试块相邻的 1/2 块宽度训练样本。Brier score 越低越好。

数据集	缓冲	$\Delta F1$	Brier _简	Brier _{CNN}
Indian Pines	0	+ .109	.048	.039
	1	+ .024	.092	.087
	2	+ .106	.055	.046
Pavia U	0	+ .123	.027	.013
	1	+ .037	.115	.099
	2	+ .104	.040	.027
Salinas	0	+ .055	.014	.011
	1	+ .025	.091	.088
	2	+ .036	.029	.026
WHU-Hi	0	+ .116	.006	.002
	1	+ .100	.051	.040
	2	+ .064	.045	.042

Table 15

简单可加模型的超参灵敏度 (宏 F1, 防泄漏空间分块 CV, 8000 像素子样本)。逐一扫描 FPCA 维数 K 、邻域窗 w 、分块粒度, 其余固定于基线 ($K=15, w=9$, 粒度=6) (下划线)。末行为各列扫描极差 (max–min)。

超参	取值	IP	PaviaU	Salinas
K	5	0.347	0.701	0.807
	10	0.415	0.805	0.889
	<u>15</u>	<u>0.489</u>	<u>0.781</u>	<u>0.846</u>
	20	0.356	0.772	0.868
	30	0.467	0.726	0.953
w	5	0.439	0.763	0.906
	7	0.408	0.812	0.901
	<u>9</u>	<u>0.404</u>	<u>0.831</u>	<u>0.930</u>
	11	0.493	0.789	0.941
	13	0.528	0.768	0.930
粒度	4	0.292	0.662	0.767
	<u>6</u>	<u>0.483</u>	<u>0.812</u>	<u>0.843</u>
	8	0.448	0.843	0.940
扫描极差		0.236	0.181	0.186

乎为零, 为何深度模型仍在所有基准上显著优于简单可加? 消融实验 (表 13) 提供了线索: 空间上下文的增益 (+0.062) 远大于交互项 (+0.001), 而深度模型的额外提升 (+0.058) 与空间上下文的增益量级相当。这表明深度模型的优势主要来自其更强的可加空间上下文建模能力 (更大的感受野、层次化特征、端到端优化), 而非对不可加空谱交互的捕获。换言之, 在本任务上, 深度 CNN 本质上是一个更强大的空间上下文提取器, 而非空谱交互建模器。这一解释与表 7 中注意力模型 (SE/CBAM) 无系统性优势的观察一致——若交互是关键, 注意力机制理应带来额外增益; 但实际并未发生。

对实践的启示: (i) 在上复杂空谱融合网络前, 先估计 $\hat{\gamma}$ 作为筛查信号: 若小且深度基线增益亦温和, 则约 270–480 参数的可加函数型模型即可逼近最优, 且更易

Table 16

负控与数据完整性（简单可加模型，防泄漏空间分块 CV，6000 像素子样本）。真实宏 F1 远超标签置换零分布；随机特征近随机；ID 探针在随机划分下被抬高，佐证空间泄漏。

数据集	真实宏 F1	置换零分布 (均值)	置换 p	随机特征 F1	ID 探针 (空间分块)	ID 探针 (随机划分)
Indian Pines	0.470	0.032	≤ 0.003	0.023	0.155	0.230
Pavia University	0.859	0.068	≤ 0.003	0.067	0.104	0.116
Salinas	0.889	0.032	≤ 0.003	0.011	0.405	0.599

解释、更省算力；(ii) 报告精度时必须采用防泄漏空间划分，否则绝对数不可比、亦不可信；(iii) 面对新仪器/新地点/新物候，先算映射漂移证书判定是否需重标定。

局限：(i) 命题下界骨架属已知理论（ANOVA 分解与后验漂移），本文新意在 HSI 实例化与诊断化；(ii) 评测局限于像素级分类四基准，深度基线涵盖 2D/3D-CNN 与空谱 Transformer——近期状态空间模型（SpectralMamba [17]、MambaHSI [18]）、图卷积（GCN）与光谱遥感基础模型（SpectralGPT [20]）未纳入实测对比；但本文论点是“在 $\hat{\gamma}$ 小的任务上简单可加已逼近表征力更强的联合模型”，更强架构若仍受限于小交互能量预期不改变定性结论，此外推仍需验证；向连续目标回归与更大规模数据的外推亦有待检验；(iii) 简单与深度模型的宏 F1 差距虽温和（+0.06 ~ +0.18 ($K_{\text{outer}}=5$ ））但统计显著（Nadeau-Bengio t -test，全四基准 $p < 0.01$ ，Cohen's $d = 3.3 \sim 5.6$ ），本文主张按 γ 与漂移先验决策以权衡精度与成本，而非否定深度方法。(iv) **LLH-GBID** 局限性：GBIDS 是条件相对评价指标，依赖指标体系、权重、基准值与 (q_B, q_W) 参数设定，不构成唯一真理排序。本文仅使用效益型线性效用、维度等权、理论无技能基准与 ($q_B=q_W=2$) 的主分析配置；不同权重或基准设定下排序可能变化（敏感性分析见表 8）。

对结果有效性的威胁：（外部有效性）本文结论建立在像素级地物/作物分类与农业 HSI 队列数据上；对连续生化指标回归、时序 HSI 以及更大规模场景的外推需进一步验证。（构造有效性）交互能量 $\hat{\gamma}$ 以低阶谱 $\times$ 空间交叉项对可加残差的可解释方差占比估计；合成验证（图 3(a)）证实它在高阶交互下系统性低估真 γ （中位仅恢复约 27%），故 $\hat{\gamma}$ 应理解为交互能量的保守下界而非无偏估计——仅凭“ $\hat{\gamma}$ 小”不能断言交互为零，需辅能以表征高阶交互的深度模型增益亦小作为独立佐证。更深层的局限是：本文的“交互”操作化为 FPCA 得分 $\times$ 邻域均值的低阶交叉项；原始立方体中可能通过其他通道（如非 FPCA 主成分的空间分布、波段间非线性联合统计）存在本文特征化未捕获的空谱交互。更富表达力的交互参数化（核方法、深度交互层、全波段交叉）下交互能量的精确刻画仍是开放问题。（内部有效性）防泄漏评测以 6×6 空间留块实现；第 6.8 节的缓冲带敏感性分析量化了块边界残存泄漏：加 1 块缓冲后 CNN2D 优势系统性缩减（Indian Pines 降 78%、PaviaU 降 70%、Salinas 降 55%），表明部分深度增益被边界泄漏夸大，但缓冲修正后深度仍优于简单可加且优势量级温和（ ≤ 0.10 ），不改变方向性结论。（统计-算力权衡）深度模型精度-成本对比已升级至 5 种子 mean $\pm$ std + Nadeau-Bengio 配对 t 检验

($p < 0.01$ ，Cohen's $d = 3.3 \sim 5.6$)；四个数据集的比较经 Holm-Bonferroni 多重比较校正后仍全部显著（校正后 $p \leq 0.0095$ ），已控制多重比较，深度优势的统计显著性现已建立。（统计结论有效性）迁移二分律已由置换检验（中位差 $p = 9 \times 10^{-4}$ ）、Mann-Whitney 检验（ $p = 2.6 \times 10^{-4}$ ）、自助 95% 置信区间（两组互不重叠）与 Cliff's $\delta = 0.88$ 共同支撑（第 6.6 节）；但迁移证书与落差的偏相关基于 21 个单元、样本量有限，跨更多数据集的外推仍需进一步验证。

未来工作：四个方向值得推进：(i) 在更丰富的交互参数化下（全波段核交互、深度隐式交互层）重新评估 γ ，检验当前 FPCA 特征化是否遗漏了重要交互结构；(ii) 把可加 $\oplus$ 交互分解推广到连续目标的函数型回归与多指标联合预测，检验低阶显式交互收益有限是否跨任务类型成立；(iii) 为 γ 与 Δ_{map} 建立带置信区间的可计算估计与显著性检验，使先验筛查具备统计保证；(iv) 将映射漂移证书与按队列的自适应重标定结合，形成“先验判定 $\rightarrow$ 条件重标定”的部署流水线，并在跨传感器、跨年份的真实业务场景中量化其降低标注与重训成本的效益。

广义影响：本文的方法学含义超出 HSI：任何“连续信号 $\times$ 离散结构”的多模态融合（如时序 $\times$ 传感器、光谱 $\times$ 形貌、文本 $\times$ 图结构）都可套用“可加 $\oplus$ 交互”分解与交互能量 γ 的先验诊断，从而在投入复杂联合架构前，以可计算量回答“融合是否值得”。在评测层面，本文对空间泄漏的量化提醒：凡训练/测试样本存在结构相关（空间、时间、层级、系统发育）的领域，随机划分都可能系统性夸大泛化，应采用结构感知的交叉验证 [34, 33]。这两点对可信、可复现、资源高效的科学机器学习具有普适价值。

8. 结论

我们将函数型 ANOVA 分解应用至 HSI 空谱融合，并进一步将其总交互能量 γ 分解为二阶与高阶分量。理论表明：二阶占比 $\rho_2 = \gamma_{(2)}/\gamma$ 越高，浅层可加-双线性模型越逼近理论最优，深度模型的结构性增益空间被 $\gamma_{(3+)}$ 上界控制。四基准防泄漏实证一致验证，在本研究采用的 FPCA+ 邻域均值特征化方式下：(1) 二阶交互压倒性主导（ $\rho_2 = 0.54 \sim 0.80$ ，高阶 ≤ 0.008 ），四种互补特征化交叉验证；(2) 可加空间上下文贡献了融合增益的主要部分，低阶显式空谱交互的额外收益极小（ ≤ 0.022 宏 F1）；(3) 约 270–480 参数的可加模型以远低于深度基线的参数达到其 75% ~ 93% 性能；(4) 随机划分将绝对精度夸大最高 +7.5 个百分点（ $K_{\text{outer}}=5$ ）。两个可先验计算的诊断量（ $\hat{\gamma}$ （含分阶）和 $\hat{\Delta}$ ）为研究者提供了可操作的筛查工具，用以在自身数据上评估融合必要性与跨场景可迁移性。

CRedit authorship contribution statement

李盼林：概念构思，方法学，软件实现，形式化分析，研究实施，可视化，撰写——初稿。李宇畅：软件实现，结果验证，数据管理，撰写——审阅与编辑。冯雨桐：软件实现，结果验证。李龙杰：软件实现，研究实施，数据管理。刘亚：资源提供，研究实施，数据管理。黄华：概念构思，监督指导，经费获取，项目管理，撰写——审阅与编辑。

Declaration of competing interests

作者声明：本文不存在任何可能影响本研究工作的已知竞争性经济利益或个人关系。

Data & Code availability

本文主实验所用四个公开基准：Indian Pines、Pavia University、Salinas 取自 EHU 高光谱遥感场景库 (http://www.ehu.es/ccwintco/index.php/Hyperspectral_Remote_Sensing_Scenes)，WHU-Hi-LongKou 取自武汉大学 RSIDEA 课题组公开数据集；跨队列迁移分析所用 7 个农业光谱数据集（编号 001/006/012/013/018/019/029）除 001（作者单位内部采集，需联系通讯作者）外均为公开数据集，确切来源（Mendeley/Figshare/USDA Ag Data Commons 等）见正文数据卡（表 2）脚注。复现本文全部实验、图表与诊断量计算的源代码及预处理公开数据集已于公开仓库开放获取：<https://github.com/2004lryan/019hsi-fusion-diagnostics>（MIT 许可，含环境锁定文件与 SHA-256 校验）；内部数据集（编号 001）可联系通讯作者按需获取。

Declaration of generative AI and AI-assisted technologies in the manuscript preparation process

在本文撰写过程中，作者使用了 Anthropic 公司的 Claude Opus 4.8 大语言模型，主要用于语言润色与表达改进。使用该工具后，作者已对全部内容进行审阅与编辑，并对本文的科学内容、数据与结论承担全部责任。

Funding

研究受以下基金资助：新疆维吾尔自治区自然科学基金面上项目（编号待补）；2026 年新疆农业大学大学生创新项目（S202610758116、DXSCX2026349、DXSCX2026350）。其中自治区自然科学基金项目编号待下达后据实补全。

A. 命题证明

本附录给出第 4 节命题 1–4 的完整证明。记号沿用第 3–4 节。

A.1. 命题 1（联合表征可识别性）

证明. 记联合分布 $P_{s,a}$ 下的可加函数闭子空间

$$\mathcal{H}_{\text{add}} = \overline{\{g_1(s) + g_2(a) : g_1 \in L^2(P_s), g_2 \in L^2(P_a)\}} \subseteq L^2(P_{s,a}). \quad (9)$$

步骤 1（交互残差唯一）：由 Hilbert 空间投影定理， f^* 到闭子空间 $\mathcal{H}_{\text{add}}$ 的正交投影 $\Pi_{\text{add}} f^*$ 存在且唯一，故

$$C := f^* - \Pi_{\text{add}} f^* \quad \text{唯一确定。} \quad (10)$$

该结论不要求 s, a 独立——HSI 中 s, a 由同一 FPCA 场导出而强相关，但投影几何只依赖联合测度 $P_{s,a}$ 。

步骤 2（可加分裂）：若 $\overline{L^2(s)} \cap \overline{L^2(a)} = \{\text{常数}\}$ （平凡交），则中心化约束 $\mathbb{E}[\phi_s] = \mathbb{E}[\phi_a] = 0$ 唯一确定 $\Pi_{\text{add}} f^* = \phi_s + \phi_a$ 的分裂（相依输入函数型 ANOVA，见 Hooker [28]）；否则 ϕ_s, ϕ_a 至多相差一个公共方向，而 C 与 γ 不受影响。证毕

A.2. 命题 2（融合增益 $\asymp$ 交互能量）

证明. 步骤 1（总体下界）：对任意 $h \in \mathcal{H}_{\text{add}}$ ，由 $f^* = (\phi_s + \phi_a) + C$ 与投影正交性，

$$\inf_{h \in \mathcal{H}_{\text{add}}} \mathbb{E}[(f^* - h)^2] = \mathbb{E}[(C - \Pi_{\text{add}} C)^2] = \gamma, \quad (11)$$

即拼接（可加晚融合）的总体超额风险恰为 γ 。

步骤 2（上界与夹逼）：联合类包含 f^* ，总体超额风险为 0、有限样本下 $\leq \varepsilon_{\text{joint}}(n)$ 。故

$$\text{Gap}_{\text{pop}} = \gamma, \quad \mathbb{E} \text{Gap} \in [\gamma - \varepsilon_{\text{joint}}(n), \gamma + \varepsilon_{\text{add}}(n)]. \quad (12)$$

特别地 $\gamma = 0 \Rightarrow \text{Gap}_{\text{pop}} = 0$ （拼接总体最优）。

步骤 3（函数型率）：当 $C \in W^{\bar{s}, 2}$ （谱-空间张量 Sobolev）、目标协方差迹类且特征值 $\asymp j^{-2r}$ 时，正则化最小二乘的交互估计误差

$$\varepsilon_{\text{joint}}(n) \asymp n^{-\frac{2\bar{s}}{2\bar{s} + d_{\text{eff}}}}, \quad (13)$$

d_{eff} 为协方差谱衰减决定的有效维数；式 (2) 的空间正则降低 d_{eff} 。证毕

A.3. 命题 4（跨队列迁移落差下界与证书）

证明. 步骤 1（双点构造）：取 $\beta^{(0)}$ 为 $\text{conv}\{\beta_c\}$ 中 Σ_{c^*} -最近点、 $\beta^{(1)} = \beta^{(0)} + \Delta_{\text{map}} v$ ， v 为达到下确界的单位残差方向（ $\|v\|_{\Sigma_{c^*}} = 1$ ）。构造两世界 P_0, P_1 ：源队列分布、源映射与目标协变量律 P_c^X 全同，仅目标条件均值取 $\beta^{(b)}$ 。

步骤 2（极小极大下界）：零样本估计器 $\hat{f}$ 不接触目标标签，在两世界为同一随机变量；由中点不等式 $(a - u)^2 + (a - w)^2 \geq \frac{1}{2}(u - w)^2$ 逐点取期望，

$$\max_{b \in \{0, 1\}} \mathbb{E} \text{ER}_{c^*}(\hat{f}; b) \geq \frac{1}{4} \mathbb{E}_{x \sim P_c^X} [\langle \beta^{(1)} - \beta^{(0)}, x \rangle^2] = \frac{1}{4} \Delta_{\text{map}}^2. \quad (14)$$

此为对目标类的极小极大陈述（非对固定 β_{c^*} 的逐点断言）。

步骤 3（证书一致性）：队列内最小二乘 $\hat{\beta}_c \rightarrow_p \beta_c$ （谱隙保证首方向唯一），其两两 Σ -度量不一致性 Δ 是 Δ_{map} 的单调相合估计，故可先验计算。 证毕

References

- [1] Plaza A, Benediktsson J A, Boardman J W, et al. Recent advances in techniques for hyperspectral image processing. *Remote Sensing of Environment*, 2009, 113(S1): S110–S122.
- [2] Ghamisi P, Yokoya N, Li J, et al. Advances in hyperspectral image and signal processing: A comprehensive overview of the state of the art. *IEEE Geoscience and Remote Sensing Magazine*, 2017, 5(4): 37–78.
- [3] Bioucas-Dias J M, Plaza A, Camps-Valls G, et al. Hyperspectral remote sensing data analysis and future challenges. *IEEE Geoscience and Remote Sensing Magazine*, 2013, 1(2): 6–36.
- [4] Camps-Valls G, Tuia D, Bruzzone L, Benediktsson J A. Advances in hyperspectral image classification: Earth monitoring with statistical learning methods. *IEEE Signal Processing Magazine*, 2014, 31(1): 45–54.
- [5] Fauvel M, Tarabalka Y, Benediktsson J A, et al. Advances in spectral-spatial classification of hyperspectral images. *Proceedings of the IEEE*, 2013, 101(3): 652–675.
- [6] Chen Y, Jiang H, Li C, et al. Deep feature extraction and classification of hyperspectral images based on convolutional neural networks. *IEEE TGRS*, 2016, 54(10): 6232–6251.
- [7] Roy S K, Krishna G, Dubey S R, et al. HybridSN: Exploring 3-D-2-D CNN feature hierarchy for hyperspectral image classification. *IEEE GRSL*, 2020, 17(2): 277–281.
- [8] Hong D, Han Z, Yao J, et al. SpectralFormer: Rethinking hyperspectral image classification with transformers. *IEEE TGRS*, 2022, 60: 1–15, Art. no. 5518615.
- [9] Paoletti M E, Haut J M, Plaza J, et al. Deep learning classifiers for hyperspectral imaging: A review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 2019, 158: 279–317.
- [10] Li S, Song W, Fang L, et al. Deep learning for hyperspectral image classification: An overview. *IEEE TGRS*, 2019, 57(9): 6690–6709.
- [11] Hong D, Gao L, Yao J, et al. Graph convolutional networks for hyperspectral image classification. *IEEE TGRS*, 2021, 59(7): 5966–5978.
- [12] Audebert N, Le Saux B, Lefèvre S. Deep learning for classification of hyperspectral data: A comparative review. *IEEE Geoscience and Remote Sensing Magazine*, 2019, 7(2): 159–173.
- [13] Ghamisi P, Maggiori E, Li S, et al. New frontiers in spectral-spatial hyperspectral image classification: The latest advances based on mathematical morphology, Markov random fields, segmentation, sparse representation, and deep learning. *IEEE Geoscience and Remote Sensing Magazine*, 2018, 6(3): 10–43.
- [14] Melgani F, Bruzzone L. Classification of hyperspectral remote sensing images with support vector machines. *IEEE TGRS*, 2004, 42(8): 1778–1790.
- [15] Wold S, Sjöström M, Eriksson L. PLS-regression: a basic tool of chemometrics. *Chemometrics and Intelligent Laboratory Systems*, 2001, 58(2): 109–130.
- [16] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition. In: *CVPR*, 2016: 770–778.
- [17] Yao J, Hong D, Li C, Chanussot J. SpectralMamba: Efficient Mamba for hyperspectral image classification. *arXiv preprint arXiv:2404.08489*, 2024.
- [18] Li Y, Luo Y, Zhang L, Wang Z, Du B. MambaHSI: Spatial-spectral Mamba for hyperspectral image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 2024, 62: 1–16.
- [19] Wang D, Zhang J, Du B, Zhang L, Tao D. DCN-T: Dual context network with transformer for hyperspectral image classification. *IEEE Transactions on Image Processing*, 2023, 32: 2536–2551.
- [20] Hong D, Zhang B, Li X, et al. SpectralGPT: Spectral remote sensing foundation model. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024, 46(8): 5227–5244.
- [21] Roy S K, Deria A, Hong D, Rasti B, Plaza A, Chanussot J. Multimodal fusion transformer for remote sensing image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 2023, 61: 1–20.
- [22] Meyer H, Pebesma E. Machine learning-based global maps of ecological variables and the challenge of assessing them. *Nature Communications*, 2022, 13: 2208.
- [23] Dalla Mura M, Prasad S, Pacifici F, et al. Challenges and opportunities of multimodality and data fusion in remote sensing. *Proceedings of the IEEE*, 2015, 103(9): 1585–1601.
- [24] Gómez-Chova L, Tuia D, Moser G, et al. Multimodal classification of remote sensing images: A review and future directions. *Proceedings of the IEEE*, 2015, 103(9): 1560–1584.
- [25] Ramsay J O, Silverman B W. *Functional Data Analysis*. 2nd ed. New York: Springer, 2005.
- [26] Wang J L, Chiou J M, Müller H G. *Functional data analysis. Annual Review of Statistics and Its Application*, 2016, 3: 257–295.
- [27] Morris J S. *Functional regression. Annual Review of Statistics and Its Application*, 2015, 2: 321–359.
- [28] Hooker G. Generalized functional ANOVA diagnostics for high-dimensional functions of dependent variables. *Journal of Computational and Graphical Statistics*, 2007, 16(3): 709–732.
- [29] Hall P, Horowitz J L. Methodology and convergence rates for functional linear regression. *The Annals of Statistics*, 2007, 35(1): 70–91.
- [30] Cai T T, Yuan M. Minimax and adaptive prediction for functional linear regression. *Journal of the American Statistical Association*, 2012, 107(499): 1201–1216.
- [31] Yuan M, Cai T T. A reproducing kernel Hilbert space approach to functional linear regression. *The Annals of Statistics*, 2010, 38(6): 3412–3444.
- [32] Hughes G F. On the mean accuracy of statistical pattern recognizers. *IEEE Transactions on Information Theory*, 1968, 14(1): 55–63.
- [33] Karasiak N, Dejoux J F, Monteil C, et al. Spatial dependence between training and test sets: another pitfall of classification accuracy assessment in remote sensing. *Machine Learning*, 2022, 111(7): 2715–2740.
- [34] Roberts D R, Bahn V, Ciuti S, et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 2017, 40(8): 913–929.
- [35] Ploton P, Mortier F, Réjou-Méchain M, et al. Spatial validation reveals poor predictive performance of large-scale ecological mapping models. *Nature Communications*, 2020, 11: 4540.
- [36] Kattenborn T, Leitloff J, Schiefer F, et al. Review on convolutional neural networks (CNN) in vegetation remote sensing. *ISPRS Journal of Photogrammetry and Remote Sensing*, 2021, 173: 24–49.
- [37] Kapoor S, Narayanan A. Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 2023, 4(9): 100804.
- [38] Ben-David S, Blitzer J, Crammer K, et al. *A theory of learning from different domains. Machine Learning*, 2010, 79(1–2): 151–175.

- [39] Cai T T, Wei H. Transfer learning for nonparametric classification: Minimax rate and adaptive classifier. *The Annals of Statistics*, 2021, 49(1): 100–128.
- [40] Kpotufe S, Martinet G. Marginal singularity and the benefits of labels in covariate-shift. *The Annals of Statistics*, 2021, 49(6): 3299–3323.
- [41] Sugiyama M, Krauledat M, Müller K R. Covariate shift adaptation by importance weighted cross validation. *Journal of Machine Learning Research*, 2007, 8: 985–1005.
- [42] Quiñero-Candela J, Sugiyama M, Schwaighofer A, Lawrence N D, eds. *Dataset Shift in Machine Learning*. Cambridge, MA: MIT Press, 2009.
- [43] Breiman L. Random forests. *Machine Learning*, 2001, 45(1): 5–32.
- [44] Grinsztajn L, Oyallon E, Varoquaux G. Why do tree-based models still outperform deep learning on typical tabular data? *Advances in Neural Information Processing Systems (Datasets and Benchmarks)*, 2022, 35.
- [45] Baumgardner M F, Biehl L L, Landgrebe D A. 220 band AVIRIS hyperspectral image data set: June 12, 1992 Indian Pine test site 3. *Purdue University Research Repository*, 2015.
- [46] Zhong Y, Hu X, Luo C, Wang X, Zhao J, Zhang L. WHU-Hi: UAV-borne hyperspectral with high spatial resolution (H^2) benchmark datasets and classifier for precise crop identification based on deep convolutional neural network with CRF. *Remote Sensing of Environment*, 2020, 250: 112012.