

分布漂移下表示层泄漏对少样本与跨域评估的系统性高估

李盼林¹, 张庆莉¹, 焦齐太³, 孙佳美¹ & 黄华^{1,2,*}

在分布漂移下评估少样本与跨域泛化,是现代人工智能“先学表示、再在留出类/域上报告性能”范式的普遍环节。我们刻画其中一个隐蔽而系统的缺陷——**表示层评估泄漏**:当表示编码器在包含留出评估域的数据上学习时,测得的少样本精度被系统性高估。我们在线性-高斯最近原型模型下将其形式化,证明该泄漏偏差非负,并给出零成本的原理性修复——令表示学习训练集与评估留出域严格不相交(**折限定协议**)。在自建九域苹果近红外基准与另外五个公开光谱/高光谱数据集(横跨仪器、季节、年份、国别与空间五类漂移)上,以数据集为随机效应的混合效应模型给出稳健为正的总体泄漏($\Delta = 0.132$,六数据集 6/6 为正),表明这是跨模态、跨领域的普遍现象。四编码器分解进一步诚实界定:泄漏主因是**标签感知暴露**($\Delta_{\text{sup}} = +0.084$),纯无标签暴露分量很小($\Delta_{\text{unsup}} = +0.012$,置信区间跨零);泄漏还会在近半评估实例上改变被选出的最优方法。评估泄漏是跨光谱、遥感、医学影像与基因组学的普遍风险;我们主张把折限定与共享协议之差作为少样本与跨域评估的标准报告项——一次低成本、可普遍采纳的评估卫生升级。

1 引言

苹果 (*Malus domestica* Borkh.) 是全球消费量最大的温带水果之一,中国产量占全球供应的 47% 以上 (FAO, 2022)。这一数字背后是可观的产地经济价值差异:新疆富士与山东红富士之间的价差,有时仅凭一纸产地证明即被显著拉开。地理标志定价、食品安全溯源与打击虚假标注看似各有侧重,实则都指向同一问题:如何可靠地判别一颗苹果的产地?传统手段——稳定同位素比值分析、多元素指纹技术与感官评价——各自具备成熟而严谨的分析体系,但依赖专业实验室、检测周期动辄数小时,难以满足批量通关筛查的时效要求 (Danezis, Tsagkaris, Camin, Brusica and Georgiou, 2016)。

近红外 (NIR) 漫反射光谱在此背景下具有独特吸引力:无需消耗品,单次扫描不足一分钟即可得到可直接解读的光谱 (Nicolai, Beullens, Bobelyn, Peirs, Saeys, Theron and Lammertyn, 2007; Walsh, Blasco, Zude-Sasse and Sun, 2020)。其光谱差异来源多元——可溶性固形物、有机酸、多酚、水分等成分综合反映了产地的地球化学背景、气候节律与农事习惯,在高维光谱空间中形成具有一定区分能力的产地相关“指纹”(Cen and He, 2007; Woodcock, Downey, Kelly and O'Donnell, 2007)。需要说明的是,对于来自批发市场的商品苹果,NIR 光谱同时编码了品种、储藏条件、成熟度与供应链处理的综合信息;因此本文所指的“产地溯源”准确地说是“市售批次条件下的产地相关判别”,而非对纯地球化学成分信号的直接检测。偏最小二乘判别分析 (PLS-DA) 是这类任务的经典工具,在受控单年条件下通常可给出令人满意的精度 (Geladi and Kowalski, 1986);随着数据量趋于充裕,支持向量机 (SVM) 与卷积神经网络在部分场景下已开始超越 PLS-DA,持续外推着这一性能边界 (Cortes and Vapnik, 1995; Ekramirad, Khaled, Doyle, Loeb, Donohue, Villanueva and Adediji, 2022)。近年来,NIR/FTIR 光谱结合化学计量学与深度学习已广泛用于茶叶、食用油、大豆等多种农产品的

产地溯源与真伪鉴别 (Liu, Huang, Li, Chen, Cui, Lu, Wang, Li, Xu, Zhong and Ning, 2022; Ye and Meng, 2022; Han, Wang, Xu, Wang, Dou and Lan, 2026),其方法学演进见近期综述 (Walsh, Neupane, Koirala, Li and Anderson, 2023)。

然而,这里存在一个关键障碍:在单年受控实验中表现良好的模型,往往难以迁移到新的采收季。受控实验室数据训练的近红外模型在同年测试集上精度常轻松超过 90%,但在次年部署时,气候、土壤养分与仪器响应均发生漂移,训练分布与部署分布之间的差距随之显现 (Feudale, Woody, Tan, Myles, Brown and Ferre, 2002; Li, Huang, Wang, Liu, He and Fan, 2022a; Pan, Li, Hu, Zhang and Zhao, 2024a)。苹果近红外领域针对这种“跨年泛化”的专项研究其实相当有限:多数研究仍局限于单一年份,跨年性能至多作为附带结果一笔带过。现有校准迁移方法——无论直接标准化 (DS)、分段直接标准化 (PDS) 还是梯度增强重标定——原本均为仪器间迁移设计,且大多要求在部署端准备一批有标签目标样本,而这前提在新季节到来时往往难以满足 (Fearn, 2001)。

小样本学习 (FSL) 为此提供了一条值得认真对待的出路。其底层逻辑——以跨任务的经验积累换取新场景下从少量样本快速泛化的能力——与苹果产地筛查的实际处境高度契合:新季度开始、新产区刚接入供应链时,可获得的有标注参考样本往往寥寥数个 (Snell, Swersky and Zemel, 2017)。原型网络 (Snell et al., 2017) 尤其适合本问题——以支持集均值嵌入表示类别、以最近原型距离完成分类,结构简洁而归纳偏置充分。元学习在高光谱遥感分类中已有若干成功案例 (Yu, Gong, Song, Zhao and Chang, 2022; Hospedales, Antoniou, Micaelli and Storkey, 2022),但系统性地移植到食品近红外领域目前几乎仍属空白:两者的样本异质性来源不同——遥感可借助空间邻域上下文,点光谱食品近红外则受测量几何主导——这一差异尚未得到充分处理。

¹ 新疆农业大学数理学院, 新疆乌鲁木齐 830052, 中国. ² 新疆农业大学数值模拟与数据分析研究中心, 新疆乌鲁木齐 830052, 中国. ³ 新疆农业大学机电工程学院, 新疆乌鲁木齐 830052, 中国. * 通讯作者 (Corresponding author). e-mail: huanghua@xjau.edu.cn

文献中有三个方法论层面的缺口一直悬而未决。其一，尚无一个跨多采收年份、且配有标准化留一年评估协议的公开苹果近红外数据集，导致不同团队的跨年性能数字彼此无从比较。其二，评估泄漏问题更为隐蔽：共享编码器先在含测试折的全量数据上预训练、再用于 LOEO 评估，相当于让裁判在赛前便见过考题，而这一泄漏的量级在现有文献中从未被正式估计。其三，对水果多个表面位置的光谱取均值确有降噪之效，但该收益有多少来自支持侧（改善原型估计）、多少来自查询侧（稳定预测端），二者的非对称性从未被独立拆解。

以上三个问题构成本研究的出发点，对应四项具体贡献。

九域跨年基准数据集。整合并发布首个覆盖三个采收年份（2018、2019、2025）和四个产地（新疆、山东、山西、甘肃）的苹果近红外数据集，包含九个独立采集域共 4,529 条光谱、229 个波段，同时提出标准化、无泄漏的 LOEO-Year 评估协议。

评估泄漏的系统定量刻画。通过共享编码器与折限定编码器协议在同一 α 下的 like-for-like 配对比较，在本数据集条件下证明 $K=5$ 时评估泄漏使 LOEO 宏 F1 相较无泄漏的折限定基准系统性虚高：默认 $\alpha = 0.4$ 口径下 $\Delta = 0.363$ （共享 0.926 对比折限定 0.563），主实验最优 $\alpha = 0$ 口径下 $\Delta = 0.243$ （共享 0.922 对比折限定 0.679），两口径下泄漏均高度显著，确证其源自编码器训练集而非融合权重。据作者所知，尽管数据泄漏与污染的相关形式已被广泛讨论（见表 14 对既有概念的系统区分），分布漂移下少样本元评估中表示学习层的这一特定偏差，此前未被形式化刻画并跨领域系统量化——这正是本文的边界所在，而非泛泛声称“发现泄漏”。更重要的是，我们将该量化从单一数据集提升为跨领域现象：在六个真实测量数据集（三模态、五类漂移轴）上以混合效应统计证明泄漏稳健为正（总体 $\Delta = 0.132$, 95% CI [0.071, 0.192]；数据集级 6/6 为正），并以扩展理论（多类条件性非负、漂移依赖显式下界、原始 MMD 非充分漂移度量的反例）为其提供可证伪的形式化支撑。我们并对泄漏来源做诚实分解：以四编码器 CUDA-formal 实验把泄漏剥离为标签感知分量 $\Delta_{\text{sup}} = +0.084$ [0.023, 0.144] 与纯无监督暴露分量 $\Delta_{\text{unsup}} = +0.012$ [-0.003, 0.028]（掠过 0），据此审慎地将现象精确定位为 *label-aware* 表示层泄漏而不夸大隐蔽无监督分量；并进一步证明泄漏会影响下游方法选择（42% 的单次评估实例改变被选最优方法，整体排序仍正相关），其影响超出精度虚高。

小样本分类器系统对比与探索性变体。在 $K \in \{1, 3, 5, 10, 20, 50\}$ 范围内展开 50 次重复配对实验，对比 SVM、PLS-DA、最近质心、原始 ProtoNet 和探索性变体 ProtoNet-C（源质心融合）；在以年份偏移为主的 LOEO-2018/2019 折中，源质心融合在当前跨年分布差距下不优于折限定 ProtoNet ($\alpha = 0$)，两者的性能交叉点 ($K \approx 3-5$) 划定了以可用支持样本量为轴的方法选择边界。ProtoNet-C 在此作为探索性变体提出，而非本文的核心算法贡献。

面均值增益的非对称分解。基于 2×2 消融设计，将 2025 多面折的面均值增益分解为查询侧 (+0.071) 和支持侧 (+0.019) 两项独立贡献，对现场扫描协议的资源分配具有实践指导意义。

超越苹果：为何广义读者应当关心。本研究的主对象并非苹果，而是评估方法本身。现代人工智能的主流范式是“先在大规模数据上学习表示，再在留出的类/域上报告少样本、长尾、跨域或零样本结果”。只要表示学

习的训练数据与评估留出域不严格隔离，所报告的泛化数字便含本文刻画的乐观偏差（该偏差非负，且我们证明其量级主要由留出域标签的暴露驱动，纯无标签暴露在本文自监督目标下很小）。这一缺陷不同于已被熟知的特征选择泄漏 (Ambroise and McLachlan, 2002)：它发生在表示学习层且专属于分布漂移下的少样本元评估，更为隐蔽——“编码器”看过“目标域”，而评估时只给少量样本，表面上仍像合法的少样本评估。在样本稀缺、跨批次/跨仪器/跨年份漂移常态化的科学测量领域（光谱学、遥感、医学影像、基因组学），此类评估被广泛采用，一旦虚高便会把“看似可跨域部署”的模型推向真实失败，危及科学结论与监管决策 (Kapoor and Narayanan, 2023; Roberts, Driggs, Thorpe et al., 2021; Whalen, Schreiber, Noble and Pollard, 2022; Apicella, Isgrò and Prevete, 2025)。苹果跨年近红外数据将“分布漂移 + 少样本 + 表示学习”三要素干净耦合，构成隔离并量化该泄漏的理想受控台架；而其修复（折限定协议）零成本且对任意“表示 + 最近原型/线性探针”式评估通用。我们进一步在独立公开的 OliveOil 光谱数据上复现该现象，表明它并非苹果特例。

2 相关工作

2.1 近红外光谱用于水果产地溯源

近红外光谱在水果地理产地溯源中的应用已有二十余年积累。早期苹果研究证实，近红外漫反射能捕获足够的成分变异——可溶性糖、苹果酸、绿原酸和矿物结合水——以 PLS-DA 区分产地 (Cen and He, 2007; Nicolai et al., 2007)。Woodcock et al. (2007) 验证了近红外光谱编码地理指纹的可行性，后续对苹果及其他水果的研究在受控单年条件下将判别精度逐步推至 90% 以上 (Walsh et al., 2020)。标准预处理流程——标准正态变量 (SNV) 变换 (Barnes, Dhanoa and Lister, 1989)、Savitzky-Golay 微分 (Savitzky and Golay, 1964) 和乘法散射校正——在抑制光程和粒径变异方面已形成较为稳固的共识，但预处理方法的选择本身仍需针对具体任务审慎评估、避免误伤有效信号 (Mishra, Rutledge, Roger, Wali and Khan, 2021)。当训练数据充足时，SVM 和随机森林在部分场景下可匹敌甚至超越 PLS-DA (Cortes and Vapnik, 1995; Ekramirad et al., 2022)，卷积和注意力机制神经网络 (He, Zhang, Ren and Sun, 2016; Vaswani, Shazeer, Parmar, Uszkoreit, Jones, Gomez, Kaiser and Polosukhin, 2017) 也开始出现在食品近红外应用中 (Mishra and Passos, 2021; Benmouna, García-Mateos, Sabzi, Fernández-Beltrán, Parras-Burgos and Molina-Martínez, 2022)。不过有一点值得留意：绝大多数苹果近红外溯源研究至今仍停留在单一采收年份，跨年性能偶尔附带提及，从未成为研究的正面目标。

2.2 跨年与跨仪器域偏移

校准迁移——将训练于某一仪器或条件的化学计量模型适配到另一仪器或条件的问题——在近红外光谱中有悠久历史 (Feudale et al., 2002)。直接标准化和分段直接标准化仍广泛用于仪器间迁移 (Fearn, 2001)，校准迁移亦扩展至苹果等水果的跨设备与跨季节场景 (Li et al., 2022a)。Liu, Zhao, Zhu, Huang and Guo (2025b) 探索了用于苹果硬度预测的近红外神经迁移学习，证明在小目标集上微调可部分恢复跨仪器性能；Li, Li, Jiang and Liu (2022b) 提出了一种免标准样品的苹果产地判别模型跨仪器校准迁移策略；Pan, Wu, Hu, Li,

Table 1 | 折限定编码器在三个 LOEO 折上的源域验证精度。

LOEO 折	源域	验证精度
2018 留出	2019 + 2025	0.9478
2019 留出	2018 + 2025	0.9411
2025 留出	2018 + 2019	0.9478
三折均值	—	0.9456

Zhang and Zhao (2024b) 则通过多季节数据库更新深度学习苹果成熟度分类模型，探索了跨季节模型鲁棒性问题。然而，这些面向回归的迁移方法假设可获得至少少量带参考测量值的有标签目标样本，这对于新产品批次持续到来的分类任务而言往往不切实际。域适应的理论框架——通过最小化源-目标分布散度来限制目标误差 (Ben-David, Blitzer, Crammer, Kulesza, Pereira and Vaughan, 2010)——在计算机视觉中得到广泛应用 (Ganin, Ustinova, Ajakan, Germain, Larochelle, Laviolette, Marchand and Lempitsky, 2016)，但在食品光谱学中由于高维度和小样本量的独特挑战，尚未得到充分采用。

2.3 元学习与小样本分类

元学习解决的是“学会学习”的问题：通过跨任务分布训练，模型积累归纳偏置，使其能在测试时从少量样本快速适应新场景 (Hospedales et al., 2022)。原型网络 (Snell et al., 2017) 用最简洁的方式实现这一目标——类原型是支持集均值嵌入，分类依赖嵌入空间中的最近原型距离。匹配网络 (Vinyals, Blundell, Lillicrap, Wierstra and Kavukcuoglu, 2016) 和关系网络 (Sung, Yang, Zhang, Xiang, Torr and Hospedales, 2018) 进一步扩展了比较范式，MAML (Finn, Abbeel and Levine, 2017) 则从梯度适应角度提供了另一条路。Tian, Wang, Krishnan, Tenenbaum and Isola (2020) 和 Chen, Liu, Kira, Wang and Huang (2019) 的实证重评估说明了一件有意思的事：训练充分的嵌入骨干配合简单最近质心推理，往往能匹敌甚至超过很多复杂元学习器——表示质量有时比算法复杂度更重要。在高光谱遥感中，原型网络和关系网络已被用于小样本土地覆盖分类 (Yu et al., 2022)，空间背景信息在那里起到了辅助判别的作用；但在点光谱的食品近红外场景中，这个额外信息源不存在。Mishra and Passos (2021) 把迁移学习用于食品溯源，但未采用情节式评估框架。评估泄漏问题——编码器预训练数据与 LOEO 测试折重叠时产生的分布泄漏——在有任何近红外光谱研究中都没有被正式识别过，更谈不上量化。

3 结果

3.1 折限定编码器验证

在报告 LOEO 性能之前，有必要先确认每个折限定编码器在源域上的判别能力，因为训练不足的编码器会干扰下游比较。2018、2019 和 2025 折的源域验证精度分别为 0.9478、0.9411 和 0.9478 (表 1)，三折均值 0.9456，表明编码器在各自的训练分布内能够干净地区分产地。2019 折的轻微下降 (0.9411) 与该年数据中山东、山西两产地间更大的光谱重叠相一致。当然，域内判别能力强并不等于跨年迁移能力强——真正的问题在于：当该编码器用于对留出目标年份的小样本分类时，性能会下降多少？

3.2 编码器与情节双层方差分解

依照第 6.8 节描述的种子矩阵设计，在 3 折 $\times$ 5 编码器种子下重训得到的 15 个独立编码器，其源域验证精度落在 **0.9256–0.9611** (中位数 0.9478，详见表 2)，与表 1 报告的三折均值 0.9456 完全吻合；任何单个种子的训练结果均落在该窄带内，表明编码器训练过程本身高度稳定。完整 18,000 次评估在 Apple Silicon MPS 上耗时约 90 分钟。

方差分解 (vanilla ProtoNet, $\alpha = 0$, 三折均值)。表 3 列出了各 K 下的编码器层标准差与情节层标准差。随 K 增大，情节层方差被支持集均值压低，而编码器层方差几乎不随 K 变化，二者比例从 $K = 1$ 时的 1:8.5 单调收敛至 $K = 20$ –50 时的 1:1。这意味着论文主表中“50 次重复 std”在小 K 区间是合理代理，但在 $K \geq 20$ 时约一半残余不确定性来自编码器初始化，此前任何“单种子 +50 情节重复”形式的报告均未量化该部分。

编码器初始化敏感度。跨 5 编码器的宏 F1 抖动幅度 (per_enc_range) 三折均值在 $K = 5$ 时为 0.041， $K = 20$ –50 时升至 ~ 0.05 。其中 **LOEO-2025 折在大 K 时编码器跨度高达 0.084–0.086**，是三折中编码器初始化最敏感的折——原因是甘肃新类原型完全由目标支持样本构建，对编码器嵌入空间的几何形状特别敏感；这一折间不对称对未来在新增产地场景下扩展本基准具有方法学意义。

方法选择的方向稳健性。本节采用与统一单面查询协议一致的 SVM (RBF 核, $C = 10$, $\gamma = \text{scale}$)。在 18 个 (折 $\times K$) 组合中，14 个 (约 78%) 的 ProtoNet/SVM 方向判定在 5 个编码器下完全一致 (unanimous)，其余 4 个为折- K 边缘点 (LOEO-2018 $K=5$ 、LOEO-2019 $K=50$ 、LOEO-2025 $K=10/20$)，即编码器初始化的方差恰好接近 ProtoNet/SVM 性能差距，在不同种子下 5 票分裂为 3:2 或 4:1 而非全部一致；这正是种子矩阵设计应当暴露的“决策边界附近不稳定”信号。在远离边界的 14 个组合下，方法选择结论不会因编码器训练种子而方向倒挂。

折级别交叉点位置存在显著差异：**LOEO-2018 折**的交叉发生在 $K = 1$ 与 $K = 3$ 之间 ($K \geq 3$ 时 SVM 全胜)；**LOEO-2025 折**的交叉发生在 $K = 10$ 与 $K = 20$ 之间 ($K \leq 10$ 时 ProtoNet 占优)；而 **LOEO-2019 折在测试的 $K \in \{1, \dots, 50\}$ 全程内均由 ProtoNet 占优** (仅 $K = 50$ 时差距收窄至接近编码器抖动量级)。表 5 三折均值给出的“ $K \approx 10$ –20 交叉点”实际上是这三个不同位置 (含 LOEO-2019 不交叉) 的折均值产物，**任何单折并不严格在 $K = 10$ –20 处实际交叉**；这一折间不一致提示不同部署条件下的最优方法选择应基于折级别 (即与目标年份/产地情境最接近的源域配置) 而非全局三折均值。

与主表数值的吻合。5 编码器三折均值在 $K = 5$ 时为 0.6547 (vanilla ProtoNet $\alpha = 0$, 统一单面查询；本节方差分析为 MPS pilot)，与表 5 中 CUDA formal 原始 ProtoNet 的 0.650 仅相差 +0.005，落在表 3 中 $K = 5$ 总标准差 ± 0.049 的范围内；其余 K 值的三折均值偏差均在 $|0.015|$ 以内。表 5 报告的 ProtoNet 主表数值处于跨编码器种子分布的中心位置，未被异常种子拉高或拉低。需要说明的是，本节的 SVM/PLS-DA/最近质心三个非神经基线统一采用与英文版 20_unified_singleface_kshot 脚本一致的 RBF SVC ($C = 10$, $\gamma = \text{scale}$) / PLSRegression / 最近质心实现，与

表 5 中的 LinearSVC 数字 ($K = 5$ SVM=0.707) 属不同 SVM 族; 本次 SVM 三折均值 ($K \in \{1, 3, 5, 10, 20, 50\}$ 依次为 $\{0.516, 0.574, 0.606, 0.657, 0.697, 0.759\}$) 与英文版统一面板的逐项偏差均在 $|0.006|$ 以内, 表明评估管线在跨实现层面亦可对齐。

Table 2 | 15 个独立编码器 (3 折 $\times$ 5 种子) 的源域验证精度、训练终止 episode 与检查点 SHA-256 前 16 位哈希。所有验证精度均落在 0.9256–0.9611 内, 与表 1 报告的三折均值 0.9456 一致。

LOEO 折	编码器种子	验证精度	终止 episode	SHA-256 (16)
2018	42	0.9478	1700	49b655ea642b7446
2018	43	0.9456	1900	83ba47556bc9c0ca
2018	44	0.9433	1300	bee31efbc3d3aec2
2018	45	0.9489	1900	b16f7f7050b7cf5b
2018	46	0.9467	1900	5718c7abdc31259
2019	42	0.9478	1900	eb6d8daf7637f81c
2019	43	0.9356	1500	1abe7bba972b9f3f
2019	44	0.9367	1800	e920c13c002221fe
2019	45	0.9256	2000	a6861c8f74c69498
2019	46	0.9400	1800	5abaaea5ef686cb0
2025	42	0.9611	1800	d0965ec662865ace
2025	43	0.9467	2000	e3ad54835216bffb
2025	44	0.9567	1900	846197adf448a1f9
2025	45	0.9567	1700	31ef3644cffdad0e
2025	46	0.9489	2000	87e29720f7c30b51

Table 3 | vanilla ProtoNet ($\alpha = 0$) 在 5 编码器种子 $\times$ 50 情节种子下的方差分解 (三折均值, 单位: 宏 F1)。“编码器层 SD”为 5 个编码器均值的标准差; “情节层 SD”为各编码器内 50 个情节标准差的均值; “编码器跨度”为 5 个编码器均值的最大值减最小值。比例栏给出“编码器: 情节”标准差比。

K	三折均值	编码器层 SD	情节层 SD	比例	编码器跨度
1	0.583	0.009	0.077	1:8.5	0.023
3	0.627	0.016	0.060	1:3.7	0.041
5	0.655	0.017	0.047	1:2.8	0.041
10	0.672	0.019	0.028	1:1.5	0.043
20	0.678	0.021	0.021	1:1.0	0.050
50	0.684	0.020	0.019	1:1.0	0.049

3.3 评估泄漏: 共享编码器对比折限定编码器

如表 4 与图 1 所示, 为把编码器泄漏与源质心融合权重 α 彻底解耦, 我们在两种同 α 口径下各做一次 like-for-like 对照。口径一 (两臂 $\alpha = 0.4$): 共享编码器 (在含目标折的全部三年数据上训练) 三折均值宏 F1 为 0.926, 折限定编码器 (仅在非目标年份上重训, 脚本 10_loeo_year_foldwise) 为 0.563, 泄漏 $\Delta = 0.363$ 。口径二 (两臂 $\alpha = 0$, 即主实验最优配置 C): 共享 0.922 对比折限定 0.679, 泄漏 $\Delta = 0.243$ (5 种子 mean $\pm$ std, 跨种子标准差 0.011)。两个口径下评估泄漏均高度显著为正, 确证泄漏源自编码器“看过”目标域、而非融合权重 α 的假象——这与评估泄漏偏差非负定理 (第 6.3 节) 的 $\Delta \geq 0$ 预测一致。关于“漂移越大、泄漏越大”的逐折单调性推论, 须诚实区分口径: 在 $\alpha = 0.4$ 口径下 Δ 随各折漂移强度单调递增——以年份偏移为主的 LOEO-2018、LOEO-2019 折 Δ 分别为 0.250、0.339, 而同时混淆年份、协议与类别空间的 LOEO-2025 折 Δ 达 0.501, 为三折最大; 但在 $\alpha = 0$ 口径下逐折 Δ 大致持平 (LOEO-2018/2019/2025 分别为 0.260、0.227、0.240), 无明显漂移单调性。这一口径差异有明确机制: $\alpha = 0.4$

Table 4 | 评估泄漏: $K = 5$ 时共享编码器 (含目标折的全数据训练) 对比折限定编码器 (10_loeo_year_foldwise, 仅非目标年重训, 无泄漏), 5 种子 mean。为排除源质心融合权重 α 与编码器泄漏的混淆, 给出两种同 α 口径的 like-for-like 对照: 上组两臂均取脚本默认 $\alpha = 0.4$ (即表 7 配置 A), 下组两臂均取主实验最优 $\alpha = 0$ (配置 C)。两口径下评估泄漏偏差 Δ 均高度显著为正 (均值 0.363 与 0.243), 证明泄漏源自编码器训练集、非 α 假象。注意逐折单调性依赖口径: $\alpha = 0.4$ 口径下 Δ 随漂移单调递增 (LOEO-2025 折最大 0.501), 与第 6.3 节定理推论一致; 而 $\alpha = 0$ 口径下逐折 Δ 大致持平 (0.260/0.227/0.240, 无明显漂移单调性), 因源融合在协议失配的 2025 折严重有害、在 $\alpha = 0.4$ 口径下把该折折限定基线由 0.668 压至 0.414、从而人为放大该折 Δ ; 一旦取 $\alpha = 0$ 移除此有害融合, 2025 折折限定基线回升、该折 Δ 回落至与其余折相当的水平。

协议	2018 折	2019 折	2025 折	均值
口径一: 两臂 $\alpha = 0.4$ (脚本默认, 配置 A)				
共享编码器 (全数据)	0.929	0.935	0.915	0.926
折限定 (折内重训)	0.678	0.596	0.414	0.563
评估泄漏 Δ	0.250	0.339	0.501	0.363
口径二: 两臂 $\alpha = 0$ (主实验最优, 配置 C; like-for-like)				
共享编码器 (全数据)	0.928	0.929	0.908	0.922
折限定 (折内重训)	0.668	0.702	0.668	0.679
评估泄漏 Δ	0.260	0.227	0.240	0.243

的源质心融合在协议失配的 2025 折严重有害, 把折限定臂由 0.668 压至 0.414、从而人为放大该折 Δ ; 一旦取 $\alpha = 0$ 移除此有害融合, 折限定 2025 回升至 0.668、该折 Δ 回落至与其余折相当的水平。因此单调性推论的经验支持来自固定 $\alpha = 0.4$ 口径, 其成因部分是 $\alpha = 0.4$ 融合在 2025 折的有害效应; 在无融合的 $\alpha = 0$ 口径下逐折泄漏大致均——我们据此仅将单调性作为 $\alpha = 0.4$ 口径下的观察, 不对定理单调性推论作跨口径的普适断言。需要说明的是, 源质心融合 (α) 并非泄漏来源; α 消融 (第 3.6 节, 表 7) 在折限定编码器基础上单独考察, 与本节的编码器泄漏效应正交。

本研究报告的泄漏差距仅在特定实验条件下成立: 四产地苹果 NIR (新疆、山东、山西、甘肃)、本文的可见-近红外采集与谐波条件 (591–1001 nm 分析窗口)、本文描述的 LOEO-Year 协议。不同数据集结构、仪器配置或评估协议下, 泄漏量级可能有所不同; 该数值应被理解为本基准条件下的参考量, 而非普遍适用的常数。

这些数字说明, 当使用共享编码器时——在近红外元学习文献中相当普遍——0.9+ 范围的 LOEO 宏 F1 报告值需要打一个折扣: 它们在相当程度上反映的是协议本身的漏洞, 而非方法真实的跨年泛化能力。折限定编码器协议是跨年基准更合适的评估标准。本文后续所有结果均使用折限定编码器。




Figure 1. $K = 5$ 时共享（全数据）编码器与折限定（折内重训）编码器的三折 Macro-F1 对比 ($\alpha = 0.4$ 口径, 5 种子 mean±std, 点为均值、误差棒为跨种子标准差, 虚线为 3 类随机基线)。共享编码器在三折上均显著高于折限定编码器; 在此 $\alpha = 0.4$ 口径下评估泄漏 Δ 随各折分布漂移强度单调递增 (2018 +0.250 < 2019 +0.339 < 2025 +0.501)。 $\alpha = 0$ like-for-like 口径的对照数值见表 4 (该口径下泄漏均值仍达 0.243、但逐折 Δ 大致持平、无单调漂移依赖, 因 $\alpha = 0.4$ 融合对 2025 折的有害放大效应已被移除)。

3.4 不同 K -Shot 规模下的跨方法比较

结果解读框架。按照方法论部分的折分类, 本节结果分两个层次报告: (i) 以年份偏移为主——LOEO-2018 和 LOEO-2019 折, 目标侧测量协议和类别空间与对方来源年份一致 (注: 源域包含 2025 数据, 编码器并非纯单面协议训练); (ii) 复合偏移压力测试——LOEO-2025 折, 同时混淆年份、协议和类别空间三类变化。三折均值在正文中提供汇总参考, 但跨年泛化结论的主要依据为前两个严格时间折; 2025 折的结论单独解读。以下结果分析及第 4 节的讨论将严格遵循此分类框架展开。

所有五种方法的宏 F1 随 K 变化的情况如图 2 和表 5 所示。性能格局揭示了一个清晰的交叉模式, 拐点位于 $K = 3$ 到 $K = 5$ 之间。

在极端小样本区间 ($K \leq 3$), ProtoNet-C (配置 C, $\alpha = 0$) 稳定优于所有基线。在 $K = 1$ 时, 宏 F1 按降序排列为: ProtoNet-C (0.610)、原始 ProtoNet (0.574)、最近质心 (0.567)、SVM (0.504)、PLS-DA (0.490)。在 $K = 3$ 时, 排序调整为——ProtoNet-C (0.664)、SVM (0.650)、最近质心 (0.637)、PLS-DA (0.626)、原始 ProtoNet (0.625)——SVM 已上升至第二位, 但 ProtoNet-C 仍保持领先。

需要说明的是, ProtoNet-C 与原始 ProtoNet 在 LOEO-2018 和 LOEO-2019 折上采用完全相同的评估协议 ($\alpha = 0$, 单面查询), 在这两折上的宏 F1 完全一致; 两者在三折均值上的差距完全来自 LOEO-2025 折——ProtoNet-C 在该折采用多面查询均值, 而原始 ProtoNet 采用单面查询。因此, ProtoNet-C 相对于原始 ProtoNet 的整体优势实质上反映了 LOEO-2025 折的面均值增益 (详见第 3.7 节), 而非源质心融合 (α) 的贡献。两者相对于其余基线的共同优势, 则来源于编码器的元训练归纳偏置: 经过数百个模拟三类情节的训练, 编码器已学会在嵌入空间中将同产地样本投影到相近位置, 使得即使单个支持样本也能将类原型置于信息上有利的位。

当 K 超过 5 后, SVM 逐渐超越 ProtoNet-C。在 $K = 5$ 时 SVM 达到 0.707, 而 ProtoNet-C 为 0.680;

到 $K = 50$ 时, SVM 达到 0.880, 而 ProtoNet-C 停滞在 0.717。这种饱和反映了固定容量编码器的固有局限性: 随着更多支持样本可用, SVM 的最大间隔优化能利用更丰富的目标几何, 而 ProtoNet-C 的最近原型机制一旦原型均值稳定后, 从额外支持多样性中获益相对有限。PLS-DA 处于中间位置, 在大 K 时紧随 SVM 但在小 K 时落后, 原因在于其线性投影对小 K 时高方差的原型估计较为敏感。最近质心始终低于 ProtoNet-C, 印证了元训练在同等嵌入基础上带来的增益。

Table 5 | 五种方法在各 K 值下的 LOEO 宏 F1 (三折均值, 每折 50 次重复)。粗体表示各 K 下最优方法。原始 ProtoNet 在 $K > 5$ 时采用 50 次重复补充实验 (单面评估, 与 2018/2019 协议一致)。

K	ProtoNet-C	SVM	原始 ProtoNet	PLS-DA	最近质心
1	0.610	0.504	0.574	0.490	0.567
3	0.664	0.650	0.625	0.626	0.637
5	0.680	0.707	0.650	0.677	0.657
10	0.701	0.773	0.670	0.708	0.672
20	0.711	0.825	0.680	0.727	0.682
50	0.717	0.880	0.687	0.741	0.692




Figure 2. 五种分类器的 LOEO 宏 F1 随 K 变化情况 (三折均值, 50 次重复; 阴影带: 95% CI)。ProtoNet-C 与 SVM 的性能交叉发生在 $K = 3$ 到 $K = 5$ 之间, 定义了两个操作上截然不同的部署区间。

3.5 统计显著性分析

统计解释说明 (前置警示): 以下所有 p 值和置信区间均基于对同一固定数据集的独立随机情节采样, 量化的是在该数据集上反复随机抽取支持/查询情节时的重复采样稳定性, 而非跨独立采收季、独立果园批次或独立仪器的总体统计推断。50 次情节重复来自相同苹果个体, 存在潜在的伪重复问题 (pseudo-replication)——不同情节共享同一批水果, 可能导致统计显著性被高估。因此, 本文以折级宏 F1 均值一致性和效应量 (Cohen's d) 作为主要证据, p 值仅作为辅助参考, 不建议解读为跨独立实验的显著性检验结论, 与元学习基准评估的现有实践一致 (Bates, Hastie and Tibshirani, 2024)。此外, 读者应注意, 折级检验 ($n_{\text{primary}} = K_{\text{outer}} = 3$) 中, 每折内 50 次重复来自同一数据划分, 仅 3 个年份折使折级统计功效有限, 折间相关性亦未被显式建模; 严格的跨年性能主张需要来自独立采收季的多个数据集进行验证。

基于图 2 与表 5 所揭示的清晰交叉模式 ($K \approx 3-5$), 表 6 进一步报告了 ProtoNet-C 与 SVM 在三个代表性

K 值下的折级配对统计检验 ($n_{\text{primary}} = K_{\text{outer}} = 3, 5$ 种子; Nadeau-Bengio 修正 + Holm 校正)。

在 $K = 1$ 时, ProtoNet-C 三折均值领先 $+0.106$ (折级 95% CI $[+0.098, +0.110]$, 配对 t 检验 $p = 0.001$, Cohen's d 为大效应 (Cohen, 1988)), 其优势在折级尺度上稳健且跨 5 个编码器种子一致。在 $K = 3$ 时差距缩至 $+0.014$ ($p = 0.98$, 方向为正但不显著); 到 $K = 5$ 时方向逆转为 -0.027 (SVM 领先, $p = 0.21$)。受限于 LOEO-Year 仅有 3 个年份折, $K = 3/5$ 的折级检验统计功效有限, 但三者的均值差方向与表 5 的交叉模式完全一致, 且在 5 个模型种子上稳定复现。图 3 可视化了三个 K 值下的折级 F1 差值分布。上述结论基于 LOEO-2018 和 LOEO-2019 折 (以年份偏移为主) 更为可靠; LOEO-2025 折的三重混淆会影响折均值, 应与前两折分开解读。

从实际操作角度解读上述统计结果: 在每产地有标注参考样本不足四个的现场快速筛查场景 ($K \leq 3$), ProtoNet-C 相比 SVM 的优势在统计层面和实践层面均具有充分支撑; 在能够建立适度规模参考集的实验室或检验站环境 ($K \geq 5$), SVM 的性能优势兼具更低的推理复杂度, 使其成为更值得推荐的选择。需要说明的是, 该方法选择分界线是在本文特定仪器型号和产区条件下确定的, 实际应用中应针对具体部署背景重新评估。

Table 6 | ProtoNet-C 对比 SVM 的折级配对统计 ($n_{\text{primary}} = K_{\text{outer}} = 3, 5$ 种子; Nadeau-Bengio 修正 t , Δ 为 5 种子 mean $\pm$ std)。正 Δ 有利于 ProtoNet-C。折级 $n = 3$ 统计功效有限, $K = 3/5$ 方向与表 5 交叉一致但未达显著。

K	Δ (mean $\pm$ std)	折级 95% CI (代表)	配对 t p (代表)	Cohen's d
1	$+0.106 \pm 0.015$	$[+0.098, +0.110]$	0.001	4.14
3	$+0.014 \pm 0.010$	$[-0.069, +0.068]$	0.983	0.28
5	-0.027 ± 0.021	$[-0.127, +0.004]$	0.206	-0.44




Figure 3. $K \in \{1, 3, 5\}$ 时 ProtoNet-C 减 SVM 的 F1 差值分布 (每折 50 次重复情节, 3 折 $\times$ 5 种子)。箱体跨越四分位距; 须延伸至 $1.5 \times \text{IQR}$; $\times$ 标记均值。 $K = 3$ 与 $K = 5$ 之间均值差由正转负, 直观呈现方法选择交叉点 (折级检验见表 6)。

3.6 源原型融合权重消融

表 7 和图 4 呈现了 α 消融的核心结果。三种代表性配置在 $K = 5$ 时的三折均值宏 F1 分别为: 配置 A 0.563, 配置 B 0.648, 配置 C ($\alpha = 0$) 0.679——配置 C 在三折均值上取得最优。源域融合在 2025 折引起的性能损失最为显著 (配置 A: 0.414 vs 配置 C: 0.668), 此时源域质心由单面 2018/2019 光谱计算, 而目标原型来自多

面 2025 光谱——测量协议不匹配使源质心将情节原型从其真实分布位置拉开。

完整 $\alpha \in [0, 1]$ 连续敏感性扫描 (图 4, $K = 5$, 21 个等间距取值; 该连续曲线由 5 个固定种子在 NVIDIA RTX 4090 (CUDA) 上正式复跑聚合——每 α 取值 50 次重复 $\times$ 5 种子, 实线为跨种子均值、阴影为 ± 1 跨种子标准差; 其 $\alpha = 0$ 估计与表 7 (独立的配置消融脚本) 一致, 三折差异均 ≤ 0.01 , 互为交叉验证) 进一步揭示了各折的响应特征。LOEO-2025 折和 LOEO-2019 折均呈严格单调递减: 前者自 $\alpha = 0$ 的 $F1=0.671$ 起持续下降至 $\alpha = 1.0$ 时的 0.199, 后者自 $\alpha = 0$ 的 $F1=0.698$ 持续递降至 $\alpha = 1.0$ 时的 0.520——任何正 α 值均带来显著性能损失, 与高域差距条件下源质心偏差主导的理论预测一致。LOEO-2018 折的曲线则明显平坦: 整体自 $\alpha = 0$ 的 $F1=0.678$ 缓降至 $\alpha = 1.0$ 的 0.650 (仅 -4.1%), 峰值在 $\alpha \approx 0.20$ ($F1=0.691$), 与 $\alpha = 0$ 的差距仅 0.013, 相对 2019/2025 折的大幅下降属小量级; 该折弱非单调性与其相对较小的域差距预期一致 (源域包含 2025 多面数据, 协议不对称程度低于 2025 折)。上述发现与域适应理论 (Ben-David et al., 2010) 关于“源-目标差距足够大时, 源先验引入的偏差主导”的预测一致。在本文描述的跨年苹果近红外场景下, 折限定情节原型应优先从目标年份支持样本中计算 ($\alpha = 0$): 该配置在高域差距折中可避免显著损失, 在低域差距折中代价可忽略不计, 是稳健的默认选择。本文后续所有“ProtoNet-C”结果均采用 $\alpha = 0$, 与表 5 中的“原始 ProtoNet”共享同一编码器, 区别仅在于面位评估协议 (表 5 的原始 ProtoNet 列在 2025 折统一采用单面评估; ProtoNet-C 列在 2025 折使用多面均值以获得最优性能)。

Table 7 | $K = 5$ 时三种 α 配置在三个 LOEO 折上的宏 F1 (5 种子均值, 每折 50 次重复)。A: 全折 $\alpha = 0.4$; B: 仅 2025 折 $\alpha = 0$; C: 全折 $\alpha = 0$ 。

配置	2018 折	2019 折	2025 折	均值
配置 A	0.678	0.596	0.414	0.563
配置 B	0.678	0.596	0.668	0.648
配置 C	0.668	0.702	0.668	0.679




Figure 4. ProtoNet-C 在 $K = 5$ 时三个 LOEO-Year 折上的完整 $\alpha \in [0, 1]$ 敏感性曲线 (21 个等间距取值, 每 α 点 50 次重复 $\times 5$ 固定种子 CUDA 正式复跑, 实线为跨种子均值, 阴影为 ± 1 跨种子标准差)。LOEO-2025 和 LOEO-2019 折均呈严格单调递减, $\alpha = 0$ 为最优 (2025 折自 0.671 降至 $\alpha = 1.0$ 的 0.199; 2019 折自 0.698 降至 0.520); LOEO-2018 折曲线平坦, 在 $\alpha \approx 0.20$ 处存在峰值 ($F1=0.691$), 与 $\alpha = 0$ ($F1=0.678$) 差距仅 0.013。橙色虚线为 $\alpha = 0.4$ 参考线。本连续曲线与表 7 报告的 5 种子 CUDA formal α 消融为两个独立脚本的一致结果 (硬件披露见第 6.9 节), 共同支持”折限定情节原型应优先取 $\alpha = 0$ ”的稳健结论。

3.7 面均值增益分解 (LOEO-2025 折探索性分析)

以下分析为探索性案例研究, 限于 LOEO-2025 折 (唯一具有多面数据的年份), 50 次重复, 单一仪器设置; 结论的外部效度有待在其他折和仪器条件下进一步验证。

表 8 和图 5 呈现了 LOEO-2025 折上的 2×2 面均值消融 ($K = 5$, 50 次重复)。基线 $S_{\text{单面}}Q_{\text{单面}}$ 达到宏 $F1 = 0.569$ 。仅在支持侧添加多面均值 ($S_{\text{多面}}Q_{\text{单面}}$) 提升至 0.588 (+0.019); 仅在查询侧添加多面均值 ($S_{\text{单面}}Q_{\text{多面}}$) 提升至 0.640 (+0.071)。完整多面配置 ($S_{\text{多面}}Q_{\text{多面}}$) 达到 0.671, 残差交互项为 $0.671 - (0.588 + 0.640 - 0.569) = +0.012$, 表明支持侧和查询侧均值之间存在小但正向的协同效应。

因此主要贡献来自查询侧: 跨多个位置平均查询光谱降低了单次测量的方差, 这一效果可能来自两个不相互排斥的机制——(a) 抑制与表面异质性相关的生物学噪声 (如向阳面与背阴面之间的叶绿素浓度差异), 以及 (b) 测试时集成效应 (test-time ensembling), 即多个独立预测的集成在统计上优于单次预测。当前设计无法将两种机制的贡献严格分离; 在本实验条件下, 查询侧多面均值带来的整体增益使查询嵌入更稳定地接近其期望类原型。支持侧多面均值也有正向作用, 但增益仅为 +0.019, 统计功效相对较弱 (跨 5 种子 95% 置信下界接近零), 结论的可靠性弱于查询侧增益 (+0.071, 跨 5 种子置信区间稳健为正)。建议在其他折和仪器条件下重复本消融以增强结论的外部效度。

作为比较, SVM-Kshot 对照——将每个面测量作为独立训练样本, 有效使用约 5K 个实例——达到宏 $F1 = 0.715$, 大幅超过所有 ProtoNet-C 配置。这种比较并非完全受控 (SVM 看到更多训练数据), 但说明了当面测量被充分利用为独立证据时可达到的性能参考水平。

Table 8 | LOEO-2025 折上的面均值 2×2 消融 ($K = 5$, 50 次重复 $\times 5$ 种子均值)。增益相对于 $S_{\text{单面}}Q_{\text{单面}}$ 基线。

策略	宏 F1	相对基线增益
$S_{\text{单面}}Q_{\text{单面}}$ (基线)	0.569	—
$S_{\text{多面}}Q_{\text{单面}}$ (仅支持侧均值)	0.588	+0.019
$S_{\text{单面}}Q_{\text{多面}}$ (仅查询侧均值)	0.640	+0.071
$S_{\text{多面}}Q_{\text{多面}}$ (完整均值, 主要方法)	0.671	+0.102
SVM-Kshot 对照	0.715	—




Figure 5. LOEO-2025 折上四种支持/查询策略与 SVM-Kshot 对照的 K-shot 曲线 (每策略 50 次重复 $\times 5$ 种子, 阴影带为 95% CI)。完整多面均值在 ProtoNet 方案中始终最优, 且仅查询侧采用多面均值的收益明显大于仅支持侧采用多面均值。

3.8 各产地识别难度: 折限定编码器下的 Per-Class 分析

为排除共享编码器训练泄漏对产地识别难度结论的干扰, 在折限定编码器下、 $K = 5$ 、50 次重复情节评估中系统分析各产地的 per-class Recall 和 F1 (表 9)。

Table 9 | 折限定编码器下各产地 per-class Recall 和 F1 ($K = 5$, 50 次重复均值; 括号内为标准差)。各折内按 Recall 升序排列。

折	产地	Recall (均值 $\pm$ std)	F1 (均值 $\pm$ std)
LOEO-2018	山东 (SD)	0.516 $\pm$ 0.021	0.529 $\pm$ 0.021
	山西 (SX)	0.556 $\pm$ 0.020	0.546 $\pm$ 0.019
	新疆 (XJ)	0.987 $\pm$ 0.010	0.958 $\pm$ 0.006
LOEO-2019	山东 (SD)	0.622 $\pm$ 0.062	0.569 $\pm$ 0.048
	山西 (SX)	0.649 $\pm$ 0.037	0.630 $\pm$ 0.042
	新疆 (XJ)	0.823 $\pm$ 0.020	0.895 $\pm$ 0.012
LOEO-2025	甘肃 (GS)	0.522 $\pm$ 0.067	0.550 $\pm$ 0.046
	山东 (SD)	0.742 $\pm$ 0.049	0.682 $\pm$ 0.037
	新疆 (XJ)	0.772 $\pm$ 0.053	0.780 $\pm$ 0.050

三折分析揭示了一致的产地识别难度格局: (i) XJ (新疆) 始终最易识别。LOEO-2018 折 Recall 高达 0.987, LOEO-2019 折为 0.823, 即使在复合偏移的 2025 折也达 0.772, 反映新疆光谱指纹在四产地间具有显著区分度。 (ii) SD (山东) 和 SX (山西) 是已建立产地中识别难度最高的两类。LOEO-2018 折中 SD Recall (0.516) 略低于 SX (0.556), LOEO-2019 折中亦为 SD (0.622) 低于 SX (0.649); 两折一致表现为山东/山西光谱存在较大重叠、类边界模糊, 其中山东略难 (两折均值下 SD F1 约 0.549, SX F1 约 0.588)。 (iii) GS (甘肃) 在 LOEO-2025 折中识别难度最高。GS Recall 仅 0.522, 为该折最低; 这是新类别挑战——源域中不存在甘肃参考光谱, 仅靠目标侧 5 个支持苹果建立原型, 叠加测量协议偏移, 是三重偏移压力的集中体现, 不宜与 2018/2019 折的 SD/SX 难度直接类比。

以上产地识别难度格局在折限定编码器下完全成立, 确认先前分析中 XJ 最易、SD/SX 最难 (已建立产地) 的定性结论不受训练泄漏干扰, 可作为稳健结论在论文其余各处引用。

源域配置鲁棒性核实验。作为补充检验, 比较 LOEO-2018 和 LOEO-2019 折在两种源域配置下的宏 F1: 干

净折 (源域仅含单一非目标年份, 排除 2025 数据, 以消除测量协议差异) 与混合折 (源域含两个非目标年份, 含 2025 数据, 与主实验一致)。干净折在 $K = 5$ 时分别达到 ProtoNet 宏 F1 0.606 (LOEO-2018) 和 0.624 (LOEO-2019), 混合折分别为 0.688 和 0.724; 混合折在两个以年份偏移为主的折上均高于干净折, 说明纳入 2025 来源数据能为编码器提供额外的光谱多样性, 主实验中混合源域的选择合理, 且方法选择的方向性结论 (ProtoNet 在 $K \leq 3$ 时优、SVM 在 $K \geq 5$ 时优) 在两种源域配置下均保持一致。

3.9 外部验证: 公开 OliveOil 数据上的评估泄漏复现 为检验评估泄漏并非苹果数据特有, 我们在完全独立的公开光谱数据集 OliveOil (FT-IR, 四国产地, 60 样本, 570 波段) 上以相同的两协议对照复现该现象: 以产地为类、按产地留出构造少样本情节, 分别训练折限定编码器与共享编码器。结果表明, 共享协议同样系统性高估外部集少样本 macro-F1, 泄漏 Δ (共享 - 折限定, $K = 5$) 为 0.178 ± 0.053 (折限定 0.822 ± 0.053 , 共享 1.000; 5 种子 mean $\pm$ std), 其符号 $\Delta > 0$ 与苹果一致。这提示评估泄漏或非苹果数据特有; 但单一外部集不足以支撑“普遍现象”的主张, 为此我们进一步在一整套真实测量数据集上系统检验。

3.10 跨领域普遍性: 多数据集泄漏与混合效应统计

为把“苹果单例”提升为可检验的跨领域现象, 并摆脱单一基准仅 3 个年份折 ($n_{\text{primary}} = 3$) 的统计局限, 我们在四个额外的公开真实测量数据集上以完全相同的两协议对照 (共享编码器对比折限定编码器, $K = 5$ 折限定情节原型 $\alpha = 0$) 重复泄漏量化。这些数据集横跨三种测量模式与四类分布漂移轴: 玉米近红外 (Cargill corn 基准 (Eigenvector Research, 2000), 跨仪器 m5/mp5/mp6, 蛋白含量三分位分类)、药片近红外 (2002 IDRC shootout (IDRC, 2002), 跨仪器, 活性成分三分位)、芒果近红外 (Anderson, Walsh, Subedi and Hayes, 2020 跨采收四季, 干物质三分位)、Indian Pines 高光谱成像 (Baumgardner, Biehl and Landgrebe, 2015, 跨空间域, 2×2 象限, 原生地物类)。回归型目标按源域三分位离散化为三类 (阈值仅由源域计算, 杜绝标签泄漏), native 分类集用原生标签。合并本文苹果与 OliveOil, 共六数据集。本套件全部数据集的模式、规模、任务、来源与 SHA-256 校验汇总于表 10 (数据卡)。全部实验以 5 个固定种子重复; 受算力配置所限, 本跨领域套件在 Apple Silicon (MPS) 上运行, 作为对 CUDA-formal 苹果核心结论的跨领域稳健性验证 (硬件披露见第 6.9 节), 其数值不承担主实验精度声明。

泄漏跨领域稳健复现。四个新数据集共产生 13 个留一域折; 与本文苹果 (3 个年份折, $\alpha = 0$ like-for-like) 及 OliveOil 合并, 构成六数据集、17 折的统一证据集。如图 8 与图 10 所示, 17 折中 16 折评估泄漏 $\Delta > 0$ (94%, 折级符号二项检验 $p = 1.4 \times 10^{-4}$), 仅 Indian Pines 一个高漂移空间象限折为轻微负值 ($\Delta = -0.03$)。为对相关折 (同一数据集内多折共享底层样本) 作正确推断, 我们以数据集为随机效应拟合混合效应模型 $\Delta \sim 1 + (1 | \text{数据集})$: 总体泄漏固定截距为 $\Delta = 0.132$ (95% CI [0.071, 0.192], 数据集间随机效应方差仅 0.0047, 表明跨数据集异质性小); 以数据集为簇的 cluster-bootstrap (2000 次) 给出一致的 95% CI [0.084, 0.191]。这里混合效应在折级观测单位上拟合 (24 的种子级记录先按折跨 5 种子聚合为折级均值, 再与苹果/OliveOil

折级 Δ 合并为 17 折, 每折等权), 与符号检验/cluster-bootstrap 的折级口径一致。在最保守的数据集级独立检验下, 六个数据集全部呈正泄漏 (6/6, 符号二项检验 $p = 0.016$)。据此, 表示层评估泄漏在跨模态、跨仪器/季节/年份/国别/空间的真实测量数据集上是一个统计显著、量级稳定的普遍现象, 而非苹果近红外的特例或超参数假象。需说明的是, 混合效应合并的是各数据集在其各自任务定义 (native 分类或源域三分位) 下的宏 F1 泄漏 Δ , 故截距量级应理解为“跨异质任务的方向一致的泄漏强度综合”, 而非单一可比精度差; 我们对此已通过数据集级符号检验与随机效应方差予以稳健性交代。需进一步强调的是, 此处共享编码器在含目标域的有标签全量数据上元训练, 故该总体 Δ 是 label-aware 表示层泄漏的上界; 第 3.11 节将以四编码器分解把它进一步剥离为标签感知分量 Δ_{sup} 与纯无监督暴露分量 Δ_{unsup} , 并诚实界定二者各自的量级与可靠性。

多重稳健性核检。为排除结论依赖单一数据集、三分位离散化或特定统计设定, 我们做了系统的敏感性分析 (共 13 种设定, 详见补充材料)。(i) 留一数据集: 逐个剔除任一数据集重拟合, 总体泄漏截距落在 0.126–0.145, 全部 95% CI 下界为正——结论不由任何单一数据集驱动。(ii) 去三分位离散化: 仅保留原生分类数据集 (苹果、OliveOil、Indian Pines, 剔除全部三分位 binning 的回归集) 时, 截距不降反升至 $\Delta = 0.185$ (95% CI [0.123, 0.248]), 说明泄漏并非 binning 的人为产物。(iii) 去 HSI 得 0.137 ([0.049, 0.224])、去苹果得 0.128 ([0.070, 0.187])。(iv) 折层嵌套随机效应 $\Delta \sim 1 + (1 | \text{数据集/留一域})$ 得 0.132 ([0.071, 0.192]), 显式建模折层相关后截距依旧稳健。(v) 归一化 Δ (各折 Δ 除以该数据集共享臂均值以消任务尺度) 得相对截距 0.216 ([0.108, 0.324])。全部 13 种敏感性设定的截距 95% CI 下界均严格为正, 泄漏为正这一结论对数据集构成、任务离散化方式与随机效应设定均稳健。

3.11 泄漏的监督/无监督分解: 主因是 label-aware 表示层泄漏

前述跨领域泄漏量化中, 共享编码器在含目标域的有标签全量数据上元训练——目标域的 x 与 y 同时进入表示学习。这是一个必须诚实澄清的关键点: 该协议下测得的泄漏 Δ 是 label-aware (标签感知) 表示层泄漏的上界, 它把“目标域标签进入表示学习”与“目标域无标签分布被表示塑造”两个来源合并在一起。为将二者干净剥离, 我们在四个跨领域数据集的 13 个留一域折上做一次四编码器分解 (脚本 31_leakage_decomposition, CUDA formal, 5 固定种子, 共 65 个种子 $\times$ 折)。监督臂对照 E_0 (编码器仅在源域 (x, y) 有监督元训练, 合法折限定基线) 与 E_2 (在源 + 目标域 (x, y) 有监督元训练, 复现现有共享协议), 其差 $\Delta_{\text{sup}} = E_2 - E_0$ 隔离标签感知泄漏; 无监督臂对照 U_{src} (掩码光谱自监督重构仅在源域 x 上预训练, 绝不接触标签) 与 U_{tgt} (同一掩码自监督目标在源 + 目标域 x 上预训练), 其差 $\Delta_{\text{unsup}} = U_{\text{tgt}} - U_{\text{src}}$ 在固定自监督目标下仅改变是否含目标域无标签 x , 从而干净隔离真正“隐蔽”的无监督暴露分量, 避免与“有监督 $\rightarrow$ 自监督”目标变化相混淆。掩码自监督采用 30% 波段的连续段掩码 (span=5)、仅在掩码位置计 L2 重构损失、以验证集重构损失早停, 编码器全程不接触任何标签。

结果给出一个明确而诚实的结论 (图 6): 泄漏的主因是 label-aware 表示层泄漏, 而非隐蔽的无监督暴

Table 10 | 数据卡：本文所用全部数据集的模式、规模、任务与来源。上半 = 主实验自建九域苹果 NIR 基准；下半 = 跨领域（跨队列）迁移分析所用 5 个公开光谱/高光谱数据集（队列由采集仪器、采收季/物候、年份、产地或空间域定义）。所有数据集原始与预处理文件均记录 SHA-256 校验值以保证可追溯（见脚注）。

数据集	模式 / 波段	规模 / 队列（漂移轴）	任务	来源
主实验（自建九域基准）				
苹果（九域 NIR）	NIR 点谱 / 229 波段（591–1001 nm）	4,529 谱 / 1,950 果, 3 年 × 4 产地（9 域）	地理产地判别（4 类）	新疆农大自采 ^a
跨领域迁移分析（5 个公开数据集，队列 = 漂移轴）				
OliveOil	FT-IR 谱 / 570 波段	60 样 / 4 国别	产地判别（4 类）	UCR 时序档案 ^b
玉米（Corn）	NIR 点谱 / 700 波段	80 样 × 3 仪器（m5/mp5/mp6）	蛋白（源域三分位 3 类）	Cargill corn (Eigenvec-tor Research, 2000)
药片（Tablet）	NIR 点谱 / 650 波段	655 样 × 2 仪器	活性成分（源域三分位 3 类）	2002 IDRC (IDRC, 2002)
芒果（Mango）	NIR 点谱 / 306 波段（684–990 nm）	11,691 样 / 4 采收季	干物质（源域三分位 3 类）	Anderson 2020 (Anderson et al., 2020)
Indian Pines	AVIRIS HSI / 200 波段	145×145 px / 2×2 空间象限	16 类地物	Purdue/EHU (Baum-gardner et al., 2015)

^a 新疆农业大学自采（managed access, 非公开, 可向通讯作者申请, 见 Data availability）。^bUCR Time Series Classification Archive (OliveOil, 公开)。^c 原始/预处理文件 SHA-256（前 16 位, 全值见 03data/processed 数据卡）：苹果（预处理正典）f5c0afff9b18c3eb；OliveOil 472c5b73157b2e0f；玉米 e28fd4be274a54ca；药片 129a32ec9e194e56；芒果 86159e2df9244fa5；Indian Pines 立方体 ec2f880710919d5 / 标注 65c4687a8ab04f6d。

露。以数据集为随机效应的混合效应模型给出 $\Delta_{\text{sup}} = +0.084$ (95% CI [0.023, 0.144], 13 折中 12 折为正, 4/4 数据集为正)；而纯无监督暴露分量 $\Delta_{\text{unsup}} = +0.012$ (cluster-bootstrap 95% CI [-0.003, 0.028], 11/13 折为正但 corn 数据集为负, CI 下界掠过 0)，二者之比约 7 倍。这表明：当共享编码器接触目标域标签时，泄漏大且稳健；而当仅接触目标域无标签分布（自监督）时，泄漏很小、且不能稳健地与零区分。据此我们**审慎收窄主张**——本文核心泄漏现象是标签感知的表示层泄漏，我们不声称存在一个大的、隐蔽的纯无监督泄漏分量。这一诚实区分对实践直接相关：常见的“共享编码器 + 留出域少样本评估”协议，只要在表示学习阶段使用了目标域标签，即会引入约 0.08 量级的宏 F1 系统虚高。为检验 Δ_{unsup} 之小是否只是掩码光谱重构这一特定自监督目标的产物，我们进一步用一个**更强的 target-aware 无监督目标——SimCLR 式对比学习**（谱增强 + NT-Xent 损失，编码器同样绝不接触标签；脚本 35_stronger_ssl_control, CUDA formal, 5 种子）在同 4 数据集 13 折上复核无监督臂：其无标签暴露分量 $\Delta_{\text{unsup}}^{\text{ctr}} = +0.001$ (95% CI [-0.013, +0.012], 5/13 折为正)，甚至比掩码臂 (+0.012) 更接近 0。这表明“仅无标签目标暴露产生的泄漏很小”的结论**跨两种自监督目标（掩码重构与对比学习）一致稳健**，并非某一弱自监督目标的假象。我们仍诚实保留一处**适用边界**：本文未穷尽所有无监督/域适应目标（如显式域对抗对齐、无监督域适应），此为界定清晰的后续方向。与理论一致的是，两臂 Δ_{unsup} 点估计均非负或近 0，符合定理“分布暴露产生非负偏差”的预测，其量级均远小于标签感知分量。

去风险： Δ_{unsup} 之小是否为自监督欠拟合假象？一个合理质疑是： Δ_{unsup} 小是否只因掩码自监督表征太弱、看了目标 x 也翻译不成下游增益？两点排除之。其一，掩码自监督已采用验证集重构损失早停，非固定轮数欠训。其二，我们把自监督预训练预算 ssm_epochs 在 {100, 300, 600} 三档扫描（脚本 34_ssm_budget_sensitivity, CUDA formal, 覆盖 Δ_{unsup} 两端最敏感的 corn 与 Indian Pines 共 7 折）：增大预算并不把 Δ_{unsup} 推高——预算由 100 增至 300 时

Δ_{unsup} 反而微降 (+0.026 → +0.020)，且 300 与 600 档结果完全一致（早停在 300 轮前已收敛）， U_{src} 绝对效用跨预算档几乎不变（波动仅 0.0003）。这表明 Δ_{unsup} 的小量级不是“训练不足的下限”、不会因更充分的自监督训练而放大，自监督表示已收敛。故“无标签目标暴露泄漏小”这一结论对训练预算稳健，非欠拟合假象（图见补充材料）。

泄漏影响下游方法选择：排序敏感性证据。评估泄漏的影响不止于精度虚高，还会作用于**方法选择**这一研究决策环节。在同一 13 折上，我们对四种下游分类头（最近原型、logistic 线性探针、 k -NN、SVM）分别在共享（泄漏）协议与折限定（无泄漏）协议下评估，比较两协议给出的方法排序（脚本 33_ranking_flip, CUDA formal, 5 固定种子；图 7）。首先，四种头在共享协议下的宏 F1 均系统高于折限定协议（如最近原型 0.712 对比 0.624, logistic 0.677 对比 0.591），确认泄漏对分类头具有**普适性**、并非最近原型规则特有。其次，两协议给出的整体头排序仍呈正相关（13 折平均 Kendall $\tau = +0.349$ ，即排序并非崩坏、而是弱-中度一致），但被选中的最优方法对协议敏感：在单次（种子，留出域）评估实例层面（ $n = 65$ ），泄漏协议选出的 top-1 方法与无泄漏协议不一致的比例为 42% (27/65)；跨 5 种子聚合到折级（ $n = 13$ ）后方法选择更稳定（仅 1/13 折翻转），平均模型选择遗憾较小但非零（0.0136 宏 F1）。这表明：评估泄漏虽不至于打乱整体方法排序，却会在具体评估实例上以相当比例改变“哪种方法最优”的判断，代价虽小但方向系统。这为“应把折限定与共享之差 Δ 作为少样本/跨域评估的标准报告项”提供了超出精度层面的证据。




Figure 6. 泄漏的监督/无监督分解（四数据集 13 折，CUDA formal 5 种子）。橙点为 label-aware 泄漏 $\Delta_{\text{sup}} = E_2 - E_0$ （目标 $x+y$ 进入有监督表示学习，泄漏上界），蓝点为纯无监督暴露 $\Delta_{\text{unsup}} = U_{\text{tgt}} - U_{\text{src}}$ （同一掩码自监督目标下仅加无标签目标 x ）；末行为以数据集为随机效应的混合效应总体截距，横条为 95% CI。 $\Delta_{\text{sup}} = +0.084 [0.023, 0.144]$ 稳健为正， $\Delta_{\text{unsup}} = +0.012 [-0.003, 0.028]$ 掠过 0——泄漏主因是标签感知，而非隐蔽的无监督暴露。Wong color-blind 配色。




Figure 7. 泄漏协议扭曲下游方法选择（四数据集 13 折，四分类头 proto/logistic/k-NN/SVM，CUDA formal 5 种子）。共享（泄漏）协议下各头宏 F1 系统高于折限定（无泄漏）协议；整体头排序仍正相关（13 折平均 Kendall $\tau = +0.349$ ），但被选最优方法在 42% 的单次（种子，域）评估实例上改变（27/65；折级聚合后仅 1/13），平均模型选择遗憾 0.0136。泄漏虽不打乱整体排序，却在具体实例上影响“哪种方法最优”的判断。Wong color-blind 配色。

原始 MMD 非线性预测逐折泄漏——与理论一致的诚实结果。我们进一步以混合效应回归 $\Delta \sim z(\text{MMD}^2) + (1 | \text{数据集})$ （MMD 在数据集内标准化以消除量纲差异）检验“漂移越大、泄漏越大”是否在输入空间原始 MMD 尺度上跨数据集成立。结果斜率为 -0.009 ($p = 0.65$)，不显著。这一空结果并非反例，而恰好印证第 6.3 节理论的核心诚实边界：原始边缘分布 MMD 不是充分的漂移度量——如定理反例所示，源目标共同平移使 $\text{MMD} > 0$ 而泄漏 $\Delta = 0$ ；只有泄漏相关的可分性层漂移（汇合目标缺口 $D_{\text{pool}, \lambda}$ ）才解析地下界 Δ 。因此我们不声称“ Δ 随原始 MMD 单调”，而将跨领域证据严格限定为“泄漏稳健为正”这一由定理 $\Delta \geq 0$ 直接支撑的主张（图 9）。这一理论与经验在负结果上的一致，强于任何事后拟合的单调关系。




Figure 8. 四个新增数据集折级评估泄漏 Δ 雨云图（点为各留一域折的 5 种子均值 Δ ，小提琴为分布，黑竖线为数据集内均值；橙虚线为六数据集混合效应总体截距 $\Delta = 0.132$ ）。跨玉米/药片/芒果/Indian Pines 泄漏一致为正（苹果与 OliveOil 的折级 Δ 见第 3.3、3.9 节，已并入混合效应），Wong color-blind 配色。




Figure 9. 逐折泄漏 Δ 对标准化输入空间漂移 $z(\text{MMD}^2)$ （按数据集着色）。回归斜率不显著 (-0.009 , $p = 0.65$)，与理论“原始 MMD 非充分漂移度量”的结论一致——泄漏稳健为正但不由原始 MMD 线性决定。




Figure 10. 各数据集 $\times$ 留一域评估泄漏 Δ 热图（红正蓝负，RdBu 发散配色）。仅 Indian Pines 一个高漂移象限折为轻微负值，其余 12 折均为正。

3.12 负控

作为投稿必要前提，我们对折限定 ProtoNet 施加三类负控 (≥ 1000 次置换)：(i) 标签置换——打乱产地标签后重训，真实 macro-F1 应显著高于置换零分布，逐折 $p = 0.000999$ （三折一致， $p < 0.001$ 为通过）；(ii) 随机特征——同形状噪声替换光谱输入，性能退化至随机水平（三折 macro-F1 ≈ 0.33 ，与 3 类随机基线 1/3 相当）；(iii) ID 探针——仅用中性样本序号做逻辑回归，不高于随机（三折 macro-F1 0.21–0.24，均低于随机基线）。三项负控确认模型性能来自真实光谱-产地关联，而非标签结构、数据管线或采样顺序等捷径。

3.13 不确定性校准

高风险溯源决策要求概率可信，我们以期望校准误差 (ECE, ≥ 10 bins)、最大校准误差 (MCE) 与可靠性图

评估折限定 ProtoNet 的校准，并以温度缩放做后处理；对无分布假设的预测集覆盖保证，共形预测 (conformal prediction) 提供了互补途径 (Angelopoulos and Bates, 2023)。逐折 ECE 为 0.028、0.075、0.089 (2018/2019/2025 折)，其中 $ECE > 0.05$ 的 2019、2025 折经温度缩放 ($T = 0.60$ 、 2.60 ；2018 折 $T = 0.85$) 后 ECE 分别降至 0.057、0.051 (2018 折 0.026)，表明少样本产地分类存在中等过自信、可由单参数缩放有效缓解。

3.14 可解释性：波段重要性与化学归属

为验证判别的化学可解释性，我们以可解释代理模型对“光谱 → 产地”计算 SHAP 全局与局部重要性及置换重要性 (按苹果编号分组划分以防同果泄漏)，并将高重要性波段映射到 NIR 化学归属。结果显示 top 判别波段集中于 591–605 nm (可见光-色素区，中位 603.5 nm) 附近，对应可见光色素、C–H (糖类/有机物) 与 O–H (水分) 合频/倍频吸收，与苹果成分的产地相关差异在化学上自洽，支持模型捕获的是有意义的成分指纹而非伪相关。

3.15 多模型综合评价 (LLH-GBID)

依据本文综合评价方案 (第 6.3 节所属方法体系)，我们以 LLH-GBID 条件相对综合评价框架 ($q_B = q_W = 2$) 对候选方法在四项指标 ($K = 5/K = 20$ macro-F1、最弱类 F1、 $F1@K5$ 跨折标准差) 上综合排序，综合结果表、原始指标表与敏感性总表分别见表 11、表 12 与表 13 (均为 5 种子 formal)。在软否决准入下，无一方法通过核心指标门槛——所有方法最弱类 F1 相对 3 类随机基线的效用均低于 0.30 阈值 (表 11 中 Pass 全为否)，说明跨年场景下最难产地的识别尚无方法达到“可接受”水平；故主排序按综合指数 GBIDS 给出。PLS-DA (GBIDS 38.3) 与主实验采用的折限定 ProtoNet ($\alpha=0$ ，GBIDS 38.1) 综合最前 (平均主排名 2.0、2.2，二者差异在跨种子标准差内)，最近质心 (37.9)、SVM (37.2) 居中，而 $\alpha=0.4$ 的源质心融合变体因跨年分布失配退居末位 (GBIDS 29.0、平均主排名 5.0)，从综合评价角度进一步印证源质心融合在本跨年场景无益、 $\alpha=0$ 为稳健选择。上述格局在多重敏感性分析下稳定： q 短板配置、维度权重 $\pm 20\%$ 扰动与 Dirichlet 随机权重、固定基准与候选集最差值两种基准方案、以及等权/相关性折扣/Mahalanobis 去相关三种相关性处理下，前二名与末位排名均不变 (相关性处理三方案排名 Kendall τ 均值 0.87)；1000 次跨 5 种子重采样中 PLS-DA 与折限定 ProtoNet 分列第一名频率 0.45、0.42，其余方法接近零 (详见表 13)。

Table 11 | LLH-GBID 综合结果表 (5 种子 formal, $q_B = q_W = 2$)。GBIDS 为 0–100 综合指数得分 (越高越优，非综合准确率)。Pass 为软否决准入 (核心指标 $F1@K5$ 与最弱类 $F1@K5$ 效用 ≥ 0.30)；本任务所有方法最弱类 F1 相对随机基线效用偏低，均未通过，故按 GBIDS 排序。 $\bar{u}/C_B/C_W$ 为 GBID 分解的平均效用缺口/维度间与维度内不均衡分量。

方法	Pass	$\bar{u}$	C_B	C_W	GBIDS	平均排名	第一名频率
PLS-DA	否	0.403	0.153	0.021	38.3	2.0	0.40
ProtoNet ($\alpha=0$)	否	0.401	0.154	0.013	38.1	2.2	0.40
最近质心	否	0.393	0.127	0.014	37.9	2.6	0.20
SVM	否	0.392	0.152	0.038	37.2	3.2	0.00
ProtoNet+ 融合 ($\alpha=0.4$)	否	0.351	0.285	0.003	29.0	5.0	0.00

Table 12 | LLH-GBID 原始指标表 (5 种子均值)。四项指标： $K=5/K=20$ 三折 macro-F1 (效益型)、最弱类 $F1@K5$ (效益型)、 $F1@K5$ 跨折标准差 (成本型，越低越优)。

方法	$F1@K5$	$F1@K20$	最弱类 $F1@K5$	$F1@K5$ 标准差	GBIDS
PLS-DA	0.631	0.678	0.460	0.046	38.3
ProtoNet ($\alpha=0$)	0.648	0.678	0.458	0.048	38.1
最近质心	0.615	0.647	0.479	0.049	37.9
SVM	0.609	0.697	0.452	0.048	37.2
ProtoNet+ 融合 ($\alpha=0.4$)	0.562	0.570	0.274	0.030	29.0

Table 13 | LLH-GBID 敏感性总表 (§15.5 四项 + 重采样, 5 种子 formal)。基准敏感列为固定基准与候选集最差值两方案下的主排名区间；相关性处理 (等权/相关折扣/Mahalanobis 去相关) 三方案排名 Kendall τ 均值 0.87 (等权-折扣 1.00，等权-Mahalanobis 0.80，折扣-Mahalanobis 0.80)；重采样第一名频率为 1000 次跨 5 种子配对 bootstrap。

方法	主排名	q 敏感均排名	权重扰动第一名概率	基准敏感排名区间	重采样第一名频率
PLS-DA	1	1.50	0.200	[1, 1]	0.448
ProtoNet ($\alpha=0$)	2	2.50	0.254	[2, 2]	0.423
最近质心	3	2.00	0.344	[3, 4]	0.129
SVM	4	4.00	0.069	[3, 4]	0.000
ProtoNet+ 融合 ($\alpha=0.4$)	5	5.00	0.133	[5, 5]	0.000

4 讨论

4.1 评估泄漏：普遍性与应对措施

正如第 3.3 节量化结果所示，共享编码器协议导致了显著的评估泄漏 (三折均值 $\Delta F1 = 0.363$)。这一差距的绝对值或许不大，但其揭示的系统性漏洞影响深远。这一现象并非某一边界案例下的偶发结果，而是元学习社区广泛沿用的共享编码器 workflow 在逻辑上的必然产物——编码器在含测试域的全量数据上预训练后“冻结”，表面上流程简洁，但其参数在接触第一个支持样本之前，就被测试域的分布特征所塑造。在近红外光谱这一特定场景下，泄漏还存在额外的放大机制：229 维输入空间相对低维而判别信息密集，接触过 2025 多面光谱的编码器已经学习了多面测量协议特有的空间结构，从而在评估时人为地降低了 2025 情节的分类难度。本文报告的 Δ 以共享编码器 (含目标折的全数据训练) 对照无泄漏的折限定编码器 (10_loeo_year_foldwise) 为参照；源质心融合 (α) 是与编码器泄漏正交的独立因素，在折限定基础上单独消融 (第 3.6 节)，不计入泄漏量。

值得指出的是，本文所描述的评估泄漏现象在机制上不依赖于特定编码器架构——无论采用全连接网络、一维卷积网络 (如 ResNet-1D) 还是 Transformer，只要共享编码器在含测试折的全量数据上联合训练，均会引入同类型的分布泄漏。本文报告的三折均值 $\Delta = 0.363$ 仅为当前全连接架构在本数据集条件下的具体量化，其他架构的泄漏量级可能有所差异，但泄漏存在性在逻辑上是确定的。

有效的补救方案较为直接：为每一 LOEO 折独立地仅在源域数据上重新训练编码器。此操作的计算代价不可忽视，然而目前尚无在保证评估纯洁性的同时绕过这一代价的可靠替代方案。跨年外部验证的基本思路并不新鲜 (Feudale et al., 2002; Liu et al., 2025b; Pan et al., 2024b)；本文的核心补充在于：一个公开的三年四产区基准，以及在情节式元学习框架下对该评估协议差距量级的系统量化。相应规范建议亦较为明确——未来的跨年近红外基准研究至少应当明确所用编码器协议，将折限定性能作为必要基线，并将共享编码器结果标注为”

上限参考”而非真实性能声明，以使跨论文的性能比较具备可比性。

4.2 跨学科影响与评估卫生

本研究的意义超出苹果近红外本身。第 6.3 节的定理表明，评估泄漏并非实现层面的偶然，而是**分布漂移下少样本/跨域评估设计的原理性缺陷**：让留出域参与表示学习，会使期望测得精度产生非负的系统性正偏，其大小由表示在目标域上的可分性增益刻画，随域漂移增大而增强、随漂移消失而归零（该单调性针对分布漂移；真实嵌入的有限 K 诊断显示偏差在 $K \in [1, 20]$ 内量级稳定且略随 K 收窄）。这一规律对一大类现代人工智能评估直接适用——凡“先在大规模数据上学习表示、再在留出的类/域上报告少样本、长尾、跨域或零样本结果”的范式，只要表示训练数据与评估留出域未严格隔离，所报告的泛化数字便含同型偏差。它不同于已被熟知的特征选择泄漏 (Ambroise and McLachlan, 2002; Kaufman, Rosset, Perlich and Stitelman, 2012)：泄漏发生在表示学习层且专属于分布漂移下的少样本元评估，更为隐蔽，且与自适应数据分析中“留出信息一旦回流即失效”的理论一致 (Dwork, Feldman, Hardt, Pitassi, Reingold and Roth, 2015)。标准域泛化基准 (如 DomainBed、WILDS) 正是以严格的留域协议来评估跨分布泛化 (Gulrajani and Lopez-Paz, 2021; Koh, Sagawa, Marklund, Xie, Zhang et al., 2021)；本文的折限定协议与之精神一致，但专门针对分布漂移下的少样本元评估，并给出可证伪的定理刻画。

与已知泄漏/污染形式的边界。为避免与既有概念混淆，表 14 系统区分本文“表示层评估泄漏”与已被讨论的相关形式。本文的新颖性**不在于**“发现泄漏”这一泛概念——数据泄漏、预处理泄漏、预训练污染、转导/无监督域适应均已见文献——**而在于精确定位一个此前未被形式化的组合**：编码器（表示学习层）在分布漂移下的少样本元评估中接触了留出域的分布（不需样本级重复），从而使“看似合法的归纳性少样本泛化”被系统性高估。尤须与转导/无监督域适应划清界限：若研究声明其设置为 target-aware（转导），让编码器见过目标域并无不当；但若声明评估的是留出域的归纳泛化，却让编码器在表示学习阶段见过目标域，则构成协议错配——本文的贡献不是禁止 target-aware 表示学习，而是要求报告时明确区分归纳（折限定）与转导（共享/汇合）两种口径。为例证这一倡导的必要性，我们对跨域少样本高光谱分类文献做了一次中性的评估协议报告审计 ($N=4$ 篇代表性近期论文，基于各自可获取的方法描述；例证性、非穷尽)：其中三篇在表示学习阶段使用了目标域数据（域适应或自监督），但仅一篇明确声明其转导/target-aware 性质；唯一严格将目标域排除于表示学习的一篇，亦未把该隔离作为显式报告项。这并非指控任何工作结论有误——按表 14，明确声明的 target-aware 设置完全合法——而是表明该领域**尚无统一的表示层隔离与归纳/转导区分的报告规范**：接触目标域者未必声明其转导性质，隔离者亦未必显式报告。将折限定协议与共享—折限定之差 Δ 作为少样本/跨域评估的标准报告项，可系统性消除这一不确定性。

在样本稀缺、跨批次/跨仪器/跨年份/跨站点漂移常态化的科学测量领域，少样本与跨域评估被广泛采用，本研究的警示尤为切要：在光谱学与化学计量学中按年份/仪器留出（本研究）、在遥感对地观测中按地理/季节留出、在医学影像中按医院/设备留出、在基因组学中按批次/染色体留出 (Whalen et al., 2022)——若表示

学习未与留出域隔离，跨域泛化将被系统性高估，把“看似可部署”的模型推向真实失败，进而危及科学结论与监管决策。已有大规模复盘显示，泄漏与训练-测试重叠是机器学习驱动科学中可复现性危机的主要来源之一 (Kapoor and Narayanan, 2023; Roberts et al., 2021; Magar and Schwartz, 2022)；本文为其中的“表示层泄漏”给出了可形式化、可量化、可证伪的刻画，并在**六个真实测量数据集上以混合效应统计证明其为跨模态、跨领域的普遍现象**（第 3.10 节：总体泄漏 $\Delta = 0.132$, 95% CI [0.071, 0.192]，六数据集 6/6 呈正泄漏，覆盖仪器/季节/年份/国别/空间五类漂移轴）——上述遥感/医学/基因组等场景的按域留出隔离，正是本研究倡导的评估卫生规范在各学科的具体落地。

由此我们主张一项低成本、可被任意领域采纳的**评估卫生规范**：少样本/跨域泛化的可信报告，必须显式声明并审计“表示训练集与评估留出域的隔离关系”，并把折限定与共享协议之差 Δ 作为标准报告项——如同报告置信区间一样报告评估泄漏量。该规范不否定在可访问目标域无标签数据的部署场景中使用共享表示，而是要求此类结果不得与折限定结果直接比较、不得冒充跨域泛化。我们谨慎地不将此称为范式颠覆，而定位为评估方法层面一次小而硬的规范升级。

4.3 K 交叉点及其实践意义

图 2 与表 5 揭示的清晰交叉模式 ($K \approx 3-5$) 为方法选择提供了明确的实践指南：该交叉点不仅是两条性能曲线的几何交汇，更从量化层面划定了两种截然不同的部署情境。其一为采收季初期或新产区初次接入供应链的场景——此时每个产地可获取的有标注参考样本极为有限，物流与标注成本均不允许大规模标注等待。在该区间内，元学习方法具有显著的实践优势： $K=1$ 时折级 Cohen's $d = 4.14$ (表 6) 表明 ProtoNet-C 相对于 SVM 的误分类风险降低幅度在效应量层面属于大效应。其二为既有质量检验体系下的常规场景——例如口岸入境检验，具备条件长期维护适度规模的参考样本集。SVM 在 $K \geq 5$ 后的持续增长曲线，兼具算法简洁性与可解释性，在该情境下具有更强的实践推荐理由。两类方法不存在绝对优劣，适用性取决于部署条件。

需要明确上述结论的适用边界。本文所评估的是“中国市场流通批次条件下手持 NIR 的产地地域区分能力”，而非纯粹的地理化学成分信号——样品来自批发市场，品种构成、储藏条件和供应链处理差异均可能混入分类信号。 $K=3-5$ 的方法选择参考值仅在本文所用可见-近红外采集条件 (591–1001 nm 分析窗口) 和四个中国产区条件下成立，实际交叉点将随仪器型号、产地类别数量及域偏移强度而变化，实践者应针对具体部署背景重新估计，而非直接套用本文数值。

4.4 面均值：表面异质性作为信号与噪声

同一苹果在不同表面位置采集的光谱可能存在显著差异。向阳面叶绿素降解产物含量高、水分含量相对较低，背阴面则相反，这种果内光谱异质性有时与果间差异量级相当 (Lammertyn, Peirs, De Baerdemaeker and Nicolai, 2000; Pissard, Fernández Pierna, Baeten, Sinnaeve, Lognay, Mouteau, Dupont, Rondia and Lateur, 2013)。多位置均值化是抑制该异质性的自然策略，但其收益同时分布于两个层面：支持集原型质量的提升与查询样本预测稳定性的改善。本文通过 2×2 消融设计将两项贡献独立分解。在本实验设定下 (LOEO-2025 折, $K=5$, 50 次重复)，查询侧多面均值贡献 F1 提升 +0.071 (跨 5

Table 14 | 本文”表示层评估泄漏”与已知泄漏/污染形式的系统区分。

泄漏/污染形式	发生层	触发条件	与本文的关系
特征选择泄漏 (Ambroise and McLachlan, 2002; Kaufman et al., 2012)	特征选择	在含测试样本的全量数据上做特征筛选/统计	不同层: 本文泄漏发生在表示学习层, 与特征选择无关
预处理泄漏	预处理	全量数据拟合标准化/PCA 后再划分	不同层: 本文预处理严格折内归纳 (第 6.8 节), 泄漏专指编码器训练
预训练数据污染 (Magar and Schwartz, 2022; Kapoor and Narayanan, 2023)	样本级	测试样本本身出现在预训练语料	更弱触发: 本文不需样本级重复, 仅目标域分布参与表示训练即产生偏差
转导 / 无监督域适应	表示学习层	目标域无标签参与, 且声明为 target-aware	关键区分: 若声明留出域归纳泛化却让编码器见过目标域, 即协议错配; 本文要求显式区分归纳/转导口径
表示层评估泄漏 (本文)	表示学习层	共享编码器 + 留出域交叉 + 分布漂移下少样本元评估	本文形式化 (命题 1/2) 并跨六数据集、三模态、五漂移轴量化

种子置信区间稳健为正), 而支持侧仅贡献 +0.019 (跨 5 种子 95% 置信下界接近零)。即, 在相同扫描预算下, 将多位置扫描集中于待测样品 (查询侧) 比集中于参考集 (支持侧) 具有更高的效用。在扫描资源受限的现场部署条件下, 优先对查询侧执行多面扫描是更具效益的资源分配策略。需要说明的是, 上述结论来自单一折 (LOEO-2025) 的探索性分析, 支持侧增益的统计功效相对有限; 其他折或仪器条件下, 两侧贡献的比例可能有所不同, 推广时需审慎。

上述结果对基准设计亦具有方法论意义。若不控制测量协议而直接使用 2025 多面数据, 分类器实际上获得了比单面 2018/2019 年份更多的每苹果光谱信息, 导致年间直接性能比较缺乏公平性。本文 LOEO 协议通过将单面年份与多面年份在折间分离的方式处理这一问题。

4.5 LOEO-2025 折的多重混淆与折间解读

遵循第 3.4 节建立的解读框架, LOEO-2025 折作为”复合偏移压力测试”折, 其性能表现是年份偏移、测量协议偏移和产地类别变化三类因素共同作用的结果, 有必要区分解读。就以年份偏移为主的泛化而言, LOEO-2018 和 LOEO-2019 折提供了相对更干净的参考 (编码器源域含 2025 数据, 详见第 6.2 节注释): 两折均值下, 配置 C 在 $K=5$ 时宏 F1 达 0.685, 对比配置 A 的 0.637, 差距 $\Delta = +0.048$, 反映了排除测量协议差异后的纯年份偏移影响。LOEO-2025 折则构成最严苛的压力测试——年份、测量协议和产地类别三重变化同时发生 (配置 C, $K=5$: 0.668), 三类因素的独立贡献在当前设计下无法分解。在将 LOEO-2025 折结果与仅含年份偏移的 LOEO-2018/2019 折比较时, 需格外谨慎。泄漏分析中, 在 $\alpha=0.4$ 口径下 2025 折的评估泄漏 Δ (共享—折限定, 见表 4) 达 0.501, 明显大于 2018/2019 折的 0.250 与 0.339, 这与”共享编码器可从多面训练数据中学习协议特有的表示结构、在 2025 情节评估时获得额外优势”的预期一致; 但须注意此逐折排序依赖 α 口径——在 $\alpha=0$ 口径下逐折 Δ 大致持平 (2018/2019/2025 为 0.260/0.227/0.240、无漂移单调性), 因源质心融合在 2025 折的有害效应被移除、该折折限定基线回升 (见表 4 及第 3.3 节)。要在机制层面准确区分三类偏移的各

自贡献, 需要在三因素正交实验设计 (年份 $\times$ 协议 $\times$ 产地) 中独立控制各个维度, 这是未来工作值得深入的方向。

4.6 局限性与未来方向

本研究的结论范围限于手持 NIR 在中国市场批次条件下的产地区分能力, 其适用边界需明确界定。

样品来源与混淆因素。样品购自当地批发市场, 品种以富士苹果为主但未严格控制单一品系, 各批次的采收成熟度、储藏条件和供应链处理信息均未记录, 无法在事后进行分层或控制分析。NIR 光谱差异因此可能同时编码了地理产地、品种构成、成熟度、储藏和流通处理的综合效应, 无法干净地归因于”地理产地”本身。基于此, 本文将溯源声明的范围限定为”在市售批次条件下对产地相关光谱信号的判别”, 而非对纯地理化学成分的检测, 这一措辞已在摘要和讨论中一致体现。题目中的”跨年”聚焦于年份偏移这一主要问题, 但应认识到品种细分差异 (如不同产区的富士品系) 是该设定下不可忽视的混淆变量。如需隔离纯地理产地信号, 未来实验应采用单一品系、标准化采收期和受控储藏条件, 并系统记录样品元数据 (品种、采购渠道、储藏时长) 以支持分层分析。

地域和仪器推广性。数据集限于中国三至四个产区; 新疆分离相对容易、山东/山西重叠相对困难的判别格局, 是否能推广到欧洲 PDO 苹果或南美出口场景, 是个需要新数据才能回答的开放问题。本文使用的是可见-近红外波段 (591–1001 nm) 的采集体系; 若改用覆盖短波红外 (如 1000–2500 nm) 等不同频段的仪器, 判别模式可能有所不同。

方法层面。基线集合的覆盖面构成一项局限: 本文仅包含经典化学计量方法 (SVM、PLS-DA) 和基于元学习的原型方法, 未纳入现代深度基线 (如基于折限定源域训练的 1D ResNet (He et al., 2016) 或 1D Transformer (Vaswani et al., 2017)) 以及源域泛化基线 (如经验风险最小化 ERM+ 数据增强)。在与本文协议一致的折限定设置下, 纳入上述基线将使跨类方法比较更为完整。此外, 编码器采用平坦全连接网络; 如前所述, 无论采用何种架构, 共享编码器协议均会引入类型相同的分布泄漏, 其具体量级需针对各架构独立量化。面均

值消融目前仅在 LOEO-2025 折上进行, 在 2018/2019 样本满足多面测量条件时复现该分析, 可进一步增强增益分解结论的可推广性。此外, 本文未纳入迁移成分分析 (TCA) (Pan and Yang, 2010) 和子空间对齐 (SA) (Fernando, Habrard, Sebban and Tuytelaars, 2013) 等传统域适应基线; 在协议层面实现公平对照 (例如将 TCA/SA 限定于利用同量支持样本的“few-shot”模式) 后, 将其纳入比较框架可为小样本元学习方法提供更完整的参照背景。此外, 本文倡导的折限定源域训练范式在机制上更接近域泛化 (domain generalization) 而非经典的域适应——即在训练时无法访问目标域任何信息, 仅依赖源域多样性获得跨域泛化能力; 引入该领域的基线方法 (如元域泛化方法) 将是有价值的扩展。

往后看, 域差距感知自适应融合——从源-目标分布距离动态推断 α 而非固定——或许能在低差距场景中找回一部分源原型的收益, 同时规避高差距时的偏差陷阱。无监督域适应目标 (Ganin et al., 2016) 或基于梯度的对齐技术, 也可以尝试纳入情节训练循环。九域数据集和评估代码计划在接受后公开发布。

5 结论

三年、四产地、九个域, 2,424 个苹果、4,529 条光谱——本数据集并非研究的终点, 而是将两个长期悬而未决的问题纳入公共评估坐标系的基础性载体。其中, 评估泄漏是更易被忽视的问题: 共享编码器在 $K=5$ 条件下使 LOEO 宏 F1 相比无泄漏的折限定方案系统性虚高, 在同 α 的 like-for-like 对照下, 默认 $\alpha=0.4$ 口径 $\Delta=0.363$ 、主实验最优 $\alpha=0$ 口径 $\Delta=0.243$, 两口径均高度显著 ($\alpha=0.4$ 口径下并随各折漂移强度单调递增、2025 折达 0.501)。上述数值并非针对某一具体文献, 而是揭示了一类广泛使用的工作流的系统性后果——折限定编码器训练与归纳性协议说明, 应成为 LOEO 基准报告的基本规范要求, 而非可选项。方法选择层面, 完整 $\alpha \in [0, 1]$ 连续扫描确认 $\alpha=0$ (折限定情节原型) 是本跨年场景下的稳健默认配置。折限定 ProtoNet 在 $K=1$ 时相对于 SVM 的折级效应量 $d=4.14$ (大效应) 具有切实的实践意义, 但 $K \geq 5$ 后两者格局逆转——性能曲线的交叉点划定了以可用参考样本量为轴的方法选择边界, 在仪器和产区条件相近的场景中, 可获取的参考样本规模在相当程度上决定了方法的优先次序。面均值消融的发现具有相对独立的意义: 查询侧增益 +0.071 远大于支持侧 +0.019, 非对称格局在本实验条件下清晰, 但其外部效度有待在其他折与仪器条件下进一步验证。数据集和评估代码将在接受后公开, 以支持后续研究的直接复现与延伸。

6 材料与方法

6.1 数据集构建

苹果近红外漫反射光谱在三个采收年份 (2018、2019、2025) 和中国四个主要产区采集: 新疆 (XJ)、山东 (SD)、山西 (SX) 和甘肃 (GS)。所采集样品以富士 (Fuji) 品种为主, 购自当地批发市场, 各产地采样尽量覆盖多个果园批次以提高代表性。样品在室温 (20–25 °C) 下存放不超过三天后进行测量, 以减少储藏导致的光谱漂移; 不同年份样品来源于各自的采收季节, 年份间可能存在果实成熟度、糖度的系统性差异, 这是真实部署场景中跨年域偏移的来源之一。2018 和 2019 年数据集各包含三个产地 (XJ、SD、SX), 2025 年数据集包含三个产地 (XJ、SD、GS), 采购来源的自然变化同时为 2025 测试

Table 15 | 数据集统计: 按年份和产地的水果数量与光谱条数。3 年 $\times$ 4 产地共 12 个理论域单元, 实际填充 9 个 (每年采集 3 个产地; 2018/2019 采集新疆/山东/山西, 2025 采集新疆/山东/甘肃), 空白单元格含义: 2025 年甘肃为新产地, 2018/2019 未采集; 甘肃在 2025 折中构成新类别挑战。

年份	产地	域编号	水果数	每果扫描数	光谱条数
2018	新疆 (XJ)	E1	327	1	327
2018	山东 (SD)	E2	298	1	298
2018	山西 (SX)	E3	270	1	270
2019	新疆 (XJ)	E4	341	1	341
2019	山东 (SD)	E5	286	1	286
2019	山西 (SX)	E6	253	1	253
2025	新疆 (XJ)	E7	204	4–5	~864
2025	山东 (SD)	E8	215	4–5	~910
2025	甘肃 (GS)	E9	230	4–5	~980
合计	—	E1–E9	2,424	—	4,529

折引入了新类挑战。各采集域按年份-产地顺序编号为 E1 至 E9 (E1: 2018-XJ, E2: 2018-SD, E3: 2018-SX, E4: 2019-XJ, E5: 2019-SD, E6: 2019-SX, E7: 2025-XJ, E8: 2025-SD, E9: 2025-GS)。2018、2019 年光谱由光纤式可见-近红外点光谱仪采集 (原生 590–1250 nm, 2,048 波段), 每果仅在最均匀的赤道面采集一条光谱; 2025 年光谱由便携式可见-近红外推扫式高光谱成像系统采集 (原生 391–1001 nm, 346 波段), 每果在 4–5 个面位各采集一条光谱。跨年谐调时将两台仪器统一裁剪至 590–1001 nm 公共重叠窗口, 并以三次样条插值重采样到 2025 波长网格, 最终得到 229 个均匀分布的波段 (591–1001 nm)。仪器型号与详细采集参数将在接受后随数据集一并公开。

年份间存在重要的测量协议不对称性: 2018 和 2019 年每个苹果仅在单一表面位置采集一条光谱, 因此光谱条数与水果数相同; 2025 年每个苹果在果面 4 至 5 个分布位置各采集一条光谱 (多面设计)。具体样本量见表 15。2018 子集共 895 个水果、895 条光谱 (XJ: 327, SD: 298, SX: 270); 2019 子集共 880 个水果、880 条光谱 (XJ: 341, SD: 286, SX: 253); 2025 子集共 649 个水果 (XJ: 204, SD: 215, GS: 230), 多面扫描产生 2,754 条光谱 (平均 4.24 条/水果)。三年合计 2,424 个水果、4,529 条光谱。**本文所有实验中, “样本” 均指单条光谱测量记录;** 当需区分水果与光谱时, 将明确使用“水果” 或“光谱”。多面设计为 2025 数据提供了显式的果内空间异质性信息, 并在面均值消融实验中得到系统利用 (第 6.7 节)。

预处理对每条光谱独立进行 (图 11), 不使用任何跨样本统计量, 以保留年间分布差异——这对评估跨年泛化至关重要。第一步采用 15 点窗口、二阶多项式的 Savitzky-Golay 平滑 (Savitzky and Golay, 1964), 在抑制高频噪声的同时保留吸收峰结构; 其滤波系数仅由窗口长度决定, 与数据无关。第二步施加 SNV 变换 (Barnes et al., 1989), 逐条光谱去除因水果表面几何形态与漫反射光程差异引起的加性和乘性散射效应; SNV 为逐样本变换, 不依赖任何跨样本统计量。默认主流程即为“SG 平滑 + SNV”, 对目标年份完全盲。若需进一步的年内幅度对齐, 可选地施加严格源域 Z-score——其均值与标准差仅由各折源域光谱估计, 再以只读方式施加于目标域 (见下文归纳性说明)。对各年独立处理保留了跨年协变量偏移; 联合跨年标准化会人为对齐年间分布、导致过于乐观的结果, 故本文刻意回避。

三年 × 产地 NIR 光谱预处理前后对比 (每产地 5 条代表样本)




Figure 11 | 三年 × 产地 NIR 光谱预处理前后对比 (每产地随机 5 条代表样本, 公共波段 591–1001 nm)。左列为对齐后原始反射率光谱, 右列为 SNV 变换后光谱。原始光谱中产地间与年份间基线偏移及整体强度差异显著 (2025 年采用多面扫描协议, 与 2018/2019 单面采集在整体光谱强度上存在系统性差异); SNV 变换后各光谱在形状上趋于一致, 同时保留了可见光—近红外过渡区的判别相关结构, 包括约 600 nm 处的色素 (叶绿素/花青素) 吸收与约 970 nm 处的水分吸收, 与可解释性分析 (第 3.14 节) 识别的 top 判别波段一致。

关于归纳性 (inductive) 保证: 默认主流流程 (SG 平滑 + SNV) 本身即对目标年份完全盲: SG 滤波系数仅由固定窗口长度决定、与数据无关, SNV 为逐条光谱的行内标准化 (以每条光谱自身的均值与标准差归一), 二者均不使用任何跨样本或跨年份的聚合统计量。唯一可能引入聚合统计量的是可选的严格源域 Z-score 变体: 其年内均值与标准差仅在各折源域光谱上估计, 再以只读方式施加于目标域, 目标域光谱不参与任何参数估计。以 LOEO-2025 折为例, 该 Z-score 参数由 2018、2019 源域光谱计算, 2025 目标光谱仅作线性变换; 这不同于将 2025 数据纳入标准化估计的半转导 (semi-transductive) 做法, 后者会引入与本文所批评的共享编码器协议同类的分布泄漏。综上, 无论是否启用可选 Z-score, 在任何 LOEO 折中目标年份的分布统计量都不参与预处理参数估计, 从而确保预处理流程对目标年份完全盲的归纳性保证。

最终特征空间由每个样本 229 个光谱变量组成, 覆盖 591–1001 nm 可见光-近红外过渡区: 其中约 600 nm 处为色素 (叶绿素/花青素) 电子跃迁吸收, 长波端包含 O-H 与 C-H 键的高阶泛音及合频 (含约 970 nm 处的水分吸收)。这些区间承载了已被证实可区分苹果产地的可溶性固形物、有机酸与水分信息 (Nicolai et al., 2007; Pissard et al., 2013; Lammertyn et al., 2000)。

图 12 进一步给出了九个采集域之间的两种分布距离度量。无论采用线性 MMD² 还是中心点欧氏距离, 2025 年的三个域与 2018/2019 六个单面域之间都表现出更大的跨域差异, 说明跨年迁移难度不仅来自类别变化, 也来自测量协议和年份条件的共同漂移。

6.2 评估框架: 留一集外 (LOEO)

主要评估框架为留一年外 (Leave-One-Year-Out, LOEO-Year, 本文缩写沿用 LOEO 指称该年份级别的留出协议, 以区别于通用的 “leave-one-out” 交叉验证), 每个采




Figure 12 | 九个采集域之间的分布差异可视化。左图为线性 MMD^2 ，右图为中心点欧氏距离；颜色越深表示域差异越大。2025 三个多面域与 2018/2019 六个单面域之间的距离整体更大，为后续 LOEO-Year 跨年迁移难度提供了数据层解释。

收年份依次被指定为目标域，其余两年作为源域。由此定义三个评估折：(i) LOEO-2018：源域 = {2019, 2025}，目标域 = 2018；(ii) LOEO-2019：源域 = {2018, 2025}，目标域 = 2019；(iii) LOEO-2025：源域 = {2018, 2019}，目标域 = 2025。2025 折构成最难评估场景，因为甘肃是源域中不存在的新产地，而新疆和山东在不同测量条件下（单面对比多面）出现在源域中。所有报告结果为每折 50 次独立重复的均值，每次重复使用新的情节采样和随机种子。主要性能指标为宏 F1，无论样本不平衡如何，均等权重所有产地类别。

评估协议分类。为精确界定评估泄漏的边界，有必要区分三类评估协议：(i) 纯源域折限定协议——编码器仅在当前折的源域上训练，目标域数据在评估期间完全不可见；这是本文倡导的无泄漏标准；(ii) 无监督目标域暴露协议——编码器在含目标域无标签数据的全量数据上进行表示学习（如半监督或自监督预训练），目标域数据参与了表示空间的塑造，但未提供标签监督；(iii) 有标签目标域适应协议——编码器或分类器在含目标域标签样本的条件下进行微调，对应于校准迁移场景。本文所称“评估泄漏”，指当第 (ii) 或第 (iii) 类协议被用于 LOEO 基准测评、却以第 (i) 类归纳泛化的名义报告时引入的分布泄漏——即留出域的统计在评估前已通过共享编码器训练进入模型参数。需明确的是，本文主实验的共享编码器在含目标域有标签数据上元训练，其协议对应第 (iii) 类，故所测泄漏是**标签感知泄漏的上界**；我们在第 3.11 节以四编码器分解把它进一步剥离为第 (iii) 类的标签感知分量 Δ_{sup} 与第 (ii) 类的纯无监督暴露分量 Δ_{unsup} ，并诚实报告后者很小、CI 掠过 0。这一问题属于基准公平性问题，而非对第 (ii) / (iii) 类协议本身的否定；在声明为 target-aware（转导）的部署场景中，让编码器见过目标域是合理的，但此时不应以第 (i) 类归纳泛化的名义报告，也不应与第 (i) 类协议结果直接比较。

折限定编码器的正式定义。正式定义两种可量化比较的协议：共享编码器协议在所有九个域上联合预训练编码器，在 LOEO 评估中冻结，对应已发表元学习的常见做法；折限定编码器协议为每个 LOEO 折从头重新训练编码器，仅使用源域情节，编码器训练期

间目标折信息完全不可访问。本文中所有性能比较均使用折限定编码器，除非明确注明。

LOEO-2025 折的多重混淆说明。LOEO-2025 折并非纯粹的时间域偏移折，而是同时混淆了三类独立变化——(i) 年份偏移 (2018/2019 → 2025)；(ii) 测量协议偏移 (单面 → 多面扫描)；(iii) 类别空间变化 (SX → GS, 甘肃为新产地)。因此，LOEO-2025 折报告的性能下降幅度不能单独归因于年份变化；所有基于 2025 折的结论均应在“三重偏移”背景下解读。相比之下，LOEO-2018 和 LOEO-2019 折的目标侧以年份偏移为主，提供了相对更干净的时间泛化参考（见表 4）；但需注意，这两折的编码器源域均包含 2025 年数据（多面协议、甘肃新产地），因此编码器表示仍受 2025 来源数据影响，严格意义上不能将其称为“纯年份偏移”折。甘肃 (GS) 为新类别，在 2018 和 2019 源域中均不存在；在该折的 ProtoNet-C 评估中，GS 类的源域质心 $c_{\text{GS}}^{\text{src}}$ 无法定义，融合权重自动退化为 $\alpha = 0$ 。XJ 和 SD 类在 2025 折中有源域质心（由单面 2018/2019 光谱计算），但与多面 2025 目标光谱存在协议不匹配，这是 α 消融实验（第 6.6 节）中考察的主要因素。

情节构建细节。每个评估情节从目标折中随机采样 3-way K -shot 支持集和每类 15 个查询样本（共 45 个查询光谱）。为防止水果内信息泄漏，支持集与查询集在**水果个体 (fruit-ID) 层面严格不相交**：对于每个水果，其所有面扫描光谱被整体分配至支持集或查询集之一，同一水果的任何面扫描光谱绝不同时出现在支持集和查询集中。这一约束确保模型无法通过“在支持集中见过同一水果的不同角度光谱来”识别“查询集中的水果”，排除了水果内泄漏对面均值分析和 LOEO-2025 折结果的影响。元训练情节从源域进行类似的水果级不相交采样。每次独立重复使用新的随机种子，不同重复间情节采样相互独立。

6.3 评估泄漏的理论刻画

折限定与共享编码器协议的经验差距并非实现层面的偶然，而是分布漂移下评估设计的原理性缺陷。本节在一个可解析的线性-高斯最近原型模型下，将其形式化为一个关于**评估泄漏偏差非负性**的定理，从而把“共享编

机器虚高”从经验观察升级为可证伪的规律（完整证明与经交叉模型对抗校验的推导见补充材料 §S1）。

设定与假设。目标域 T 上类 c 的样本服从 $x|c \sim \mathcal{N}(\mu_c, \Sigma)$ （同协方差、类等概率）；编码器为线性映射 $\phi_W(x) = Wx$ ， W 取自对两协议相同、且满足非退化下界（各类均值差与投影噪声一致有下界 $\rho > 0$ ）的紧致可行集 $\mathcal{W}$ ；采用欧氏最近原型规则，并在**总体原型**（ $p_c = W\mu_c$ ，即大 K/oracle 极限）下分析。定义类对 (c, c') 的**嵌入可分性**（查询沿决策法向投影的信噪比，非 Mahalanobis 距离） $s_{cc'}(W; \mathcal{D}) = \|W(\mu_c^{\mathcal{D}} - \mu_{c'}^{\mathcal{D}})\| / \sqrt{\bar{d}_{cc'}^{\top}(W\Sigma^{\mathcal{D}}W^{\top})\bar{d}_{cc'}}$ ，可分性目标 $J(W; \mathcal{D}) = \sum_{c < c'} w_{cc'} s_{cc'}^2(W; \mathcal{D})$ （ $w_{cc'} > 0$ ），它是 ProtoNet 度量损失在该高斯模型下的总体对应。两协议编码器分别为源域目标的极大点 $W_R = \arg \max_W J(W; \text{src})$ 与汇合目标的极大点 $W_H = \arg \max_W [(1 - \lambda)J(W; \text{src}) + \lambda J(W; T)]$ ， $\lambda \in (0, 1]$ 反映留出域 T 在汇合训练集中的有效权重。

引理 1（总体原型成对正确概率）。在上述设定与总体原型下，类 c 查询更近其本类原型（相对 c' ）的概率恰为

$$\Pr[\text{正确} | (c, c')] = \Phi(s_{cc'}(W; T)/2), \quad (1)$$

Φ 为标准正态 CDF。由决策中垂超平面投影可知该概率仅经 $s_{cc'}$ 依赖 W, Σ （与法向正交的协方差分量不影响），且对 $s_{cc'}$ 严格递增。（有限 K 时样本原型带噪、判别法向亦随机，精确成对概率为两高斯的正交概率 $\Pr[B^{\top}D > 0]$ ，一般不再是单一 s 的函数；该噪声为两协议共享，正式实验以 $K \in \{1, 3, 5, 10, 20, 50\}$ 经验检验有限 K 下的次序。）

引理 2（汇合编码器的目标域可分性目标不低于源域编码器）。由 W_R, W_H 的最优性，

$$J(W_H; T) - J(W_R; T) \geq \frac{1-\lambda}{\lambda} (J(W_R; \text{src}) - J(W_H; \text{src})) \geq 0. \quad (2)$$

该式仅界定标量目标 $J(\cdot; T)$ ，不单独界定任一 $s_{cc'}$ 或精度。

定理（评估泄漏偏差非负，二类）。设 A_H, A_R 为共享、折限定协议在 T 上的期望少样本精度， $\Delta := A_H - A_R$ 。在上述假设、总体原型与 $C = 2$ 下，

$$\Delta = \Phi(s(W_H; T)/2) - \Phi(s(W_R; T)/2) \geq 0, \quad (3)$$

当且仅当 $s(W_H; T) = s(W_R; T)$ 时取等。（多类 $C > 2$ 的条件性推广见下文命题 1；因改变 W 同时改变各决策法向的相关结构，仅成对可分性均值支配不足以保证多类精度支配，故需显式耦合条件。）

推论。(i) 无漂移即无泄漏：若源域与目标域同分布且极大点唯一，则 $J(\cdot; \text{src}) \equiv J(\cdot; T) = J_{\text{pool}}$ ， $W_H = W_R$ ， $\Delta = 0$ ；评估泄漏是分布漂移的产物。(ii) 零漂移处消失、漂移下一般为正： Δ 关于源/目标参数连续、在无漂移集上取零；当 W_R 非汇合目标的极大点（源域最优与目标域最优编码器相异的一般情形）且 (2) 严格时， $s(W_H; T) > s(W_R; T)$ ，二类下 $\Delta > 0$ 。(iii) 原理性修复：要无偏估计跨域少样本泛化，表示学习的训练集必须与评估留出域不相交，这正是折限定协议。（有限 K 的原型噪声使 A_R, A_H 同降， Δ 的 K 依赖为经验刻画，不作闭式单调断言。）

命题 1（多类 $C > 2$ 条件性非负）。上述二类定理不能由引理 2 单独推广到多类，因为改变 W 会同时改

变各决策法向的相关结构。我们给出一个显式充分条件下的严格多类结果。对真实类 c ，定义其相对各竞争类 $c' \neq c$ 的标准化决策边际向量 $Y_c(W) \in \mathbb{R}^{C-1}$ ，总体原型下 $Y_c(W) \sim \mathcal{N}(m_c(W), R_c(W))$ ，其中均值第 c' 坐标为 $\frac{1}{2}s_{cc'}(W; T)$ ， $R_c(W)$ 为标准化边际相关矩阵；类 c 正确当且仅当 $Y_c(W)$ 落入正卦限。若 (i) 同类噪声相关结构在两协议下相同 $R_c(W_H) = R_c(W_R)$ ，且 (ii) 各成对可分性坐标支配 $s_{cc'}(W_H; T) \geq s_{cc'}(W_R; T) \forall c'$ ，则借助辅助空间上的同分布公共噪声耦合可得逐类正卦限概率支配 $P_c(W_H) \geq P_c(W_R)$ ，从而 $A_H \geq A_R$ ，即 $\Delta \geq 0$ 。该条件为充分而非必要，可用目标域大样本诊断（核对 $\hat{R}_c$ 变化与各 $\hat{s}_{cc'}$ 增量的符号）；正文多类实证不依赖其成立，仅将其作为多类可证明性的显式边界（完整证明见补充材料 §S1）。

命题 2（漂移依赖的显式泄漏下界）。把“漂移越大、泄漏越大”提升为解析下界。定义**泄漏相关漂移**为汇合目标缺口 $D_{\text{pool}, \lambda} := J_{\lambda}(W_H) - J_{\lambda}(W_R) \geq 0$ （ $J_{\lambda} = (1 - \lambda)J(\cdot; \text{src}) + \lambda J(\cdot; T)$ ），它刻画“令目标域进入表示训练后可分性目标相对源域最优编码器能额外获得多少”。设目标域信噪比在可行集上有上界 $S_T < \infty$ （由 $\mathcal{W}$ 紧致与非退化保证）。则二类下

$$\Delta \geq \frac{\exp(-S_T^2/8)}{4\sqrt{2\pi} w S_T \lambda} D_{\text{pool}, \lambda}, \quad (4)$$

右端在 $D_{\text{pool}, \lambda} = 0$ （无漂移）时为零、关于漂移单调不减、在漂移严格为正时给出严格正下界（证明见补充材料 §S1）。**须强调：原始输入空间 MMD 不是式 (4) 中的充分漂移量。**反例：源、目标类均值共同平移 $a \neq 0$ 时，类间间隔与最近原型可分性不变， $\Delta = 0$ ，但线性核 $\text{MMD} = a^2 > 0$ 。因此原始 MMD 只在“其下控制泄漏相关可分性漂移”的额外校准假设下才进入下界；否则 Δ 对 MMD 的关系应作经验规律报告而非无条件定理——这与第 3.10 节跨数据集回归中 MMD 斜率不显著的观察一致。

该理论给出的可证伪核心是 $\Delta \geq 0$ （二类严格、多类在命题 1 条件下严格），以及泄漏受泄漏相关漂移而非原始 MMD 的下界控制。本文在苹果 NIR、公开 OliveOil、及玉米/药片/芒果/Indian Pines 共六数据集上检验（第 3.3、3.9、3.10 节）：泄漏跨领域稳健为正，而原始 MMD 非线性预测其量级——与理论及其诚实边界完全吻合。

命题条件的经验诊断与有限 K 验证。为把理论与实际神经编码器、有限 K 、多类 regime 衔接，我们对命题 1 的充分条件作直接诊断（脚本 28_g2_theory_diagnostic）。在四个多类数据集的 13 个留一域折上，于目标域嵌入中估计各类对可分性 $s_{cc'}$ ，命题 1 条件 (ii) “坐标支配”（ $s_{cc'}(W_H; T) \geq s_{cc'}(W_R; T)$ ）的成立比例均值达 0.862；尤为一致的是，坐标支配比例最低的折（Indian Pines 某高漂移象限，仅 0.40）恰是第 3.10 节中唯一泄漏为负的折——即理论条件在何处失效，泄漏便在何处不再为正，二者机制对应。条件 (i) 标准化边际相关结构变化在点光谱数据集上很小（ ≤ 0.13 ），在高光谱成像上较大，与该模态更强的几何重排一致。此外，我们以有限 K 样本原型（而非总体原型）在线性-高斯模型中经验估计 $\mathbb{E}[\Delta]$ ：在 $K \in \{1, 3, 5, 10, 20\}$ 全程 $\mathbb{E}[\Delta] > 0$ （+0.020 至 +0.006），且单情节 $\Delta \geq 0$ 的概率为 0.81–0.93，表明非负泄漏在超出总体原型极限的有限 K regime 依然稳健成立。

正式统计检验与真实嵌入机制验证。为把上述描述性诊断升为正式推断，并将有限 K 论证从解析仿真

提升到真实神经嵌入，我们进一步做两项检验（脚本 29_g2_theory_validation）。其一，把坐标支配比例作为命题 1 条件强度的连续代理，检验其与实际泄漏 Δ ($K=5$, 真实目标域嵌入上重采样有限原型所得) 逐折的关系：二者呈正相关 (Spearman $\rho = +0.44$)，方向与理论一致；置换检验 $p = 0.12$ 未达显著，我们诚实地将其归因于折数有限 ($n=13$) 导致的功效不足，以及真实嵌入下所有 13 折 Δ 均为正使“失效折”对照几近缺失。坐标支配比例本身则稳健地高于随机基准 0.5：均值 0.813，2000 次 percentile bootstrap 95% CI 为 [0.682, 0.931]，下界远高于 0.5，为命题 1 条件 (ii) 提供了正式的证据。其二，我们在真实目标域嵌入（共享编码器 W_H 与折限定编码器 W_R 的实际输出）上重采样有限 K 原型，逐 K 计算 $\Delta(K)$ ： $K \in \{1, 3, 5, 10, 20\}$ 上 $\mathbb{E}[\Delta]$ 分别为 +0.079, +0.079, +0.078, +0.073, +0.062，逐折为正比例达 0.69–1.00。真实神经嵌入上的非负泄漏幅度明显大于线性-高斯仿真 (0.06–0.08 对 0.006–0.02)，说明理想化模型是保守下界、真实表征几何进一步放大了泄漏。这两项检验把命题 1/2 从理想化陈述连接到本文实际的多类、有限 K 、神经编码器实验条件。

6.4 ProtoNet-C：源域质心融合原型网络

原始原型网络 (Snell et al., 2017) 将 K 个支持样本的均值嵌入作为类原型，然后在平方欧氏距离下将查询样本分配给最近原型。在 K 极小时（如 $K=1$ ），单样本原型具有高方差，源域中丰富的类统计信息未被利用。

ProtoNet-C (C 代表质心融合) 通过将每个情节原型 $\mathbf{c}_k^{\text{task}}$ 与源域质心 $\mathbf{c}_k^{\text{src}}$ 线性插值来解决这一问题：

$$\hat{\mathbf{c}}_k = (1 - \alpha) \mathbf{c}_k^{\text{task}} + \alpha \mathbf{c}_k^{\text{src}}, \quad (5)$$

其中 $\alpha \in [0, 1]$ 为融合权重， $\mathbf{c}_k^{\text{src}}$ 为类 k 所有源域样本的均值嵌入， $\mathbf{c}_k^{\text{task}}$ 为当前情节支持集的 K 样本均值。当 $\alpha = 0$ 时模型退化为原始 ProtoNet；当 $\alpha = 1$ 时模型退化为完全锚定在源原型上的最近质心分类器。

偏差-方差视角：融合公式 (5) 可从偏差-方差权衡的角度理解。在 K 极小时， $\mathbf{c}_k^{\text{task}}$ 是类中心的高方差估计；当源-目标域差距较小时，注入 $\mathbf{c}_k^{\text{src}}$ 可降低估计方差，代价是引入可接受的偏差，从而可能提升期望分类精度 (Ben-David et al., 2010)。然而，当域差距超过某个阈值——如跨年分布偏移或测量协议不匹配——源质心引入的偏差将主导，导致融合权重 $\alpha > 0$ 反而有害。本文将在第 3.6 节通过控制实验检验该理论预测，以确定在苹果跨年 NIR 场景下适宜的 α 取值。

编码器 f_θ 为五层全连接网络 (输入 229, 隐藏维度 512-256-128-64, ReLU 激活, dropout 0.3 (Srivastava, Hinton, Krizhevsky, Sutskever and Salakhutdinov, 2014))，投影到 64 维 ℓ_2 归一化嵌入空间。元训练采用情节策略：每个情节从源域采样 3-way K -shot 任务，用 Adam 优化器 (Kingma and Ba, 2015, $lr = 10^{-3}$) 最小化查询预测的交叉熵损失。训练进行 500 轮，每轮 100 个情节；在留出源验证划分上宏 F1 最高的检查点用于评估。

6.5 基线方法

与 ProtoNet-C 并行比较四种基线方法。SVM 基线采用 C-支持向量分类器 (C-SVC, RBF 核)，正则化参数 $C \in \{0.01, 0.1, 1, 10, 100\}$ 和核宽度 $\gamma \in \{\text{scale}, 0.001, 0.01, 0.1, 1\}$ 通过源域验证集 5 折交叉验证网格搜索选取；测试时分类器在 K 个目标域支持样本上重新拟合（无超参数重新选取，使用源域最优超参数）。PLS-DA 使用 K 个支持样本构建 PLS 投

影，潜在成分在 $[2, \min(10, K - 1)]$ 范围内通过留一交叉验证优化；当 $K \leq 2$ 时潜在成分数固定为 1。原始 ProtoNet 是 ProtoNet-C 在 $\alpha = 0$ 时的特例，使用与 ProtoNet-C 架构和训练流程完全相同的折限定编码器，在 $K \in \{1, 3, 5, 10, 20, 50\}$ 下均有报告（各折统一采用单次随机面位评估，与 2018/2019 折的单面采集协议保持一致）。最近质心在嵌入空间中按最近支持集均值对每个查询分类，无任何元训练，作为最简单的基于原型的参考。

需要说明的是，本文未将迁移成分分析 (TCA) (Pan and Yang, 2010)、子空间对齐 (SA, Subspace Alignment) (Fernando et al., 2013) 等传统无监督域适应方法纳入基线。上述方法在执行分布对齐时通常需要访问目标域全量无标签数据，与本文情节式 K -shot 评估框架——仅允许在推理阶段访问目标域 K 个有标签支持样本——存在协议层面的根本性不对称，直接比较将引入对传统方法有利的信息优势。因此，在当前评估协议下纳入 TCA/SA 无法实现公平对照；将其纳入可行的未来对照框架是值得考虑的扩展方向，详见第 4 节。

6.6 Alpha 消融：源原型融合权重

为确定源质心融合在各折中是否有益并识别最优 α ，比较三种代表性配置：**配置 A** 在所有三个 LOEO 折中统一使用 $\alpha = 0.4$ ；**配置 B** 在 2018 和 2019 折使用 $\alpha = 0.4$ ，在 2025 折使用 $\alpha = 0$ （动机：在单面数据上训练的源域质心可能无法代表多面 2025 目标分布）；**配置 C** 在所有位置设 $\alpha = 0$ ，等价于折限定编码器的原始 ProtoNet。该消融直接检验源质心注入在跨年分布偏移下是有益还是有害。

此处 $\alpha = 0.4$ 作为代表性非零融合权重，通过在源域验证划分上对 $\alpha \in \{0.1, 0.2, 0.4, 0.6, 0.8\}$ 进行粗粒度网格搜索确定：在 LOEO-2018 和 LOEO-2019 折的源域验证集上， $\alpha = 0.4$ 在该候选集中给出了次优至中等水平的验证性能，同时与域适应文献中融合权重多设于 $[0.3, 0.5]$ 区间的惯例一致 (Pan and Yang, 2010)。完整的 $\alpha \in [0, 1]$ 连续敏感性曲线见第 3.6 节 (图 4)。

6.7 面均值消融

2025 子集每个苹果约提供五个测量位置，使我们能够系统检验多面聚合如何影响分类。我们定义 2×2 设计，交叉支持侧策略（单面对比多面均值）和查询侧策略（单面对比多面均值）： $S_{\text{单面}}Q_{\text{单面}}$ （基线）、 $S_{\text{多面}}Q_{\text{单面}}$ （仅支持侧均值）、 $S_{\text{单面}}Q_{\text{多面}}$ （仅查询侧均值）、 $S_{\text{多面}}Q_{\text{多面}}$ （双侧均值，主要方法）。该 2×2 设计允许均值增益的主效应分解和交互作用评估。消融在 $K = 5$ 、50 次重复情节的 LOEO-2025 折上进行，因为 2025 是唯一具有多面数据的年份。还包含 SVM-Kshot 对照，其中多面苹果的每个面均作为独立训练样本，使 SVM 能访问约 $5K$ 个有效训练实例。

6.8 多种子方差分析设计

跨论文比较一项 NIR 基准的前提，是评估不确定性的各个来源被显式拆解、并分别给出量级，这也呼应机器学习界对可复现性报告规范的倡议。本文将随机性来源分为三层：(i) **数据划分层**—LOEO-Year 在年份粒度上是确定性留出，不存在随机划分自由度；(ii) **编码器训练层**—每个 LOEO 折独立用 5 个种子 (42–46) 从头重训 ProtoEncoder，其余训练超参（架构、Adam $lr = 10^{-3}$ 、CosineAnnealing、patience=12×100 episodes、 $n_{\text{way}}=3$ 、 $k_{\text{support}}=5$ 、 $q_{\text{query}}=10$ 、temperature=10）与第 6.4 节完全一致；(iii) **情节采样层**—每个编码器再用 50 个独立

种子 (42–91) 抽取支持/查询情节。

由此构成 3 折 $\times$ 5 编码器种子 = 15 个独立编码器, 每个编码器再展开 6 个 K 值 $\times$ 50 个情节种子 $\times$ 4 个方法 (vanilla ProtoNet $\alpha = 0$ 、SVM、PLS-DA、最近质心) = 18,000 次评估的全因子设计; 其中 ProtoNet 评估方式与第 6.5 节“统一单面查询协议”严格一致。所有编码器检查点 (.pt) 的 SHA-256 前 16 位哈希、源域验证精度、训练终止 episode 一并记录。完整实验记录 (编码器元数据、长格式情节级 F1 记录、汇总方差分解表、方向一致性表) 随论文附件公开。

评估方差从两个轴量化: (a) 编码器层标准差 (between-encoder SD) 一对每个编码器先按 50 个情节求宏 F1 均值, 再求 5 个编码器之间的标准差; (b) 情节层标准差 (within-encoder SD) 一每个编码器内 50 个情节的标准差, 再对 5 个编码器求平均。两者之比反映“换一个种子重训编码器”和“换一组随机情节抽样”对结果的相对扰动量级, 并由此界定“50 次重复 std”作为单一不确定性指标的适用区间 (详见第 3.2 节)。

6.9 硬件、确定性配置与双阶段实验

本文实验分两个阶段执行并分别披露。**Formal 阶段 (正文报告的全部核心结果)** 在单块 NVIDIA RTX 4090 (24 GB) 上以 CUDA 运行, 覆盖评估泄漏量化、 K -shot 方法对比、 α 消融、面均值消融、统计检验、逐类 F1、外部验证、负控、不确定性校准、可解释性与 LLH-GBID 综合评价, 统一使用 5 个固定模型种子 {20060515, 20041210, 19810915, 2023, 2024}, 并开启 `torch.use_deterministic_algorithms(True)`、`cuda.deterministic=True`、`cuda.benchmark=False`; 输入数据以 SHA-256 校验锁定冻结正典。**Pilot/补充阶段** 在 Apple Silicon MPS 上运行, 仅用于可行性验证与编码器-情节双层方差分解 (第 3.2 节, 种子 42–46 / 42–91); MPS 后端对个别算子不提供确定性内核, 故该部分结果明确标注硬件来源为 MPS, 仅作方法学补充, 不承担核心结论。所有报告的标准差仅反映模型随机性 (编码器初始化与情节采样), 不含硬件层数值抖动; 任何跨独立采收季的总体统计推断均需未来独立数据集验证。每条正式 run 的 GPU 型号、wall-clock、GPU-hours、峰值显存、能耗与碳当量经 `track_compute` 记录并汇入各脚本 `xlsx` 的 `compute` 表。

6.10 统计检验

主要方法比较 (ProtoNet-C 对比 SVM) 以折为主分析单位 ($n_{\text{primary}} = K_{\text{outer}} = 3$): 每折先在 50 次重复情节上求宏 F1 均值, 再于 3 折上做配对检验并跨 5 个模型种子聚合报告。同时应用配对 Student's t 检验和 Wilcoxon 符号秩检验 (Wilcoxon, 1945) 评估显著性, Cohen's d (Cohen, 1988) 量化效应量 (约定: $|d| < 0.2$ 可忽略, 0.2–0.5 小, 0.5–0.8 中, ≥ 0.8 大)。对于跨多个 K 值的比较, Benjamini-Hochberg 程序 (Benjamini and Hochberg, 1995) 将虚假发现率控制在 5%。此外, 折间分析 (LOEO-2018 和 LOEO-2019 对比 LOEO-2025) 提供了对结论方向的额外独立核验, 因为两对单面折与 2025 折在数据来源上互不重叠。

作者贡献声明 (CRediT)

李盼林: 概念化、方法论、软件、验证、形式分析、数据整理、可视化、撰写——原始草稿。张庆莉: 调查 (样品采集与光谱测量)、数据整理、验证。焦齐太: 资源

(近红外采集仪器与测量平台)、调查 (光谱采集)。孙佳美: 调查 (样品采集)、数据整理、可视化。黄华: 概念化、监督、项目管理、资金获取、撰写——审阅与编辑。

利益冲突声明

作者声明不存在已知的可能影响本文所报告工作的竞争性经济利益或个人关系。

数据与代码可用性

本文全部核心方法实现 (评估泄漏量化、 $\Delta_{\text{sup}}/\Delta_{\text{unsup}}$ 四编码器分解、排序翻转、跨领域混合效应统计、理论诊断与去风险对照)、预处理流程、数据集卡与复现指南已在公开 GitHub 仓库发布: <https://github.com/2004lryan/016representation-layer-eval-leakage> (MIT 许可)。跨领域验证与监督/无监督泄漏分解所用数据集均为公开标准基准: OliveOil 光谱、玉米近红外 (Cargill corn (Eigenvector Research, 2000))、药片近红外 (2002 IDRC shootout (IDRC, 2002))、芒果近红外 (Anderson et al., 2020)、Indian Pines 高光谱 (Baumgardner et al., 2015), 均可经标准渠道获取 (仓库 `data/DATA.md` 记录各集来源、许可与 SHA-256 校验)。支撑本文结论的九域苹果近红外光谱数据集为新疆农业大学内部数据, 受限获取 (managed access), 暂未公开发布——其公开存档目前尚未获得数据所有方授权; 研究者如需复现或扩展本文实验, 可向通讯作者按个案提出申请, 并遵循新疆农业大学的数据共享政策。该苹果数据集的数据集卡 (含各域描述性统计、按水果 ID 的分割逻辑与 SHA-256 校验) 已随上述公开代码仓库一并发布。在期刊单盲审稿流程中, 可经编辑部安排为审稿人提供仅供评审的匿名化数据访问链接以支持独立核验。

资金来源

本研究由新疆维吾尔自治区科技创新团队 (天山创新团队) (2022TSYCTD0011)、国家自然科学基金项目 (61367001) 和 2025 年国家级大学生创新训练计划 (202510758022) 资助。资助方在研究设计、数据收集、分析、结果解释及论文撰写中未直接参与。

References

- Ambroise, C., McLachlan, G.J., 2002. Selection bias in gene extraction on the basis of microarray gene-expression data. *Proceedings of the National Academy of Sciences* 99, 6562–6566. doi:10.1073/pnas.102102699.
- Angelopoulos, A.N., Bates, S., 2023. A gentle introduction to conformal prediction and distribution-free uncertainty quantification. *Foundations and Trends in Machine Learning* 16, 494–591. ArXiv:2107.07511.
- Apicella, A., Isgrò, F., Prevete, R., 2025. Don't push the button! Exploring data leakage risks in machine learning and transfer learning. *Artificial Intelligence Review* 58, 339. doi:10.1007/s10462-025-11326-3.
- Barnes, R.J., Dhanoa, M.S., Lister, S.J., 1989. Standard normal variate transformation and de-trending

- of near-infrared diffuse reflectance spectra. *Applied Spectroscopy* 43, 772–777. doi:10.1366/0003702894202201.
- Bates, S., Hastie, T., Tibshirani, R., 2024. Cross-validation: what does it estimate and how well does it do it? *Journal of the American Statistical Association* 119, 1434–1445. doi:10.1080/01621459.2023.2197686.
- Ben-David, S., Blitzer, J., Crammer, K., Kulesza, A., Pereira, F., Vaughan, J.W., 2010. A theory of learning from different domains. *Machine Learning* 79, 151–175. doi:10.1007/s10994-009-5152-4.
- Benjamini, Y., Hochberg, Y., 1995. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B* 57, 289–300. doi:10.1111/j.2517-6161.1995.tb02031.x.
- Benmouna, B., García-Mateos, G., Sabzi, S., Fernández-Beltrán, R., Parras-Burgos, D., Molina-Martínez, J.M., 2022. Convolutional neural networks for estimating the ripening state of Fuji apples using visible and near-infrared spectroscopy. *Food and Bioprocess Technology* 15, 2226–2236. doi:10.1007/s11947-022-02880-7.
- Cen, H., He, Y., 2007. Theory and application of near infrared reflectance spectroscopy in determination of food quality. *Trends in Food Science & Technology* 18, 72–83. doi:10.1016/j.tifs.2006.09.003.
- Chen, W.Y., Liu, Y.C., Kira, Z., Wang, Y.C.F., Huang, J.B., 2019. A closer look at few-shot classification, in: *International Conference on Learning Representations*, pp. 1–16.
- Cohen, J., 1988. *Statistical Power Analysis for the Behavioral Sciences*. 2nd ed., Lawrence Erlbaum Associates, Hillsdale, NJ.
- Cortes, C., Vapnik, V., 1995. Support-vector networks. *Machine Learning* 20, 273–297. doi:10.1007/BF00994018.
- Danezis, G.P., Tsagkaris, A.S., Camin, F., Brusica, V., Georgiou, C.A., 2016. Food authentication: techniques, trends & emerging approaches. *TrAC Trends in Analytical Chemistry* 85, 123–132. doi:10.1016/j.trac.2016.02.026.
- Dwork, C., Feldman, V., Hardt, M., Pitassi, T., Reingold, O., Roth, A., 2015. The reusable holdout: Preserving validity in adaptive data analysis. *Science* 349, 636–638. doi:10.1126/science.aaa9375.
- Ekramirad, N., Khaled, A.Y., Doyle, L.E., Loeb, J.R., Donohue, K.D., Villanueva, R.T., Adedeji, A.A., 2022. Nondestructive detection of codling moth infestation in apples using pixel-based NIR hyperspectral imaging with machine learning and feature selection. *Foods* 11, 8. doi:10.3390/foods11010008.
- FAO, 2022. *FAOSTAT: Crops and Livestock Products*. Technical Report. Food and Agriculture Organization of the United Nations. Statistical Database, <https://www.fao.org/faostat/> (accessed 2026-04-15).
- Fearn, T., 2001. Standardisation and calibration transfer for near infrared instruments: a review. *Journal of Near Infrared Spectroscopy* 9, 229–244. doi:10.1255/jnirs.309.
- Fernando, B., Habrard, A., Sebban, M., Tuytelaars, T., 2013. Unsupervised visual domain adaptation using subspace alignment, in: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 2960–2967. doi:10.1109/ICCV.2013.368.
- Feudale, R.N., Woody, N.A., Tan, H., Myles, A.J., Brown, S.D., Ferre, J., 2002. Transfer of multivariate calibration models: a review. *Chemometrics and Intelligent Laboratory Systems* 64, 181–192. doi:10.1016/S0169-7439(02)00085-0.
- Finn, C., Abbeel, P., Levine, S., 2017. Model-agnostic meta-learning for fast adaptation of deep networks, in: *Proceedings of the 34th International Conference on Machine Learning*, pp. 1126–1135.
- Ganin, Y., Ustinova, E., Ajakan, H., Germain, P., Larochelle, H., Laviolette, F., Marchand, M., Lempit-sky, V., 2016. Domain-adversarial training of neural networks. *Journal of Machine Learning Research* 17, 1–35.
- Geladi, P., Kowalski, B.R., 1986. Partial least-squares regression: a tutorial. *Analytica Chimica Acta* 185, 1–17. doi:10.1016/0003-2670(86)80028-9.
- Gulrajani, I., Lopez-Paz, D., 2021. In search of lost domain generalization, in: *International Conference on Learning Representations (ICLR)*.
- Yu, C., Gong, B., Song, M., Zhao, E., Chang, C.I., 2022. Multiview calibrated prototype learning for few-shot hyperspectral image classification. *IEEE Transactions on Geoscience and Remote Sensing* 60, 1–13. doi:10.1109/TGRS.2022.3225947.
- Han, T., Wang, Z., Xu, S., Wang, J., Dou, J., Lan, Y., 2026. Synergetic application of near-infrared spectroscopy and electronic eye combined with an improved CNN-VMamba mixed network for soybean origin traceability. *European Food Research and Technology* 252, 252. doi:10.1007/s00217-026-05184-8.
- He, K., Zhang, X., Ren, S., Sun, J., 2016. Deep residual learning for image recognition, in: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770–778. doi:10.1109/CVPR.2016.90.
- Hospedales, T.M., Antoniou, A., Micaelli, P., Storkey, A.J., 2022. Meta-learning in neural networks: a survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 44, 5149–5169. doi:10.1109/TPAMI.2021.3079209.

- Kapoor, S., Narayanan, A., 2023. Leakage and the reproducibility crisis in machine-learning-based science. *Patterns* 4, 100804. doi:10.1016/j.patter.2023.100804.
- Kaufman, S., Rosset, S., Perlich, C., Stitelman, O., 2012. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data* 6, 1–21. doi:10.1145/2382577.2382579.
- Kingma, D.P., Ba, J., 2015. Adam: a method for stochastic optimization, in: *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*.
- Koh, P.W., Sagawa, S., Marklund, H., Xie, S.M., Zhang, M., et al., 2021. Wilds: A benchmark of in-the-wild distribution shifts, in: *Proceedings of the 38th International Conference on Machine Learning (ICML)*, pp. 5637–5664.
- Lammertyn, J., Peirs, A., De Baerdemaeker, J., Nicolai, B., 2000. Light penetration properties of NIR radiation in fruit with respect to non-destructive quality assessment. *Postharvest Biology and Technology* 18, 121–132. doi:10.1016/S0925-5214(99)00071-X.
- Li, L., Huang, W., Wang, Z., Liu, S., He, X., Fan, S., 2022a. Calibration transfer between developed portable vis/nir devices for detection of soluble solids contents in apple. *Postharvest Biology and Technology* 183, 111720. doi:10.1016/j.postharvbio.2021.111720.
- Li, L., Li, B., Jiang, X., Liu, Y., 2022b. A standard-free calibration transfer strategy for a discrimination model of apple origins based on near-infrared spectroscopy. *Agriculture* 12, 366. doi:10.3390/agriculture12030366.
- Liu, Y., Huang, J., Li, M., Chen, Y., Cui, Q., Lu, C., Wang, Y., Li, L., Xu, Z., Zhong, Y., Ning, J., 2022. Rapid identification of the green tea geographical origin and processing month based on near-infrared hyperspectral imaging combined with chemometrics. *Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy* 267, 120537. doi:10.1016/j.saa.2021.120537.
- Liu, S., Zhao, X., Zhu, Q., Huang, M., Guo, X., 2025b. A feature-enhanced approach based on joint domain alignment and multi-order derivative spectral reconstruction for predicting apple firmness using Vis-NIR spectroscopy. *Food Chemistry* 476, 143457. doi:10.1016/j.foodchem.2025.143457.
- Magar, I., Schwartz, R., 2022. Data contamination: From memorization to exploitation, in: *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pp. 157–165. doi:10.18653/v1/2022.ac1-short.18.
- Mishra, P., Passos, D., 2021. Deep chemometrics: validation and transfer of a global deep near-infrared fruit model to use it on a new portable instrument. *Journal of Chemometrics* 35, e3367. doi:10.1002/cem.3367.
- Mishra, P., Rutledge, D.N., Roger, J.M., Wali, K., Khan, H.A., 2021. Chemometric pre-processing can negatively affect the performance of near-infrared spectroscopy models for fruit quality prediction. *Talanta* 229, 122303. doi:10.1016/j.talanta.2021.122303.
- Nicolai, B.M., Beullens, K., Bobelyn, E., Peirs, A., Saey, W., Theron, K.I., Lammertyn, J., 2007. Non-destructive measurement of fruit and vegetable quality by means of near infrared spectroscopy: a review. *Postharvest Biology and Technology* 46, 99–118. doi:10.1016/j.postharvbio.2007.06.024.
- Pan, L., Li, H., Hu, Z., Zhang, M., Zhao, J., 2024a. Standard-free sample model transfer of visible/near-infrared spectral model of apple ripeness under seasonal variation. *Journal of Food Composition and Analysis* 128, 106028. doi:10.1016/j.jfca.2024.106028.
- Pan, L., Wu, W., Hu, Z., Li, H., Zhang, M., Zhao, J., 2024b. Updating apple Vis-NIR spectral ripeness classification model based on deep learning and multi-seasonal database. *Biosystems Engineering* 245, 164–176. doi:10.1016/j.biosystemseng.2024.07.010.
- Pan, S.J., Yang, Q., 2010. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering* 22, 1345–1359. doi:10.1109/TKDE.2009.191.
- Pissard, A., Fernández Pierna, J.A., Baeten, V., Sinnaeve, G., Lognay, G., Mouteau, A., Dupont, P., Rondia, A., Lateur, M., 2013. Non-destructive measurement of vitamin C, total polyphenol and sugar content in apples using near-infrared spectroscopy. *Journal of the Science of Food and Agriculture* 93, 238–244. doi:10.1002/jsfa.5779.
- Roberts, M., Driggs, D., Thorpe, M., et al., 2021. Common pitfalls and recommendations for using machine learning to detect and prognosticate for covid-19 using chest radiographs and ct scans. *Nature Machine Intelligence* 3, 199–217. doi:10.1038/s42256-021-00307-0.
- Savitzky, A., Golay, M.J.E., 1964. Smoothing and differentiation of data by simplified least squares procedures. *Analytical Chemistry* 36, 1627–1639. doi:10.1021/ac60214a047.
- Snell, J., Swersky, K., Zemel, R.S., 2017. Prototypical networks for few-shot learning, in: *Advances in Neural Information Processing Systems*, pp. 4077–4087.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., Salakhutdinov, R., 2014. Dropout: a simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research* 15, 1929–1958.

- Sung, F., Yang, Y., Zhang, L., Xiang, T., Torr, P.H.S., Hospedales, T.M., 2018. Learning to compare: relation network for few-shot learning, in: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 1199–1208. doi:10.1109/CVPR.2018.00131.
- Tian, Y., Wang, Y., Krishnan, D., Tenenbaum, J.B., Isola, P., 2020. Rethinking few-shot image classification: a good embedding is all you need? *arXiv preprint arXiv:2003.11539*.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I., 2017. Attention is all you need, in: *Advances in Neural Information Processing Systems*, pp. 5998–6008.
- Vinyals, O., Blundell, C., Lillicrap, T., Wierstra, D., Kavukcuoglu, K., 2016. Matching networks for one shot learning, in: *Advances in Neural Information Processing Systems*, pp. 3630–3638.
- Walsh, J., Neupane, A., Koirala, A., Li, M., Anderson, N., 2023. Review: The evolution of chemometrics coupled with near infrared spectroscopy for fruit quality evaluation. ii. the rise of convolutional neural networks. *Journal of Near Infrared Spectroscopy* 31, 109–125. doi:10.1177/09670335231173140.
- Walsh, K.B., Blasco, J., Zude-Sasse, M., Sun, X., 2020. Visible-NIR ‘point’ spectroscopy in postharvest fruit and vegetable assessment: the science behind three decades of commercial use. *Postharvest Biology and Technology* 168, 111246. doi:10.1016/j.postharvbio.2020.111246.
- Whalen, S., Schreiber, J., Noble, W.S., Pollard, K.S., 2022. Navigating the pitfalls of applying machine learning in genomics. *Nature Reviews Genetics* 23, 169–181. doi:10.1038/s41576-021-00434-9.
- Wilcoxon, F., 1945. Individual comparisons by ranking methods. *Biometrics Bulletin* 1, 80–83. doi:10.2307/3001968.
- Woodcock, T., Downey, G., Kelly, J.D., O'Donnell, C., 2007. Geographical classification of honey samples by near-infrared spectroscopy: a feasibility study. *Journal of Agricultural and Food Chemistry* 55, 9128–9134. doi:10.1021/jf072010q.
- Ye, Q., Meng, X., 2022. Highly efficient authentication of edible oils by ftir spectroscopy coupled with chemometrics. *Food Chemistry* 385, 132661. doi:10.1016/j.foodchem.2022.132661.
- Baumgardner, M.F., Biehl, L.L., Landgrebe, D.A., 2015. 220 band AVIRIS hyperspectral image data set: June 12, 1992 Indian Pine test site 3. *Purdue University Research Repository*. doi:10.4231/R7RX991C.
- Anderson, N.T., Walsh, K.B., Subedi, P.P., Hayes, C.H., 2020. Achieving robustness across season, location and cultivar for a NIRS model for intact mango fruit dry matter content. *Postharvest Biology and Technology* 168, 111202. doi:10.1016/j.postharvbio.2020.111202.
- Eigenvector Research, 2000. Corn dataset: NIR spectra of corn samples measured on three instruments (m5, mp5, mp6). Eigenvector Research Inc., standard chemometrics benchmark, <https://eigenvector.com/data/Corn/>.
- IDRC, 2002. 2002 International Diffuse Reflectance Conference software shootout: pharmaceutical tablet NIR data (two instruments). *International Diffuse Reflectance Conference*, Chambersburg, PA.