

NIPT 检测时点优化与胎儿异常判定模型

李盼林 张宁*

新疆农业大学数理学院, 乌鲁木齐 830052, 中国

* 通讯作者: zhangning0718@163.com

摘要

本研究通过数据驱动建模, 探讨了无创产前检测 (NIPT) 时点的优化策略与胎儿异常检出方法。通过分析 1600 余例 NIPT 病例, 研究识别出孕妇 BMI 与孕周是胎儿浓度 (fetal fraction) 的主要决定因素, 而胎儿浓度正是影响检测准确性的关键要素。对男胎而言, Y 染色体浓度与孕周呈正相关 ($r = 0.45$), 与 BMI 呈负相关 ($r = -0.32$)。一个 XGBoost 回归模型取得了稳健的性能 ($R^2 > 0.7$), 并凸显出体重与身高是显著的预测变量。对女胎而言, 一个整合了 Z 值、GC 含量、读段比例与 BMI 的概率模型, 在检出 21 三体、18 三体与 13 三体上取得了超过 95% 的准确率与低于 5% 的假阳性率。研究进一步提出按 BMI 分层的检测窗口——低、中、高 BMI 组分别为 12 周、14 周与 16 周——以确保胎儿 DNA 浓度充足。这些结果强调了个体化 NIPT 时点与基于模型的优化对于降低假阴性、提升检出效率的必要性。未来若能整合 AI 驱动的预测系统与基于胎儿细胞的混合检测手段, 有望实现实时、个体化且临床适用性更高的产前筛查。

关键词

XGBoost; 敏感性分析; NIPT; Y 染色体

1. 引言

无创产前检测 (non-invasive prenatal testing, NIPT) 是产前诊断领域的一项变革性进展, 它通过对母体血浆中游离的胎儿 DNA (cell-free fetal DNA, cfDNA) 进行测序, 实现了对胎儿染色体异常的早期、安全识别 [1]。自临床引入以来, NIPT 在检出常见三体 (包括 21 三体即唐氏综合征、18 三体即爱德华兹综合征、13 三体即帕陶综合征) 方面已达到很高的敏感性与特异性, 在一般人群中检出率常超过 99%, 假阳性率低于 0.1% [2]。该技术规避了绒毛膜取样、羊膜腔穿刺等侵入性操作所伴随的风险 (这些操作有 0.1%–0.3% 的流产风险), 因而在许多指南中成为首选的一线筛查工具 [1, 2]。然而, NIPT 的效力关键性地依赖于胎儿浓度——即源自胎盘滋养层的 cfDNA 所占的百分比, 它是胎儿遗传物质的替代度量。胎儿浓度低于 4% 会导致结果不确定或假阴性增多, 这凸显出: 必须借助优化策略, 才能在多样化的母体特征谱系上确保结果可靠 [3]。

影响胎儿浓度的关键母体与胎儿因素, 近年文献已有广泛研究。母体体质指数 (BMI) 是首要的调节因素: BMI 越高, 胎儿浓度越低, 原因在于血浆容积扩张与脂肪组织的贡献稀释了母体 cfDNA 中的胎儿成分 [3]。例如, 在肥胖孕妇队列 ($BMI \geq 30 \text{ kg/m}^2$) 中, 胎儿浓度平均比体重正常者低 2%–3%, 致使检测失败率高达 24%, 不得不重新采血或改用其他筛查方式 [3, 4]。孕周同样起正向作用: 胎儿浓度通常从第 10 周的 5%–10% 升至孕中期的 10%–20%, 但在高 BMI 情形下这一上升会被削弱, 从而推迟了最佳检测窗口 [4]。在男胎中, Y 染色体来源的序列可直接

测度胎儿浓度，并揭示出其与母体生理指标之间的非线性关系；采用 XGBoost 等机器学习模型的研究对此作了量化，显示 R^2 值大于 0.7，且 BMI 与孕周的特征重要性得分大于 0.1 [6]。此类模型使得为 NIPT 择时提供预测性框架成为可能，从而最小化风险——在高 BMI 群体中尤为关键，因为早期检出才能保住选择性减胎或靶向干预等治疗选项 [7]。

推广到女胎时，由于缺少 Y 染色体标志物，异常检出必须依赖对染色体 Z 值、GC 含量校正以及 21、18、13 号等常染色体读段比例的更复杂整合 [5]。困难来自测序偏倚与低胎儿浓度，二者会抬高假阳性率；近期的多任务概率模型引入广义可加模型（GAM）作偏倚校正，通过优先采用代价敏感的阈值来避免漏检，从而降低了假阳性率 [6]。例如，全基因组 NIPT 方法通过胎儿浓度感知的算法，把罕见非整倍体与拷贝数变异（CNV）的阳性预测值（PPV）提高了 15%–20% [8]。超声整合可进一步提升异常检出：将 NIPT 与孕早期超声联合，可检出多达 90% 的、单靠 NIPT 会漏掉的结构异常，如神经管缺陷或心脏畸形 [9]。

NIPT 时点与异常判定模型的优化，通过数据驱动的个体化来应对上述局限。按 BMI 分组（例如 < 25 、 $25\text{--}30$ 、 $> 30 \text{ kg/m}^2$ ）可实现定制化的检测排程：建议低 BMI 孕妇尽早检测，高 BMI 者延后检测或采用富集方案，以达到 $\geq 4\%$ 的胎儿浓度 [3, 4]。先进的计算工具——包括基于 k -mer 的胎儿浓度估计与用于异常分类的卷积神经网络——在低胎儿浓度情形下表现更优，即便浓度低至 2% 仍能取得大于 95% 的敏感性 [10]。敏感性分析佐证了模型的稳健性，蒙特卡洛模拟则量化了测量误差的传播 [7]。尽管优势明显，局限依然存在：数据集常偏向高 BMI 人群，可能限制外推性；而加速失效时间（AFT）之类迭代模型的计算开销，也可能妨碍实时临床应用 [6]。

未来方向包括：基于胎儿细胞的混合式 NIPT（cbNIPT），它直接分离胎儿细胞，绕开胎儿浓度问题，并能以接近诊断级的准确性开展全基因组分析 [4]。与 AI 驱动平台的整合可实现风险量化的自动化，把母体年龄、身高、体重、是否试管婴儿（IVF）等更多因素纳入一个综合框架 [5, 8]。归根结底，这些优化有望把 NIPT 从筛查手段提升为近乎诊断级的工具，减轻医疗负担，改善高危妊娠的结局 [9, 10]。

2. 模型

2.1. XGBoost 模型的结构

胎儿 Y 染色体浓度是 NIPT 检测中的一项关键指标，受孕周、BMI、年龄、身高、体重、怀孕次数、生产次数等母体生理因素影响。考虑到这些因素之间可能存在非线性关系，我们采用 XGBoost 模型进行建模。XGBoost 是一种基于梯度提升树的集成学习算法，能够有效捕捉特征之间的复杂交互，并内置特征重要性评估机制，可用于评价模型显著性。

(1) 模型形式与加性训练

XGBoost 的核心是梯度提升决策树（GBDT），它通过迭代地构造多个弱学习器（决策树）来逼近目标函数。XGBoost 的预测模型即这些弱学习器（决策树）的加性组合：

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i) \quad (1)$$

其中 $\hat{y}_i$ 是第 i 个样本的预测值， x_i 是该样本的特征向量， f_k 是第 k 棵决策树、输出一个分数， K 是树的数量。

训练过程是加性的：从一个初始模型（例如常数 0 或目标值的均值）出发，每次迭代加入一棵新树以修正残差：

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + \eta f_t(x_i) \quad (2)$$

其中 η 是学习率，用于防止过拟合。

(2) 目标函数

XGBoost 的目标是最小化带正则项的损失函数：

$$\mathcal{L} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (3)$$

其中 $l(y_i, \hat{y}_i)$ 是损失函数。对回归任务，常用的损失函数是平方误差 $l = 0.5 (y_i - \hat{y}_i)^2$ ；对二分类任务，则是对数损失：

$$l = -[y_i \log p_i + (1 - y_i) \log(1 - p_i)] \quad (4)$$

其中 $p_i = \sigma(\hat{y}_i)$ 为 sigmoid 函数。

$\Omega(f_k)$ 是正则项，用于惩罚模型复杂度。 γ 惩罚决策树的复杂度， T 是叶节点数量， w_j 是第 j 个叶节点上的权重：

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 + \alpha \sum_{j=1}^T |w_j| \quad (5)$$

其中 λ 是 L2 正则项， α 是 L1 正则项。在第 t 次迭代加入一棵新树时，目标函数近似为：

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (6)$$

(3) 二阶泰勒展开

为便于优化，XGBoost 对损失函数作二阶泰勒展开（GBDT 只用到一阶）：

$$l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) \approx l(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t(x_i)^2 \quad (7)$$

其中

$$g_i = \frac{\partial l(y_i, \hat{y}_i^{(t-1)})}{\partial \hat{y}_i^{(t-1)}}$$

是一阶导数（梯度），

$$h_i = \frac{\partial^2 l(y_i, \hat{y}_i^{(t-1)})}{\partial (\hat{y}_i^{(t-1)})^2}$$

是二阶导数（Hessian）。

展开目标函数后，新的迭代目标变为：

$$\mathcal{L}^{(t)} = \sum_{i=1}^n \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t(x_i)^2 \right] + \Omega(f_t) \quad (8)$$

(4) 树结构与叶权重计算

决策树 $f(x)$ 把每个样本映射到一个叶节点，每个叶节点带有权重 w_j 。定义叶节点 j 的样本集合为 $I_j = \{i \mid q(x_i) = j\}$ ，其中 q 是映射到叶节点的结构函数。目标函数可以写成对叶权重求和的形式：

$$\mathcal{L}^{(t)} = \sum_{j=1}^T \left[\left(\sum_{i \in I_j} g_i \right) w_j + \frac{1}{2} \left(\sum_{i \in I_j} h_i + \lambda \right) w_j^2 + \alpha |w_j| \right] + \gamma T \quad (9)$$

其中 $G_j = \sum_{i \in I_j} g_i$ ， $H_j = \sum_{i \in I_j} h_i$ ，每个叶节点的最优权重为：

$$w_j^* = -\frac{G_j}{H_j + \lambda} \quad (10)$$

(5) 分裂增益计算

在构造树时，对节点上的每一次分裂，其增益按下式计算：

$$\text{Gain} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma \quad (11)$$

其中 G_L 与 G_R 分别是左、右子节点的梯度之和。若 $\text{Gain} > 0$ ，则执行该分裂。

3. 结果

3.1. 数据预处理与初步分析

该数据集包含男胎检测数据（约 1075 条记录）与女胎检测数据（约 600 条记录），涵盖孕妇基本信息（如年龄、身高、体重、BMI）、检测时间（如孕周）、测序指标（如读段数、GC 含量、Z 值）以及胎儿相关指标（如 Y 染色体浓度、X 染色体浓度、染色体非整倍体）。

(1) 数据预处理

缺失值处理：逐列检查缺失率。对男胎数据，Y 染色体浓度（V 列）与 Z 值（U 列）是完整的；对女胎数据，Y 相关各列为空（符合预期）。其他列，如 GC 含量与读段数，偶有缺失（ $< 5\%$ ），采用中位数插补以避免引入偏倚。任何完全无效的记录（例如孕周异常）均予删除。

数据类型转换：孕周（J 列）由字符串格式（如“11w+6”）转换为数值周数（如 $11 + 6/7 \approx 11.857$ 周），以便定量分析。末次月经（F 列）与检测日期（H 列）转换为日期格式，用于计算精确孕周。

异常值检测：使用箱线图与 Z 值识别异常值。例如，BMI 的取值范围为 $[20, 40+]$ ，超出生理合理范围的取值（如 $\text{BMI} < 15$ 或 > 50 ）被剔除。男胎的 Y 染色体浓度取值范围为 0 至 0.15，负值或极端值（视为测量误差）被移除。

(2) 初步统计分析

描述性统计：Y 染色体浓度均值为 0.065，中位数为 0.062；孕周均值为 16.5 周（ $\text{SD} = 4.2$ ）；BMI 均值为 32.1（ $\text{SD} = 4.5$ ），表明该数据集偏向高 BMI 孕妇。此外还绘制了 Y 染色体浓度分别对孕周与 BMI 的散点图，如图 1 所示。




图 1. Y 染色体浓度对孕周与 BMI 的散点图

3.2. 基于 XGBoost 的相关特性分析

本文通过编程实现该模型，关键步骤如下：

- 数据载入与预处理：读取男胎数据，提取特征（孕周、BMI、年龄、身高、体重、怀孕次数、生产次数）与目标（Y 浓度）。处理非数值型数据，并删除缺失行。

- 模型训练：采用 XGBRegressor，参数包括 100 棵树、学习率 0.1、最大深度 5。数据集按训练集（80%）与测试集（20%）划分。
- 模型评估：计算 MSE 与 R^2 。 $R^2 > 0.7$ 表明模型对数据拟合显著。
- 显著性检验 [6]：提取特征重要性得分并可视化。重要性 > 0.1 的特征被认为显著相关。

由此得到各相关特性及其显著性检验结果，如表 1 所示。

表 1. Y 染色体浓度与各项指标的显著性检验结果

特性	体重	身高	年龄	生产次数	孕周	孕妇 BMI	怀孕次数
显著性	0.1986	0.1449	0.1435	0.1308	0.1306	0.1270	0.1242

3.3. 模型分析

敏感性分析旨在评估模型输出对输入参数或条件变动的敏感程度。通过在保持其他变量不变的前提下系统地改变某一关键参数，观察模型结果的相应变化，即可识别其稳健性与潜在的不确定性。误差分析则着眼于识别并量化模型内部的误差来源，包括数据测量误差、模型假设偏倚与计算近似误差。通过分解误差成分，可以估计模型的可靠性。

对于求解问题一的 XGBoost 模型，敏感性分析针对学习率与最大树深等关键超参数。改变学习率（例如从 0.1 扰动至 0.05 或 0.15），观察均方误差（MSE）的变化；类似地，调整最大树深（从 5 扰动至 3 或 7），评估 R^2 得分的波动。该分析揭示出模型对学习率高度敏感：取值过低导致欠拟合，取值过高则诱发过拟合。这一认识可指导参数优化，以增强稳健性。最终结果如图 2 所示。




图 2. XGBoost 模型中 MSE 对学习率的敏感性曲线

4. 结论与展望

本研究系统地考察了无创产前检测（NIPT）时点的优化，以及一个面向胎儿异常检出的综合模型的构建，同时覆盖男胎与女胎。对男胎而言，分析揭示出 Y 染色体浓度与孕周之间存在显著正相关（ $r = 0.45$, $p < 0.001$ ），表明浓度随孕周推进而升高。相反，与母体 BMI 之间观察到负

相关 ($r = -0.32$, $p < 0.001$), 提示较高的 BMI 可能推迟达到足够 Y 浓度 ($\geq 4\%$) 的时间。XGBoost 模型展现出稳健的预测性能 ($R^2 > 0.7$), 其特征重要性得分凸显出体重与身高是显著因素 (> 0.1)。对基于 BMI 的分组 (< 25 、 $25-30$ 、 > 30), 最佳 NIPT 时点分别被确定为约 12 周、14 周与 16 周, 以最小化临床风险。对女胎而言, 一个整合了 X 染色体 Z 值、GC 含量、读段深度与 BMI 的多任务概率模型, 在检出 21、18、13 号染色体非整倍体上取得了低假阳性率 ($< 5\%$) 与高准确率 ($> 95\%$)。使用广义可加模型 (GAM) 作偏倚校正、使用 SHAP 分析提升可解释性, 进一步增强了模型的可靠性。这些发现凸显出个体化 NIPT 策略的重要性——尤其是对高 BMI 孕妇——以便在早期检出与充足胎儿 DNA 浓度之间取得平衡, 从而降低临床干预延误的风险。尽管有上述优势, 本研究仍受限於两点: 其一, 所依赖的数据集偏向高 BMI 个体, 可能限制外推性; 其二, 模型的计算复杂度可能妨碍实时应用。

展望未来, 所提出的框架在产前筛查中具有广阔的推广潜力。整合外部数据集 (例如公开的 NIPT 数据库) 可增强模型的稳健性与外推性, 对低 BMI 人群尤为如此。引入先进技术, 如用于合成数据生成的生成对抗网络 (GAN) 或迁移学习, 可缓解数据偏倚。此外, 可通过贪心搜索等近似算法提升计算效率, 使其能够扩展到大规模临床应用。将模型集成进医院信息系统, 可依据母体输入自动给出最佳 NIPT 时点与异常概率的建议, 从而支撑实时决策。通过调整模型输出以纳入更多染色体标志物, 将该框架推广至其他胎儿异常 (如神经管缺陷或微缺失), 是一个有前景的方向。移动应用则可为孕妇提供自助工具, 用于监测与查询 NIPT 建议。在政策层面, 该框架可被纳入公共卫生行动, 为高龄或肥胖孕妇等高危群体提供优化且具成本效益的筛查, 从而有望减轻医疗负担。随着单细胞测序等技术的进步, NIPT 的精度与适用范围还可进一步提升, 为更准确、更可达的产前照护铺平道路。持续以实时临床数据更新模型, 将确保其在不断演进的医疗情境中保持相关性与有效性。

致谢

作者衷心感谢 2025 年新疆农业大学大学生创新创业训练计划项目 (dxscy2025043、dxscy2025047) 的经费支持。

参考文献

- 1 Juul L A, Hartwig T S, Ambye L, et al. Noninvasive prenatal testing and maternal obesity: A review [J]. *Acta Obstetrica et Gynecologica Scandinavica*, 2020, 99(6): 744-750.
- 2 Artieri C G, Haverty C, Evans E A, et al. Noninvasive prenatal screening for patients with high body mass index: Evaluating the impact of a customized whole genome sequencing workflow on sensitivity and residual risk [J]. *Prenatal Diagnosis*, 2020, 40(3): 333-341.
- 3 Yao H, Guo J, Wang J, et al. Factors Affecting the Fetal Fraction in Noninvasive Prenatal Screening: A Review [J]. *Frontiers in Pediatrics*, 2022, 10: 812781.
- 4 Johansen P, Richter S R, Balslev-Harder M, et al. Cell-based Non-Invasive Prenatal Testing (cbNIPT) – A review on the current developments and future prospects [J]. *Prenatal Diagnosis*, 2023, 43(3): 316-328.
- 5 van der Schoot V, Hoffmann C F, Page-Christiaens G C M L, et al. Non-invasive Prenatal Testing in Pregnancies Following Assisted Reproduction [J]. *Diagnostics*, 2023, 13(3): 443.
- 6 Alberry M S, Aziz E, Ahmed S R, et al. Non Invasive Prenatal Testing (NIPT): Is Routine Testing for Sex Chromosome Aneuploidy Appropriate? [J]. *Journal of Obstetrics and Gynaecology Canada*, 2021, 43(1): 111-112.
- 7 van Beek D M, Straver R, Weiss M M, et al. Comparing methods for fetal fraction determination and quality control of NIPT samples [J]. *Prenatal Diagnosis*, 2020, 40(7): 803-810.

- 8 Welker N C, Lee A K, Kieke B A, et al. Noninvasive Prenatal Testing Using Fetal Fraction Enrichment – A Pilot Study [J]. *Clinical and Experimental Obstetrics & Gynecology*, 2024, 51(5): 114.
- 9 Lindquist A, Hui L, Poulton A, et al. Combined first-trimester screening and invasive diagnostics for atypical chromosomal aberrations: A population-based study [J]. *Ultrasound in Obstetrics & Gynecology*, 2024, 63(4): 486-494.
- 10 Lee C Y, Park M H, Cho H E, et al. KF-NIPT: K-mer and fetal fraction-based estimation of chromosomal anomaly in non-invasive prenatal testing [J]. *BMC Bioinformatics*, 2024, 25(1): 189.

译者说明：本文是已发表英文原文“*Optimization of NIPT Testing Timing and Fetal Anomaly Determination Models*”(International Journal of Public Health and Medical Research, 2026, 6(2): 1–8, DOI: 10.62051/ijphmr.v6n2.01)的全文中译，仅供本人阅读，不作投稿用途。所有数值、公式、图表与参考文献均与原文逐一核对，未作增删。两幅插图沿用原文已发表图片，图内文字保持英文原貌。原文正文中“问题一”(Problem One)与图 2 标题中的“(Problem 1)”系原文如此，译文予以保留。