

基于共形分数阶累加的改进核正则化非齐次灰色模型

Wujian Rao^{1,#}, Panlin Li^{2,#}

¹School of Mathematics, Yunnan Normal University, Kunming, China, 650500

²College of Mathematics and Physics, Xinjiang Agricultural University, Urumqi, China, 830052

[#]These authors contributed equally.

关键词：灰色模型；核正则化；徒步优化算法；能源消费量预测。

摘要：本文提出了一种改进的灰色预测模型，称为共形分数阶累加核正则化非齐次灰色模型 (CFAKRNGM)，用于能源消费量预测，并使用 HOA 优化模型参数，CFAKRNGM 模型在数据拟合与预测精度方面表现出显著优势。为了验证模型的有效性，本文通过对中国可再生能源消费量与天然气消费量的数据分析，比较了 CFAKRNGM 模型与 KRNGM 模型的预测结果。以期为中国能源生产与消费规划提供理论支持和实践参考。结果表明，CFAKRNGM 模型在处理复杂的非线性时间序列数据方面优于 KRNGM，并具有更高的预测精度与可靠性。

1. 引言

近年来，能源预测方面的研究不断发展。智能网络模型、统计模型和灰色模型在该领域的应用已取得显著成果。灰色模型一直受到国内外学者的广泛研究。灰色系统理论由邓聚龙 [1] 提出，它是一种处理不确定性问题的新理论。灰色预测模型是灰色系统理论的中间部分，它在小样本时间序列预测中非常有效，其中 GM(1,1) 模型已被广泛应用。

通过改进 GM(1,1) 模型得到的新灰色模型已在现实生活生产中得到验证和接受。例如，Zhou 等 [2] 设计了一种新的离散灰色模型，用于预测中国江苏省的天然气消费量。Cheng 等 [3] 通过改进灰色模型 GM(1,N) 预测了 2025 年中国的清洁能源消费量，论证了经济增长在拉动清洁能源需求方面的作用。然而，当灰色系统加入更多变量信息时，现有灰色预测模型 GM(1,N) 的求解并不准确，导致预测精度不可预知。此外，Ding 等 [4] 提出了一种新颖的优化灰色预测模型 NOGM(1,1) 用于预测中国的电力消费量，论证了其在处理复杂非线性时间序列方面的优越性。然而，当系统中出现多参数形式并包含非线性结构时，NOGM(1,1) 模型的有效性大大降低。机器学习理论中的核方法在处理非线性模式分析问题上具有显著优势。Duan 等 [5] 基于高斯核函数和多项式核函数，结合灰色预测模型的特点，提出了适用于非线性的 GMC(1,N) 模型。此外，Liu 等 [6] 使用邻近非齐次灰色模型预测了欧洲和世界的可再生能源消费量，并使用启发式算法优化参数，显著提高了预测精度。

在研究过程中，进一步引入了灰色预测模型与其他模型的结合来预测能源消费与生产。Wu 和 Shen [7] 提出了一种新颖的 LSSVM 模型 [7]，将灰色关联分析 (GRA) 与 LSSVM 相结合。新模型简称为 GRA-LSSVM，用于获得更准确的结果。上述关于灰色模型的研究逐步丰富了灰色系统理论，并在一定程度上增强了预测能力。然而，面对一些非线性和波动性的系统序列，现有的灰色模型及其推广由于其线性结构，难以提供令人满意的精度。而且，现有的非齐次灰色模型在预测复杂非线性时间序列时效率低下。因此，必须改进模型结构，以进一步解决以非线性和波动性为特征的系统预测问题。

本文将 KRNGM 模型与共形分数阶累加相结合，建立了 CFAKRNGM 模型，并通过预测中国可再生能源消费量与中国天然气消费量的变化趋势，验证了所提模型的有效性。以期能为能源生产与消费规划提供理论支持和实践参考，从而促进中国能源的健康与可持续发展。

本文其余部分安排如下。第 2 节简要介绍原始 KRNGM 模型的构建原理与参数估计过程。第 3 节描述 CFAKRNGM 模型的建模步骤。第 4 节介绍 CFAKRNGM 模型的超参数优化与 HOA 算法。第 5 节给出预测中国可再生能源消费量与天然气消费量的案例研究。研究结论在第 6 节给出。

2. KRNGM 模型

2.1. KRNGM 模型的表示

原始序列 $(x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(n))$ 的一次累加生成(1-AGO)序列记为 $(x^{(1)}(1), x^{(1)}(2), \dots, x^{(1)}(n))$, 其中

$$x^{(1)}(j) = \sum_{k=1}^j x^{(0)}(k).$$

微分方程 (见 [8])

$$\frac{dx^{(1)}(t)}{dt} + ax^{(1)}(t) = f(t) + c, \#(1)$$

称为 KRNGM 模型, 它也可以表示为 (见 [8])

$$\frac{dx^{(1)}(t)}{dt} + ax^{(1)}(t) = w^T \varphi(t) + c, \#(2)$$

2.2. KRNGM 模型参数估计

为了估计 KRNGM 模型 [8] 的参数, 我们需要考虑方程 (3) 的积分, 在区间 $[j-1, j]$ 上, 我们有 [8]

$$\int_{j-1}^j dx^{(1)}(t) + a \int_{j-1}^j x^{(1)}(t) dt = w^T \int_{j-1}^j \psi(t) dt + \int_{j-1}^j c dt, \#(3)$$

注意到 $\int_{j-1}^j dx^{(1)}(t) = x^{(1)}(j) - x^{(1)}(j-1) = x^{(0)}(j)$ 以及 $\int_{j-1}^j c dt = c$, 使用两点梯形公式, 我们有

$$x^{(0)}(j) + az^{(1)}(j) = w^T \Psi(j) + c, \#(4)$$

$$z^{(1)}(j) = \frac{1}{2} (x^{(1)}(j) + x^{(1)}(j-1))$$

$$\Psi(j) = \frac{1}{2} (\psi(j) + \psi(j-1)).$$

参数可以按如下方式估计。(见 [8])

$$\min J(a, w, c; e) = \frac{a^2}{2} + \frac{w^T w}{2} + \frac{\gamma}{2} \sum_{i=2}^r e_i^2, \#(5)$$

其中 γ 是正则化参数。

定义拉格朗日函数为

$$L := \frac{a^2}{2} + \frac{w^T w}{2} + \frac{\gamma}{2} \sum_{i=2}^n e_i^2 + \sum_{j=2}^n \lambda_j [x^{(0)}(j) + az^{(1)}(j) - w^T \Psi(j) - c - e_j], \#(6)$$

则 KKT 条件 [8] 给出为

$$\begin{pmatrix} 0 & \vec{1}_{n-1}^T \\ \vec{1}_{n-1} & \Omega + \gamma^{-1} I_{n-1} \end{pmatrix} \begin{pmatrix} c \\ \overline{\square} \end{pmatrix} = \begin{pmatrix} 0 \\ Y \end{pmatrix}, \#(7)$$

其中

$$\begin{aligned} \vec{E}_{n-1} &= [1, 1, \dots, 1]_{n-1}^T, \\ \Omega &= (\psi(i) \cdot \psi(k) - z^{(1)}(i)z^{(1)}(k))_{(n-1) \times (n-1)} \\ \overline{\square} &= [\lambda_2, \lambda_3, \dots, \lambda_n]^T, \\ Y &= [x^{(0)}(2) - x^{(0)}(1), x^{(0)}(3) - x^{(0)}(2), \dots, x^{(0)}(n) - x^{(0)}(n-1)]^T, \end{aligned} \#(8)$$

结合 ψ 的定义, 我们有

$$\Psi(i) \cdot \Psi(j) = \frac{1}{4} (\psi(i) + \psi(i-1)) \cdot (\psi(j) + \psi(j-1)). \#(9)$$

核函数 [8] $K(\cdot, \cdot)$ 为

$$\psi(i) \cdot \psi(j) = H(i, j) = H_{ij}, \#(10)$$

则 $\psi(i) \cdot \psi(j)$ 可以写为

$$\Psi(i) \cdot \Psi(j) = \frac{1}{4} (H_{ij} + H_{i-1,j} + H_{i,j-1} + H_{i-1,j-1}). \#(11)$$

高斯核为

$$H(i, j) = \exp \left\{ -\frac{\|i-j\|^2}{2\sigma^2} \right\}, \#(12)$$

其中 σ 是核参数。

该微分方程可以求解为 (见 [8])

$$\hat{x}^{(1)}(t) = x^{(0)}(1)e^{-a(t-1)} + \int_1^t e^{-a(t-\tau)} \Phi(\tau) d\tau, \#(13)$$

其中

$$\Phi(t) = w^T \psi(t) + c, \#(14)$$

非线性函数 $w^T \varphi(t)$ 可以重写为 (见 [8])

$$w^T \psi(t) = \left[\sum_{j=2}^n \lambda_j \Psi(j) \right] \cdot \psi(t) = \frac{1}{2} \sum_{j=2}^n \lambda_j [\psi(j) + \psi(j-1)] \cdot \psi(t), \#(15)$$

我们有

$$w^T \psi(t) = \frac{1}{2} \sum_{j=2}^n \lambda_j [\psi(j) + \psi(j-1)] \cdot \psi(t) = \frac{1}{2} \sum_{j=2}^n \lambda_j [H_{j,t} + H_{j-1,t}], \#(16)$$

以及 (见 [8])

$$\hat{x}^{(\alpha)}(j) = x^{(\alpha)}(1)e^{-\hat{a}(k-1)} + \frac{1}{2} \sum_{\tau=2}^k [e^{-\hat{a}(k-\tau)}\Phi(\tau) + e^{-\hat{a}(k-\tau+1)}\Phi(\tau-1)], \#(17)$$

预测值可以得到为

$$\hat{x}^{(\alpha)}(j) = \hat{x}^{(1)}(j) - \hat{x}^{(1)}(j-1). \#(18)$$

3. CFAKRNGM 模型

显然, KRNGM 模型的建立本质上采用了传统的灰色累加算子, 对于小样本和非光滑时间序列预测仍然存在局限性。我们将用共形分数阶累加算子改进原模型。建模过程与 KRNGM 非常相似, 但有细微的修改。

3.1 共形分数阶累加与差分

对所有 $t > 0, \alpha \in (0, 1]$, 给定一个可微函数 $g : [0, \infty) \rightarrow R$. 那么 g 的 α 阶 CFD 定义为

$$T_\alpha(g)(t) = \lim_{\varepsilon \rightarrow 0} \frac{g(t+\varepsilon t^{1-\alpha}) - g(t)}{\varepsilon}. \#(19)$$

定义 1 (见 [9]). g 的 α 阶 CFA 定义为 $\nabla^\alpha g(k) = \nabla \left(\frac{g(k)}{k^{1-\alpha}} \right) = \sum_{i=1}^k \left(\frac{g(j)}{j^{1-\alpha}} \right)$, 对所有 $k \in N^+, \alpha \in (0, 1]$.

定义 2 (见 [9]). α 阶 ($\alpha \in (n, n+1)$) CFA 定义为

$$\nabla^\alpha g(k) = \nabla^n \left(\frac{g(k)}{k^{|\alpha|-\alpha}} \right). \#(20)$$

由定义 2, 我们可以推导出一个递推等式

$$\nabla^\alpha g(k) = \nabla \left(\nabla^{n-1} \left(\frac{g(k)}{k^{|\alpha|-\alpha}} \right) \right) = \sum_{j=1}^k (\nabla^{\alpha-1} g(j)), \alpha \geq 1, \text{ for } n = [\alpha] - 1. \#(21)$$

结合上述定义, 我们开始构建 CFAKRNGM 模型。

原始非负序列为 $X^{(0)} = (x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(N))^T$, N 为序列长度, $\alpha \in R^+$, 我们有 $X^{(\alpha)} = (x^{(\alpha)}(1), x^{(\alpha)}(2), \dots, x^{(\alpha)}(N))^T$,

它是 $X^{(0)}$ 的共形分数的 α 阶累加所生成的序列, 微分方程

$$\frac{dx^{(\alpha)}(t)}{dt} + \hat{b}x^{(\alpha)}(t) = g(t) + m, \#(22)$$

称为共形分数阶核正则化非齐次灰色模型, 简称 CFAKRNGM 模型, 该微分方程也可以表示为

$$\frac{dx^{(\alpha)}(t)}{dt} + \hat{b}x^{(\alpha)}(t) = \omega^T \psi(t) + m. \#(23)$$

3.2 CFAKRNGM 模型的参数估计

与 KRNGM 模型类似, 方程 (23) 需要离散化, 给定样本和 α , 我们有

$$\int_{j-1}^j dx^{(\alpha)}(t) + \hat{b} \int_{j-1}^j x^{(\alpha)}(t)dt = \omega^T \int_{j-1}^j \psi(t)dt + \int_{j-1}^j mdt, \#(24)$$

因为 $\int_{j-1}^j dx^{(\alpha)}(t) = x^{(\alpha)}(j) - x^{(\alpha)}(j-1)$, 我们有

$$x^{(\alpha)}(j) - x^{(\alpha)}(j-1) + \hat{b}z^{(\alpha)}(j) = \omega^T \Psi(j) + m, \#(25)$$

其中

$$z^{(\alpha)}(j) = \frac{1}{2}(x^{(\alpha)}(j) + x^{(\alpha)}(j-1))$$

$$\Psi(j) = \frac{1}{2}(\psi(j) + \psi(j-1))$$

。

使用下面的正则化问题来估计参数 $\hat{b}, \omega, m$

$$\min \Gamma(\hat{b}, \omega, m; e) = \frac{\hat{b}^2}{2} + \frac{\omega^T \omega}{2} + \frac{\gamma}{2} \sum_{k=2}^r e_k^2, \#(26)$$

其中

$$e_k = x^{(\alpha)}(k) + \hat{b}z^{(\alpha)}(k) - \omega^T \Psi(k) - m,$$

拉格朗日函数为

$$F := \frac{\hat{b}^2}{2} + \frac{\omega^T \omega}{2} + \frac{\gamma}{2} \sum_{j=2}^n e_j^2 + \sum_{j=2}^n \lambda_j [x^{(\alpha)}(j) + \hat{b}z^{(\alpha)}(j) - \omega^T \Psi(j) - m - e_j], \#(27)$$

上述 KKT 条件可以转化为。

$$\begin{pmatrix} 0 & \vec{1}_{n-1}^T \\ \vec{1}_{n-1} & \xi + \gamma^{-1} I_{n-1} \end{pmatrix} \begin{pmatrix} \frac{c}{\lambda} \\ \frac{c}{\lambda} \end{pmatrix} = \begin{pmatrix} 0 \\ \frac{c}{Y} \end{pmatrix}, \#(28)$$

其中

$$\begin{aligned} \vec{E}_{n-1} &= [1, 1, \dots, 1]_{n-1}^T, \\ \xi &= (\psi(i) \cdot \psi(k) - z^{(\alpha)}(i)z^{(\alpha)}(k))_{(n-1) \times (n-1)}, \\ \vec{\square} &= [\lambda_2, \lambda_3, \dots, \lambda_n]^T, \\ \mathbf{Y} &= [x^{(\alpha)}(2) - x^{(\alpha)}(1), x^{(\alpha)}(3) - x^{(\alpha)}(2), \dots, x^{(\alpha)}(n) - x^{(\alpha)}(n-1)]^T. \end{aligned} \#(29)$$

条件 $x^{(\alpha)}(1) = \nabla \frac{x^{(0)}(1)}{1^{|\alpha|-\alpha}} = x^{(0)}(1)$ 可用于求解式 (23), 我们有

$$\hat{x}^{(\alpha)}(j) = x^{(\alpha)}(1)e^{-\hat{b}(j-1)} + \frac{1}{2} \sum_{\tau=2}^j \left[e^{-\hat{b}(j-\tau)} \Phi(\tau) + e^{-\hat{b}(j-\tau+1)} \Phi(\tau-1) \right]. \#(30)$$

最后我们有

$$\hat{x}^{(0)}(j) = \begin{cases} \hat{x}^{(0)}(j) = j^{1-\alpha} (\hat{x}^{(\alpha)}(j) - \hat{x}^{(\alpha)}(j-1)) & 0 < \alpha \leq 1, \\ j^{[\alpha]-\alpha} \Delta^n \hat{x}^{(\alpha)}(j) & n < \alpha \leq n+1. \end{cases} \#(31)$$

4. CFAKRNGM 模型的超参数优化

4.1. HOA 算法

Oladejo S O 等提出了一种称为“HOA”的新算法，它基于 (THF) [10]。过程如下：

$$\Phi_{i,t} = 6e^{-3.5|S_{i,t}+0.05|}, \#(32)$$

$W_{i,t}$ 是研究对象的第 i 个速度 (km/h)。(见 [10])

$$S_{i,t} = \frac{dy}{dx} = \tan \varpi_{i,t}, \#(33)$$

其中 dy 和 dx 是高程差与距离差。此外， $\varpi_{i,t}$ 是小径或地形的坡度。(见 [10])

$$\mathcal{W}_{i,t} = \mathcal{W}_{i,t-1} + \mu_{i,t} (\beta_{best} - \alpha_{i,t} \beta_{i,t}), \#(34)$$

其中 $\mu_{i,t}$ 是均匀分布的数， $\mathcal{W}_{i,t}$ 和 $\mathcal{W}_{i,t-1}$ 表示当前速度与初始速度， β_{best} 是领队徒步者的位置， $\eta_{i,t}$ 是攀登者 i 的扫掠因子。

$$\beta_{i,t+1} = \beta_{i,t} + \Phi_{i,t}, \#(35)$$

$\beta_{i,t+1}$ 表示徒步者 i 的更新后位置。徒步者位置的初始化由下式表示

$$\beta_{i,t} = \chi_j^1 + \delta_j (\chi_j^2 - \chi_j^1), \#(36)$$

其中 δ_j 是均匀分布的数。 χ_j^1 和 χ_j^2 表示第 j 维的下界与上界 (见 [10])。

4.2. 模型超参数的优化策略

算法 1: 搜索 CFAKRNGM 模型参数的 HOA 算法

输入: 原始数据
 $X^{(0)}, ub, lb, objfun, nhikers, ndim,$
 $MaxIter, nn$

输出: $\square, \square, \square$

初始化 $MaxIter$ 与徒步者数量

算法 1: 搜索 CFAKRNGM 模型参数的 HOA 算法

2	随机初始化徒步者的位置。
3	for $j = 1; j < T; j = j + 1$ do
4	for each hiker do
5	更新参数 $\square', \square', \square'$
6	用式 (30) 计算 $\hat{x}^{(\alpha)}(j)$
7	用式 (31) 计算 $\hat{x}^{(0)}(j)$;
8	end
9	用式 (37) 计算 MAPE
10	if $MAPE < MAPE_{\min}$ then
11	$MAPE_{\min} \leftarrow MAPE$
12	$\square' \leftarrow \alpha, \square' \leftarrow \square, \square' \leftarrow \square$
13	end
14	end
15	返回 $\square', \square', \square'$

然后我们需要构建一个简单的优化问题来确定参数的最优值，如下所示。

$$\min_{\alpha} MAPE = \sum_{j=1}^N \left| \frac{\hat{x}^{(\alpha)}(j) - x^{(\alpha)}(j)}{x^{(\alpha)}(j)} \right| \times 100\% \quad (37)$$

该公式通常用于带有可调参数的非线性灰色模型。以最小化 MAPE 作为目标函数。

5. 数值算例

本节通过中国可再生能源消费量与天然气消费量的案例研究，从可再生资源与非可再生资源两方面评估 CFAKRNGM 模型的有效性。将 CFAKRNGM 模型的结果与 KRNGM 进行比较，以检验 CFAKRNGM 模型的预测性能。

采用最小化的 MAPE（平均绝对百分比误差）和 ARE（平均相对误差，average relative error）来检验模型的精度，ARE 定义如下

$$ARE = \frac{1}{N} \sum_{j=1}^N \left| \frac{\hat{x}^{(\alpha)}(j) - x^{(\alpha)}(j)}{x^{(\alpha)}(j)} \right| \times 100(\%).$$

算例 1: 中国可再生能源的短期消费量预测

在本算例中，分别使用 CFAKRNGM 模型和 KRNGM 模型预测中国可再生资源的消费量。数据来自 the energy institute (<https://www.energyinst.org/statistical-review>)，结合能源数据的时效性以及灰色模型中小样本序列指数分布的特点，我们收集了 2004 年至 2023 年的 20 个样本数据，并在表 1 中列出。为了直观地表达模型的有效性与真实性，预测误差被降低。2004 年至 2019 年共 16 组数据用于拟合阶段以构建预测模型。2020 年与 2023 年的数据用于验证模型精度。

表 1: 2004 年至 2023 年中国可再生资源消费量。

年份	可再生资源消费量	年份	可再生资源消费量
2004	3.73	2014	12.79
2005	4.20	2015	13.71
2006	4.36	2016	14.89
2007	5.16	2017	16.22
2008	6.81	2018	17.79
2009	6.78	2019	19.47
2010	7.97	2020	21.03
2011	7.99	2021	23.51
2012	10.01	2022	25.55
2013	10.92	2023	27.60

表 2: 算例 1 中两个模型的最优可调参数。

模型	α	β	γ
CFAKRNGM	1.0706	206.9354	0.9998
KRNGM	0.9563	3.9364	

通过计算和比较两个模型的 MAPE，徒步优化算法找到的最优可调参数如表 2 所示。

表 3: 算例 1 中模型的预测结果与误差

年份	原始数据	CFAKRNGM	KRNGM
2004	3.73	3.7300	3.7300
2005	4.20	4.1777	4.2352
2006	4.36	4.5566	4.6298
2007	5.16	5.3171	5.4113
2008	6.81	6.5278	6.3625
2009	6.78	7.0989	7.0859
2010	7.97	7.6373	7.6546
2011	7.99	8.3389	8.4618
2012	10.01	9.6868	9.6918
2013	10.92	11.1758	11.1514
2014	12.79	12.5992	12.5551
2015	13.71	13.8493	13.7713
2016	14.89	14.8429	14.9248
2017	16.22	16.2537	16.2356
2018	17.79	17.7720	17.7594
2019	19.47	19.4710	19.5722
ARE (拟合)		0.0012	0.0013
MAPE (拟合)		0.0195	0.0220
2020	21.03	21.5930	21.7910
2021	23.51	24.1850	24.3443
2022	25.55	27.0879	27.1067
2023	27.60	30.1686	30.0939

年份	原始数据	CFAKRNGM	KRNGM
ARE (预测)		0.0130	0.0139
MAPE (预测)		0.0522	0.0557

拟合与测试阶段的预测结果与误差如表 3 所示。表 2 表明，CFAKRNGM 模型中得到的三个最优可调参数为 $\alpha=0.9998$ 、 $\delta=1.0706$ 和 $\gamma=206.9354$ 。同时，从表 3 中两个模型的评价指标值可以得到，两类灰色预测模型的拟合精度与预测精度都比较高，但在模型的拟合与测试阶段，CFAKRNGM 模型的 MAPE 和 ARE 均小于 KRNGM。这表明 CFAKRNGM 模型的预测精度与拟合精度高于 KRNGM 模型。

图 1: 算例 1 中，CFAKRNGM 与 KRNGM 模型的数据拟合曲线

图 1 展示了两个模型的数据拟合折线。由此可以看出，两条曲线的数据变化趋势与指数曲线相似。结合表 3，我们可以清楚地得到，在拟合与预测两个阶段，CFAKRNGM 模型的 ARE 和 MAPE 均小于 KRNGM 模型，且 CFAKRNGM 模型的预测数据更接近真实数据，预测误差也更小。

算例 2: 中国天然气的短期消费量预测

算例 1 拟合并预测了符合近似指数分布规律的数据。算例 2 分析并预测中国 2004 年至 2023 年的天然气消费量，原始数据如表 4 所示。共有 20 组数据，前 16 组数据用于构建预测模型，其余 4 组数据用于验证模型的预测精度。

表 4: 2004 年至 2023 年中国天然气消费量

年份	天然气消费量	年份	天然气消费量
2004	1.44	2014	6.78
2005	1.69	2015	7.01
2006	2.08	2016	7.54
2007	2.56	2017	8.69
2008	2.95	2018	10.22
2009	3.25	2019	11.10
2010	3.92	2020	12.12
2011	4.87	2021	13.69
2012	5.43	2022	13.60
2013	6.19	2023	14.57

由 HOA 得到的最优可调参数列于表 5，两个模型在拟合与测试阶段的预测结果与误差如表 6 所示。从下表中我们可以得到，CFAKRNGM 模型中得到的三个最优可调参数为 $\alpha=0.9998$ 、 $\delta=1.0706$ 和 $\gamma=206.9354$ 。

表 5: 算例 2 中两个模型的最优可调参数

模型	α	δ	γ
CFAKRNGM	1.1318	12.9982	0.9995
KRNGM	1.0054	3.9156	

图 2: 算例 2 中 CFAKRNGM 与 KRNGM 模型的拟合曲线




Figure 1: 图 1: 中国可再生能源消费量预测结果对比




Figure 2: 图 2: 中国天然气消费量预测结果对比

CFAKRNGM 模型的拟合精度与预测精度得到了不同幅度的提高，MAPE 和 ARE 更低。预测效果明显更好。

表 6：算例 2 中模型的预测结果与误差

年份	原始数据	CFAKRNGM	KRNGM
2004	1.44	1.4400	1.4400
2005	1.69	1.7373	1.7905
2006	2.08	2.0864	2.0946
2007	2.56	2.5776	2.5320
2008	2.95	2.9381	2.9206
2009	3.25	3.2806	3.3351
2010	3.92	3.9427	3.9714
2011	4.87	4.7698	4.7506
2012	5.43	5.4675	5.4862
2013	6.19	6.1531	6.1552
2014	6.78	6.7380	6.6870
2015	7.01	7.0461	7.0735
2016	7.54	7.5606	7.6723
2017	8.69	8.7395	8.7508
2018	10.22	10.1184	10.0271
2019	11.10	11.1905	11.2202
ARE (拟合)		0.0005	0.0009
MAPE (拟合)		0.0080	0.0153
2020	12.12	12.3225	12.5183
2021	13.69	13.8816	14.1051
2022	13.60	15.7065	15.9124
2023	14.57	17.6733	17.9008
ARE (预测)		0.0025	0.0029
MAPE (预测)		0.0996	0.1155

算例 2 中给出的数据与算例 1 中的相同，它们按近似指数规律分布。图 2 展示了两个模型的数据拟合折线。由此我们可以直观地看到，两条曲线的走向大致相同，但 CFAKRNGM 模型的数据曲线明显更接近真实值。结合表 6 中模型的结果与图 2 中给出的数据曲线，可以清楚地看到，CFAKRNGM 模型的预测结果比 KRNGM 更接近真实值。

6. 结论

对于容易受复杂因素影响的数据序列，CFAKRNGM 模型有效地克服了 KRNGM 模型在预测与拟合阶段的数据偏差。两个实际算例验证了本文的理论结果与模型的合理性。结果表明，CFAKRNGM 模型能够更好地反映数据的发展趋势，其拟合精度与预测精度相比 KRNGM 模型有所提高。与现有模型相比，所提出的 CFAKRNGM 模型在长期预测以及对不稳定时间序列的预测中更为有效。在现实世界中，一个系统的发展不仅要考虑其自身历史因素的影响，还要考虑其他不可控因素，并且可能表现出不稳定性、周期性、非线性等特征，这使得对系统的准确预测非常困难。因此，在未来的研究中，可以考虑将徒步优化算法（HOA）与多变量超参数灰色预测模型相结合，以解决不可控因素对多变量数据的影响，提高模型的精度与实用性。

参考文献

1. Deng Julong. Grey System Theory Tutorial [M]. Wuhan Huazhong University of Science and Technology Press, 1992
2. Zhou W, Wu X, Ding S, et al. Application of a novel discrete grey model for forecasting natural gas consumption: A case study of Jiangsu Province in China[J]. Energy, 2020, 200: 117443.
3. Cheng M, Li J, Liu Y, et al. Forecasting clean energy consumption in China by 2025: using improved grey model GM (1, N)[J]. Sustainability, 2020, 12(2): 698.
4. Ding S, Hipel K W, Dang Y. Forecasting China's electricity consumption using a new grey prediction model[J]. Energy, 2018, 149: 314-328.
5. Duan H, Wang D, Pang X, et al. A novel forecasting approach based on multi-kernel nonlinear multivariable grey model: A case report[J]. Journal of Cleaner Production, 2020, 260: 120929.
6. Liu L, Wu L. Forecasting the renewable energy consumption of the European countries by an adjacent non-homogeneous grey model[J]. Applied Mathematical Modelling, 2021, 89: 1932-1948.
7. Wu Y H, Shen H. Grey-related least squares support vector machine optimization model and its application in predicting natural gas consumption demand[J]. Journal of Computational and Applied Mathematics, 2018, 338: 212-220.
8. Ma, Xin, Yi-sheng Hu, and Zhi-bin Liu. "A novel kernel regularized nonhomogeneous grey model and its applications." Communications in Nonlinear Science and Numerical Simulation 48 (2017): 51-62.
9. Ma X, Wu W, Zeng B, et al. The conformable fractional grey system model[J]. ISA transactions, 2020, 96: 255-271.
10. Oladejo S O, Ekwe S O, Mirjalili S. The Hiking Optimization Algorithm: A novel human-based meta-heuristic approach[J]. Knowledge-Based Systems, 2024, 296: 111880.

译者注

原文投稿稿中存在三处拼写错误，本中文稿按其正确含义翻译，未在译文中复刻：

1. 标题中的 comfortable fractional accumulation 实为 conformable fractional accumulation（共形分数阶累加）。已发表版（Transactions on Computational and Applied Mathematics, Clausius Scientific Press, 2024, Vol.4 Num.1, DOI: 10.23977/tracam.2024.040118）已更正为 conformable。
2. 第1节标题 Introtuction 实为 Introduction（引言）。
3. 关键词中的 Energy Comsumption Forecasts 实为 Energy Consumption Forecasts（能源消费量预测）。